

U-NET for Metal Artifact Reduction in Computed Tomography



Ludmila Montorsi Queiroz

Mestrado em Física Médica

Departamento de Física e Astronomia

Faculdade de Ciências da Universidade do Porto

2026



UNIVERSIDADE DO PORTO

MASTERS THESIS

U-NET for Metal Artifact Reduction in Computed Tomography

Author:

Ludmila MONTORSI QUEIROZ

Supervisor:

Hélder Filipe PINTO DE OLIVEIRA

Co-supervisor:

Eduardo MATOS RODRIGUES

*A thesis submitted in fulfilment of the requirements
for the degree of MSc. Medical Physics*

at the

Faculdade de Ciências da Universidade do Porto
Departamento de Ciência de Computadores
Departamento de Física e Astronomia
INESC TEC

17 de agosto de 2026

"The Universe is under no obligation to make sense to you."

Neil deGrasse Tyson, *Astrophysics for People in a Hurry* (2017)

"Nothing in life is to be feared; it is only to be understood."

Marie Curie, *Madame Curie: A Biography* (1937)

Acknowledgements

I would like to express my deepest gratitude to my supervisor, Helder Filipe Pinto de Oliveira, for his invaluable guidance, support, and encouragement throughout this research journey. His expertise and insights have been instrumental in shaping this thesis. I am also grateful to my co-supervisor, Eduardo Matos Rodrigues, for his constructive feedback and encouragement, which have greatly contributed to the development of this work.

UNIVERSIDADE DO PORTO

Abstract

Faculdade de Ciências da Universidade do Porto

Departamento de Ciência de Computadores

Departamento de Física e Astronomia

INESC TEC

MSc. Medical Physics

U-NET for Metal Artifact Reduction in Computed Tomography

by [Ludmila MONTORSI QUEIROZ](#)

This thesis addresses deep learning approaches for metal artifact reduction in computed tomography images, presenting a comparative study of the different techniques proposed in the literature and measuring their performance in a rigorous and reproducible manner.

Keywords: Computed Tomography, Metal Artifact Reduction, Medical Physics, Medical Imaging, Deep Learning, Artefact, Medical Diagnostics, Physics

UNIVERSIDADE DO PORTO

Resumo

Faculdade de Ciências da Universidade do Porto

Departamento de Ciência de Computadores

Departamento de Física e Astronomia

INESC TEC

MSc. Medical Physics

U-NET para Redução de Artefatos de Metal em Tomografia Computadorizada

por [Ludmila MONTORSI QUEIROZ](#)

Esta tese aborda abordagens de aprendizado profundo para a redução de artefatos de metal em imagens de tomografia computadorizada, apresentando um estudo comparativo das diferentes técnicas propostas na literatura e avaliando seu desempenho de maneira rigorosa e reprodutível.

Palavras-chave: Tomografia Computadorizada, Redução de Artefatos de Metal, Física Médica, Imagem Médica, Aprendizado Profundo, Artefato, Diagnóstico Médico, Física

Índice

Acknowledgements	ii
Abstract	iii
Resumo	iv
Índice	v
Lista de Figuras	viii
Lista de Gráficos	x
Lista de Tabelas	xi
Lista de Abreviaturas	xii
1 Introdução	1
1.1 Contexto clínico e técnico	3
1.2 Problema de investigação	3
1.3 Contribuições e organização da dissertação	4
2 Objetivos e Questões de Investigação	5
2.1 Objetivo geral	5
2.2 Objetivos específicos	5
2.3 Hipóteses e desfechos	6
3 Enquadramento e Trabalhos Relacionados	7
3.1 Artefactos metálicos em tomografia computadorizada	7
3.2 Redução de artefactos baseada em aprendizagem profunda	8
3.3 Avaliação reprodutível e generalização	9
4 Materiais e Métodos	11
4.1 Dados, curadoria e rastreabilidade	11
4.1.1 Conjunto CT-MAR e fontes de referência	11
4.1.2 Particionamento ao nível do paciente	12
4.1.3 Coorte final e Exclusões	16
4.1.4 Estratificação Anatômica	17

4.2	Pré-processamento	19
4.2.1	Verificação de integridade	19
4.2.2	Máscara Corporal	19
4.2.3	Janela de intensidade e normalização	20
4.2.4	Máscara de artefacto para supervisão auxiliar	20
4.3	Arquiteturas em comparação	20
4.3.1	U-Net	20
4.3.2	U-Net Dual Supervision	21
4.4	Treino reprodutível	22
4.4.1	Configuração, determinismo e seleção de checkpoint	22
4.4.2	Função de Perda	23
4.5	Avaliação interna	24
4.5.1	Métricas globais	25
4.5.2	Avaliação por regiões de interesse	25
4.5.3	Análise estatística	28
4.6	Avaliação externa por médicos	28
4.6.1	Desenho e casos	28
4.6.2	Participantes e proteção de dados	29
4.6.3	Apresentação e instrumento de avaliação	29
4.6.4	Desfechos e análise	29
4.6.5	Estado operacional	29
5	Resultados	30
5.1	Coorte final e integridade experimental	30
5.1.1	Resultados da Aprovação Automática x Inspeção Manual	30
5.1.2	Análise Complementar com MS-SSIM	30
5.2	Treino dos modelos	38
5.2.1	Convergência e seleção dos checkpoints	38
5.2.2	Rastreabilidade das execuções	38
5.3	Avaliação interna no conjunto de teste	43
5.3.1	Desfechos globais	43
5.3.2	Análise por região de interesse e preservação anatômica	43
5.4	Comparação pareada single-head versus dual-head	51
5.5	Desempenho computacional	54
5.6	Avaliação externa por médicos	56
5.6.1	Estado da recolha e participantes	56
5.6.2	Desfecho primário: visualização anatômica	56
5.6.3	Desfechos secundários e segurança percebida	57
5.6.4	Interpretação limitada ao desenho observacional	57
6	Discussão	58
6.1	Síntese dos achados principais	58
6.2	Interpretação da comparação arquitetural	58
6.3	Preservação anatômica e segurança da reconstrução	58
6.4	Generalização e avaliação externa	58
6.5	Avaliação por médicos	58
6.6	Limitações	59

6.7	Implicações e trabalho futuro	59
7	Conclusões	60
7.1	Conclusões do estudo	60
7.2	Contribuições da dissertação	60
7.3	Perspetivas futuras	60
	Bibliography	60
A	Appendix Title Here	66

Lista de Figuras

4.1	Diagrama da arquitetura Single Supervision.	21
4.2	Diagrama da arquitetura Dual Supervision.	22
4.3	Exemplos de zonas de ROI em fatias de CT com artefatos metálicos. Em cada par, a imagem da esquerda mostra a Zona de Artefato ($\mathcal{R}_{art}$, sobreposição a vermelho) e a da direita a Zona Distante ($\mathcal{R}_{dist}$, sobreposição a verde). As fatias cobrem anatomias torácica (topo), abdominal (meio) e torácica com implante unilateral (base), ilustrando a variabilidade da extensão e forma da zona de artefato em função da localização e número de implantes metálicos.	27
5.1	Distribuição de MS-SSIM entre pares correspondentes (CT-MAR vs DL/Stroke, aprovados automaticamente). Acima: histograma com os percentis P1 e P5, mediana, média e limiar de 0.9. Abaixo: zoom do histograma para a região de maior interesse, com destaque para os pares com MS-SSIM inferior a 0.9, que foram sujeitos a revisão manual.	31
5.2	Distribuição de MS-SSIM entre pares correspondentes (CT-MAR vs DL/Stroke, aprovados automaticamente). À esquerda: histograma com os percentis P1 e P5, mediana, média e limiar de 0.9. À direita: ECDF correspondente. Os pares com MS-SSIM inferior a 0.9 foram sujeitos a revisão manual.	33
5.3	Exemplos de pares correspondentes com valores de MS-SSIM (0.7597, 0.7694 e 0.7717, respetivamente) aprovados após revisão visual humana mesmo com pontuações baixas.	34
5.4	3 pares reprovados após inspeção visual humana com valores de MS-SSIM (head_1159: 0.4573, head_369: 0.5652 e head_763: 0.6009, respetivamente). As pontuações desses pares na similaridade de cosseno foram head_1159: 0.9960, head_369: 0.9952 e head_763: 0.9951.	35
5.5	Distribuição dos valores de similaridade de cosseno para os pares inspecionados visualmente.	36
5.6	Distribuição dos valores de MS-SSIM para os pares inspecionados visualmente.	37
5.7	Distribuição dos <i>scores</i> de similaridade de cosseno (DL vs Stroke EIT) para os pares sem correspondência aprovada em nenhum dos dois <i>datasets</i> de origem (N=435). À esquerda: histograma das pontuações por <i>dataset</i> ; à direita: ECDF correspondente com o limiar de 0,98 assinalado.	38
5.8	Curva de treino gerada pelo workflow: training_curves_dualhead.png.	39
5.9	Curva de treino gerada pelo workflow: lr_schedule.png.	39
5.10	Curva de treino gerada pelo workflow: training_curves_singlehead.png.	40
5.11	Curva de treino gerada pelo workflow: training_curves_dualhead.png.	41
5.12	Curva de treino gerada pelo workflow: lr_schedule.png.	41
5.13	Curva de treino gerada pelo workflow: training_curves_singlehead.png.	42

5.14 Resultado de avaliacao interna: bland_altman.png.	43
5.15 Resultado de avaliacao interna: scatter_mean_hu_per_slice.png.	44
5.16 Resultado de avaliacao interna: scatter_pixel_hu.png.	44
5.17 Resultado de avaliacao interna: bland_altman.png.	45
5.18 Resultado de avaliacao interna: scatter_mean_hu_per_slice.png.	45
5.19 Resultado de avaliacao interna: scatter_pixel_hu.png.	46
5.20 Resultado de avaliacao interna: pair_712_body_11945.png.	46
5.21 Resultado de avaliacao interna: pair_713_body_11946.png.	47
5.22 Resultado de avaliacao interna: pair_714_body_11947.png.	47
5.23 Resultado de avaliacao interna: pair_715_body_11948.png.	47
5.24 Resultado de avaliacao interna: pair_716_body_11949.png.	47
5.25 Resultado de avaliacao interna: pair_717_body_11950.png.	48
5.26 Resultado de avaliacao interna: stability_seed_comparison.png.	48
5.27 Distribuicao de metricas e analise de correlacao: boxplots_preservation_analysis.png. 48	
5.28 Distribuicao de metricas e analise de correlacao: correlation_preservation_vs_improvement.png.	
5.29 Distribuicao de metricas e analise de correlacao: hist_delta_improvement.png. 49	
5.30 Distribuicao de metricas e analise de correlacao: roi_comparison_boxplots.png. 49	
5.31 Distribuicao de metricas e analise de correlacao: roi_safety_scatter.png. . . 50	
5.32 Distribuicao de metricas e analise de correlacao: scatter_baseline_vs_model.png. 50	
5.33 Comparacao entre modelos: comparison_bar_charts.png.	51
5.34 Comparacao entre modelos: comparison_scatter_tradeoff.png.	52
5.35 Comparacao entre modelos: comparison_bar_charts.png.	52
5.36 Comparacao entre modelos: comparison_scatter_tradeoff.png.	53
5.37 Comparacao entre modelos: comparison_bar_charts.png.	53
5.38 Comparacao entre modelos: comparison_scatter_tradeoff.png.	54
5.39 Benchmark de inferencia: benchmark_latency.png.	54
5.40 Benchmark de inferencia: benchmark_latency.png.	55
5.41 Benchmark de inferencia: benchmark_latency.png.	55
5.42 Benchmark de inferencia: benchmark_latency.png.	55
5.43 Benchmark de inferencia: benchmark_latency.png.	56
5.44 Benchmark de inferencia: benchmark_latency.png.	56

Lista de Gráficos

Lista de Tabelas

4.1	Resultados do rastreio antes da análise complementar com MS-SSIM.	16
4.2	Resultados do rastreio depois da análise complementar com MS-SSIM.	16
4.3	Dados dos pares sem correspondência que foram excluídos antes e após a análise complementar com MS-SSIM.	17
4.4	Distribuição anatômica por subconjunto ao nível de pacientes.	18
4.5	Distribuição percentual dos pacientes por subconjunto.	18
4.6	Distribuição dos pares por subconjunto e categoria anatômica.	18
4.7	Distribuição percentual dos pares por subconjunto.	19
4.8	Métricas utilizadas por contexto de avaliação.	28
5.1	Resultados quantitativos no conjunto de test.	43
5.2	Comparacao pareada dual-head menos single-head, agregada por paciente. . .	51

Lista de Abreviaturas

AMP Automatic Mixed Precision.

ASPP Atrous Spatial Pyramid Pooling.

BCE Binary Cross-Entropy.

BN Batch Normalization.

CBAM Convolutional Block Attention Module.

CNN Convolutional Neural Network.

CT Computed Tomography.

CT-MAR CT Metal Artifact Reduction Challenge.

DICE Dice Similarity Coefficient.

DL Deep Learning.

FBP Filtered Back Projection.

FC Fully Connected.

FCUP Faculdade de Ciências da Universidade do Porto.

FLOPs Floating Point Operations.

GAN Generative Adversarial Network.

GAP Global Average Pooling.

GPU Graphics Processing Unit.

HU Unidade Hounsfield.

iMAR Iterative Metal Artifact Reduction.

IR Iterative Reconstruction.

MAE Mean Absolute Error.

MAR Metal Artifact Reduction.

MBIR Model-Based Iterative Reconstruction.

MLP Multi-Layer Perceptron.

MS-SSIM Multi-Scale Structural Similarity Index Measure.

NMAR Normalized Metal Artifact Reduction.

NPY NumPy Array.

O-MAR Orthopedic Metal Artifact Reduction.

PSNR Peak Signal-to-Noise Ratio.

ReLU Rectified Linear Unit.

RMSE Root Mean Square Error.

ROI Region of Interest.

SE Squeeze-and-Excitation.

SE-Net Squeeze-and-Excitation Network.

SEMAR Single Energy Metal Artifact Reduction.

SSIM Structural Similarity Index Measure.

TCIA The Cancer Imaging Archive.

U-Net U-shaped Network.

UP Universidade do Porto.

This thesis is dedicated to my husband, for his love and support.

Capítulo 1

Introdução

Quando Wilhelm Conrad Röntgen, professor de Física da Universidade de Würzburg, na Alemanha, decidiu repetir o experimento feito por Philipp Lenard com um tubo de Crookes modificado para estudar raios catódicos, ninguém podia prever o impacto de suas descobertas na medicina. Não demorou muito para que seus experimentos apresentassem resultados surpreendentes que demonstravam que o comportamento observado não era compatível com raios catódicos, mas sim com uma espécie de raio mais penetrante e que não sofria desvios na presença de um campo magnético. Durante o manuseio das peças usadas nos seus experimentos, percebeu que o contorno dos seus ossos estava sendo estampado na tela fluorescente que utilizava.

Assim, em 22 de dezembro de 1895, convidou sua esposa, Anna Bertha, a fazer uma exposição de 15 minutos a esses raios, obtendo-se o que seria a primeira radiografia do corpo humano. Nesse mesmo ano, Röntgen publicou o artigo "On a new kind of rays", no qual batiza o agente responsável como "raios-X". Já em janeiro de 1896, os jornais anunciavam em primeira página a descoberta como uma forma revolucionária de observar o interior do corpo humano sem a necessidade de incisões cirúrgicas, apontando seu potencial uso no diagnóstico médico [1, 2].

Em fevereiro de 1896, em Massachusetts (EUA), Edwin Brant Frost produziu uma radiografia da fratura de Colles de um paciente para seu irmão, um médico local, marcando o início da incorporação dos raios-X à prática médica [1]. Assim, em menos de um ano após o anúncio da descoberta por Röntgen, os raios-X rapidamente saíram dos laboratórios e passaram a ser utilizados de forma extensiva no diagnóstico e na terapia [1]. Desde então, a técnica passou por sucessivas modernizações e diversificou-se em múltiplas modalidades e dispositivos,

consolidando-se como ferramenta indispensável na saúde moderna [3, 4].

Dessas sucessivas modernizações surgiu, em 1971, o primeiro tomógrafo computadorizado. Essa tecnologia baseia-se no princípio de atenuação dos raios-X, em que a quantidade de radiação absorvida ou dispersa pelo material relaciona-se à sua densidade [5, 6]. A tomografia computadorizada (CT) foi a primeira modalidade de imagem médica a fornecer informações quantitativas sobre a atenuação dos tecidos, algo que não era possível com a radiografia convencional [7]. Além disso, ao permitir a visualização seccional do corpo humano, a tomografia computadorizada eliminou a sobreposição de estruturas anatômicas inerente às imagens bidimensionais, possibilitando a localização precisa e a avaliação da extensão de lesões[7].

Entretanto, esses avanços trouxeram um aumento significativo da complexidade tecnológica. A aquisição de múltiplas projeções, aliada à reconstrução computacional e ao processamento digital da imagem, introduziu novas formas de degradação que eram inexistentes ou pouco relevantes na radiografia convencional. Dessa forma, a tomografia computadorizada tornou-se particularmente suscetível à presença de artefatos, os quais podem comprometer a qualidade diagnóstica e a confiabilidade clínica das imagens [7].

Diversos tipos de artefatos podem ser observados em tomografia computadorizada, incluindo ruído, endurecimento do feixe, movimento, artefatos de anel e artefatos metálicos, os quais podem obscurecer ou simular patologias [8]. As causas desses artefatos são variadas, podendo incluir desde falhas ou descalibração dos detectores, limitações estatísticas associadas a baixas contagens de fótons, até fenômenos físicos como endurecimento e dispersão do feixe, que produzem estrias escuras entre objetos de alta atenuação, como metal, osso ou meios de contraste iodados [7].

Especificamente, artefatos de estrias causados por implantes metálicos são observados em aproximadamente 21% das varreduras tomográficas, sendo considerados extremamente comuns na prática clínica [7]. A elevada atenuação ou mesmo o bloqueio total dos raios-X por esses implantes impede que a radiação alcance adequadamente os detectores, resultando em dados de projeção de baixa qualidade e comprometendo a reconstrução da imagem [9].

O aumento do uso de implantes metálicos, impulsionado pela evolução dos cuidados de saúde, intensificou as preocupações relacionadas ao impacto negativo desses artefatos na qualidade de imagem e na confiabilidade das análises diagnósticas [9]. Tradicionalmente, diversos algoritmos de redução de artefatos de metal (MAR) foram propostos, incluindo técnicas de preenchimento de imagem, preenchimento de sinogramas e métodos de reconstrução

iterativa baseada em modelo (*MBIR*) ou combinações dessas abordagens [10].

Embora métodos analíticos como a *Filtered Back Projection (FBP)* tenham dominado a reconstrução tomográfica por décadas devido à sua eficiência computacional e simplicidade conceitual, suas limitações tornam-se evidentes em condições clínicas não ideais, exigindo doses de radiação mais elevadas para garantir qualidade de imagem [11]. Métodos *MBIR* surgiram como alternativa para superar essas limitações, ao custo de maior demanda computacional e da introdução de texturas artificiais na imagem reconstruída [11].

Mais recentemente, abordagens baseadas em aprendizado profundo têm sido amplamente investigadas para a correção de artefatos em tomografia computadorizada, demonstrando desempenho superior e maior aplicabilidade clínica em comparação com métodos convencionais [12]. Em particular, redes neurais convolucionais (*CNNs*) têm sido propostas para a redução de artefatos metálicos, permitindo a supressão de ruído e a preservação de detalhes anatômicos e de tecidos moles [12].

1.1 Contexto clínico e técnico

Devido ao fato de que artefatos em CT podem esconder ou simular patologias, a sua presença pode comprometer a qualidade diagnóstica e a confiabilidade clínica das imagens. Um erro de diagnóstico pode trazer consequências graves para o paciente, incluindo atrasos no tratamento, tratamentos inadequados ou desnecessários, e até mesmo risco de vida. Além disso, devido a constante evolução tecnológica, torna-se cada vez mais comum o uso de implantes metálicos no contexto médico, o que aumenta consideravelmente a presença desse tipo de artefato especificamente e também os erros de diagnóstico associados. Sendo assim, a redução de artefatos em CT é uma área de pesquisa com importância clínica significativa e o desenvolvimento de métodos eficazes para reduzir artefatos ganha elevado valor na prática médica.

1.2 Problema de investigação

Embora estudos utilizando *Deep Learning* para redução de artefatos metálicos não seja novidade, a maioria dos trabalhos publicados até o momento não apresenta uma avaliação rigorosa e detalhada do desempenho dos modelos propostos. Principalmente, no que se trata a avaliação do desempenho dos modelos em conjunto de dados externos, que não foram utilizados durante o treino do modelo ou avaliação das imagens por médicos qualificados. Além de que,

os treinos de modelos supervisionados dependem de imagens de referência, que são difíceis de obter em contexto clínico, o que cria dependência de imagens sintéticas ou simuladas, que pode limitar a generalização dos modelos treinados para o contexto de imagens reais. Nesse sentido, o presente estudo propõe uma avaliação mais rigorosa e detalhada do desempenho de modelos de *Deep Learning* para essa finalidade.

1.3 Contribuições e organização da dissertação

Esse trabalho visa avaliar o desempenho de duas versões de uma [U-shaped Network \(U-Net\)](#), comparando seus resultados. Ao final, foi realizada uma avaliação externa com imagens reais, que foi então avaliadas por médicos qualificados, para validar a eficácia dos modelos propostos e sua eventual aplicabilidade clínica.

Capítulo 2

Objetivos e Questões de Investigação

2.1 Objetivo geral

O objetivo geral desta dissertação é desenvolver, avaliar e comparar de forma rigorosa um modelo baseado em *Convolutional Neural Networks (CNNs)* para deteção e redução de artefatos em imagens de Tomografia Computorizada, privilegiando a preservação anatómica, a robustez à variação de domínio e a interpretabilidade do processo de correção.

2.2 Objetivos específicos

Os objetivos específicos deste trabalho incluem:

- Desenvolver um *pipeline* reproduzível para treino e avaliação de modelos de redução de artefatos em CT no domínio da imagem, com separação rigorosa entre dados de treino, validação e teste.
- Avaliar o desempenho de uma arquitetura U-Net convencional para reconstrução de imagem na redução de artefatos metálicos e compará-la com uma versão dela mesma com acréscimo de uma supervisão extra de máscara de artefato.
- Avaliar o desempenho das duas versões utilizando métricas quantitativas (PSNR, MS-SSIM, SSIM, BCE e DICE), análise qualitativa e mapas de erro.
- Investigar a capacidade de generalização da versão que se sair melhor na etapa de avaliação interna em dados reais e externos ao treino provenientes do *The Cancer Imaging Archive (TCIA)*.

2.3 Hipóteses e desfechos

Capítulo 3

Enquadramento e Trabalhos Relacionados

3.1 Artefactos metálicos em tomografia computadorizada

[A preencher: mecanismos físicos, impacto clínico e limitações dos métodos convencionais.]

Os métodos tradicionais de redução de artefatos em **CT** baseiam-se predominantemente em princípios físicos e matemáticos associados à formação da imagem. Barrett e Keat[13] descrevem detalhadamente a origem dos principais artefatos em **CT**, incluindo endurecimento de feixe, *photon starvation*, dispersão e efeitos geométricos, bem como estratégias clássicas para sua mitigação.

Técnicas de reconstrução como a Retroprojeção Filtrada (**FBP**) foram amplamente utilizadas devido à sua eficiência computacional, porém apresentam elevada sensibilidade ao ruído e aos artefatos metálicos. Métodos mais avançados, como *Iterative Reconstruction (IR)* e *Model-Based Iterative Reconstruction (MBIR)*, incorporam modelos estatísticos do sistema de aquisição e do ruído, permitindo redução parcial de artefatos. Contudo, essas abordagens frequentemente introduzem texturas artificiais e apresentam limitações em cenários clínicos complexos [11].

Revisões recentes indicam que algoritmos comerciais de *Metal Artifact Reduction (MAR)*, como **O-MAR**, **iMAR** e **SEMAR**, embora eficazes em situações específicas, dependem de parâmetros proprietários e exibem desempenho inconsistente em casos de implantes densos ou múltiplos [9, 14]. Essas limitações impulsionaram a investigação de abordagens baseadas em aprendizagem profunda.

3.2 Redução de artefactos baseada em aprendizagem profunda

As primeiras aplicações de DL para MAR concentraram-se no domínio da imagem, explorando redes convolucionais para mapear imagens degradadas para versões corrigidas. Gjestebj et al. [15] investigaram a redução de artefactos metálicos no domínio da imagem baseada em CNN e demonstraram melhorias quantitativas significativas em comparação com as técnicas convencionais.

Zhang e Yu [16] também propuseram um modelo supervisionado baseado em Convolutional Neural Network (CNN) para redução de artefactos metálicos em CT, obtendo ganhos consistentes em Peak Signal-to-Noise Ratio (PSNR) e Root Mean Square Error (RMSE). Esses trabalhos ajudaram a consolidar o uso de redes convolucionais para MAR no domínio da imagem. Em particular, Zhang e Yu utilizaram uma CNN rasa totalmente convolucional para fusão de informação de múltiplas imagens pré-corrigidas. Os trabalhos subsequentes adotaram cada vez mais arquiteturas de codificador-decodificador, especialmente as baseadas em U-Net, para tarefas de correção/restauração. Redes do tipo U-Net e suas variantes são capazes de capturar informações contextuais globais por meio do caminho de contração, e recuperar detalhes espaciais finos por meio do caminho de expansão e Skip Connections[17].

Revisões sistemáticas mais recentes consolidam esses avanços, destacando que a maioria dos métodos supervisionados no domínio da imagem apresenta desempenho competitivo, especialmente quando treinados com dados pareados de alta qualidade [9, 11].

Além do domínio da imagem, alguns estudos exploraram o domínio do sinograma, com métodos de interpolação linear e Normalized Metal Artifact Reduction (NMAR). Essas abordagens operam diretamente nos dados de projeção e atuam diretamente na origem física dos artefactos metálicos[18]. No entanto, o acesso aos dados de projeção brutos é frequentemente restrito em sistemas de CT comerciais, limitando a aplicabilidade de tais abordagens em ambientes clínicos [15].

Além disso, modelos híbridos têm sido propostos para aproveitar as vantagens de cada abordagem. O método proposto por Zhang e Yu [16] procura mesclar CNN no domínio de imagem e MAR clássico no domínio do sinograma. Na abordagem adotada, o refinamento inicial ocorre no domínio da imagem, mas o método completo utiliza a imagem gerada pela CNN como *prior* para substituição de regiões afetadas no sinograma. Isso caracteriza uma abordagem híbrida, mas ainda não emprega CNN nos dois domínios. Modelos mais recentes, como o DuDoNet[19], integram redes profundas em ambos os domínios, demonstrando desempenho

elevado e caracterizando o que chamamos de *Dual Domain*. No entanto, esses métodos apresentam maior complexidade computacional e dependência do acesso ao sinograma bruto, o que motiva a exploração contínua de soluções robustas no domínio da imagem.

Para contornar a escassez de dados pareados anatomicamente idênticas com artefato de metal/Livre de artefato de metal, surgiram abordagens baseadas em aprendizagem auto-supervisionada. Yu et al. [20] propuseram um método capaz de reduzir artefatos metálicos sem a necessidade de imagens de referência totalmente limpas, ampliando a aplicabilidade clínica dessas técnicas.

Outros trabalhos exploraram o uso de *Generative Adversarial Network (GAN)* para MAR. Huang et al. [21] utilizaram fusão multimodal e GANs para melhorar a preservação de textura e reduzir suavização excessiva. Apesar dos bons resultados visuais, métodos baseados em GAN podem introduzir instabilidade no treino e maior risco de alucinação estrutural[22], o que levanta preocupações clínicas.

3.3 Avaliação reprodutível e generalização

A avaliação de modelos de DL para CT é tipicamente realizada por meio de métricas quantitativas como PSNR, RMSE e índices baseados em similaridade estrutural. Métricas tradicionais baseadas em erro, como RMSE e PSNR, quantificam discrepâncias pixel a pixel, mas não capturam adequadamente informações estruturais relevantes para a percepção visual e interpretação clínica. Nesse contexto, Wang et al. [23] introduziram o *Structural Similarity Index Measure (SSIM)* como uma métrica perceptual que modela explicitamente luminância, contraste e estrutura. Posteriormente, o *Multi-Scale Structural Similarity Index Measure (MS-SSIM)* foi proposto para incorporar variações estruturais dependentes de escala, estendendo o SSIM para múltiplos níveis de resolução [24]. Horé e Ziou [25] demonstraram que tanto PSNR quanto SSIM apresentam limitações dependendo do tipo de distorção considerada, sugerindo que a escolha da métrica pode depender do contexto de aplicação. Dado que os artefatos metálicos se manifestam principalmente como distorções estruturais que afetam limites anatômicos e padrões de estrias de longo alcance, métricas sensíveis à preservação estrutural, como SSIM e MS-SSIM, mostram-se particularmente adequadas para avaliar o desempenho de métodos de MAR, pois consideram explicitamente componentes estruturais em diferentes escalas espaciais [23, 24]. Além disso, um desafio crítico identificado na literatura é a generalização dos modelos. Zech et al. [26] demonstraram que modelos com elevado desempenho em bases

internas podem falhar significativamente quando aplicados a dados externos, evidenciando o impacto do *domain shift*. Revisões recentes reforçam a necessidade de validação externa e avaliação clínica rigorosa para garantir segurança, robustez e aplicabilidade real [27, 28]. A literatura revisada demonstra avanços significativos na redução de artefatos em CT por meio de DL, mas também evidencia lacunas persistentes: falta de padronização experimental, validação externa limitada e risco de alucinação anatômica.

Capítulo 4

Materiais e Métodos

4.1 Dados, curadoria e rastreabilidade

4.1.1 Conjunto CT-MAR e fontes de referência

O *dataset* principal utilizado neste trabalho provém do [CT Metal Artifact Reduction Challenge \(CT-MAR\)](#) [29, 30] promovido pela *American Association of Physicists in Medicine* e consiste em 14.000 pares de treino contendo imagens de CT com artefatos metálicos simulados e suas versões originais sem artefatos. Os dados foram gerados através de um *framework* de simulação híbrida [31], que incorpora imagens clínicas publicamente disponíveis e objetos metálicos simulados com o simulador CatSim, integrado na *toolkit* de código aberto XCIST [32]. O conjunto é distribuído em duas categorias anatômicas:

- **Head:** 1.626 (11.61%) amostras derivadas da base *UCLH Stroke EIT Data* [33, 34];
- **Body:** 12.374 (88.38%) amostras derivadas da base *NIH DeepLesion Data* [35].

Onde as pastas da categoria *body* apresentavam CTs de tronco, abrangendo fatias axiais, torácica e abdominal. Os dados estão organizados em subpastas, cada uma contendo até 1.000 amostras. Foram utilizados apenas os seguintes ficheiros para treino e validação:

1. **Imagens sem metal (referência):** Ficheiros contidos na pasta *Target* de dimensão 512×512×1 pixels;
2. **Imagens com artefatos metálicos (corrompidas):** Ficheiros contidos na pasta *Baseline* de dimensão 512×512×1 pixels;

Todos os ficheiros de imagem (.raw) do *dataset* são apresentados em formato binário sem cabeçalho, com precisão *float32* em ordem *little endian*. As imagens já vieram convertidas de coeficientes de atenuação linear (em unidades mm^{-1}) para [Unidade Hounsfield \(HU\)](#), utilizando o valor de normalização de 0.02 mm^{-1} para água. Não havia no conjunto de dados informações adicionais sobre a que exame cada *slice* pertencia, se eram de um mesmo paciente, ou quais regiões anatómicas específicas estavam representadas. A única informação disponível era a organização por pasta, que indicava a categoria anatómica (Head ou Body). A falta de metadados detalhados impôs a necessidade de uma abordagem de pré-processamento cuidadosa para garantir que os dados fossem adequadamente organizados e utilizados durante o treino e validação dos modelos. Dessa forma, um esforço significativo foi dedicado ao rastreio das imagens aos conjuntos de dados originais (UCLH Stroke EIT Data e NIH DeepLesion Data) para obter informações adicionais sobre os exames e pacientes, permitindo um particionamento adequado dos dados.

4.1.2 Particionamento ao nível do paciente

[A preencher: manifesto canónico, semente fixa, proporções treino/validação/teste e auditoria de leakage.]

O particionamento dos dados foi estratificado por pacientes, garantindo que os *slices* de um mesmo paciente não fossem distribuídos entre os conjuntos de treino, validação e teste. Esta abordagem evita vazamento de informações e assegura uma avaliação mais realista da capacidade de generalização dos modelos.

Dado que os dados do [CT-MAR dataset](#) não continham metadados clínicos detalhados, foi necessário realizar um rastreio algorítmico dos *slices* até aos conjuntos de dados originais (UCLH Stroke EIT e NIH DeepLesion Data) para tornar possível a associação dos metadados fornecidos aos *slices* do [CT-MAR](#). Este processo permitiu identificar a qual exame e paciente do DeepLesion/UCLH Stroke EIT cada imagem [CT-MAR](#) pertencia. Essas informações foram posteriormente utilizadas para realizar o particionamento dos dados em treino, validação e teste ao nível do paciente, reduzindo o risco de *data leakage* entre conjuntos experimentais.

A correta separação dos dados é particularmente importante em estudos de imagem médica baseados em *deep learning*, uma vez que *slices* pertencentes ao mesmo exame frequentemente apresentam elevada similaridade anatómica. Dessa forma, a presença simultânea de imagens do mesmo paciente em treino e teste pode inflacionar artificialmente o desempenho do modelo e comprometer a avaliação da sua capacidade de generalização [36].

As imagens do dataset DeepLesion [35] encontram-se armazenadas em formato PNG de 16 bits, enquanto as imagens do CT-MAR são disponibilizadas em formato `.raw` diretamente em unidades de Hounsfield (HU). Já o UCLH Stroke EIT [33] disponibiliza os exames em formato DICOM. Assim, independentemente do formato original, todas as imagens foram convertidas para HU antes da comparação, garantindo uniformidade entre os diferentes conjuntos de dados.

Após a conversão, todas as imagens foram representadas numa mesma escala de intensidade para permitir comparação direta.

O algoritmo utilizado baseia-se no facto de que imagens CT preservam informação quantitativa em unidades de Hounsfield (HU), refletindo diretamente as propriedades de atenuação dos diferentes tecidos. Como as estruturas anatómicas apresentam elevada continuidade espacial entre *slices* consecutivos de uma mesma aquisição, imagens correspondentes à mesma fatia anatómica tendem a apresentar distribuições semelhantes de HU e padrões estruturais globais altamente consistentes [23, 37].

Dessa forma, o método não procura verificar igualdade absoluta pixel-a-pixel entre imagens, mas sim determinar se a organização estrutural global da anatomia permanece extremamente semelhante entre diferentes representações da mesma fatia. Esse comportamento é particularmente importante porque pequenas variações locais de intensidade, discretização numérica e transformações lineares associadas à conversão entre formatos de armazenamento tendem a preservar a estrutura anatómica global da imagem mesmo quando ocorrem pequenas variações locais de intensidade [23, 37].

Assim, a metodologia adotada procura identificar correspondências entre imagens com base na similaridade estrutural global, permitindo uma margem de variação local que não comprometa a identificação correta do exame e paciente de origem. Inicialmente, cada imagem foi reduzida para uma representação compacta através de *downsampling*, preservando principalmente a informação anatómica global relevante. Essa etapa reduz significativamente o custo computacional sem comprometer a estrutura geral da imagem.

Em seguida, foi calculado um vetor representativo (*fingerprint*) para cada imagem. Os *fingerprints* das imagens CT-MAR foram então comparados com os *fingerprints* das imagens DeepLesion e UCLH Stroke EIT através de uma métrica de similaridade vetorial baseada em produto escalar normalizado (similaridade de cosseno), escolhida por ser invariante a diferenças de escala global entre os vetores — propriedade relevante dado que as imagens provêm

de formatos distintos com diferentes normalizações de intensidade. Para cada imagem **CT-MAR**, foi selecionada a imagem com maior score de similaridade.

Como a maior parte das imagens do **CT-MAR** teve origem no DeepLesion, o processo de rastreio foi inicialmente priorizado nesse dataset. Posteriormente, a mesma metodologia foi aplicada aos exames DICOM do UCLH Stroke EIT para identificação das imagens restantes. Dessa forma, foi possível implementar uma estratégia unificada de rastreabilidade independentemente do formato de armazenamento dos datasets de origem.

As correspondências foram consideradas válidas apenas quando o score de similaridade excedia um limiar previamente definido empiricamente. Casos com scores muito elevados foram automaticamente marcados como correspondências seguras, pois observou-se que todos os pares analisados visualmente com pontuação superior a 0.993 correspondiam efetivamente à mesma imagem. Para manter uma margem adicional de segurança, a correspondência foi considerada automaticamente válida apenas quando a pontuação excedia 0.994.

Pontuações inferiores a esse limiar indicavam correspondências potencialmente ambíguas e eram submetidas à inspeção visual manual. Já pontuações inferiores a aproximadamente 0.98 indicavam correspondências claramente incorretas e eram automaticamente descartadas sem necessidade de revisão manual. Dessa forma, todos os pares que apresentavam pontuações entre 0.98 e 0.994 foram analisados visualmente para confirmação da validade da correspondência. A fim de evitar a exclusão de pares de forma desnecessária, todos os pares com pontuação inferior a 0.98 para ambos os datasets (DeepLesion e UCLH Stroke EIT) foram submetidos a inspeção visual para garantir que não fossem erroneamente descartados.

Para os 530 pares que permaneceram sem correspondência aprovada após a busca direta nos dois datasets de origem, foi aplicada uma etapa complementar de correspondência indireta. Nessa etapa, cada imagem **CT-MAR** não correspondida foi comparada com imagens **CT-MAR** já rastreadas; os vizinhos mais semelhantes foram usados para selecionar exames candidatos do DeepLesion e, em seguida, todos os *slices* desses exames foram pesquisados com *fingerprints* de dimensão 64×64 . As 530 propostas foram inspecionadas visualmente: 95 correspondências foram aprovadas e incorporadas ao manifesto consolidado, enquanto 435 permaneceram sem correspondência segura e foram excluídas.

Além disso, o método foi concebido para ignorar automaticamente imagens previamente verificadas como correspondências corretas, reduzindo redundâncias e acelerando reprocessamentos futuros. Devido ao elevado número de imagens presentes nos datasets, o processamento foi paralelizado e otimizado através da utilização de operações matriciais vetorizadas.

Quando disponível, o algoritmo utiliza aceleração por GPU para reduzir o tempo de execução. Os *fingerprints* calculados também foram armazenados em cache para evitar recomputação desnecessária em execuções subsequentes.

Embora a representação compacta baseada exclusivamente na média de intensidades dos blocos (HU) seja eficiente, ela pode, em teoria, gerar falsos positivos quando exames de pacientes diferentes são adquiridos com protocolos de aquisição idênticos ou apresentam estruturas anatómicas muito semelhantes, uma vez que essas condições tendem a produzir distribuições de intensidade similares e, consequentemente, *fingerprints* com pontuação elevada. Para mitigar esse risco, adotou-se um limiar de aceitação automática conservador (0,994) e a validação visual sistemática de todos os pares com scores entre 0,98 e 0,994. Adicionalmente, como salvaguarda complementar, todos os *matches* automáticos foram analisados em termos de [MS-SSIM](#), onde os pares com pontuações mais críticas foram submetidos a uma revisão visual adicional para garantir a confiabilidade das correspondências.

Apesar disso, essa limitação não compromete o objetivo principal da metodologia. Pois, mesmo que *Slices* consecutivos de um mesmo exame frequentemente apresentem elevada redundância espacial e podem, portanto, obter scores de similaridade muito próximos entre si. O propósito do algoritmo não foi realizar alinhamento voxel-a-voxel rigoroso, mas sim identificar corretamente o exame e o paciente de origem de cada imagem [CT-MAR](#). Dessa forma, mesmo eventuais ambiguidades entre *slices* adjacentes permanecem restritas ao mesmo volume anatómico e não introduzem risco relevante de *data leakage* entre treino, validação e teste.

A literatura demonstra que a qualidade dos pares utilizados em estudos supervisionados influencia diretamente o desempenho e a capacidade de generalização dos modelos de MAR [9, 19]. Além disso, métricas estruturais de qualidade de imagem, como o [SSIM](#), têm sido amplamente utilizadas em imagem médica devido à sua maior sensibilidade à preservação estrutural [23]. Embora o método implementado não utilize diretamente [SSIM](#), a estratégia adotada procura preservar precisamente a informação estrutural global da imagem durante o processo de correspondência.

Mais ainda, a utilização dos dados sem qualquer tratamento de rastreo desse tipo, condicionaria todo o projeto a um vazamento de dados inerente ao dataset, comprometendo a avaliação do desempenho dos modelos e a validade dos resultados. Assim, mesmo que o método de rastreo não seja perfeito, ele representa uma melhoria significativa em relação à ausência total de rastreo, garantindo uma base mais confiável.

Tendo isso em conta, essa etapa constituiu um importante procedimento de controlo de qualidade do dataset experimental e foi fundamental para garantir um particionamento adequado dos dados utilizados no treino, validação e teste dos modelos, assegurando que os subconjuntos fossem estratificados por paciente e evitando vazamento de informação entre conjuntos experimentais.

4.1.3 Coorte final e Exclusões

Nem todas as fatias puderam ser rastreadas, mas a maioria dos dados foi associado com sucesso aos exames originais. Ao final das etapas de correspondência direta e indireta, e antes da análise complementar com [MS-SSIM](#), dos 14.000 pares disponibilizados pelo [CT-MAR](#) Dataset, 11.942 foram rastreados até ao DeepLesion (incluindo os 95 recuperados pela correspondência indireta) e 1.623 até ao UCLH Stroke EIT, totalizando 13.565 pares com metadados associados [4.1](#).

Tabela 4.1 Resultados do rastreio antes da análise complementar com [MS-SSIM](#).

Dataset	Rastreados	Correspondidos	Não correspondidos
DeepLesion	12.374	11.942	432
UCLH Stroke	1.626	1.623	3
Total	14.000	13.565	435

Na etapa de avaliação via [MS-SSIM](#), dentre todos os pares com pontuação abaixo de 0.90, apenas 3, anteriormente associados ao Deep Lesion, foram reprovados na inspeção visual [4.2](#).

Tabela 4.2 Resultados do rastreio depois da análise complementar com [MS-SSIM](#).

Dataset	Rastreados	Correspondidos	Não correspondidos
DeepLesion	12.374	11.939	435
UCLH Stroke	1.626	1.623	3
Total	14.000	13.562	438

Dado que uma quantidade significativa dos dados pôde ser rastreada com elevada confiabilidade, os casos restantes que não puderam ser agrupados de forma segura foram excluídos do processo de treino e validação. No total, 438 pares foram removidos por não apresentarem informação suficiente para garantir agrupamento seguro ao nível do paciente. Entre eles, os

3 pares reprovados por ser falso positivo na etapa de avaliação via [MS-SSIM](#). Todos os pares removidos desse estudo foram inspecionados visualmente para confirmar a ausência de correspondência, garantindo que a exclusão foi justificada.

Tabela 4.3 Dados dos pares sem correspondência que foram excluídos antes e após a análise complementar com [MS-SSIM](#).

	Excluídos	
	Antes	Depois
Total	435	438

Assim, dos 14.000 pares originalmente disponibilizados pelo [CT-MAR](#) Dataset, 13.562 foram incluídos neste trabalho, enquanto 438 foram excluídos para preservar a integridade do particionamento experimental e minimizar o risco de *data leakage*.

4.1.4 Estratificação Anatômica

A proporção anatômica dos 14.000 pares do [CT-MAR](#) Dataset, mudou pouco após o processo de rastreio e exclusão dos pares com baixa confiabilidade. Dos 438 casos removidos 435 eram do tipo *body*, 3 do tipo *head*. A distribuição anatômica dos pares incluídos no estudo é a seguinte:

- **Body:** aproximadamente 88.03% ;
- **Head:** aproximadamente 11.97% .

A estratificação foi implementada dentro de cada subconjunto (train/val/test) de modo a manter a proporção anatômica ao nível de pacientes, garantindo que a proporção relativa entre categorias seja preservada em todos os subconjuntos. Dessa forma, o balanceamento anatômico é preservado, garantindo que os modelos sejam treinados e avaliados em uma representação adequada da diversidade anatômica presente no conjunto de dados original.

A nível de pacientes, a distribuição anatômica é a seguinte:

- **Body:** aproximadamente 95.9% (258/269 pacientes);
- **Head:** aproximadamente 4.1% (11/269 pacientes).

Após o particionamento, os subconjuntos de treino, validação e teste apresentaram a seguinte distribuição:

Tabela 4.4 Distribuição anatômica por subconjunto ao nível de pacientes.

Split	Body	Head	% Body	% Head
Train	180	7	96.3%	3.7%
Val	39	2	95.1%	4.9%
Test	39	2	95.1%	4.9%
Total	258	11	–	–

A partição paciente-nível foi definida uma única vez, com semente aleatória fixa, mantendo aproximadamente 70% dos pacientes para treino, 15% para validação e 15% para teste. Esta partição fixa garantiu subconjuntos independentes para validação e teste e foi mantida inalterada em todas as repetições experimentais.

Tabela 4.5 Distribuição percentual dos pacientes por subconjunto.

Split	Pacientes	% Total
Train	187	69.52%
Val	41	15.24%
Test	41	15.24%
Total	269	100%

Devido a grande variação na quantidade de fatias por paciente, a distribuição anatômica ao nível de pares é bastante diferente da distribuição ao nível de pacientes (Tabelas 4.6 e 4.7). O mesmo ocorre para a distribuição dos pares totais. Dessa forma, a proporção $\sim 70/15/15$ foi mantida ao nível de pacientes mas ao nível dos pares não segue exatamente a mesma proporção.

Tabela 4.6 Distribuição dos pares por subconjunto e categoria anatômica.

Split	Body	Head	% Body	% Head
Train	8 563	953	89.98%	10.02%
Val	2 147	385	84.79%	15.21%
Test	1 229	285	81.17%	18.83%
Total	11 939	1 623	–	–

Tabela 4.7 Distribuição percentual dos pares por subconjunto.

Split	Pares	% Total
Train	9 516	70.17%
Val	2 532	18.67%
Test	1 514	11.16%
Total	13 562	100%

4.2 Pré-processamento

4.2.1 Verificação de integridade

Todos os pares foram validados através de um relatório de integridade, que verifica a existência de ambos os lados do par (imagem com artefacto e imagem limpa). Não houve nenhum par com dados faltantes, garantindo que o conjunto de dados estava completo e pronto para as etapas subsequentes de pré-processamento e treino dos modelos.

4.2.2 Máscara Corporal

As imagens de [CT](#) frequentemente contêm grandes áreas de fundo que não contribuem para a tarefa de remoção de artefatos metálicos. Isso cria um desequilíbrio de classes nos dados de treino que predomina voxels de fundo irrelevantes sobre as regiões anatômicas de interesse. Esse desequilíbrio, por sua vez, dificulta a aprendizagem e desvia o foco do modelo das estruturas clinicamente relevantes [38, 39]. Para abordar esse desafio, foi implementada uma etapa de pré-processamento também baseada em [Deep Learning \(DL\)](#). Uma [U-Net](#) foi treinada para segmentar o tecido corporal do fundo, gerando máscaras binárias que foram aplicadas às imagens originais para isolar as regiões de interesse. Esse modelo foi treinado utilizando ~ 1.500 amostras do próprio [CT-MAR dataset](#), onde as máscaras de segmentação foram geradas automaticamente através de um processo de limiarização. Além disso, um refinamento manual foi feito nas máscaras obtidas para garantir a qualidade dos dados de treino e consequentemente a eficácia do modelo de segmentação.

Esta etapa foi crucial para reduzir a influência de artefatos de fundo e melhorar a qualidade das *features* extraídas durante o treino.

4.2.3 Janela de intensidade e normalização

As intensidades das imagens vêm expressas em HU do CT-MAR dataset. Para reduzir variações extremas foi aplicada uma janela de intensidade adequada ao contexto anatômico. Após o janelamento, os valores foram normalizados para o intervalo $[0, 1]$ e são gerados tensores NPY de dimensão 256×256 2D para cada fatia e seu par.

4.2.4 Máscara de artefacto para supervisão auxiliar

Foram produzidas máscaras binárias de diferença das regiões afetadas por artefatos que foram utilizadas como sinal de supervisão adicional na arquitetura com dupla supervisão. Essas máscaras são utilizadas exclusivamente durante o treino, não sendo necessárias durante a inferência. A máscara binária de diferenças é definida formalmente como:

$$M_{diff}(i, j) = \begin{cases} 1; & \text{se } |I_{artifact}(i, j) - I_{clean}(i, j)| > \tau \\ 0; & \text{caso contrário} \end{cases} \quad (4.1)$$

onde $I_{artifact}$ representa a imagem com artefatos, I_{clean} a imagem de referência limpa, e τ é o limiar de diferença normalizada. O valor desse limiar foi definido empiricamente para capturar regiões com diferenças perceptíveis mantendo robustez a ruído de baixa amplitude.

4.3 Arquiteturas em comparação

4.3.1 U-Net

O primeiro modelo consiste em uma arquitetura baseada em U-Net [17], composta por *encoder-decoder* com conexões de atalho (*skip connections*). Li et al [40], aplicam blocos de Batch Normalization (BN) e funções de ativação Rectified Linear Unit (ReLU) após cada convolução dinâmica. Esse trabalho faz algo semelhante, mas opta por utilizar convoluções padrão com *kernel* 3×3 , seguida dos blocos de BN e funções de ativação ReLU. A escolha por convoluções padrão é justificada pela simplicidade e eficiência computacional, além de manter a abordagem utilizada por Ronneberger et al [17]. Assim como Li et al [40], o *decoder* também utiliza *bilinear upsampling*. Essa arquitetura possui apenas um *output*.




Fig.4.1 Diagrama da arquitetura Single Supervision.

4.3.2 U-Net Dual Supervision

Uma variação do modelo acima descrito foi concebida, mantendo-se o *encoder* e o *decoder* compartilhados e acrescentando-se uma saída independente na última camada. Dessa forma, há duas saídas distintas no decoder, cada uma com sua própria função de perda. A primeira saída é responsável pela reconstrução da imagem corrigida, enquanto a segunda saída é dedicada à predição da máscara de artefatos.

A justificativa para a adição da supervisão auxiliar da máscara de artefatos baseia-se na premissa de que a presença de uma perda adicional focada na segmentação de regiões afetadas por artefatos pode fornecer informações complementares ao modelo, auxiliando na aprendizagem de representações mais robustas e discriminativas. Essa abordagem é inspirada em trabalhos anteriores que demonstraram que a supervisão multi-tarefa pode melhorar o desempenho em tarefas relacionadas [41, 42].

As duas arquiteturas foram avaliadas entre si para determinar o impacto da supervisão adicional com máscara de artefatos na qualidade da reconstrução e na capacidade de redução de artefatos. Toda a base de ambos os modelos são iguais, sendo a única diferença a presença da saída de predição da máscara de artefatos na segunda versão. Dessa forma, a comparação

entre as duas arquiteturas é justa e isolada, permitindo avaliar exclusivamente o impacto da supervisão adicional da máscara de artefatos.




Fig.4.2 Diagrama da arquitetura Dual Supervision.

4.4 Treino reprodutível

4.4.1 Configuração, determinismo e seleção de checkpoint

Os dois modelos foram treinados sob a mesma configuração, com precisão *float32*. Para avaliar a estabilidade face às diferentes inicializações e ordens de apresentação dos lotes, cada arquitetura foi treinada com operações determinísticas e com as sementes 1337, 42 e 2024, sempre sobre a mesma partição dos pacientes. A precisão mista foi desativada e os lotes foram mantidos completos, incluindo o último lote de cada época, de modo a evitar que amostras fossem excluídas do treino, validação ou avaliação.

Foi utilizado o otimizador AdamW, com taxa de aprendizagem inicial de 2.26×10^{-4} , *weight decay* de 1.00×10^{-4} e *gradient clipping* com norma 1.00, idênticos para as duas arquiteturas. A taxa de aprendizagem foi ajustada pelo scheduler *ReduceLROnPlateau*, com fator de redução 0.50, paciência de duas épocas, *cooldown* de uma época e valor mínimo de 1.00×10^{-6} ,

monitorizando a métrica **SSIM** da imagem reconstruída no conjunto de validação, em ambos os modelos. O treino tinha um limite máximo de 300 épocas e a paragem antecipada só podia ser acionada após, no mínimo, cinco épocas e ocorria quando a métrica monitorizada não melhorava pelo menos 1.00×10^{-4} durante 15 épocas consecutivas. Em cada execução, foi retido o checkpoint correspondente ao melhor valor da métrica de validação monitorizada.

Durante o treino, foram monitorizadas as seguintes quantidades:

- **Perda de reconstrução**, para acompanhar a otimização da imagem corrigida;
- **Perda de segmentação**, apenas no modelo dual, para acompanhar a supervisão auxiliar da máscara;
- **SSIM, PSNR e MAE na escala HU**, calculados na região corporal para acompanhar a fidelidade estrutural e radiométrica das reconstruções.

4.4.2 Função de Perda

- **Reconstrução:** Apesar de L2 ser amplamente utilizada para restauração de imagem, Zhao et al. [43] destacam os melhores resultados de L1 ao estudar diferentes funções de perda para essa tarefa. Os autores também estudaram funções de perda baseadas em **SSIM** e **MS-SSIM**, sendo que a primeira alcança resultados igual ou levemente inferior a L1, enquanto a segunda apresenta desempenho melhor que **SSIM** mas ainda não supera L1 de forma clara. O trabalho também testa um mix de L1 e **MS-SSIM**, e obteve-se resultados superiores em todas as métricas avaliadas pelos autores. Essa combinação é justificada pela complementaridade entre as duas funções, onde L1 favorece fidelidade local e **MS-SSIM** promove preservação estrutural, resultando em uma correção mais equilibrada dos artefatos. Embora o melhor resultado relatado pelos autores tenha envolvido L1 e **MS-SSIM**, neste trabalho adotou-se a soma ponderada de L1 e **SSIM**. Esta escolha mantém o princípio geral de combinar uma componente de fidelidade por píxel com uma componente estrutural, sem reproduzir a formulação específica nem os pesos utilizados por Zhao et al. Os pesos utilizados para o protocolo experimental foram 0.7 para L1 e 0.3 para **SSIM**. A relação adotada para a combinação das funções de perda é a seguinte:

$$\mathcal{L}_{Recon} = 0.7 \cdot \mathcal{L}_{L1} + 0.3 \cdot (1 - \text{SSIM})$$

Na perda híbrida, Zhao et al. [43] aplicam uma ponderação espacial Gaussiana à componente L1, de modo a compatibilizá-la com a distribuição espacial dos gradientes da componente MS-SSIM. Neste trabalho, a componente L1 foi calculada diretamente como o erro absoluto médio na região corporal, sem ponderação Gaussiana adicional. Como a normalização utilizada é linear em relação aos valores de HU, esta componente mantém uma penalização diretamente proporcional ao erro radiométrico, enquanto o SSIM contribui para a preservação estrutural local. Essa combinação de função de perda é adotada para a arquitetura *single task* e também para a cabeça de reconstrução da arquitetura *dual*. Dessa forma, garante-se que a ablação entre as duas versões seja justa, isolando o impacto da supervisão adicional da máscara.

- **Supervisão auxiliar da máscara:** A cabeça de predição da máscara de artefatos, presente na arquitetura *dual*, foi treinada com a soma da perda Dice e da Binary Cross-Entropy (BCE). Essa combinação fornece simultaneamente supervisão para a sobreposição global entre as máscaras e para a classificação por píxel, sendo adequada a problemas de segmentação com desequilíbrio de classes [38]. A relação adotada para a combinação das funções de perda é a seguinte:

$$\mathcal{L}_{Seg} = \mathcal{L}_{Dice} + \mathcal{L}_{BCE}$$

A função de perda total para a versão *dual-head* é composta pela ponderação das perdas de reconstrução e segmentação, e é definida como:

$$\mathcal{L} = 1.0 \cdot \mathcal{L}_{Recon} + 0.045 \cdot \mathcal{L}_{Seg}$$

Os experimentos foram executados numa GPU NVIDIA RTX A4500, utilizando Python e TensorFlow/Keras.

4.5 Avaliação interna

Na fase de inferência, os modelos foram avaliados utilizando métricas quantitativas amplamente adotadas na literatura, em comparação com o *Ground Truth*. As métricas utilizadas para a avaliação da qualidade da imagem reconstruída global e por ROI foram:

- PSNR ;
- SSIM ;

- **MAE.**

Wang et al. [24] descrevem **MS-SSIM** como um método de avaliação de qualidade de imagem através de cinco escalas com *downsampling* iterativo por fator 2, resultando em uma redução de resolução de até 1/16 do tamanho original. O método foi validado em bases de dados de imagens completas, sem considerar aplicação em regiões fragmentadas ou espacialmente seletivas. Devido ao *downsampling* progressivo, a aplicação **MS-SSIM** em **ROIs** pequenas ou fragmentadas (como a zona distante em nossa análise) resultaria na mistura de pixels de **ROI** e não-**ROI** nas escalas reduzidas, comprometendo a interpretabilidade dos resultados. Por isso, utilizou-se **SSIM** regular em vez de **MS-SSIM** nesse trabalho. De fato, as literaturas recentes tem demonstrado performance estatisticamente muito melhor em fidelidade para **MS-SSIM** e **SSIM** comparado a outras métricas de avaliação de qualidade de imagem[44]. Especialmente para imagens médicas, onde a fidelidade das imagens preditas é crucial, a escolha de métricas que refletem a percepção humana de qualidade e preservação estrutural é fundamental. Portanto, **SSIM** foi selecionado como a principal métrica para avaliação quantitativa da qualidade das imagens reconstruídas, garantindo uma análise robusta e relevante para o contexto clínico. E o **PSNR** foi utilizado como métrica complementar para avaliar a fidelidade radiométrica das reconstruções, especialmente importante em tomografias computadorizadas onde a precisão dos valores de **HU** é essencial para diagnóstico e planejamento clínico.

A validação interna foi conduzida nos conjuntos de validação e teste, avaliando consistência, estabilidade e capacidade de generalização intra-*dataset*.

4.5.1 Métricas globais

Para a avaliação global, as imagens preditas e de referência são desnormalizadas para a janela $[-1000, 400]$ HU, correspondendo a uma amplitude $MAX = 1400$ HU. Adicionalmente, a região de avaliação é recortada ao menor retângulo envolvente (*bounding box*) da máscara corporal antes da avaliação de **SSIM**, eliminando janelas de varredura compostas exclusivamente por fundo — que pontuariam $SSIM = 1,0$ artificialmente e inflariam a métrica global.

4.5.2 Avaliação por regiões de interesse

A avaliação global não distingue o comportamento do modelo nas regiões diretamente afetadas pelos artefatos daquele nas regiões saudáveis distantes do implante. Para uma análise

mais granular, a região corporal é dividida em duas zonas complementares, definidas a partir da diferença entre a imagem de entrada e a referência limpa.

- **Zona de Artefato** ($\mathcal{R}_{art}$): pixels cuja diferença absoluta entre entrada e referência, após remoção do *bias* de endurecimento de feixe, excede o limiar $\tau \approx 0,05$ (correspondente a ~ 70 HU acima do *bias* mediano corporal), dilatados com um disco morfológico de raio 10 pixels para incluir os braços de *streak* que caem abaixo do limiar:

$$M_{art}(i, j) = \left[|\Delta_{bias}(i, j)| > \tau \right] \otimes D_{10}$$

- **Zona Distante** ($\mathcal{R}_{dist}$): complemento da zona de artefato dentro da região corporal, que avalia a capacidade do modelo de preservar tecido saudável sem introduzir distorções secundárias:

$$M_{dist} = M_{body} \setminus M_{art}$$

A [Figure 4.3](#) ilustra a aplicação das duas zonas em fatias representativas do conjunto de dados, cobrindo diferentes regiões anatômicas e padrões de artefato.




Fig.4.3 Exemplos de zonas de ROI em fatias de CT com artefatos metálicos. Em cada par, a imagem da esquerda mostra a Zona de Artefato ($\mathcal{R}_{art}$, sobreposição a vermelho) e a da direita a Zona Distante ($\mathcal{R}_{dist}$, sobreposição a verde). As fatias cobrem anatomias torácica (topo), abdominal (meio) e torácica com implante unilateral (base), ilustrando a variabilidade da extensão e forma da zona de artefato em função da localização e número de implantes metálicos.

Para cada zona, calculam-se as métricas como deltas em relação ao desempenho da entrada corrompida, permitindo isolar a contribuição do modelo na região de artefato da sua contribuição nas regiões saudáveis:

$$\Delta\text{PSNR}_{ROI} = \text{PSNR}(\hat{I}|_{ROI}, I|_{ROI}) - \text{PSNR}(I_{art}|_{ROI}, I|_{ROI})$$

$$\Delta\text{SSIM}_{ROI} = \text{SSIM}(\hat{I}|_{ROI}, I|_{ROI}) - \text{SSIM}(I_{art}|_{ROI}, I|_{ROI})$$

Valores positivos indicam melhoria face à entrada corrompida. Utiliza-se [SSIM](#) regular, que opera localmente com janela de 11×11 pixels.

Tabela 4.8 Métricas utilizadas por contexto de avaliação.

Métrica	Treino	Global	ROI Artefato	ROI Distante
PSNR	✓	✓	✓	✓
SSIM	✓	✓	✓	✓
MAE	✓	✓	✓	✓

4.5.3 Análise estatística

[A preencher: paciente como unidade independente, Wilcoxon bilateral, intervalos bootstrap e correção de Holm.]

4.6 Avaliação externa por médicos

A validação externa foi realizada em dados independentes provenientes do [The Cancer Imaging Archive \(TCIA\)](#), permitindo avaliar o impacto de *domain shift* e a robustez do modelo em cenários não vistos durante o treino.

4.6.1 Desenho e casos

[A preencher: estudo observacional, transversal, multileitor e cego quanto à condição A/B; conjunto TCIA, 2 casos de treino excluídos da análise, 15 casos principais e 2 repetições ocultas.]

4.6.2 Participantes e proteção de dados

[A preencher: recrutamento direto, autodeclaração de uso mensal de CT, categorias profissionais retidas e ausência de identificadores diretos.]

4.6.3 Apresentação e instrumento de avaliação

[A preencher: apresentação simultânea e contrabalanceada de entrada/saída como Imagem A/B; escalas ordinais para interferência do artefacto e visualização anatômica, preferência pareada e sinalização de possível dano.]

4.6.4 Desfechos e análise

[A preencher: desfecho primário de diferença pareada na visualização de tecidos e limites anatômicos; desfechos secundários, consistência intraleitor e análise ordinal compatível com amostra pequena.]

4.6.5 Estado operacional

[A preencher: distinguir claramente pré-produção, piloto e recolha concluída; não apresentar resultados clínicos antes da recolha aprovada e concluída.]

Capítulo 5

Resultados

5.1 Coorte final e integridade experimental

[A preencher: pares incluídos, pacientes, distribuição anatômica, partições e resultados das verificações de integridade.]

5.1.1 Resultados da Aprovação Automática x Inspeção Manual

É importante deixar claro como ficou a distribuição dos dados que foram aprovados e reprovados automaticamente, e também quais foram avaliados manualmente. O gráfico abaixo, mapeia todos os pares do [CT-MAR Dataset](#), destacando os que foram aprovados automaticamente, os que foram reprovados e os que foram sujeitos a inspeção visual humana. A distribuição anatômica dos pares é representada por cores, permitindo uma análise visual da relação entre a aprovação automática e a localização anatômica dos artefatos metálicos.

5.1.2 Análise Complementar com [MS-SSIM](#)

Antes de avançar para a análise dos resultados dos modelos de redução de artefatos, foi realizada mais uma avaliação dos resultados [CT-MAR](#) x DeepLesion/Stroke EIT para verificar a qualidade das correspondências automáticas. Esta etapa é crucial para garantir uma camada extra de confiança nos resultados obtidos pelo algoritmo de comparação de similaridade estrutural. Todos os pares que tiveram a correspondência aprovada automaticamente pelo fato de seu score ser acima de 0.994 foram revisados por um novo algoritmo que calcula o [MS-SSIM](#) entre as imagens correspondentes. Um histograma da distribuição dos [MS-SSIM](#) foi gerado,

e os pares com pontuação menor que 0.9 foram revisados manualmente sendo aprovado ou recusado com base em avaliação humana.




Fig.5.1 Distribuição de MS-SSIM entre pares correspondentes (CTMAR vs DL/Stroke, aprovados automaticamente). Acima: histograma com os percentis P1 e P5, mediana, média e limiar de 0.9. Abaixo: zoom do histograma para a região de maior interesse, com destaque para os pares com MS-SSIM inferior a 0.9, que foram sujeitos a revisão manual.

A análise da distribuição entre os pares correspondentes revela que a maioria dos pares apresenta alta similaridade estrutural, com um valor médio de 0.9694 e uma mediana de 0.9830, indicando que o processo de correspondência automática é, em geral, confiável e eficaz na identificação de pares correspondentes entre os datasets [CT-MAR](#) e DeepLesion/Stroke EIT.

Os pares com pontuação de [MS-SSIM](#) abaixo de 0.9 eram 340 no total, apenas 3 foram reprovados após inspeção visual humana [5.2](#). Nessa inspeção, percebe-se que mesmo os casos com pontuações bastante baixas de [MS-SSIM](#) não eram falsos positivos e sim devido a diferenças no pós-processamento ou tratamento geral das imagens que geram alterações locais no qual o [MS-SSIM](#) é mais sensível. Isso pode ser visualizado na figura [5.3](#). Esse fato evidencia a eficácia da estratégia de correspondência por similaridade estrutural global adotada, que conseguiu identificar os pares com precisão, com apenas 3 falsos positivos identificados, mesmo após análise rigorosa [5.4](#). Mostrando que a metodologia é robusta e teve desempenho superior em detectar slices nesse trabalho do que uso do próprio [MS-SSIM](#). Pois, enquanto as diferenças locais afetaram o [MS-SSIM](#) de forma mais significativa, a metodologia baseada em similaridade de cosseno conseguiu identificar as correspondências corretas com pontuação global elevada, mesmo em casos de diferenças locais acentuadas.




Fig.5.2 Distribuição de MS-SSIM entre pares correspondentes (CT-MAR vs DL/Stroke, aprovados automaticamente). À esquerda: histograma com os percentis P1 e P5, mediana, média e limiar de 0.9. À direita: ECDF correspondente. Os pares com MS-SSIM inferior a 0.9 foram sujeitos a revisão manual.




Fig.5.3 Exemplos de pares correspondentes com valores de **MS-SSIM** (0.7597, 0.7694 e 0.7717, respetivamente) aprovados após revisão visual humana mesmo com pontuações baixas.

Os pares reprovados apresentavam **MS-SSIM** claramente fora do padrão (< 0.61), com valores extremamente baixos, como podem ver na figura 5.4. Além disso, representaram os pares com pontuação mais próximas do limiar de aceitação automática de 0.994 5.5. Demonstrando que os casos em que o método falha são outliers claros em **MS-SSIM** e permanecem

justamente na zona cinzenta e propensa a erros da determinação empírica do limiar de aceitação automática. Além disso, os pares reprovados possuem características visuais bastante particulares com fundo dominando a imagem e poucas estruturas anatômicas visíveis, o que torna a avaliação de similaridade estrutural mais desafiadora devido a grande homogeneidade das características visuais.




Fig.5.4 3 pares reprovados após inspeção visual humana com valores de [MS-SSIM](#) (head_1159: 0.4573, head_369: 0.5652 e head_763: 0.6009, respetivamente). As pontuações desses pares na similaridade de cosseno foram head_1159: 0.9960, head_369: 0.9952 e head_763: 0.9951.




Fig.5.5 Distribuição dos valores de similaridade de cosseno para os pares inspecionados visualmente.

Os pares com **MS-SSIM** mais críticos logo acima dos reprovados tinham valores maiores que 0.75 5.3, demonstrando uma distancia clara entre os falsos positivos e os aprovados visualmente. Todos os pares inspecionados com pontuação acima desse valor de **MS-SSIM** passaram no teste de inspeção visual 5.6. Como os pares que não passaram por esse escrutínio tinham pontuação acima de 0.90 em **MS-SSIM**, é seguro assumir que os pares automaticamente aprovados com pontuação acima desse limiar são confiáveis.




Fig.5.6 Distribuição dos valores de MS-SSIM para os pares inspecionados visualmente.

Na busca direta, 530 pares não obtiveram correspondência aprovada em nenhum dos dois datasets de origem. A etapa complementar de correspondência indireta recuperou 95 desses casos após inspeção visual, restando 435 pares sem correspondência segura.

Com relação aos possíveis falsos negativos que poderiam ter resultado em exclusão de pares de forma injusta nesse estudo, a metodologia adotada foi ainda mais robusta. Já que eram poucos os pares que não tiveram aprovação em nenhum dos dois datasets de origem, ficou fácil verificar visualmente cada um desses casos para confirmar se realmente não havia correspondência ou se o método falhou em identificá-la. Dos 435 pares excluídos 245 foram excluídos devido ao critério automatizado baseado no limiar de 0.98. Nenhum desses casos eram realmente falsos negativos, confirmando mais uma vez a eficácia do método de correspondência automática adotado. Os outros 190 pares caíram na faixa de pontuação pouco confiável (0.98 – 0.994) e foram marcados como falsa correspondência nessa etapa evidenciando a importância de ter-se determinado uma zona cinzenta de pontuação para a qual o método de correspondência automática não é eficiente, e que a revisão visual humana torna-se indispensável 5.7.




Fig.5.7 Distribuição dos *scores* de similaridade de cosseno (DL vs Stroke EIT) para os pares sem correspondência aprovada em nenhum dos dois *datasets* de origem (N=435). À esquerda: histograma das pontuações por *dataset*; à direita: ECDF correspondente com o limiar de 0,98 assinalado.



5.2 Treino dos modelos


5.2.1 Convergência e seleção dos checkpoints

[A preencher: curvas de treino/validação e checkpoints selecionados pelo monitor pré-especificado.]

5.2.2 Rastreabilidade das execuções

[A preencher: snapshots de reprodutibilidade, versões do ambiente e hashes dos checkpoints.]

Fig.5.8 Curva de treino gerada pelo workflow: `training_curves_dualhead.png`.Fig.5.9 Curva de treino gerada pelo workflow: `lr_schedule.png`.

Fig.5.10 Curva de treino gerada pelo workflow: `training_curves_singlehead.png`.




Fig.5.11 Curva de treino gerada pelo workflow: training_curves_dualhead.png.




Fig.5.12 Curva de treino gerada pelo workflow: lr_schedule.png.




Fig.5.13 Curva de treino gerada pelo workflow: training_curves_singlehead.png.

5.3 Avaliação interna no conjunto de teste

5.3.1 Desfechos globais

[A preencher: PSNR, MS-SSIM, SSIM, MAE e intervalos de confiança por paciente.]

Tabela 5.1 Resultados quantitativos no conjunto de test.

Modelo	Δ PSNR (dB)	Δ SSIM	Pacientes
singlehead-031-0.9510-ssim_hu_20260808_143625	7.70	0.1078	41
dualhead-041-0.9494-img_out_ssim_hu_20260807_150303	7.68	0.1063	41
singlehead-033-0.9511-ssim_hu_20260808_113413	7.82	0.1081	41
dualhead-023-0.9503-img_out_ssim_hu_20260808_114026	7.77	0.1071	41
singlehead-044-0.9511-ssim_hu_20260807_171329	7.74	0.1080	41
dualhead-028-0.9490-img_out_ssim_hu_20260805_163859	7.56	0.1060	41




Fig.5.14 Resultado de avaliação interna: bland_altman.png.

5.3.2 Análise por região de interesse e preservação anatômica

[A preencher: regiões de artefacto e distantes, mapas residuais e inspeção qualitativa.]




Fig.5.15 Resultado de avaliação interna: scatter_mean_hu_per_slice.png.




Fig.5.16 Resultado de avaliação interna: scatter_pixel_hu.png.




Fig.5.17 Resultado de avaliação interna: bland_altman.png.




Fig.5.18 Resultado de avaliação interna: scatter_mean_hu_per_slice.png.




Fig.5.19 Resultado de avaliação interna: scatter_pixel_hu.png.




Fig.5.20 Resultado de avaliação interna: pair_712_body_11945.png.




Fig.5.21 Resultado de avaliacao interna: pair_713_body_11946.png.




Fig.5.22 Resultado de avaliacao interna: pair_714_body_11947.png.




Fig.5.23 Resultado de avaliacao interna: pair_715_body_11948.png.




Fig.5.24 Resultado de avaliacao interna: pair_716_body_11949.png.




Fig.5.25 Resultado de avaliacao interna: pair_717_body_11950.png.




Fig.5.26 Resultado de avaliacao interna: stability_seed_comparison.png.




Fig.5.27 Distribuicao de metricas e analise de correlacao: boxplots_preservation_analysis.png.




Fig.5.28 Distribuicao de metricas e analise de correlacao: correlation_preservation_vs_improvement.png.




Fig.5.29 Distribuicao de metricas e analise de correlacao: hist_delta_improvement.png.




Fig.5.30 Distribuicao de metricas e analise de correlacao: roi_comparison_boxplots.png.




Fig.5.31 Distribuicao de metricas e analise de correlacao: roi_safety_scatter.png.




Fig.5.32 Distribuicao de metricas e analise de correlacao: scatter_baseline_vs_model.png.

5.4 Comparação pareada single-head versus dual-head

[A preencher: diferença dual menos single, Wilcoxon bilateral, IC 95% bootstrap e p-valores ajustados por Holm.]

Tabela 5.2 Comparacao pareada dual-head menos single-head, agregada por paciente.

Metrica	Diferenca media	IC 95%	p Holm
model_psnr	-0.0245	[-0.0670, 0.0161]	0.2739
model_ssim	-0.0014	[-0.0017, -0.0012]	0.0000




Fig.5.33 Comparacao entre modelos: comparison_bar_charts.png.




Fig.5.34 Comparacao entre modelos: comparison_scatter_tradeoff.png.




Fig.5.35 Comparacao entre modelos: comparison_bar_charts.png.




Fig.5.36 Comparacao entre modelos: comparison_scatter_tradeoff.png.




Fig.5.37 Comparacao entre modelos: comparison_bar_charts.png.




Fig.5.38 Comparacao entre modelos: comparison_scatter_tradeoff.png.

5.5 Desempenho computacional

[A preencher: benchmark de inferência, se reportado.]




Fig.5.39 Benchmark de inferencia: benchmark_latency.png.




Fig.5.40 Benchmark de inferencia: benchmark_latency.png.




Fig.5.41 Benchmark de inferencia: benchmark_latency.png.




Fig.5.42 Benchmark de inferencia: benchmark_latency.png.




Fig.5.43 Benchmark de inferencia: benchmark_latency.png.




Fig.5.44 Benchmark de inferencia: benchmark_latency.png.

5.6 Avaliação externa por médicos

5.6.1 Estado da recolha e participantes

[A preencher: estado de pré-produção, piloto ou recolha concluída; número de leitores analisados e características categóricas, apenas quando existirem dados reais.]

5.6.2 Desfecho primário: visualização anatómica

[A preencher: comparação pareada entre entrada e saída para visualização de tecidos e limites anatómicos.]

5.6.3 Desfechos secundários e segurança percebida

[A preencher: interferência do artefacto, preferência A/B, possível dano, utilidade complementar e consistência intraleitor.]

5.6.4 Interpretação limitada ao desenho observacional

[A preencher: reportar intervalos de confiança e limitações; não inferir benefício clínico para além das avaliações realizadas.]

Capítulo 6

Discussão

6.1 Síntese dos achados principais

[A preencher: resposta direta aos objetivos e hipótese primária.]

6.2 Interpretação da comparação arquitetural

[A preencher: significado prático e estatístico da comparação single-head versus dual-head.]

6.3 Preservação anatômica e segurança da reconstrução

[A preencher: leitura conjunta de métricas globais, regiões de interesse e inspeção qualitativa.]

6.4 Generalização e avaliação externa

[A preencher: interpretar apenas as evidências externas disponíveis e delimitar o que permanece por validar.]

6.5 Avaliação por médicos

[A preencher: interpretar a avaliação multileitor cega em conjunto com os resultados técnicos; distinguir melhoria percebida, segurança percebida e eficácia clínica.]

6.6 Limitações

[A preencher: dados simulados/pareados, desequilíbrio anatômico, dimensão ao nível do paciente, desenho observacional e limites da avaliação externa.]

6.7 Implicações e trabalho futuro

[A preencher: validação prospetiva, dados clínicos adicionais e evolução do protocolo de observadores.]

Capítulo 7

Conclusões

7.1 Conclusões do estudo

[A preencher: conclusão proporcional às evidências finais e aos resultados confirmatórios.]

7.2 Contribuições da dissertação

- *[A preencher: curadoria rastreável e partição por paciente.]*
- *[A preencher: comparação controlada entre duas arquiteturas U-Net.]*
- *[A preencher: avaliação por paciente e produção reprodutível de resultados.]*
- *[A preencher: protocolo de avaliação externa por médicos e respetivo estado de execução.]*

7.3 Perspetivas futuras

[A preencher: validação externa concluída, extensão multicêntrica e avaliação clínica prospectiva.]

Bibliografia

- [1] November 8, 1895: Roentgen's Discovery of X-Rays. <https://www.aps.org/apsnews/2001/11/1895-roentgens-discovery-xrays>. [Cited on page 1.]
- [2] Emico Okuno and Elisabeth Yoshimura. *Física das Radiações*. Oficina de Textos, 2010. [Cited on page 1.]
- [3] JOEL D. HOWELL. EARLY CLINICAL USE OF THE X-RAY. *Transactions of the American Clinical and Climatological Association*, 127:341–349, 2016. [Cited on page 2.]
- [4] Allen Taylor. Illuminating Health: The Evolution and Significance of X-ray Imaging. *Imaging in Medicine*, 15(6):133–134, December 2023. [Cited on page 2.]
- [5] Reza Vali. Unveiling the Marvels of Computed Tomography (CT) Imaging. *Imaging in Medicine*, 16(1):150–151, February 2024. [Cited on page 2.]
- [6] Mohd Noor. An Overview of Computed Tomography: What it is and How it Works? Applications of Computed Tomography. *Imaging in Medicine*, 15(5):93–94, October 2023. [Cited on page 2.]
- [7] Raymond A. Schulz, Jay A. Stein, and Norbert J. Pelc. How CT happened: The early development of medical computed tomography. *Journal of Medical Imaging*, 8(5):052110, September 2021. [Cited on page 2.]
- [8] F. Edward Boas and Dominik Fleischmann. CT artifacts: Causes and reduction techniques. *Imaging in Medicine*, 4(2):229–240, April 2012. [Cited on page 2.]
- [9] Cecile E.J. Kleber, Ramez Karius, Lucas E. Naessens, Coen O. Van Toledo, Jochen A. C. Van Osch, Martijn F. Boomsma, Jan W.T. Heemskerk, and Aart J. Van Der Molen. Advancements in supervised deep learning for metal artifact reduction in computed tomography:

- A systematic review. *European Journal of Radiology*, 181:111732, December 2024. [Cited on pages 2, 7, 8, and 15.]
- [10] Sathyathas Puvanasunthararajah, Davide Fontanarosa, Marie-Luise Wille, and Saskia M. Camps. The application of metal artifact reduction methods on computed tomography scans for radiotherapy applications: A literature review. *Journal of Applied Clinical Medical Physics*, 22(6):198–223, May 2021. [Cited on page 3.]
- [11] Asutosh Sahu, Shobhit Mathur, Hiroyuki Takaoka, Joji Ota, Felix G. Meinel, Benjamin Böttcher, Benoît Magnin, Ankush Jajodia, and Corey T. Jensen. Transforming CT imaging with deep learning: Noise reduction, artifact management, and clinical applications – A comprehensive review. *European Journal of Radiology Artificial Intelligence*, 4:100042, December 2025. [Cited on pages 3, 7, and 8.]
- [12] Mohanad Alkhodari, Eman Alefishat, Herbert F. Jelinek, Ahmed Kaabneh, and Panos Liatsis. Enhancing CCTA image quality: A review of deep learning approaches for advanced artifact correction and denoising. *Artificial Intelligence Review*, 58(10):331, August 2025. [Cited on page 3.]
- [13] Julia F. Barrett and Nicholas Keat. Artifacts in CT: Recognition and Avoidance. *RadioGraphics*, 24(6):1679–1691, November 2004. [Cited on page 7.]
- [14] Mark Selles, Jochen A.C. Van Osch, Mario Maas, Martijn F. Boomsma, and Ruud H.H. Wellenberg. Advances in metal artifact reduction in CT images: A review of traditional and novel metal artifact reduction techniques. *European Journal of Radiology*, 170:111276, January 2024. [Cited on page 7.]
- [15] Lars Gjestebj, Qingsong Yang, Yan Xi, Bernhard E. H. Claus, Yannan Jin, Bruno De Man, Ge Wang, and Hongming Shan. Deep learning methods for CT image-domain metal artifact reduction. In Bert Müller and Ge Wang, editors, *Developments in X-Ray Tomography XI*, page 31, San Diego, United States, September 2017. SPIE. [Cited on page 8.]
- [16] Yanbo Zhang and Hengyong Yu. Convolutional Neural Network Based Metal Artifact Reduction in X-Ray Computed Tomography. *IEEE Transactions on Medical Imaging*, 37(6):1370–1381, June 2018. [Cited on page 8.]
- [17] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-Net: Convolutional Networks for Biomedical Image Segmentation, May 2015. [Cited on pages 8 and 20.]

- [18] Esther Meyer, Frank Bergner, Rainer Raupach, Thomas Flohr, and Marc Kachelriess. Normalized metal artifact reduction (NMAR) in computed tomography. In *2009 IEEE Nuclear Science Symposium Conference Record (NSS/MIC)*, pages 3251–3255, Orlando, FL, October 2009. IEEE. [Cited on page 8.]
- [19] Wei-An Lin, Haofu Liao, Cheng Peng, Xiaohang Sun, Jingdan Zhang, Jiebo Luo, Rama Chellappa, and Shaohua Kevin Zhou. DuDoNet: Dual Domain Network for CT Metal Artifact Reduction. In *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 10504–10513, Long Beach, CA, USA, June 2019. IEEE. [Cited on pages 8 and 15.]
- [20] Lequan Yu, Zhicheng Zhang, Xiaomeng Li, Hongyi Ren, Wei Zhao, and Lei Xing. Metal Artifact Reduction in 2D CT Images with Self-supervised Cross-domain Learning. *Physics in Medicine & Biology*, 66(17):175003, September 2021. [Cited on page 9.]
- [21] Zhiwei Huang, Guo Zhang, Jinzhao Lin, Yu Pang, Huiqian Wang, Tong Bai, and Lisha Zhong. Multi-modal feature-fusion for CT metal artifact reduction using edge-enhanced generative adversarial networks. *Computer Methods and Programs in Biomedicine*, 217:106700, April 2022. [Cited on page 9.]
- [22] Xin Yi, Ekta Walia, and Paul Babyn. Generative Adversarial Network in Medical Imaging: A Review. *Medical Image Analysis*, 58:101552, December 2019. [Cited on page 9.]
- [23] Zhou Wang, A.C. Bovik, H.R. Sheikh, and E.P. Simoncelli. Image quality assessment: From error visibility to structural similarity. *IEEE Transactions on Image Processing*, 13(4):600–612, April 2004. [Cited on pages 9, 13, and 15.]
- [24] Z. Wang, E.P. Simoncelli, and A.C. Bovik. Multiscale structural similarity for image quality assessment. In *The Thrity-Seventh Asilomar Conference on Signals, Systems & Computers, 2003*, pages 1398–1402, Pacific Grove, CA, USA, 2003. IEEE. [Cited on pages 9 and 25.]
- [25] Alain Hore and Djemel Ziou. Image Quality Metrics: PSNR vs. SSIM. In *2010 20th International Conference on Pattern Recognition*, pages 2366–2369, Istanbul, Turkey, August 2010. IEEE. [Cited on page 9.]

- [26] John R. Zech, Marcus A. Badgeley, Manway Liu, Anthony B. Costa, Joseph J. Titano, and Eric Karl Oermann. Variable generalization performance of a deep learning model to detect pneumonia in chest radiographs: A cross-sectional study. *PLOS Medicine*, 15(11):e1002683, November 2018. [Cited on page 9.]
- [27] Martin J. Willemink, Wojciech A. Koszek, Cailin Hardell, Jie Wu, Dominik Fleischmann, Hugh Harvey, Les R. Folio, Ronald M. Summers, Daniel L. Rubin, and Matthew P. Lungren. Preparing Medical Imaging Data for Machine Learning. *Radiology*, 295(1):4–15, April 2020. [Cited on page 10.]
- [28] Christopher J. Kelly, Alan Karthikesalingam, Mustafa Suleyman, Greg Corrado, and Dominic King. Key challenges for delivering clinical impact with artificial intelligence. *BMC Medicine*, 17(1):195, December 2019. [Cited on page 10.]
- [29] Eri Haneda, Nils Peters, Jiayong Zhang, Grigorios Karageorgos, Wenjun Xia, Harald Paganetti, Ge Wang, Yi Guo, Jianhua Ma, Hyoung Suk Park, Kiwan Jeon, Fuxin Fan, Mareike Thies, and Bruno De Man. AAPM CT metal artifact reduction grand challenge. *Medical Physics*, 52(10):e70050, October 2025. [Cited on page 11.]
- [30] xcist. AAPM CT Metal Artifact Reduction (CT-MAR) Grand Challenge Benchmark Tool. https://github.com/xcist/example/tree/main/AAPM_datachallenge/. [Cited on page 11.]
- [31] Nils Peters, Eri Haneda, Jiayong Zhang, Grigorios Karageorgos, Wenjun Xia, Joost Verburg, Ge Wang, Harald Paganetti, and Bruno De Man. A hybrid training database and evaluation benchmark for assessing metal artifact reduction methods for X-ray CT imaging. *Medical Physics*, 52(10):e70020, October 2025. [Cited on page 11.]
- [32] Mingye Wu, Paul FitzGerald, Jiayong Zhang, W. Paul Segars, Hengyong Yu, Yongshun Xu, and Bruno De Man. XCIST – An Open Access X-ray/CT Simulation Toolkit. *Physics in medicine and biology*, 67(19):10.1088/1361–6560/ac9174, September 2022. [Cited on page 11.]
- [33] Nir Goren, James Avery, Thomas Dowrick, Eleanor Mackle, Anna Witkowska-Wrobel, David Werring, and David Holder. Multi-frequency electrical impedance tomography and neuroimaging data in stroke patients. *Scientific Data*, 5:180112, July 2018. [Cited on pages 11 and 13.]
- [34] Nir Goren, Thomas Dowrick, James Avery, and David Holder. UCLH Stroke EIT Dataset - Radiology Data, August 2017. [Cited on page 11.]

- [35] Ke Yan, Xiaosong Wang, Le Lu, and Ronald M. Summers. DeepLesion: Automated mining of large-scale lesion annotations and universal lesion detection with deep learning. *Journal of Medical Imaging*, 5(3):036501, July 2018. [Cited on pages 11 and 13.]
- [36] Mustafa Umit Oner, Yi-Chih Cheng, Hwee Kuan Lee, and Wing-Kin Sung. Training machine learning models on patient level data segregation is crucial in practical clinical applications, April 2020. [Cited on page 12.]
- [37] Jiang Hsieh. *Computed Tomography: Principles, Design, Artifacts, and Recent Advances*. Wiley Interscience ; SPIE Press, Hoboken, N.J. : Bellingham, Wash, 2nd ed edition, 2009. [Cited on page 13.]
- [38] Saeid Asgari Taghanaki, Yefeng Zheng, S. Kevin Zhou, Bogdan Georgescu, Puneet Sharma, Daguang Xu, Dorin Comaniciu, and Ghassan Hamarneh. Combo Loss: Handling Input and Output Imbalance in Multi-Organ Segmentation, September 2021. [Cited on pages 19 and 24.]
- [39] Uğur Kesimal, Habip Eser Akkaya, Önder Polat, and Murat Sağlam. Use of Deep Learning Models in the Diagnosis of Proptosis Through Orbital Magnetic Resonance Imaging. *Medical Science Monitor*, 32, April 2026. [Cited on page 19.]
- [40] Yang Li, Bobo Yan, Jianxin Hou, Bingyang Bai, Xiaoyu Huang, Canfei Xu, and Limei Fang. UNet based on dynamic convolution decomposition and triplet attention. *Scientific Reports*, 14(1):271, January 2024. [Cited on page 20.]
- [41] Rich Caruana. Multitask Learning. [Cited on page 21.]
- [42] Sebastian Ruder. An Overview of Multi-Task Learning in Deep Neural Networks, June 2017. [Cited on page 21.]
- [43] Hang Zhao, Orazio Gallo, Iuri Frosio, and Jan Kautz. Loss Functions for Image Restoration With Neural Networks. *IEEE Transactions on Computational Imaging*, 3(1):47–57, March 2017. [Cited on pages 23 and 24.]
- [44] Lin Zhang, Lei Zhang, Xuanqin Mou, and D. Zhang. FSIM: A Feature Similarity Index for Image Quality Assessment. *IEEE Transactions on Image Processing*, 20(8):2378–2386, August 2011. [Cited on page 25.]

Apêndice A

Appendix Title Here

Write your Appendix content here.