

U-NET for Metal Artifact Reduction in Computed Tomography



Ludmila Montorsi Queiroz

Mestrado em Física Médica

Departamento de Física e Astronomia

Faculdade de Ciências da Universidade do Porto

2026



UNIVERSIDADE DO PORTO

MASTERS THESIS

U-NET for Metal Artifact Reduction in Computed Tomography

Author:

Ludmila MONTORSI QUEIROZ

Supervisor:

Hélder Filipe PINTO DE OLIVEIRA

Co-supervisor:

Eduardo MATOS RODRIGUES

*A thesis submitted in fulfilment of the requirements
for the degree of MSc. Medical Physics*

at the

Faculdade de Ciências da Universidade do Porto
Departamento de Ciência de Computadores
Departamento de Física e Astronomia
INESC TEC

20 de maio de 2026

"The Universe is under no obligation to make sense to you."

Neil deGrasse Tyson, *Astrophysics for People in a Hurry* (2017)

"Nothing in life is to be feared; it is only to be understood."

Marie Curie, *Madame Curie: A Biography* (1937)

Acknowledgements

I would like to express my deepest gratitude to my supervisor, Helder Filipe Pinto de Oliveira, for his invaluable guidance, support, and encouragement throughout this research journey. His expertise and insights have been instrumental in shaping this thesis. I am also grateful to my co-supervisor, Eduardo Matos Rodrigues, for his constructive feedback and encouragement, which have greatly contributed to the development of this work.

UNIVERSIDADE DO PORTO

Abstract

Faculdade de Ciências da Universidade do Porto

Departamento de Ciência de Computadores

Departamento de Física e Astronomia

INESC TEC

MSc. Medical Physics

U-NET for Metal Artifact Reduction in Computed Tomography

by [Ludmila MONTORSI QUEIROZ](#)

This thesis addresses deep learning approaches for metal artifact reduction in computed tomography images, presenting a comparative study of the different techniques proposed in the literature and measuring their performance in a rigorous and reproducible manner.

Keywords: Computed Tomography, Metal Artifact Reduction, Medical Physics, Medical Imaging, Deep Learning, Artefact, Medical Diagnostics, Physics

UNIVERSIDADE DO PORTO

Resumo

Faculdade de Ciências da Universidade do Porto

Departamento de Ciência de Computadores

Departamento de Física e Astronomia

INESC TEC

MSc. Medical Physics

U-NET para Redução de Artefatos de Metal em Tomografia Computadorizada

por [Ludmila MONTORSI QUEIROZ](#)

Esta tese aborda abordagens de aprendizado profundo para a redução de artefatos de metal em imagens de tomografia computadorizada, apresentando um estudo comparativo das diferentes técnicas propostas na literatura e avaliando seu desempenho de maneira rigorosa e reprodutível.

Palavras-chave: Tomografia Computadorizada, Redução de Artefatos de Metal, Física Médica, Imagem Médica, Aprendizado Profundo, Artefato, Diagnóstico Médico, Física

Índice

Acknowledgements	ii
Abstract	iii
Resumo	iv
Índice	v
Lista de Figuras	vii
Lista de Gráficos	viii
Lista de Tabelas	ix
Lista de Abreviaturas	x
1 Introdução	1
1.1 Objetivo Geral	3
1.2 Objetivos Específicos	3
2 Trabalhos Relacionados	5
2.1 Métodos Tradicionais de Redução de Artefatos em CT	5
2.2 Deep Learning para Redução de Artefatos em CT	6
2.2.1 Abordagens no Domínio da Imagem	6
2.2.2 Abordagens no Domínio do Sinograma e Dual-Domain	6
2.2.3 Aprendizagem Auto-Supervisionada e GANs	7
2.3 Arquiteturas Avançadas e Mecanismos de Atenção	7
2.4 Avaliação, Generalização e Aplicabilidade Clínica	8
2.5 Síntese Crítica e Motivação do Trabalho	9
3 Materiais e Métodos	10
3.1 Visão Geral da Metodologia	10
3.2 <i>Datasets</i> Utilizados	11
3.2.1 <i>Datasets</i> Principal	11
3.2.2 <i>Dataset</i> para Validação Externa	12
3.3 Pré-processamento dos Dados	12
3.3.1 Verificação de integridade dos dados	12

3.4	Estratégia de Particionamento dos Dados	12
3.4.1	Estratificação por Pacientes	12
3.4.2	Correspondência entre imagens CT-MAR e DeepLesion/UCLH Stroke EIT Data	13
3.4.3	Estratificação Anatômica	17
3.4.4	Remoção do Fundo dos Exames	18
3.4.5	Normalização das Intensidades	19
3.4.6	Máscaras de Artefato	19
3.5	Arquitetura dos Modelos	19
3.5.1	Modelo Baseline	19
3.6	Estudos de ablação	21
3.7	Fluxo de Treino	22
3.7.1	Componentes de Configuração de Treino	22
3.7.2	Estratégia de Treino	23
3.8	Métricas	26
3.9	Protocolos de Validação	26
3.9.1	Validação Interna	26
3.9.2	Validação Externa	26
3.10	Visão Geral do Pipeline	26
3.11	Infraestrutura Computacional	26
4	Resultados	28
4.1	Correspondências CT-MAR x DeepLesion/Stroke EIT Data	28
4.2	Ablação – Fase 1	34
4.2.1	<i>Single-Head vs Dual-Head</i>	34
4.3	Ablação – Fase 2	35
4.3.1	Impacto dos Módulos de Atenção -	35
4.4	Seleção do Modelo para Treino Intermédio	36
4.5	Treino com Duração Intermediária	36
4.6	Treino com Duração Prolongada	36
4.7	Análise de Distribuições e Overfitting – Modelo Final	36
4.8	Análise Estatística Pareada – Modelo Final	37
4.9	Resumo dos Resultados	37
5	Discussion	38
6	Conclusion	39
	Bibliography	39
A	Appendix Title Here	46

Lista de Figuras

3.1	Arquitetura baseada em U-Net utilizada como modelo <i>baseline</i>	20
3.2	Arquitetura baseada em U-Net utilizada como modelo <i>dual-head</i>	21
4.1	Distribuição de MS-SSIM entre pares correspondentes (CT-MAR vs DL/Stroke, aprovados automaticamente). Acima: histograma com os percentis P1 e P5, mediana, média e limiar de 0.9. Abaixo: zoom do histograma para a região de maior interesse, com destaque para os pares com MS-SSIM inferior a 0.9, que foram sujeitos a revisão manual.	29
4.2	Distribuição de MS-SSIM entre pares correspondentes (CT-MAR vs DL/Stroke, aprovados automaticamente). À esquerda: histograma com os percentis P1 e P5, mediana, média e limiar de 0.9. À direita: ECDF correspondente. Os pares com MS-SSIM inferior a 0.9 foram sujeitos a revisão manual.	30
4.3	Exemplos de pares correspondentes com valores de MS-SSIM (0.7597, 0.7694 e 0.7717, respetivamente) aprovados após revisão visual humana mesmo com pontuações baixas.	31
4.4	3 pares reprovados após inspeção visual humana com valores de MS-SSIM (head_1159: 0.4573, head_369: 0.5652 e head_763: 0.6009, respetivamente). As pontuações desses pares na similaridade de cosseno foram head_1159: 0.9960, head_369: 0.9952 e head_763: 0.9951.	32
4.5	Distribuição dos valores de similaridade de cosseno para os pares inspecionados visualmente.	33
4.6	Distribuição dos valores de MS-SSIM para os pares inspecionados visualmente.	34

Lista de Gráficos

Lista de Tabelas

3.1	Resultados do rastreio antes da análise complementar com MS-SSIM.	16
3.2	Resultados do rastreio depois da análise complementar com MS-SSIM.	16
3.3	Dados dos pares sem correspondência que foram excluídos antes e após a análise complementar com MS-SSIM.	17
3.4	Distribuição anatômica por subconjunto ao nível de pacientes.	18
3.5	Distribuição dos pares por subconjunto, categoria anatômica e pacientes.	18
4.1	Métricas quantitativas do modelo baseline em validação e teste.	34
4.2	Resultados do estudo de <i>trade-off</i> entre reconstrução e segmentação para diferentes pesos da máscara.	35

Lista de Abreviaturas

AMP Automatic Mixed Precision.

ASPP Atrous Spatial Pyramid Pooling.

BCE Binary Cross-Entropy.

BN Batch Normalization.

CBAM Convolutional Block Attention Module.

CNN Convolutional Neural Network.

CT Computed Tomography.

CT-MAR CT Metal Artifact Reduction Challenge.

DICE Dice Similarity Coefficient.

DL Deep Learning.

FBP Filtered Back Projection.

FC Fully Connected.

FCUP Faculdade de Ciências da Universidade do Porto.

FLOPs Floating Point Operations.

GAN Generative Adversarial Network.

GAP Global Average Pooling.

GPU Graphics Processing Unit.

HU Unidade Hounsfield.

iMAR Iterative Metal Artifact Reduction.

IR Iterative Reconstruction.

MAE Mean Absolute Error.

MAR Metal Artifact Reduction.

MBIR Model-Based Iterative Reconstruction.

MLP Multi-Layer Perceptron.

MS-SSIM Multi-Scale Structural Similarity Index Measure.

NMAR Normalized Metal Artifact Reduction.

NPY NumPy Array.

O-MAR Orthopedic Metal Artifact Reduction.

PSNR Peak Signal-to-Noise Ratio.

ReLU Rectified Linear Unit.

RMSE Root Mean Square Error.

ROI Region of Interest.

SE Squeeze-and-Excitation.

SE-Net Squeeze-and-Excitation Network.

SEMAR Single Energy Metal Artifact Reduction.

SSIM Structural Similarity Index Measure.

TCIA The Cancer Imaging Archive.

U-Net U-shaped Network.

UP Universidade do Porto.

This thesis is dedicated to my husband, for his love and support.

Capítulo 1

Introdução

Quando Wilhelm Conrad Röntgen, professor de Física da Universidade de Würzburg, na Alemanha, decidiu repetir o experimento feito por Philipp Lenard com um tubo de Crookes modificado para estudar raios catódicos, ninguém podia prever o impacto de suas descobertas na medicina. Não demorou muito para que seus experimentos apresentassem resultados surpreendentes que demonstravam que o comportamento observado não era compatível com raios catódicos, mas sim com uma espécie de raio mais penetrante e que não sofria desvios na presença de um campo magnético. Durante o manuseio das peças usadas nos seus experimentos, percebeu que o contorno dos seus ossos estava sendo estampado na tela fluorescente que utilizava.

Assim, em 22 de dezembro de 1895, convidou sua esposa, Anna Bertha, a fazer uma exposição de 15 minutos a esses raios, obtendo-se o que seria a primeira radiografia do corpo humano. Nesse mesmo ano, Röntgen publicou o artigo "On a new kind of rays"[?], no qual batiza o agente responsável como "raios-X". Já em janeiro de 1896, os jornais anunciavam em primeira página a descoberta como uma forma revolucionária de observar o interior do corpo humano sem a necessidade de incisões cirúrgicas, apontando seu potencial uso no diagnóstico médico [1].

Em fevereiro de 1896, em Massachusetts (EUA), Edwin Brant Frost produziu uma radiografia da fratura de Colles de um paciente para seu irmão, um médico local, marcando o início da incorporação dos raios-X à prática médica [2]. Assim, em menos de um ano após o anúncio da descoberta por Röntgen, os raios-X rapidamente saíram dos laboratórios e passaram a ser utilizados de forma extensiva no diagnóstico e na terapia [2]. Desde então, a técnica passou por sucessivas modernizações e diversificou-se em múltiplas modalidades e dispositivos,

consolidando-se como ferramenta indispensável na saúde moderna [3, 4].

Dessas sucessivas modernizações surgiu, em 1971, o primeiro tomógrafo computadorizado. Essa tecnologia baseia-se no princípio de atenuação dos raios-X, em que a quantidade de radiação absorvida ou dispersa pelo material relaciona-se à sua densidade [5, 6]. A tomografia computadorizada (CT) foi a primeira modalidade de imagem médica a fornecer informações quantitativas sobre a atenuação dos tecidos, algo que não era possível com a radiografia convencional [7]. Além disso, ao permitir a visualização seccional do corpo humano, a tomografia computadorizada eliminou a sobreposição de estruturas anatômicas inerente às imagens bidimensionais, possibilitando a localização precisa e a avaliação da extensão de lesões[7].

Entretanto, esses avanços trouxeram um aumento significativo da complexidade tecnológica. A aquisição de múltiplas projeções, aliada à reconstrução computacional e ao processamento digital da imagem, introduziu novas formas de degradação que eram inexistentes ou pouco relevantes na radiografia convencional. Dessa forma, a tomografia computadorizada tornou-se particularmente suscetível à presença de artefatos, os quais podem comprometer a qualidade diagnóstica e a confiabilidade clínica das imagens [7].

Diversos tipos de artefatos podem ser observados em tomografia computadorizada, incluindo ruído, endurecimento do feixe, movimento, artefatos de anel e artefatos metálicos, os quais podem obscurecer ou simular patologias [8]. As causas desses artefatos são variadas, podendo incluir desde falhas ou descalibração dos detectores, limitações estatísticas associadas a baixas contagens de fótons, até fenômenos físicos como endurecimento e dispersão do feixe, que produzem estrias escuras entre objetos de alta atenuação, como metal, osso ou meios de contraste iodados [7].

Especificamente, artefatos de estrias causados por implantes metálicos são observados em aproximadamente 21% das varreduras tomográficas, sendo considerados extremamente comuns na prática clínica [7]. A elevada atenuação ou mesmo o bloqueio total dos raios-X por esses implantes impede que a radiação alcance adequadamente os detectores, resultando em dados de projeção de baixa qualidade e comprometendo a reconstrução da imagem [9].

O aumento do uso de implantes metálicos, impulsionado pela evolução dos cuidados de saúde, intensificou as preocupações relacionadas ao impacto negativo desses artefatos na qualidade de imagem e na confiabilidade das análises diagnósticas [9]. Tradicionalmente, diversos algoritmos de redução de artefatos de metal (MAR) foram propostos, incluindo técnicas de preenchimento de imagem, preenchimento de sinogramas e métodos de reconstrução

iterativa baseada em modelo (*MBIR*) ou combinações dessas abordagens [10].

Embora métodos analíticos como a *Filtered Back Projection (FBP)* tenham dominado a reconstrução tomográfica por décadas devido à sua eficiência computacional e simplicidade conceitual, suas limitações tornam-se evidentes em condições clínicas não ideais, exigindo doses de radiação mais elevadas para garantir qualidade de imagem [11]. Métodos *MBIR* surgiram como alternativa para superar essas limitações, ao custo de maior demanda computacional e da introdução de texturas artificiais na imagem reconstruída [11].

Mais recentemente, abordagens baseadas em aprendizado profundo têm sido amplamente investigadas para a correção de artefatos em tomografia computadorizada, demonstrando desempenho superior e maior aplicabilidade clínica em comparação com métodos convencionais [12]. Em particular, redes neurais convolucionais (*CNNs*) têm sido propostas para a redução de artefatos metálicos, permitindo a supressão de ruído e a preservação de detalhes anatômicos e de tecidos moles [12].

1.1 Objetivo Geral

O objetivo geral desta dissertação é desenvolver, avaliar e comparar de forma rigorosa um modelo baseado em *Convolutional Neural Networks (CNNs)* para detecção e redução de artefatos em imagens de Tomografia Computorizada, privilegiando a preservação anatômica, a robustez à variação de domínio e a interpretabilidade do processo de correção.

1.2 Objetivos Específicos

Os objetivos específicos deste trabalho incluem:

- Desenvolver um *pipeline* reproduzível para treino e avaliação de modelos de redução de artefatos em *CT* no domínio da imagem, com separação rigorosa entre dados de treino, validação e teste.
- Desenvolver uma arquitetura *baseline* baseada em *U-Net* para correção de artefatos em imagens de *CT*, garantindo reprodutibilidade experimental.
- Avaliar o desempenho de uma arquitetura *U-Net single-head* para reconstrução de imagem na redução de artefatos metálicos e usá-lo como referência comparativa.

- Propor e avaliar uma arquitetura [U-Net dual-head](#) baseada em aprendizado multi-tarefa para reconstrução de imagem e predição de artefatos, incluindo um estudo de ablação comparativo entre as duas abordagens.
- Avaliar o desempenho dos modelos utilizando métricas quantitativas ([PSNR](#), [MS-SSIM](#), [SSIM](#), [BCE](#) e [DICE](#)), análise qualitativa e mapas de erro.
- Investigar a capacidade de generalização do modelo selecionado por meio de validação externa em dados independentes provenientes do [The Cancer Imaging Archive \(TCIA\)](#).

Capítulo 2

Trabalhos Relacionados

A redução de artefatos em [Computed Tomography \(CT\)](#) constitui um problema amplamente estudado, dada a sua relevância clínica e o impacto direto na precisão diagnóstica [9]. Ao longo das últimas décadas, diversas abordagens foram propostas, evoluindo de métodos baseados em modelos físicos e reconstrução clássica para técnicas avançadas fundamentadas em [Deep Learning \(DL\)](#) [9]. Este capítulo apresenta uma revisão crítica dos trabalhos mais relevantes, contextualizando o estado da arte e identificando lacunas que motivam a abordagem proposta nesta dissertação.

2.1 Métodos Tradicionais de Redução de Artefatos em [CT](#)

Os métodos tradicionais de redução de artefatos em [CT](#) baseiam-se predominantemente em princípios físicos e matemáticos associados à formação da imagem. Barrett e Keat[13] descrevem detalhadamente a origem dos principais artefatos em [CT](#), incluindo endurecimento de feixe, *photon starvation*, dispersão e efeitos geométricos, bem como estratégias clássicas para sua mitigação.

Técnicas de reconstrução como a Retroprojeção Filtrada ([FBP](#)) foram amplamente utilizadas devido à sua eficiência computacional, porém apresentam elevada sensibilidade ao ruído e aos artefatos metálicos. Métodos mais avançados, como [Iterative Reconstruction \(IR\)](#) e [Model-Based Iterative Reconstruction \(MBIR\)](#), incorporam modelos estatísticos do sistema de aquisição e do ruído, permitindo redução parcial de artefatos. Contudo, essas abordagens frequentemente introduzem texturas artificiais e apresentam limitações em cenários clínicos complexos [11].

Revisões recentes indicam que algoritmos comerciais de *Metal Artifact Reduction (MAR)*, como *O-MAR*, *iMAR* e *SEMAR*, embora eficazes em situações específicas, dependem de parâmetros proprietários e exibem desempenho inconsistente em casos de implantes densos ou múltiplos [9, 14]. Essas limitações impulsionaram a investigação de abordagens baseadas em aprendizagem profunda.

2.2 Deep Learning para Redução de Artefatos em CT

2.2.1 Abordagens no Domínio da Imagem

As primeiras aplicações de DL para MAR concentraram-se no domínio da imagem, explorando redes convolucionais para mapear imagens degradadas para versões corrigidas. Gjestebj et al. [15] investigaram a redução de artefatos metálicos no domínio da imagem baseada em CNN e demonstraram melhorias quantitativas significativas em comparação com as técnicas convencionais.

Zhang e Yu [16] também propuseram um modelo supervisionado baseado em *Convolutional Neural Network (CNN)* para redução de artefatos metálicos em CT, obtendo ganhos consistentes em *Peak Signal-to-Noise Ratio (PSNR)* e *Root Mean Square Error (RMSE)*. Esses trabalhos ajudaram a consolidar o uso de redes convolucionais para MAR no domínio da imagem. Em particular, Zhang e Yu utilizaram uma CNN rasa totalmente convolucional para fusão de informação de múltiplas imagens pré-corrigidas. Os trabalhos subsequentes adotaram cada vez mais arquiteturas de codificador-decodificador, especialmente as baseadas em *U-Net*, para tarefas de correção/restauração. Redes do tipo *U-Net* e suas variantes são capazes de capturar informações contextuais globais por meio do caminho de contração, e recuperar detalhes espaciais finos por meio do caminho de expansão e *Skip Connections*[17].

Revisões sistemáticas mais recentes consolidam esses avanços, destacando que a maioria dos métodos supervisionados no domínio da imagem apresenta desempenho competitivo, especialmente quando treinados com dados pareados de alta qualidade [9, 11].

2.2.2 Abordagens no Domínio do Sinograma e Dual-Domain

Além do domínio da imagem, alguns estudos exploraram o domínio do sinograma, com métodos de interpolação linear e *Normalized Metal Artifact Reduction (NMAR)*. Essas abordagens operam diretamente nos dados de projeção e atuam diretamente na origem física dos artefatos

metálicos[18]. No entanto, o acesso aos dados de projeção brutos é frequentemente restrito em sistemas de CT comerciais, limitando a aplicabilidade de tais abordagens em ambientes clínicos [15].

Além disso, modelos híbridos têm sido propostos para aproveitar as vantagens de cada abordagem. O método proposto por Zhang e Yu [16] procura mesclar CNN no domínio de imagem e MAR clássico no domínio do sinograma. Na abordagem adotada, o refinamento inicial ocorre no domínio da imagem, mas o método completo utiliza a imagem gerada pela CNN como *prior* para substituição de regiões afetadas no sinograma. Isso caracteriza uma abordagem híbrida, mas ainda não emprega CNN nos dois domínios. Modelos mais recentes, como o DuDoNet[19], integram redes profundas em ambos os domínios, demonstrando desempenho elevado e caracterizando o que chamamos de *Dual Domain*. No entanto, esses métodos apresentam maior complexidade computacional e dependência do acesso ao sinograma bruto, o que motiva a exploração contínua de soluções robustas no domínio da imagem.

2.2.3 Aprendizagem Auto-Supervisionada e GANs

Para contornar a escassez de dados pareados anatomicamente idênticas com artefato de metal/Livre de artefato de metal, surgiram abordagens baseadas em aprendizagem auto-supervisionada. Yu et al. [20] propuseram um método capaz de reduzir artefatos metálicos sem a necessidade de imagens de referência totalmente limpas, ampliando a aplicabilidade clínica dessas técnicas.

Outros trabalhos exploraram o uso de *Generative Adversarial Network (GAN)* para MAR. Huang et al. [21] utilizaram fusão multimodal e GANs para melhorar a preservação de textura e reduzir suavização excessiva. Apesar dos bons resultados visuais, métodos baseados em GAN podem introduzir instabilidade no treino e maior risco de alucinação estrutural[22], o que levanta preocupações clínicas.

2.3 Arquiteturas Avançadas e Mecanismos de Atenção

O uso de mecanismos de atenção tem ganhado destaque em tarefas de processamento de imagem médica. Redes com módulos de atenção por canal, como o *Squeeze-and-Excitation (SE)* [23], e atenção espacial e por canal combinadas, como o *Convolutional Block Attention Module (CBAM)* [24], demonstraram melhoria na capacidade de focar regiões relevantes.

Adicionalmente, técnicas de captura de contexto multi-escala, como o *Atrous Spatial Pyramid Pooling (ASPP)* [25], permitem ampliar o campo recetivo efetivo sem aumento substancial de parâmetros. Embora esses módulos tenham sido amplamente explorados em tarefas de segmentação e visão computacional geral, sua aplicação e avaliação sistemática no contexto específico de MAR em CT ainda permanecem relativamente limitadas na literatura recente.

2.4 Avaliação, Generalização e Aplicabilidade Clínica

A avaliação de modelos de DL para CT é tipicamente realizada por meio de métricas quantitativas como PSNR, RMSE e índices baseados em similaridade estrutural. Métricas tradicionais baseadas em erro, como RMSE e PSNR, quantificam discrepâncias pixel a pixel, mas não capturam adequadamente informações estruturais relevantes para a percepção visual e interpretação clínica. Nesse contexto, Wang et al. [26] introduziram o *Structural Similarity Index Measure (SSIM)* como uma métrica perceptual que modela explicitamente luminância, contraste e estrutura. Posteriormente, o *Multi-Scale Structural Similarity Index Measure (MS-SSIM)* foi proposto para incorporar variações estruturais dependentes de escala, estendendo o SSIM para múltiplos níveis de resolução [27]. Horé e Ziou [28] demonstraram que tanto PSNR quanto SSIM apresentam limitações dependendo do tipo de distorção considerada, sugerindo que a escolha da métrica pode depender do contexto de aplicação. Dado que os artefatos metálicos se manifestam principalmente como distorções estruturais que afetam limites anatômicos e padrões de estrias de longo alcance, métricas sensíveis à preservação estrutural, como SSIM e MS-SSIM, mostram-se particularmente adequadas para avaliar o desempenho de métodos de MAR, pois consideram explicitamente componentes estruturais em diferentes escalas espaciais [26, 27].

Além disso, um desafio crítico identificado na literatura é a generalização dos modelos. Zech et al. [29] demonstraram que modelos com elevado desempenho em bases internas podem falhar significativamente quando aplicados a dados externos, evidenciando o impacto do *domain shift*. Revisões recentes reforçam a necessidade de validação externa e avaliação clínica rigorosa para garantir segurança, robustez e aplicabilidade real [30, 31].

2.5 Síntese Crítica e Motivação do Trabalho

A literatura revisada demonstra avanços significativos na redução de artefatos em CT por meio de DL, mas também evidencia lacunas persistentes: falta de padronização experimental, validação externa limitada, risco de alucinação anatômica e exploração restrita de supervisão dual e mecanismos de atenção em conjunto.

Diante desse cenário, este trabalho propõe uma abordagem supervisionada no domínio da imagem, combinando arquitetura U-Net dual-head e módulos avançados de atenção e contexto multi-escala. A estratégia experimental adotada prioriza comparação arquitetural rigorosa por meio de treinos curtos e estudos de ablação, estabelecendo bases sólidas para seleção objetiva do modelo antes de fases de treino mais prolongadas.

Capítulo 3

Materiais e Métodos

Nesse capítulo será descrito os materiais, dados, arquiteturas e procedimentos experimentais adotados neste trabalho para a detecção e redução de artefatos em imagens de [Computed Tomography \(CT\)](#). A metodologia foi concebida para garantir reprodutibilidade, rigor experimental e avaliação justa buscando utilizar as melhores práticas recomendadas na literatura de aprendizado profundo para imagem médica.

3.1 Visão Geral da Metodologia

A metodologia proposta baseia-se numa abordagem supervisionada no domínio da imagem e organiza-se nas seguintes etapas:

1. desenvolvimento de um modelo [U-Net](#) para redução de artefatos metálicos, servindo como referência comparativa;
2. avaliação objetiva do impacto de uma supervisão adicional com máscara de artefatos através de uma configuração *dual-head*;
3. análise do desempenho das duas arquiteturas utilizando métricas objetivas de qualidade de imagem, como [SSIM](#), [PSNR](#) e [MAE](#) a nível global e também especificamente nas regiões afetadas por artefatos e distante deles separadamente.
4. análise estatística dos resultados para determinar a significância das diferenças observadas entre as arquiteturas, utilizando testes estatísticos apropriados, como o teste t pareado ou o teste de Wilcoxon, dependendo da distribuição dos dados.

5. avaliar a generalização dos modelos em um conjunto de dados externo, representando um cenário realista de *domain shift*, para verificar a robustez das arquiteturas em condições de aquisição e anatomia diferentes.

3.2 Datasets Utilizados

3.2.1 Datasets Principal

O *dataset* principal utilizado neste trabalho provém do [CT Metal Artifact Reduction Challenge \(CT-MAR\)](#) [32, 33] promovido pela *American Association of Physicists in Medicine* e consiste em 14.000 pares de treino contendo imagens de CT com artefatos metálicos simulados e suas versões originais sem artefatos. Os dados foram gerados através de um *framework* de simulação híbrida [34], que incorpora imagens clínicas publicamente disponíveis e objetos metálicos simulados com o simulador CatSim, integrado na *toolkit* de código aberto XCIST [35]. O conjunto é distribuído em duas categorias anatômicas:

- **Head:** 1.626 (11.61%) amostras derivadas da base *UCLH Stroke EIT Data* [36, 37];
- **Body:** 12.374 (88.38%) amostras derivadas da base *NIH DeepLesion Data* [38].

Onde as pastas da categoria *body* apresentavam CTs de tronco, abrangendo fatias axiais, torácica e abdominal. Os dados estão organizados em subpastas, cada uma contendo até 1.000 amostras. Foram utilizados apenas os seguintes ficheiros para treino e validação:

1. **Imagens sem metal (referência):** Ficheiros contidos na pasta *Target* de dimensão 512×512×1 pixels;
2. **Imagens com artefatos metálicos (corrompidas):** Ficheiros contidos na pasta *Baseline* de dimensão 512×512×1 pixels;

Todos os ficheiros de imagem (.raw) do *dataset* são apresentados em formato binário sem cabeçalho, com precisão *float32* em ordem *little endian*. As imagens já vieram convertidas de coeficientes de atenuação linear (em unidades mm^{-1}) para [Unidade Hounsfield \(HU\)](#), utilizando o valor de normalização de 0.02 mm^{-1} para água. Não havia no conjunto de dados informações adicionais sobre a que exame cada *slice* pertencia, se eram de um mesmo paciente, ou quais regiões anatômicas específicas estavam representadas. A única informação disponível era a organização por pasta, que indicava a categoria anatômica (Head ou Body). A falta

de metadados detalhados impôs a necessidade de uma abordagem de pré-processamento cuidadosa para garantir que os dados fossem adequadamente organizados e utilizados durante o treino e validação dos modelos. Dessa forma, um esforço significativo foi dedicado ao rastreio das imagens aos conjuntos de dados originais (UCLH Stroke EIT Data e NIH DeepLesion Data) para obter informações adicionais sobre os exames e pacientes, permitindo um particionamento adequado dos dados.

3.2.2 *Dataset* para Validação Externa

Para avaliação da capacidade de generalização em dados reais independentes, foi reservado um conjunto de dados externo proveniente do *The Cancer Imaging Archive (TCIA)*. Este conjunto apresenta variações em anatomia, protocolos de aquisição e características de ruído, representando um cenário realista de *domain shift*, conforme discutido na literatura.

3.3 Pré-processamento dos Dados

3.3.1 Verificação de integridade dos dados

Todos os pares foram validados através de um relatório de integridade, que verifica a existência de ambos os lados do par (imagem com artefacto e imagem limpa). Não houve nenhum par com dados faltantes, garantindo que o conjunto de dados estava completo e pronto para as etapas subsequentes de pré-processamento e treino dos modelos.

3.4 Estratégia de Particionamento dos Dados

3.4.1 Estratificação por Pacientes

O particionamento dos dados foi estratificado por pacientes, garantindo que os *slices* de um mesmo paciente não fossem distribuídos entre os conjuntos de treino, validação e teste. Esta abordagem evita vazamento de informações e assegura uma avaliação mais realista da capacidade de generalização dos modelos.

3.4.2 Correspondência entre imagens CT-MAR e DeepLesion/UCLH Stroke EIT Data

Dado que os dados do CT-MAR *dataset* não continham metadados clínicos detalhados, foi necessário realizar um rastreamento algorítmico dos *slices* até aos conjuntos de dados originais (UCLH Stroke EIT e NIH DeepLesion Data) para tornar possível a associação dos metadados fornecidos aos *slices* do CT-MAR. Este processo permitiu identificar a qual exame e paciente do DeepLesion/UCLH Stroke EIT cada imagem CT-MAR pertencia. Essas informações foram posteriormente utilizadas para realizar o particionamento dos dados em treino, validação e teste ao nível do paciente, reduzindo o risco de *data leakage* entre conjuntos experimentais.

A correta separação dos dados é particularmente importante em estudos de imagem médica baseados em *deep learning*, uma vez que *slices* pertencentes ao mesmo exame frequentemente apresentam elevada similaridade anatómica. Dessa forma, a presença simultânea de imagens do mesmo paciente em treino e teste pode inflacionar artificialmente o desempenho do modelo e comprometer a avaliação da sua capacidade de generalização [39].

As imagens do dataset DeepLesion [38] encontram-se armazenadas em formato PNG de 16 bits, enquanto as imagens do CT-MAR são disponibilizadas em formato `.raw` diretamente em unidades de Hounsfield (HU). Já o UCLH Stroke EIT [36] disponibiliza os exames em formato DICOM. Assim, independentemente do formato original, todas as imagens foram convertidas para HU antes da comparação, garantindo uniformidade entre os diferentes conjuntos de dados.

Após a conversão, todas as imagens foram representadas numa mesma escala de intensidade para permitir comparação direta.

O algoritmo utilizado baseia-se no facto de que imagens CT preservam informação quantitativa em unidades de Hounsfield (HU), refletindo diretamente as propriedades de atenuação dos diferentes tecidos. Como as estruturas anatómicas apresentam elevada continuidade espacial entre *slices* consecutivos de uma mesma aquisição, imagens correspondentes à mesma fatia anatómica tendem a apresentar distribuições semelhantes de HU e padrões estruturais globais altamente consistentes [26, 40].

Dessa forma, o método não procura verificar igualdade absoluta pixel-a-pixel entre imagens, mas sim determinar se a organização estrutural global da anatomia permanece extremamente semelhante entre diferentes representações da mesma fatia. Esse comportamento é particularmente importante porque pequenas variações locais de intensidade, discretização

numérica e transformações lineares associadas à conversão entre formatos de armazenamento tendem a preservar a estrutura anatômica global da imagem mesmo quando ocorrem pequenas variações locais de intensidade [26, 40].

Assim, a metodologia adotada procura identificar correspondências entre imagens com base na similaridade estrutural global, permitindo uma margem de variação local que não comprometa a identificação correta do exame e paciente de origem. Inicialmente, cada imagem foi reduzida para uma representação compacta através de *downsampling*, preservando principalmente a informação anatômica global relevante. Essa etapa reduz significativamente o custo computacional sem comprometer a estrutura geral da imagem.

Em seguida, foi calculado um vetor representativo (*fingerprint*) para cada imagem. Os *fingerprints* das imagens CT-MAR foram então comparados com os *fingerprints* das imagens DeepLesion e UCLH Stroke EIT através de uma métrica de similaridade vetorial baseada em produto escalar normalizado (similaridade de cosseno), escolhida por ser invariante a diferenças de escala global entre os vetores — propriedade relevante dado que as imagens provêm de formatos distintos com diferentes normalizações de intensidade. Para cada imagem CT-MAR, foi selecionada a imagem com maior score de similaridade.

Como a maior parte das imagens do CT-MAR teve origem no DeepLesion, o processo de rastreio foi inicialmente priorizado nesse dataset. Posteriormente, a mesma metodologia foi aplicada aos exames DICOM do UCLH Stroke EIT para identificação das imagens restantes. Dessa forma, foi possível implementar uma estratégia unificada de rastreabilidade independentemente do formato de armazenamento dos datasets de origem.

As correspondências foram consideradas válidas apenas quando o score de similaridade excedia um limiar previamente definido empiricamente. Casos com scores muito elevados foram automaticamente marcados como correspondências seguras, pois observou-se que todos os pares analisados visualmente com pontuação superior a 0.993 correspondiam efetivamente à mesma imagem. Para manter uma margem adicional de segurança, a correspondência foi considerada automaticamente válida apenas quando a pontuação excedia 0.994.

Pontuações inferiores a esse limiar indicavam correspondências potencialmente ambíguas e eram submetidas à inspeção visual manual. Já pontuações inferiores a aproximadamente 0.98 indicavam correspondências claramente incorretas e eram automaticamente descartadas sem necessidade de revisão manual. Dessa forma, todos os pares que apresentavam pontuações entre 0.98 e 0.994 foram analisados visualmente para confirmação da validade da correspondência.

Embora a representação compacta baseada exclusivamente na média de intensidades dos blocos (HU) seja eficiente, ela pode, em teoria, gerar falsos positivos quando exames de pacientes diferentes são adquiridos com protocolos de aquisição idênticos ou apresentam estruturas anatómicas muito semelhantes, uma vez que essas condições tendem a produzir distribuições de intensidade similares e, conseqüentemente, *fingerprints* com pontuação elevada. Para mitigar esse risco, adotou-se um limiar de aceitação automática conservador (0,994) e a validação visual sistemática de todos os pares com scores entre 0,98 e 0,994. Adicionalmente, como salvaguarda complementar, todos os *matches* automáticos foram analisados em termos de [MS-SSIM](#), onde os pares com pontuações mais críticas foram submetidos a uma revisão visual adicional para garantir a confiabilidade das correspondências.

Além disso, o método foi concebido para ignorar automaticamente imagens previamente verificadas como correspondências corretas, reduzindo redundâncias e acelerando reprocessamentos futuros. Devido ao elevado número de imagens presentes nos datasets, o processamento foi paralelizado e otimizado através da utilização de operações matriciais vetorizadas. Quando disponível, o algoritmo utiliza aceleração por GPU para reduzir o tempo de execução. Os *fingerprints* calculados também foram armazenados em cache para evitar recomputação desnecessária em execuções subsequentes.

A implementação dessa etapa de correspondência automática permitiu aumentar a confiabilidade do pipeline experimental, reduzindo o risco de associações incorretas entre imagens e garantindo maior consistência na construção do *dataset* utilizado para treino e avaliação dos modelos de redução de artefatos metálicos.

Embora o método utilize representações reduzidas das imagens em vez de comparação pixel-a-pixel completa, essa limitação não compromete o objetivo principal da metodologia. *Slices* consecutivos de um mesmo exame frequentemente apresentam elevada redundância espacial e podem, portanto, obter scores de similaridade muito próximos entre si. No entanto, o propósito do algoritmo não foi realizar alinhamento voxel-a-voxel rigoroso, mas sim identificar corretamente o exame e o paciente de origem de cada imagem [CT-MAR](#). Dessa forma, mesmo eventuais ambiguidades entre *slices* adjacentes permanecem restritas ao mesmo volume anatómico e não introduzem risco relevante de *data leakage* entre treino, validação e teste.

A literatura demonstra que a qualidade dos pares utilizados em estudos supervisionados influencia diretamente o desempenho e a capacidade de generalização dos modelos de MAR [9, 19]. Além disso, métricas estruturais de qualidade de imagem, como o [SSIM](#), têm sido

amplamente utilizadas em imagem médica devido à sua maior sensibilidade à preservação estrutural [26]. Embora o método implementado não utilize diretamente [SSIM](#), a estratégia adotada procura preservar precisamente a informação estrutural global da imagem durante o processo de correspondência.

Este rastreio constituiu um importante procedimento de controlo de qualidade do dataset experimental e foi fundamental para garantir um particionamento adequado dos dados utilizados no treino, validação e teste dos modelos, assegurando que os subconjuntos fossem estratificados por paciente e evitando vazamento de informação entre conjuntos experimentais.

Nem todos os *slices* puderam ser rastreados, mas a maioria dos dados foi associada com sucesso aos exames originais. Dos 14.000 pares disponibilizados pelo [CT-MAR](#) Dataset, 11.942 foram rastreados inicialmente até ao DeepLesion e 1.623 até ao UCLH Stroke EIT, totalizando 13.565 pares com metadados associados [3.1](#).

Tabela 3.1 Resultados do rastreio antes da análise complementar com [MS-SSIM](#).

Dataset	Rastreados	Correspondidos	Não correspondidos
DL (DeepLesion)	12.374	11.942	432
Stroke (UCLH)	1.626	1.623	3
Total	14.000	13.565	435

Na etapa de avaliação via [MS-SSIM](#), dentre todos os pares com pontuação abaixo de 0.90, apenas 3, anteriormente associados ao Deep Lesion, foram reprovados na inspeção visual [3.2](#).

Tabela 3.2 Resultados do rastreio depois da análise complementar com [MS-SSIM](#).

Dataset	Rastreados	Correspondidos	Não correspondidos
DL (DeepLesion)	12.374	11.939	435
Stroke (UCLH)	1.626	1.623	3
Total	14.000	13.562	438

Dado que uma quantidade significativa dos dados pôde ser rastreada com elevada confiabilidade, os casos restantes que não puderam ser agrupados de forma segura foram excluídos do processo de treino e validação. No total, 438 pares foram removidos por não apresentarem informação suficiente para garantir agrupamento seguro ao nível do paciente. Entre eles, os 3 pares reprovados por ser falso positivo na etapa de avaliação via [MS-SSIM](#).

Tabela 3.3 Dados dos pares sem correspondência que foram excluídos antes e após a análise complementar com MS-SSIM.

	Excluídos	
	Antes	Depois
Total	435	438

Assim, dos 14.000 pares originalmente disponibilizados pelo CT-MAR Dataset, 13.562 foram incluídos neste trabalho, enquanto 438 foram excluídos para preservar a integridade do particionamento experimental e minimizar o risco de *data leakage*.

3.4.3 Estratificação Anatômica

A proporção anatômica dos 14.000 pares do CT-MAR Dataset, mudou pouco após o processo de rastreio e exclusão dos pares com baixa confiabilidade. Dos 438 casos removidos 435 eram do tipo *body*, 3 do tipo *head*. A distribuição anatômica dos pares incluídos no estudo é a seguinte:

- **Body:** aproximadamente 88.03% ;
- **Head:** aproximadamente 11.97% .

A estratificação foi implementada dentro de cada subconjunto (train/val/test) de modo a manter a proporção anatômica ao nível de pacientes, garantindo que a proporção relativa entre categorias seja preservada em todos os subconjuntos. Dessa forma, o balanceamento anatômico é preservado, garantindo que os modelos sejam treinados e avaliados em uma representação adequada da diversidade anatômica presente no conjunto de dados original.

A nível de pacientes, a distribuição anatômica é a seguinte:

- **Body:** aproximadamente 95.9% (258/269 pacientes);
- **Head:** aproximadamente 4.1% (11/269 pacientes).

Após o particionamento, os subconjuntos de treino, validação e teste apresentaram a seguinte distribuição:

Tabela 3.4 Distribuição anatômica por subconjunto ao nível de pacientes.

Split	Body	Head	Body%	Head%
Train	180	7	96.3%	3.7%
Val	39	2	95.1%	4.9%
Test	39	2	95.1%	4.9%
Total	258	11	95.9%	4.1%

A proporção de aproximadamente 70% dos pacientes para treino, 15% para validação e 15% para teste com semente aleatória fixa ($seed = 1337$) foi escolhida para garantir uma quantidade suficiente de dados para treino, mantendo subconjuntos independentes para validação e teste, garantindo uma avaliação confiável do desempenho dos modelos.

Tabela 3.5 Distribuição dos pares por subconjunto, categoria anatômica e pacientes.

Split	Pares	Body	Head	Body%	Head%
Train	9 516	8 563	953	89.98%	10.02%
Val	2 532	2 147	385	84.79%	15.21%
Test	1 514	1 229	285	81.17%	18.83%
Total	13 562	11 939	1 623	88.03%	11.97%

Pode-se notar, que devido a grande variação na quantidade de *slices* por paciente, a distribuição anatômica ao nível de pacientes é bastante diferente da distribuição ao nível de pares. Devido a isso, a proporção $\sim 70/15/15$ foi mantida ao nível de pacientes, mas a distribuição anatômica dos pares não segue exatamente a mesma proporção.

3.4.4 Remoção do Fundo dos Exames

Um subprojeto inicial foi dedicado à remoção do fundo dos exames para evitar a influencia de pixels irrelevantes na aprendizagem do modelo, pois as imagens de [CT](#) frequentemente contêm grandes áreas de fundo que não contribuem para a tarefa de remoção de artefatos metálicos. A presença desses pixels pode introduzir ruído e dificultar a aprendizagem, especialmente em casos onde os artefatos estão localizados em regiões específicas do corpo. Para abordar esse desafio, foi implementada uma etapa de pré-processamento também baseada em [Deep Learning \(DL\)](#). Uma [U-Net-2D](#) foi treinada para segmentar o tecido corporal do fundo, gerando máscaras binárias que foram aplicadas às imagens originais para isolar as

regiões de interesse. Esse modelo foi treinado utilizando 1.500 amostras do próprio **CT-MAR dataset**, onde as máscaras de segmentação foram geradas automaticamente através de um processo de limiarização. Além disso, um refinamento manual foi feito nas máscaras obtidas para garantir a qualidade dos dados de treino e consequentemente a eficácia do modelo de segmentação. Esta etapa foi crucial para focar o modelo nas regiões relevantes, reduzindo a influência de artefatos de fundo e melhorando a qualidade das *features* extraídas durante o treino.

3.4.5 Normalização das Intensidades

As intensidades das imagens vêm expressas em **HU** do **dataset CT-MAR**. Para reduzir variações extremas e focar em regiões clinicamente relevantes, foi aplicada uma janela de intensidade adequada ao contexto anatômico. Após o janelamento, os valores foram normalizados para o intervalo $[0, 1]$ e são gerados tensores **NPY** de dimensão 256×256 2D para cada slice.

3.4.6 Máscaras de Artefato

Foram produzidas máscaras binárias de diferenças das regiões afetadas por artefatos que foram utilizadas como sinal de supervisão adicional na arquitetura versão *Dual-Head*. Essas máscaras são utilizadas exclusivamente durante o treino, não sendo necessárias durante a inferência. A máscara binária de diferenças é definida formalmente como:

$$M_{diff}(i, j) = \begin{cases} 1; & \text{se } |I_{artifact}(i, j) - I_{clean}(i, j)| > \tau \\ 0; & \text{caso contrário} \end{cases} \quad (3.1)$$

onde $I_{artifact}$ representa a imagem com artefatos, I_{clean} a imagem de referência limpa, e $\tau = 0.05$ é o limiar de diferença normalizada. Este *threshold* foi definido empiricamente para capturar regiões com diferenças perceptíveis mantendo robustez a ruído de baixa amplitude.

3.5 Arquitetura dos Modelos

3.5.1 Modelo Baseline

O modelo escolhido para ser o *baseline* consiste em uma arquitetura baseada em **U-Net** [17], composta por *encoder-decoder* com conexões de atalho (*skip connections*). Li et al [41], aplicam blocos de normalização em lote (**BN**) e funções de ativação **ReLU** após cada convolução

dinâmica. Esse trabalho faz algo semelhante, mas opta por utilizar convoluções padrão com $\text{kernel } 3 \times 3$, seguida dos blocos de BN e funções de ativação *ReLU*. A escolha por convoluções padrão é justificada pela simplicidade e eficiência computacional, além de manter a abordagem utilizada por Ronneberger et al [17]. Assim como Li et al [41], o *decoder* também utiliza *bilinear upsampling*. Essa arquitetura possui apenas um *output*, configurando um modelo *Single-Head*. A figura 3.1 ilustra a estrutura da arquitetura baseada em U-Net utilizada como modelo *baseline*.




Fig.3.1 Arquitetura baseada em U-Net utilizada como modelo *baseline*.

Uma variação do modelo *baseline* acima descrito foi concebida, estendendo a arquitetura para uma configuração *dual-head*, onde mantêm-se o *encoder* e o *decoder* compartilhados, mas são adicionadas duas saídas independentes na última camada do *decoder*. Cada cabeça tem tarefas distintas, sendo:

- uma cabeça dedicada à reconstrução da imagem corrigida;
- uma cabeça dedicada à predição da máscara de artefatos.




Fig.3.2 Arquitetura baseada em U-Net utilizada como modelo *dual-head*.

A figura 3.2 ilustra a estrutura da arquitetura *dual-head*. Esta configuração de supervisão dual permite que o modelo aprenda a identificar explicitamente as regiões afetadas por artefatos, fornecendo um mecanismo de controle sobre as áreas modificadas durante a reconstrução. Além disso, a cabeça de máscara pode ser utilizada para gerar mapas de atenção ou para auxiliar na interpretação dos resultados, aumentando a transparência do modelo.

3.6 Estudos de ablação

As duas arquiteturas foram avaliadas entre si para determinar o impacto da supervisão adicional com máscara de artefatos na qualidade da reconstrução e na capacidade de redução de artefatos. Toda a base de ambos os modelos são iguais, sendo a única diferença a presença da cabeça de predição da máscara de artefatos na versão *dual-head*. Dessa forma, a comparação entre as duas arquiteturas é justa e isolada, permitindo avaliar exclusivamente o impacto da supervisão adicional da máscara de artefatos.

3.7 Fluxo de Treino

3.7.1 Componentes de Configuração de Treino

1. Otimizador:

Foram utilizados otimizador *AdamW* devido a sua melhor capacidade de generalização [42] em ambas as arquiteturas. O *weight decay* foi otimizado e fixado para ambos os modelos.

2. Scheduler:

O scheduler *Reduce on Plateau* foi utilizado na etapa inicial devido ao fato da quantidade de épocas ideal ser desconhecida. A taxa de aprendizagem foi ajustada proporcionalmente ao progresso inicial observado nas primeiras épocas na fase de treino piloto, garantindo uma convergência estável e eficiente para ambos os modelos. No treino final, usou-se um scheduler do tipo *Cosine Decay* com um teto alfa de 0.05 para evitar decaimento até zero. Dessa forma, garante-se que a taxa de aprendizagem permaneça em um nível mínimo razoável, permitindo que os modelos continuem a aprender e se ajustem mesmo nas últimas épocas, o que pode ser particularmente importante para evitar estagnação do aprendizado e melhorar a capacidade de generalização. Além disso, o scheduler de *Cosine Decay* é ideal para estudos de ablação, pois garante a mesma estratégia de ajuste de taxa de aprendizagem para ambos os modelos.

3. Funções de Perda:

- **Perda de Reconstrução:** Apesar de L2 ser amplamente utilizada para restauração de imagem, Zhao et al. [43] destacam os melhores resultados de L1 ao estudar diferentes funções de perda para essa tarefa. Os autores também estudaram funções de perda baseadas em SSIM e MS-SSIM, sendo que a primeira alcança resultados igual ou levemente inferior a L1, enquanto a segunda apresenta desempenho melhor que SSIM mas ainda não supera L1 de forma clara. O trabalho também testa um mix de L1 e MS-SSIM, e obteve-se resultados superiores em todas as métricas avaliadas pelos autores. Essa combinação é justificada pela complementaridade entre as duas funções, onde L1 favorece fidelidade local e MS-SSIM promove preservação estrutural, resultando em uma correção mais equilibrada dos artefatos.

Devido a esses resultados, a função de perda de reconstrução adotada neste trabalho é a soma ponderada de L1 e MS-SSIM. Os pesos utilizados foram 0.7 para L1 e 0.3 para MS-SSIM, baseando-se na recomendação de Zhao et al. [43]. A relação adotada para a combinação das funções de perda é a seguinte:

$$\mathcal{L}_{Recon} = 0.7 \cdot \mathcal{L}_{L1} + 0.3 \cdot \mathcal{L}_{MS-SSIM}$$

[43] utiliza filtragem Gaussiana em L1 para reduzir o impacto de ruído e favorecer a correção de artefatos, mas essa abordagem pode não ser ideal para tomografias computadorizadas, onde a precisão radiométrica é crucial. Portanto, neste trabalho, optou-se por utilizar a perda L1 direta sem filtragem gaussiana, garantindo máxima fidelidade na reconstrução dos valores de Unidade Hounsfield (HU), enquanto o MS-SSIM continua a garantir a preservação estrutural em múltiplas escalas. Essa combinação de função de perda é adotada para a arquitetura *single-head* e também para a cabeça de reconstrução da arquitetura *dual-head*. Dessa forma, garante-se que a ablação entre as duas versões seja justa, isolando o impacto da supervisão adicional da máscara.

- **Perda de Segmentação:** Baseado nos estudos de Isensee et al. [44], a cabeça de predição da máscara de artefatos, presente na versão *dual-head*, é treinada utilizando uma combinação de DICE Loss e Binary Cross-Entropy (BCE), que se mostrou adequada para problemas de segmentação com desequilíbrio de classes [45]. A relação adotada para a combinação das funções de perda é a seguinte:

$$\mathcal{L}_{Seg} = \mathcal{L}_{Dice} + \mathcal{L}_{BCE}$$

- **Perda Total:** A função de perda total para a versão *dual-head* é composta pela ponderação das perdas de reconstrução e segmentação, e é definida como:

$$\mathcal{L} = 1.0 \cdot \mathcal{L}_{Recon} + 0.01 \cdot \mathcal{L}_{Seg}$$

3.7.2 Estratégia de Treino

Enquanto os modelos não estavam em uma configuração estável e ainda havia necessidade de ajustes de hiperparâmetros, a fase de treino foi realizada por um número reduzido de épocas (10) para permitir uma avaliação rápida do impacto das mudanças realizadas. Isso permitiu observar tendências de desempenho iniciais sem o custo computacional associado a treinos

prolongados. Uma vez que esse projeto tem como objetivo comparar duas versões de arquitetura, é necessário garantir a reprodutibilidade e consistência dos experimentos conduzidos. Tendo isso em conta, o treino final de ambos os modelos foi realizado utilizando uma quantidade de épocas fixa, definida com base nos resultados observados durante a fase de treino piloto. Além disso, foi utilizado um scheduler de taxa de aprendizagem fixo para ambos os modelos, garantindo que as condições de treino fossem idênticas. Essa abordagem assegura que as diferenças de desempenho observadas entre os modelos possam ser atribuídas exclusivamente às diferenças arquiteturais, sem a influência de variações nos hiperparâmetros ou na duração do treino. O treino piloto foi conduzido para o modelo mais complexo, a versão *dual-head*, para identificar quantas épocas eram necessárias para alcançar um desempenho estável e evitar sobreajuste. Após a definição da configuração final dos modelos e dos hiperparâmetros, a fase de treino foi estendida para um número maior de épocas para permitir uma convergência adequada dos modelos e uma avaliação mais robusta do desempenho final. Durante essa fase, as métricas de desempenho foram monitoradas para garantir que os modelos estavam aprendendo de forma eficaz e para identificar o ponto ideal de convergência.

Foi implementado uma estratégia de *early stopping* para interromper o treino caso a métrica monitorada (**SSIM**) não apresentasse melhoria significativa por um número pré-definido de épocas em um arquivo de configuração .yaml, evitando sobreajuste e economizando recursos computacionais.

1. Monitoramento do treinamento

Durante o treinamento, as seguintes métricas foram monitoradas para avaliar o desempenho do modelo e orientar o processo de otimização:

- **Loss de Reconstrução:** Monitorada para verificar a capacidade de aprendizagem do modelo em remover artefatos (reconstruir).
- **Loss de Segmentação:** Monitorada exclusivamente para a versão *dual-head* para avaliar a capacidade de aprendizagem do modelo em identificar as regiões afetadas por artefatos (segmentar).
- **PSNR e MS-SSIM:** Monitorados para avaliar a qualidade da imagem reconstruída em termos de fidelidade e preservação estrutural.

2. Avaliação

Na fase de inferência, os modelos foram avaliados utilizando métricas quantitativas amplamente adotadas na literatura, em comparação com o *Ground Truth*. As métricas utilizadas para a avaliação global da qualidade da imagem reconstruída foram:

- **PSNR** ;
- **MS-SSIM**.

Para a análise baseada em ROI, empregamos:

- **PSNR** ;
- **SSIM**.

Wang et al. [27] descrevem **MS-SSIM** como um método de avaliação de qualidade de imagem através de cinco escalas com *downsampling* iterativo por fator 2, resultando em uma redução de resolução de até 1/16 do tamanho original. O método foi validado em bases de dados de imagens completas, sem considerar aplicação em regiões fragmentadas ou espacialmente seletivas. Devido ao *downsampling* progressivo, a aplicação **MS-SSIM** em ROIs pequenas ou fragmentadas (como a zona distante em nossa análise) resultaria na mistura de pixels de ROI e não-ROI nas escalas reduzidas, comprometendo a interpretabilidade dos resultados. Por isso, utilizou-se **SSIM** regular em vez de **MS-SSIM** nesse caso. De fato, as literaturas recentes tem demonstrado performance estatisticamente muito melhor em fidelidade para **MS-SSIM** e **SSIM** comparado a outras métricas de avaliação de qualidade de imagem[46]. Especialmente para imagens médicas, onde a fidelidade das imagens preditas é crucial, a escolha de métricas que refletem a percepção humana de qualidade e preservação estrutural é fundamental. Portanto, **MS-SSIM** e **SSIM** foram selecionados como as principais métricas para avaliação quantitativa da qualidade das imagens reconstruídas, garantindo uma análise robusta e relevante para o contexto clínico. E o **PSNR** foi utilizado como métrica complementar para avaliar a fidelidade radiométrica das reconstruções, especialmente importante em tomografias computadorizadas onde a precisão dos valores de HU é essencial para diagnóstico e planejamento clínico.

3.8 Métricas

3.9 Protocolos de Validação

3.9.1 Validação Interna

A validação interna foi conduzida nos conjuntos de validação e teste, avaliando consistência, estabilidade e capacidade de generalização intra-*dataset*.

3.9.2 Validação Externa

A validação externa foi realizada em dados independentes provenientes do [The Cancer Imaging Archive \(TCIA\)](#), permitindo avaliar o impacto de *domain shift* e a robustez do modelo em cenários não vistos durante o treino.

3.10 Visão Geral do Pipeline

O pipeline desenvolvido neste trabalho segue uma abordagem supervisionada no domínio da imagem e é composto pelas seguintes etapas principais:

1. aquisição e organização dos dados;
2. pré-processamento e normalização;
3. treino de modelos baseados em [U-Net](#) com diferentes configurações arquiteturais;
4. avaliação quantitativa e qualitativa;
5. validação externa em dados independentes.

O objetivo do pipeline é garantir reprodutibilidade, controlo experimental rigoroso e avaliação justa do impacto de cada componente arquitetural introduzida ao longo do estudo.

3.11 Infraestrutura Computacional

Esse trabalho foi realizado utilizando uma GPU RTX 4000 ADA e o ambiente de desenvolvimento baseou-se em Python, TensorFlow/Keras e *Visual Studio Code*. O projeto oferece

suporte a precisão mista (*AMP*) que pode ser desativado via argumento, permitindo otimizar o uso de memória e acelerar o treino, especialmente em modelos mais complexos.

Capítulo 4

Resultados

Neste capítulo são apresentados e analisados os resultados obtidos a partir dos experimentos descritos no Capítulo 3. A análise é organizada em quatro etapas progressivas: (i) validação da qualidade das correspondências automáticas entre os datasets **CT-MAR** e DeepLesion/Stroke EIT, assegurando a confiabilidade da base de dados utilizada; (ii) estudos de ablation em treinos curtos para comparação arquitetural dos módulos de atenção e contexto multi-escala; (iii) seleção objetiva do modelo candidato com base em critérios de consistência e significância estatística; e (iv) avaliação do modelo selecionado em treinos de duração intermédia e prolongada.

4.1 Correspondências **CT-MAR** x DeepLesion/Stroke EIT Data

Antes de avançar para a análise dos resultados dos modelos de redução de artefatos, foi realizada mais uma avaliação dos resultados **CT-MAR** x DeepLesion/Stroke EIT para verificar a qualidade das correspondências automáticas. Esta etapa é crucial para garantir uma camada extra de confiança nos resultados obtidos pelo algoritmo de comparação de similaridade estrutural. Todos os pares que tiveram a correspondência aprovada automaticamente pelo fato de seu score ser acima de 0.994 foram revisados por um novo algoritmo que calcula o **MS-SSIM** entre as imagens correspondentes. Um histograma da distribuição dos **MS-SSIM** foi gerado, e os pares com pontuação menor que 0.9 foram revisados manualmente sendo aprovado ou recusado com base em avaliação humana.




Fig.4.1 Distribuição de MS-SSIM entre pares correspondentes (CTMAR vs DL/Stroke, aprovados automaticamente). Acima: histograma com os percentis P1 e P5, mediana, média e limiar de 0.9. Abaixo: zoom do histograma para a região de maior interesse, com destaque para os pares com MS-SSIM inferior a 0.9, que foram sujeitos a revisão manual.

A análise da distribuição entre os pares correspondentes revela que a maioria dos pares apresenta alta similaridade estrutural, com um valor médio de 0.9694 e uma mediana de

0.9830, indicando que o processo de correspondência automática é, em geral, confiável e eficaz na identificação de pares correspondentes entre os datasets CT-MAR e DeepLesion/Stroke EIT.

Os pares com pontuação de MS-SSIM abaixo de 0.9 eram 340 no total, apenas 3 foram reprovados após inspeção visual humana 4.2. Nessa inspeção, percebe-se que mesmo os casos com pontuações bastante baixas de MS-SSIM não eram falsos positivos e sim devido a diferenças no pós-processamento ou tratamento geral das imagens que geram alterações locais no qual o MS-SSIM é mais sensível. Isso pode ser visualizado na figura 4.3. Esse fato evidencia a eficácia da estratégia de correspondência por similaridade estrutural global adotada, que conseguiu identificar os pares com precisão, com apenas 3 falsos positivos identificados, mesmo após análise rigorosa 4.4. Mostrando que a metodologia é robusta e teve desempenho superior em detectar slices nesse trabalho do que uso do próprio MS-SSIM. Pois, enquanto as diferenças locais afetaram o MS-SSIM de forma mais significativa, a metodologia baseada em similaridade de cosseno conseguiu identificar as correspondências corretas com pontuação global elevada, mesmo em casos de diferenças locais acentuadas.




Fig.4.2 Distribuição de MS-SSIM entre pares correspondentes (CT-MAR vs DL/Stroke, aprovados automaticamente). À esquerda: histograma com os percentis P1 e P5, mediana, média e limiar de 0.9. À direita: ECDF correspondente. Os pares com MS-SSIM inferior a 0.9 foram sujeitos a revisão manual.




Fig.4.3 Exemplos de pares correspondentes com valores de **MS-SSIM** (0.7597, 0.7694 e 0.7717, respetivamente) aprovados após revisão visual humana mesmo com pontuações baixas.

Os pares reprovados apresentavam **MS-SSIM** claramente fora do padrão (< 0.61), com valores extremamente baixos, como podem ver na figura 4.4. Além disso, representaram os pares com pontuação mais próximas do limiar de aceitação automática de 0.994 4.5. Demonstrando que os casos em que o método falha são outliers claros em **MS-SSIM** e permanecem

justamente na zona cinzenta e propensa a erros da determinação empírica do limiar de aceitação automática. Além disso, os pares reprovados possuem características visuais bastante particulares com fundo dominando a imagem e poucas estruturas anatômicas visíveis, o que torna a avaliação de similaridade estrutural mais desafiadora devido a grande homogeneidade das características visuais.




Fig.4.4 3 pares reprovados após inspeção visual humana com valores de [MS-SSIM](#) (head_1159: 0.4573, head_369: 0.5652 e head_763: 0.6009, respetivamente). As pontuações desses pares na similaridade de cosseno foram head_1159: 0.9960, head_369: 0.9952 e head_763: 0.9951.




Fig.4.5 Distribuição dos valores de similaridade de cosseno para os pares inspecionados visualmente.

Os pares com **MS-SSIM** mais críticos logo acima dos reprovados tinham valores maiores que 0.75 4.3, demonstrando uma distancia clara entre os falsos positivos e os aprovados visualmente. Todos os pares inspecionados com pontuação acima desse valor de **MS-SSIM** passaram no teste de inspeção visual 4.6. Como os pares que não passaram por esse escrutínio tinham pontuação acima de 0.90 em **MS-SSIM**, é seguro assumir que os pares automaticamente aprovados com pontuação acima desse limiar são confiáveis.




Fig.4.6 Distribuição dos valores de MS-SSIM para os pares inspecionados visualmente.

4.2 Ablação – Fase 1

4.2.1 Single-Head vs Dual-Head

O modelo baseline, baseado numa arquitetura U-Net dual-head sem módulos adicionais de atenção ou contexto multi-escala, foi utilizado como referência para todas as comparações subsequentes. Os resultados obtidos em validação e teste indicam desempenho consistente, sem sinais evidentes de sobreajuste, estabelecendo uma base estável para os estudos de ablation. A arquitetura atingiu os limiares de convergencia na epoch 7 e nessa mesma epoch obteve-se o melhor desempenho de MS-SSIM em validação, o que é consistente com a estratégia de treino curto adotada para esta fase.

As métricas quantitativas médias e suas distribuições encontram-se resumidas na Tabela 4.1.

Tabela 4.1 Métricas quantitativas do modelo baseline em validação e teste.

Conjunto	Δ PSNR (dB)	Δ MS-SSIM
Train	5.845	0.1525
Val	5.614	0.1474
Test	5.748	0.1537

De modo geral, observa-se equilíbrio entre preservação estrutural e redução de ruído, com desempenho semelhante entre os conjuntos de validação e teste.

Foi realizado um estudo para verificar qual o melhor peso de máscara para a função de perda. Foi testando os pesos 0.1, 0.05, e 0.01. A finalidade era observar qual os limites de atuação da segunda saída em regularização e preservação de detalhes. O modelo com peso 0.05 para a máscara apresentou melhor desempenho em validação, com ganhos marginais em **PSNR** e **SSIM**, sugerindo que a supervisão adicional contribui para uma correção mais equilibrada dos artefatos. O modelo com peso 0.1 apresentou resultados piores que o modelo *Single-Head*, demonstrando que a supervisão excessiva da máscara pode levar a degradação de detalhes ao competir com a tarefa de reconstrução. Dessa forma, o peso da função de perda da saída de máscara foi diminuído para 0.05. Para esse peso, os resultados melhoram para **MS-SSIM**, **SSIM**, **PSNR** e **Mean Absolute Error (MAE)** com relação ao peso 0.1, mas ainda apresentam uma leve degradação em relação ao modelo *Single-Head*. O valor do **DICE** teve uma leve queda, mas manteve-se acima de 0.70, o que é considerado um desempenho aceitável para a tarefa de segmentação de artefatos com finalidade de regularização. Para o peso 0.01, o desempenho melhora em relação ao modelo com peso 0.05, mais uma vez melhorando **MS-SSIM**, **SSIM**, **PSNR** e **MAE**, mas o valor do **Dice Similarity Coefficient (DICE)** tem uma queda mais acentuada, ficando abaixo de 0.70.

Tabela 4.2 Resultados do estudo de *trade-off* entre reconstrução e segmentação para diferentes pesos da máscara.

Configuração Métrica	Qualidade Reconstrução PSNR/MS-SSIM	Qualidade Segmentação DICE
Single-Head	5.614	0.1474
Dual-Head (w=0.1)	35.07/0.9853	0.7680
Dual-Head (w=0.05)	35.287/0.986	0.754
Dual-Head (w=0.01)	35.971/0.987	0.649

4.3 Ablação – Fase 2

4.3.1 Impacto dos Módulos de Atenção -

1. *Baseline* + **SE**

2. *Baseline* + ASPP

A introdução do módulo *Atrous Spatial Pyramid Pooling* (ASPP) no *bottleneck* da arquitetura resultou em melhorias consistentes nas métricas de similaridade estrutural. Em comparação com o modelo *baseline*, o modelo com ASPP apresentou aumento médio de SSIM tanto em validação quanto em teste, acompanhado por variações moderadas em PSNR. A análise das distribuições de desempenho mostra deslocamento positivo da mediana e redução da fração de amostras com degradação de desempenho, sugerindo benefício do contexto multi-escala capturado pelo ASPP. Estes resultados indicam que a incorporação de informação em múltiplas escalas contribui para uma correção mais estável dos artefatos.

3. *Baseline* + CBAM

4. *Baseline* + SE + ASPP + CBAM

4.4 Seleção do Modelo para Treino Intermédio

Com base nos critérios definidos — consistência entre validação e teste, análise distributiva, controlo de sobreajuste e significância estatística — foi selecionada a arquitetura candidata para a fase de treino intermédio (30 – 40 épocas).

A Tabela (model selection criteria) resume os critérios de decisão adotados neste trabalho, fornecendo transparência ao processo de seleção e evitando escolhas arbitrárias baseadas apenas em métricas médias.

4.5 Treino com Duração Intermediária

4.6 Treino com Duração Prolongada

4.7 Análise de Distribuições e Overfitting – Modelo Final

Para além das médias, foram analisadas as distribuições das métricas (P25, P50 e P75), bem como o *gap* entre treino, validação e teste. Modelos com bom desempenho apresentaram diferenças limitadas entre treino e validação, dentro dos limites definidos no protocolo experimental.

Arquiteturas que apresentaram melhorias apenas em treino, sem reflexo consistente em validação e teste, foram consideradas menos robustas e descartadas da fase seguinte.

4.8 Análise Estatística Pareada – Modelo Final

A significância estatística das melhorias observadas foi avaliada por meio de testes pareados de Wilcoxon aplicados às diferenças de PSNR e SSIM entre modelos. Para controlar o erro do tipo I associado a múltiplas comparações, foi aplicada a correção de Holm–Bonferroni.

Além do valor-p corrigido, foi utilizado o tamanho de efeito de Cliff's delta para avaliar a relevância prática das diferenças observadas. Apenas melhorias estatisticamente significativas e com tamanho de efeito não desprezível foram consideradas na seleção do modelo final.

4.9 Resumo dos Resultados

Os resultados apresentados neste capítulo demonstram que a incorporação progressiva de contexto multi-escala e mecanismos de atenção contribui para melhorias consistentes na redução de artefatos em CT. A análise detalhada evidencia a importância de critérios objetivos e avaliação estatística rigorosa para a seleção de arquiteturas robustas, estabelecendo bases sólidas para as fases subsequentes de treino prolongado e validação externa.

Capítulo 5

Discussion

Capítulo 6

Conclusion

Bibliografia

- [1] Emico Okuno and Elisabeth Yoshimura. *Física das Radiações*. Oficina de Textos, 2010. [Cited on page 1.]
- [2] November 8, 1895: Roentgen's Discovery of X-Rays. <https://www.aps.org/apsnews/2001/11/1895-roentgens-discovery-xrays>. [Cited on page 1.]
- [3] JOEL D. HOWELL. EARLY CLINICAL USE OF THE X-RAY. *Transactions of the American Clinical and Climatological Association*, 127:341–349, 2016. [Cited on page 2.]
- [4] Allen Taylor. Illuminating Health: The Evolution and Significance of X-ray Imaging. *Imaging in Medicine*, 15(6):133–134, December 2023. [Cited on page 2.]
- [5] Reza Vali. Unveiling the Marvels of Computed Tomography (CT) Imaging. *Imaging in Medicine*, 16(1):150–151, February 2024. [Cited on page 2.]
- [6] Mohd Noor. An Overview of Computed Tomography: What it is and How it Works? Applications of Computed Tomography. *Imaging in Medicine*, 15(5):93–94, October 2023. [Cited on page 2.]
- [7] Raymond A. Schulz, Jay A. Stein, and Norbert J. Pelc. How CT happened: The early development of medical computed tomography. *Journal of Medical Imaging*, 8(5):052110, September 2021. [Cited on page 2.]
- [8] F. Edward Boas and Dominik Fleischmann. CT artifacts: Causes and reduction techniques. *Imaging in Medicine*, 4(2):229–240, April 2012. [Cited on page 2.]
- [9] Cecile E.J. Kleber, Ramez Karius, Lucas E. Naessens, Coen O. Van Toledo, Jochen A. C. Van Osch, Martijn F. Boomsma, Jan W.T. Heemskerk, and Aart J. Van Der Molen. Advancements in supervised deep learning for metal artifact reduction in computed tomography:

- A systematic review. *European Journal of Radiology*, 181:111732, December 2024. [Cited on pages 2, 5, 6, and 15.]
- [10] Sathyathas Puvanasunthararajah, Davide Fontanarosa, Marie-Luise Wille, and Saskia M. Camps. The application of metal artifact reduction methods on computed tomography scans for radiotherapy applications: A literature review. *Journal of Applied Clinical Medical Physics*, 22(6):198–223, May 2021. [Cited on page 3.]
- [11] Asutosh Sahu, Shobhit Mathur, Hiroyuki Takaoka, Joji Ota, Felix G. Meinel, Benjamin Böttcher, Benoît Magnin, Ankush Jajodia, and Corey T. Jensen. Transforming CT imaging with deep learning: Noise reduction, artifact management, and clinical applications – A comprehensive review. *European Journal of Radiology Artificial Intelligence*, 4:100042, December 2025. [Cited on pages 3, 5, and 6.]
- [12] Mohanad Alkhodari, Eman Alefishat, Herbert F. Jelinek, Ahmed Kaabneh, and Panos Liatsis. Enhancing CCTA image quality: A review of deep learning approaches for advanced artifact correction and denoising. *Artificial Intelligence Review*, 58(10):331, August 2025. [Cited on page 3.]
- [13] Julia F. Barrett and Nicholas Keat. Artifacts in CT: Recognition and Avoidance. *RadioGraphics*, 24(6):1679–1691, November 2004. [Cited on page 5.]
- [14] Mark Selles, Jochen A.C. Van Osch, Mario Maas, Martijn F. Boomsma, and Ruud H.H. Wellenberg. Advances in metal artifact reduction in CT images: A review of traditional and novel metal artifact reduction techniques. *European Journal of Radiology*, 170:111276, January 2024. [Cited on page 6.]
- [15] Lars Gjestebj, Qingsong Yang, Yan Xi, Bernhard E. H. Claus, Yannan Jin, Bruno De Man, Ge Wang, and Hongming Shan. Deep learning methods for CT image-domain metal artifact reduction. In Bert Müller and Ge Wang, editors, *Developments in X-Ray Tomography XI*, page 31, San Diego, United States, September 2017. SPIE. [Cited on pages 6 and 7.]
- [16] Yanbo Zhang and Hengyong Yu. Convolutional Neural Network Based Metal Artifact Reduction in X-Ray Computed Tomography. *IEEE Transactions on Medical Imaging*, 37(6):1370–1381, June 2018. [Cited on pages 6 and 7.]
- [17] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-Net: Convolutional Networks for Biomedical Image Segmentation, May 2015. [Cited on pages 6, 19, and 20.]

- [18] Esther Meyer, Frank Bergner, Rainer Raupach, Thomas Flohr, and Marc Kachelriess. Normalized metal artifact reduction (NMAR) in computed tomography. In *2009 IEEE Nuclear Science Symposium Conference Record (NSS/MIC)*, pages 3251–3255, Orlando, FL, October 2009. IEEE. [Cited on page 7.]
- [19] Wei-An Lin, Haofu Liao, Cheng Peng, Xiaohang Sun, Jingdan Zhang, Jiebo Luo, Rama Chellappa, and Shaohua Kevin Zhou. DuDoNet: Dual Domain Network for CT Metal Artifact Reduction. In *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 10504–10513, Long Beach, CA, USA, June 2019. IEEE. [Cited on pages 7 and 15.]
- [20] Lequan Yu, Zhicheng Zhang, Xiaomeng Li, Hongyi Ren, Wei Zhao, and Lei Xing. Metal Artifact Reduction in 2D CT Images with Self-supervised Cross-domain Learning. *Physics in Medicine & Biology*, 66(17):175003, September 2021. [Cited on page 7.]
- [21] Zhiwei Huang, Guo Zhang, Jinzhao Lin, Yu Pang, Huiqian Wang, Tong Bai, and Lisha Zhong. Multi-modal feature-fusion for CT metal artifact reduction using edge-enhanced generative adversarial networks. *Computer Methods and Programs in Biomedicine*, 217:106700, April 2022. [Cited on page 7.]
- [22] Xin Yi, Ekta Walia, and Paul Babyn. Generative Adversarial Network in Medical Imaging: A Review. *Medical Image Analysis*, 58:101552, December 2019. [Cited on page 7.]
- [23] Jie Hu, Li Shen, and Gang Sun. Squeeze-and-Excitation Networks. In *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 7132–7141, June 2018. [Cited on page 7.]
- [24] Sanghyun Woo, Jongchan Park, Joon-Young Lee, and In So Kweon. CBAM: Convolutional Block Attention Module. In Vittorio Ferrari, Martial Hebert, Cristian Sminchisescu, and Yair Weiss, editors, *Computer Vision – ECCV 2018*, volume 11211, pages 3–19. Springer International Publishing, Cham, 2018. [Cited on page 7.]
- [25] Liang-Chieh Chen, George Papandreou, Florian Schroff, and Hartwig Adam. Rethinking Atrous Convolution for Semantic Image Segmentation, December 2017. [Cited on page 8.]
- [26] Zhou Wang, A.C. Bovik, H.R. Sheikh, and E.P. Simoncelli. Image quality assessment: From error visibility to structural similarity. *IEEE Transactions on Image Processing*, 13(4):600–612, April 2004. [Cited on pages 8, 13, 14, and 16.]

- [27] Z. Wang, E.P. Simoncelli, and A.C. Bovik. Multiscale structural similarity for image quality assessment. In *The Thirty-Seventh Asilomar Conference on Signals, Systems & Computers, 2003*, pages 1398–1402, Pacific Grove, CA, USA, 2003. IEEE. [Cited on pages 8 and 25.]
- [28] Alain Hore and Djemel Ziou. Image Quality Metrics: PSNR vs. SSIM. In *2010 20th International Conference on Pattern Recognition*, pages 2366–2369, Istanbul, Turkey, August 2010. IEEE. [Cited on page 8.]
- [29] John R. Zech, Marcus A. Badgeley, Manway Liu, Anthony B. Costa, Joseph J. Titano, and Eric Karl Oermann. Variable generalization performance of a deep learning model to detect pneumonia in chest radiographs: A cross-sectional study. *PLOS Medicine*, 15(11):e1002683, November 2018. [Cited on page 8.]
- [30] Martin J. Willemink, Wojciech A. Koszek, Cailin Hardell, Jie Wu, Dominik Fleischmann, Hugh Harvey, Les R. Folio, Ronald M. Summers, Daniel L. Rubin, and Matthew P. Lungren. Preparing Medical Imaging Data for Machine Learning. *Radiology*, 295(1):4–15, April 2020. [Cited on page 8.]
- [31] Christopher J. Kelly, Alan Karthikesalingam, Mustafa Suleyman, Greg Corrado, and Dominic King. Key challenges for delivering clinical impact with artificial intelligence. *BMC Medicine*, 17(1):195, December 2019. [Cited on page 8.]
- [32] Eri Haneda, Nils Peters, Jiayong Zhang, Grigorios Karageorgos, Wenjun Xia, Harald Paganetti, Ge Wang, Yi Guo, Jianhua Ma, Hyoung Suk Park, Kiwan Jeon, Fuxin Fan, Mareike Thies, and Bruno De Man. AAPM CT metal artifact reduction grand challenge. *Medical Physics*, 52(10):e70050, October 2025. [Cited on page 11.]
- [33] xcist. AAPM CT Metal Artifact Reduction (CT-MAR) Grand Challenge Benchmark Tool. https://github.com/xcist/example/tree/main/AAPM_datachallenge/. [Cited on page 11.]
- [34] Nils Peters, Eri Haneda, Jiayong Zhang, Grigorios Karageorgos, Wenjun Xia, Joost Verburg, Ge Wang, Harald Paganetti, and Bruno De Man. A hybrid training database and evaluation benchmark for assessing metal artifact reduction methods for X-ray CT imaging. *Medical Physics*, 52(10):e70020, October 2025. [Cited on page 11.]
- [35] Mingye Wu, Paul FitzGerald, Jiayong Zhang, W. Paul Segars, Hengyong Yu, Yongshun Xu, and Bruno De Man. XCIST – An Open Access X-ray/CT Simulation Toolkit. *Physics*

- in medicine and biology*, 67(19):10.1088/1361–6560/ac9174, September 2022. [Cited on page 11.]
- [36] Nir Goren, James Avery, Thomas Dowrick, Eleanor Mackle, Anna Witkowska-Wrobel, David Werring, and David Holder. Multi-frequency electrical impedance tomography and neuroimaging data in stroke patients. *Scientific Data*, 5:180112, July 2018. [Cited on pages 11 and 13.]
- [37] Nir Goren, Thomas Dowrick, James Avery, and David Holder. UCLH Stroke EIT Dataset - Radiology Data, August 2017. [Cited on page 11.]
- [38] Ke Yan, Xiaosong Wang, Le Lu, and Ronald M. Summers. DeepLesion: Automated mining of large-scale lesion annotations and universal lesion detection with deep learning. *Journal of Medical Imaging*, 5(3):036501, July 2018. [Cited on pages 11 and 13.]
- [39] Mustafa Umit Oner, Yi-Chih Cheng, Hwee Kuan Lee, and Wing-Kin Sung. Training machine learning models on patient level data segregation is crucial in practical clinical applications, April 2020. [Cited on page 13.]
- [40] Jiang Hsieh. *Computed Tomography: Principles, Design, Artifacts, and Recent Advances*. Wiley Interscience ; SPIE Press, Hoboken, N.J. : Bellingham, Wash, 2nd ed edition, 2009. [Cited on pages 13 and 14.]
- [41] Yang Li, Bobo Yan, Jianxin Hou, Bingyang Bai, Xiaoyu Huang, Canfei Xu, and Limei Fang. UNet based on dynamic convolution decomposition and triplet attention. *Scientific Reports*, 14(1):271, January 2024. [Cited on pages 19 and 20.]
- [42] Ilya Loshchilov and Frank Hutter. Decoupled Weight Decay Regularization, January 2019. [Cited on page 22.]
- [43] Hang Zhao, Orazio Gallo, Iuri Frosio, and Jan Kautz. Loss Functions for Image Restoration With Neural Networks. *IEEE Transactions on Computational Imaging*, 3(1):47–57, March 2017. [Cited on pages 22 and 23.]
- [44] Fabian Isensee, Jens Petersen, Andre Klein, David Zimmerer, Paul F. Jaeger, Simon Kohl, Jakob Wasserthal, Gregor Koehler, Tobias Norajitra, Sebastian Wirkert, and Klaus H. Maier-Hein. nnU-Net: Self-adapting Framework for U-Net-Based Medical Image Segmentation. <https://arxiv.org/abs/1809.10486v1>, September 2018. [Cited on page 23.]

-
- [45] Saeid Asgari Taghanaki, Yefeng Zheng, S. Kevin Zhou, Bogdan Georgescu, Puneet Sharma, Daguang Xu, Dorin Comaniciu, and Ghassan Hamarneh. Combo Loss: Handling Input and Output Imbalance in Multi-Organ Segmentation, September 2021. [Cited on page [23](#).]
- [46] Lin Zhang, Lei Zhang, Xuanqin Mou, and D. Zhang. FSIM: A Feature Similarity Index for Image Quality Assessment. *IEEE Transactions on Image Processing*, 20(8):2378–2386, August 2011. [Cited on page [25](#).]

Apêndice A

Appendix Title Here

Write your Appendix content here.