

Deep Learning for Metal Artifact Reduction in Computed Tomography



Ludmila Montorsi Queiroz

Mestrado em Física Médica

Departamento de Física e Astronomia

Faculdade de Ciências da Universidade do Porto

2026



UNIVERSIDADE DO PORTO

MASTERS THESIS

Deep Learning for Metal Artifact Reduction in Computed Tomography

Author:

Ludmila MONTORSI QUEIROZ

Supervisor:

Hélder Filipe PINTO DE OLIVEIRA

Co-supervisor:

Eduardo MATOS RODRIGUES

*A thesis submitted in fulfilment of the requirements
for the degree of MSc. Medical Physics*

at the

Faculdade de Ciências da Universidade do Porto
Departamento de Ciência de Computadores
Departamento de Física e Astronomia
INESC TEC

September 7, 2026

"The Universe is under no obligation to make sense to you."

Neil deGrasse Tyson, *Astrophysics for People in a Hurry* (2017)

"Nothing in life is to be feared; it is only to be understood."

Marie Curie, *Madame Curie: A Biography* (1937)

Acknowledgements

I would like to express my deepest gratitude to my supervisor, Helder Filipe Pinto de Oliveira, for his invaluable guidance, support, and encouragement throughout this research journey. His expertise and insights have been instrumental in shaping this thesis. I am also grateful to my co-supervisor, Eduardo Matos Rodrigues, for his constructive feedback and encouragement, which have greatly contributed to the development of this work.

UNIVERSIDADE DO PORTO

Abstract

Faculdade de Ciências da Universidade do Porto

Departamento de Ciência de Computadores

Departamento de Física e Astronomia

INESC TEC

MSc. Medical Physics

Deep Learning for Metal Artifact Reduction in Computed Tomography

by [Ludmila MONTORSI QUEIROZ](#)

Metal artifacts remain a common and clinically significant source of image degradation in computed tomography (CT), affecting an estimated 21% of scans and potentially obscuring or mimicking pathology. This thesis develops and rigorously evaluates a reproducible deep learning pipeline for image-domain metal artifact reduction, comparing a conventional U-Net against a dual-supervision variant that adds an auxiliary artifact-mask prediction head to a shared encoder-decoder. Using the AAPM CT-MAR benchmark dataset (14,000 image pairs derived from DeepLesion and UCLH Stroke EIT), a patient-level traceability procedure was implemented to recover exam and patient identity absent from the original metadata, enabling a leakage-free patient-level split (187/41/41 patients) across three deterministic training seeds per architecture. On the internal test set (41 patients, 1,478 slices), both architectures significantly improved PSNR (27.4 to ~ 35.1 dB), SSIM (0.836 to ~ 0.944) and MAE (36.6 to ~ 17.5 HU) relative to the corrupted input (patient-level Wilcoxon/sign tests, $p < 0.001$), with the correction concentrated in the artifact region and comparatively small change in distant tissue. A direct paired comparison showed a small but statistically significant global advantage for the single-head model and a small but significant distant-region preservation advantage for the dual-head model, indicating a correction-versus-preservation trade-off rather than a clear superiority of either design. The single-head model (seed 2024) was frozen and characterized on an independent external cohort from The Cancer Imaging Archive, where, in the absence of a clean reference, only the magnitude of input-to-output change could be quantified. A blinded, paired multi-reader evaluation by physicians was designed to assess perceived anatomical preservation and safety on these external cases; data collection was still ongoing at the time

of writing, so this thesis reports the technical evidence supporting internal validity and reproducibility, while clinical benefit and external safety remain to be established by that evaluation.

Keywords: Computed Tomography, Metal Artifact Reduction, Deep Learning, U-Net, Multi-task Learning, Reproducibility, Patient-level Data Partitioning, External Validation, Image Quality Assessment

UNIVERSIDADE DO PORTO

Resumo

Faculdade de Ciências da Universidade do Porto

Departamento de Ciência de Computadores

Departamento de Física e Astronomia

INESC TEC

MSc. Medical Physics

Aprendizado Profundo para Redução de Artefatos de Metal em Tomografia Computadorizada

por [Ludmila MONTORSI QUEIROZ](#)

Artefatos metálicos permanecem uma causa comum e clinicamente relevante de degradação de imagem em tomografia computadorizada (CT), estimados em cerca de 21% dos exames, podendo esconder ou simular patologias. Esta dissertação desenvolve e avalia rigorosamente um *pipeline* reproduzível de aprendizagem profunda para redução de artefatos metálicos no domínio da imagem, comparando uma U-Net convencional com uma variante de dupla supervisão que acrescenta uma saída auxiliar de predição da máscara de artefacto a um *encoder-decoder* partilhado. Utilizando o *dataset* de referência CT-MAR da AAPM (14.000 pares de imagens derivados do DeepLesion e do UCLH Stroke EIT), foi implementado um procedimento de rastreabilidade ao nível do paciente para recuperar a identidade do exame e do paciente, ausente nos metadados originais, permitindo um particionamento por paciente sem vazamento de dados (187/41/41 pacientes) ao longo de três sementes de treino determinísticas por arquitetura. No conjunto de teste interno (41 pacientes, 1.478 fatias), ambas as arquiteturas melhoraram significativamente o PSNR (27,4 para $\sim 35,1$ dB), o SSIM (0,836 para $\sim 0,944$) e o MAE (36,6 para $\sim 17,5$ HU) face à entrada corrompida (testes de Wilcoxon/sinais ao nível do paciente, $p < 0,001$), com a correção concentrada na região do artefacto e alteração comparativamente pequena no tecido distante. Uma comparação pareada direta mostrou uma pequena mas estatisticamente significativa vantagem global do modelo de supervisão única e uma pequena mas significativa vantagem de preservação na região distante do modelo de dupla supervisão, indicando um compromisso entre correção e preservação, e não uma superioridade clara de nenhuma das arquiteturas. O modelo de supervisão única (semente 2024)

foi congelado e caracterizado numa coorte externa independente proveniente do The Cancer Imaging Archive, onde, na ausência de referência limpa, apenas foi possível quantificar a magnitude da alteração entrada-saída. Uma avaliação cega e pareada por múltiplos médicos foi desenhada para avaliar a preservação anatômica percebida e a segurança nesses casos externos; a recolha de dados ainda estava em curso à data de redação, pelo que esta dissertação relata a evidência técnica que sustenta a validade interna e a reprodutibilidade, ficando o benefício clínico e a segurança externa por confirmar por essa avaliação.

Palavras-chave: Tomografia Computadorizada, Redução de Artefatos Metálicos, Aprendizagem Profunda, U-Net, Aprendizagem Multitarefa, Reprodutibilidade, Particionamento por Paciente, Validação Externa, Avaliação da Qualidade de Imagem

Contents

Acknowledgements	ii
Abstract	iii
Resumo	v
Contents	vii
List of Figures	x
Lista de Gráficos	xi
List of Tables	xii
1 Introduction	1
1.1 Clinical and Technical Context	3
1.2 Work Motivation	3
2 Objectives and Investigation Question	4
2.1 General Objective	4
2.2 Specific Objectives	4
2.3 Hypothesis and Outcomes	5
3 Related Works	6
3.1 Metallic Artifacts in CT	6
3.2 Artifact Reduction based on Deep Learning	6
3.3 Reproducible Evaluation and Generalization	8
4 Materials and Methods	9
4.1 Dados, curadoria e rastreabilidade	9
4.1.1 Conjunto CT-MAR e fontes de referência	9
4.1.2 Particionamento ao nível do paciente	10
4.1.3 Coorte final e Exclusões	13
4.1.4 Estratificação Anatômica	15
4.2 Pré-processamento	16
4.2.1 Verificação de integridade	16
4.2.2 Máscara Corporal	17
4.2.3 Janela de intensidade e normalização	17
4.2.4 Máscara de artefacto para supervisão auxiliar	17
4.3 Arquiteturas em comparação	18

4.3.1	U-Net	18
4.3.2	U-Net Dual Supervision	18
4.4	Treino reprodutível	20
4.4.1	Configuração, determinismo e seleção de checkpoint	20
4.4.2	Função de Perda	20
4.5	Avaliação interna	22
4.5.1	Métricas globais	23
4.5.2	Avaliação por regiões de interesse	23
4.5.3	Análise estatística	26
4.6	Avaliação externa por médicos	27
4.6.1	Desenho e casos	27
4.6.2	Caracterização quantitativa entrada-saída	28
4.6.3	Participantes e proteção de dados	28
4.6.4	Apresentação e instrumento de avaliação	28
4.6.5	Desfechos e análise	28
4.6.6	Estado operacional	28
5	Resultados	29
5.1	Coorte final e integridade experimental	29
5.1.1	Resultados da Aprovação Automática x Inspeção Manual	29
5.1.2	Análise Complementar com MS-SSIM	29
5.2	Treino dos modelos	36
5.2.1	Convergência e seleção dos checkpoints	36
5.2.2	Rastreabilidade das execuções	44
5.3	Avaliação interna no conjunto de teste	44
5.3.1	Desfechos globais	44
5.3.2	Avaliação por regiões de interesse	49
5.3.3	Mapas de resíduos em casos extremos	53
5.4	Comparação pareada Single x Dual Model	60
5.4.1	Análises Estatísticas Globais	60
5.4.2	Análise Estatística por ROI	63
5.5	Avaliação externa por médicos	66
5.5.1	Estado da recolha e participantes	66
5.5.2	Caracterização quantitativa entrada – saída	67
5.5.3	Desfecho primário: visualização anatômica	70
5.5.4	Desfechos secundários e segurança percebida	71
5.5.5	Interpretação limitada ao desenho observacional	72
6	Discussão	73
6.1	Síntese dos achados principais	73
6.2	Interpretação da comparação arquitetural	74
6.3	Preservação anatômica e segurança da reconstrução	75
6.4	Generalização e avaliação externa	76
6.5	Avaliação por médicos	76
6.6	Limitações	77
6.7	Implicações e trabalho futuro	78
7	Conclusões	79
7.1	Conclusões do estudo	79

7.2	Contribuições da dissertação	79
7.3	Perspetivas futuras	79
 Bibliography		79
 A Supplementary Internal Evaluation		85
A.1	Casos de pior desempenho	89
A.2	Desempenho computacional	91

List of Figures

4.1	Single Supervision U-Net architecture	18
4.2	Dual Supervision U-Net architecture	19
4.3	Artifact and distant ROI examples	25
5.3	Visually approved low MS-SSIM pairs	32
5.4	Visually rejected pairs	33
5.18	Greatest Artifact-ROI Δ SSIM: head_1147	54
5.19	Greatest Artifact-ROI Δ SSIM: head_1274	55
5.20	Greatest Artifact-ROI Δ SSIM: head_1280	56
5.21	Least Artifact-ROI Δ SSIM: body_11949	57
5.22	Least Artifact-ROI Δ SSIM: body_2906	58
5.23	Least Artifact-ROI Δ SSIM: body_11956	59
5.25	Least structurally changed external cases	69
5.26	Most structurally changed external cases	70

Lista de Gráficos

5.1	MS-SSIM distribution and zoom (clean CT-MAR vs DL/Stroke)	30
5.2	MS-SSIM ECDF (clean CT-MAR vs DL/Stroke)	31
5.5	Cosine similarity of MS-SSIM-audited pairs	34
5.6	MS-SSIM distribution of audited pairs	34
5.7	Score distribution of excluded pairs: DL vs Stroke EIT	35
5.8	Training curves: Dual Model, seed 1337	37
5.9	Training curves: Single Model, seed 1337	38
5.10	Training curves: Dual Model, seed 2024	39
5.11	Training curves: Single Model, seed 2024	40
5.12	Training curves: Dual Model, seed 42	41
5.13	Training curves: Single Model, seed 42	42
5.14	Per-image global PSNR and SSIM improvement	48
5.15	Patient-level Bland–Altman agreement of mean HU	48
5.16	Per-image ROI metric improvements	52
5.17	Artifact-ROI correction versus distant-ROI change	52
5.24	Global PSNR and SSIM improvement	63
A.1	Pixel-level HU agreement	85
A.2	Per-image input-output global metrics	87
A.3	Patient-level artifact load and improvement	88
A.4	Worst-case slices by global Δ SSIM	89
A.5	Worst-case slices by global Δ PSNR	90
A.6	Worst-case slices: joint Δ PSNR vs. Δ SSIM	91
A.7	Benchmark Latency	92

List of Tables

4.1	Initial pair-matching screening	14
4.2	Pair matching after MS-SSIM review	14
4.3	Excluded unmatched pairs before and after MS-SSIM review	14
4.4	Patient-level anatomical distribution by split	15
4.5	Patient distribution by split	16
4.6	Pair distribution by split and anatomical category	16
4.7	Pair distribution by split	16
4.8	Evaluation metrics by context	26
5.1	Best validation SSIM by model and seed	43
5.2	Validation PSNR at best validation SSIM	43
5.3	Validation MAE at best validation SSIM	43
5.4	Per-slice global SSIM on the test set	45
5.5	Per-slice global PSNR on the test set	45
5.6	Per-slice global MAE on the test set	45
5.7	Patient-level global Δ SSIM	46
5.8	Patient-level global Δ PSNR	46
5.9	Patient-level global Δ MAE	46
5.10	ROI Δ SSIM	49
5.11	ROI Δ PSNR	49
5.12	ROI MAE reduction	50
5.13	SSIM improvement over corrupted input	61
5.14	PSNR improvement over corrupted input	61
5.15	MAE reduction over corrupted input	61
5.16	Paired Single vs Dual Model comparison	62
5.17	Artifact-ROI SSIM improvement	63
5.18	Artifact-ROI PSNR improvement	63
5.19	Artifact-ROI MAE reduction	64
5.20	Paired Artifact-ROI improvement comparison	64
5.21	Distant-ROI SSIM preservation magnitude	64
5.22	Distant-ROI PSNR preservation magnitude	65
5.23	Distant-ROI MAE preservation magnitude	65
5.24	Paired Distant-ROI preservation advantage	65
5.25	Recruitment and completion status	66
5.26	Reader profile characteristics	66
5.27	Reader specialty distribution	67
5.28	External input-output global metrics	67
5.29	Illustrative external cases by input-output SSIM	68
5.30	Primary outcome: anatomical preservation preference	71
5.31	Primary outcome: mixed-effects model estimate	71

5.32 Secondary outcome: artifact intensity	71
5.33 Secondary outcome: distortion in other regions	71
5.34 Secondary outcome: clinical preference	72
5.35 Secondary outcome: complementary utility	72
5.36 Intra-reader reliability	72

This thesis is dedicated to my husband, for his love and support.

Chapter 1

Introduction

When Wilhelm Conrad Röntgen, University of Würzburg's physics teacher, in Germany, decided to repeat the experiment done by Philipp Lenard with a modified Crookes tube to study cathode rays, no one could foresee the impact of his discoveries on medicine.

It didn't take long for his experiments to present surprising results that demonstrated that the observed behavior was not compatible with cathode rays, but rather with a kind of more penetrating ray that did not suffer deflections in the presence of a magnetic field. During the handling of the pieces used in his experiments, he noticed that the outline of his bones was being imprinted on the fluorescent screen he was using.

Like that, on December 22, 1895, he invited his wife, Anna Bertha, to make a 15-minute exposure to these rays, obtaining what would be the first radiography of the human body. In this same year, Röntgen published the article "On a new kind of rays", in which he named the responsible agent as "X-rays". Already in January 1896, newspapers announced on the front page the discovery as a revolutionary way to observe the interior of the human body without the need for surgical incisions, pointing out its potential use in medical diagnosis [1, 2].

On February 1896, in Massachusetts (USA), Edwin Brant Frost produced a radiograph of a Colles fracture of a patient for his brother, a local doctor, marking the beginning of the incorporation of X-rays into medical practice [1]. Thus, less than a year after the announcement of Röntgen's discovery, X-rays quickly moved from laboratories to extensive use in diagnosis and therapy [1]. Since that, the techniques have undergone successive modernizations and diversified into multiple modalities and devices, consolidating themselves as an indispensable tool in modern healthcare [3, 4].

From these successive modernizations emerged, in 1971, the first computerized tomography scanner. This technology is based on the principle of x-rays attenuation, in which the amount of radiation absorbed or scattered by the material is related to its density [5, 6].

Computed Tomography (CT) was the first medical imaging modality to provide quantitative information about tissue attenuation, something that was not possible with conventional radiography [7]. Furthermore, allowing sectional visualization of the human body, it eliminated the overlap of anatomical structures inherent to two-dimensional images, enabling precise localization and assessment of the extent of lesions [7].

However, these advances brought a significant increase in technological complexity. The acquisition of multiple projections, combined with computational reconstruction and digital image processing, introduced new forms of degradation that were nonexistent or of little relevance in conventional radiography. Thus, computed tomography became particularly susceptible to the presence of artifacts, which can compromise the diagnostic quality and clinical reliability of images [7].

Various types of artifacts can be observed in computed tomography, including noise, beam hardening, motion, ring artifacts, and metal artifacts, which can obscure or simulate pathologies [8]. The causes of these artifacts are varied, ranging from detector failures or miscalibration, statistical limitations associated with low photon counts, to physical phenomena such as beam hardening and scattering, which produce dark streaks between high-attenuation objects such as metal, bone, or iodinated contrast media [7].

Specifically, streak artifacts caused by metallic implants are observed in approximately 21% of computed tomography scans, being considered extremely common in clinical practice [7]. The high attenuation or even total blockage of X-rays by these implants prevents the radiation from adequately reaching the detectors, resulting in low-quality projection data and compromising image reconstruction [9].

The increase use of metallic implants, driven by the evolution of healthcare, has intensified concerns regarding the negative impact of these artifacts on image quality and the reliability of diagnostic analyses [9]. Traditionally, various **Metal Artifact Reduction (MAR)** algorithms have been proposed, including image inpainting techniques, sinogram inpainting, and **Model-Based Iterative Reconstruction (MBIR)** or combinations of these approaches [10].

Although analytical methods such as **Filtered Back Projection (FBP)** have dominated tomographic reconstruction for decades due to their computational efficiency and conceptual simplicity, their limitations become evident under non-ideal clinical conditions, requiring higher radiation doses to ensure image quality [11]. **MBIR** methods emerged as an alternative to overcome these limitations, at the cost of higher computational demand and the introduction of artificial textures in the reconstructed image [11].

Recently, deep learning-based approaches have been widely investigated for artifact correction in computed tomography, demonstrating superior performance and greater clinical applicability compared to conventional methods [12]. In particular, [Convolutional Neural Networks \(CNNs\)](#) have been proposed for metal artifact reduction, enabling noise suppression and preservation of anatomical and soft tissue details [12].

1.1 Clinical and Technical Context

Due to the fact that artifacts in [CT](#) can hide or simulate pathologies, its presence can compromise the diagnostic quality and clinical reliability of images. A diagnostic mistake can have serious consequences for the patient, including treatment delays, inadequations or unnecessary, and even life-threatening risks. Additionally, the presence of artifacts can lead to increased radiation exposure, as additional scans may be required to obtain a clear image, which can increase the risk of radiation-induced complications. The constant technological evolution has made the use of metallic implants increasingly common in the medical context, which significantly increases the presence of this type of artifact and also the associated diagnostic mistakes.

Therefore, the reduction of artifacts in [CT](#) is a research area with significant clinical importance, and the development of effective methods to reduce artifacts gains high value in medical practice.

1.2 Work Motivation

Although studies using deep learning for metal artifact reduction are not new, a lot of the work published to date does not present a rigorous and detailed evaluation of the performance of the proposed models. In particular, the evaluation of the performance of models on external datasets (which were not used during model training) or evaluation of images by qualified professionals is often lacking. Moreover, the training of supervised models depends on reference images, which are difficult to obtain in a clinical context, creating a dependency on synthetic or simulated images. This lacking turns out to be still more relevant when considering that the performance of models trained on synthetic images may not be representative of their performance on real images, which can lead to overestimation of their effectiveness and limit their clinical applicability.

In this sense, the present study proposes a more rigorous and detailed evaluation of the performance of deep learning models for this purpose.

Chapter 2

Objectives and Investigation Question

2.1 General Objective

The general objective of this dissertation is to develop, evaluate and rigourously compare a CNN model for metal artifact reduction in CT, prioritizing anatomical preservation, robustness to domain variation and interpretability of the correction process. Additionally, the study aims to investigate the generalization of the best performing model to real and external data, with a focus on clinical applicability. Healthcare professionals will be involved in the evaluation of the model's performance on real data, providing a comprehensive assessment of its effectiveness and potential for clinical use.

2.2 Specific Objectives

The specific objectives of this study include:

- Develop a reproducible pipeline for training and evaluating metal artifact reduction models in CT in the image domain, with rigorous separation between training, validation, and test data.
- Evaluate the performance of a U-shaped Network (U-Net) to image reconstruction for metal artifact reduction and compare it with a version of itself with an additional supervision of artifact mask.
- Evaluate the performance of the two versions using quantitative metrics like: Peak Signal-to-Noise Ratio (PSNR), Structural Similarity Index Measure (SSIM), Mean Absolute Error (MAE), Binary Cross-Entropy (BCE) and Dice Similarity Coefficient (DICE). Besides, performing error maps, statistical and qualitative analysis to assess the quality of the reconstructed images.

- Investigate the generalization capability of the best performing version in the internal evaluation stage on real and external data from the [The Cancer Imaging Archive \(TCIA\)](#).

2.3 Hypothesis and Outcomes

The primary hypothesis of this study is that the reconstruction produced by each architecture significantly improves the structural quality of the image compared to the artifact input, in the internal test partition. This hypothesis is operationalized through the [SSIM](#), calculated in the [Region of Interest \(ROI\)](#) where the metal artifact is inserted and the clean [ROI](#) (where there is no artifact) would need to remain unchanged or poorly changed. The analyses were aggregated at the patient level ($n = 41$), with a null hypothesis of median paired differences input–model equal to zero.

The secondary hypothesis include: (i) the improvement of [PSNR](#) and [MAE](#), in HU, compared to the input, under the same patient-level aggregation; (ii) the same triad of metrics ([SSIM](#), [PSNR](#) and [MAE](#)) calculated in global image; and (iii) a direct paired comparison between the Single Model and the Dual Model on the same three metrics, addressing the architectural comparison objective.

As a criterion for anatomical preservation, it was defined that the change introduced in the Clean Zone should be substantially smaller, in magnitude, than the correction observed in the Artifact Zone, and that the global radiometric calibration bias, evaluated by Bland–Altman at the patient level, should be small relative to the amplitude of the [HU](#) window used. A formal equivalence margin for the Distant Zone was not pre-specified. Preservation is therefore characterized descriptively, and not tested for statistical equivalence.

Finally, as the external [TCIA](#) set does not have a clean reference, the generalization hypothesis is necessarily more limited: it is expected that the selected architecture produces, in the external cases, changes of plausible magnitude and without collapse to identity, but confirmation of artifact removal accuracy and clinical safety depends on blinded reader evaluation ([section 4.6](#)), and not on a reference metric.

Chapter 3

Related Works

3.1 Metallic Artifacts in CT

The traditional methods of artifact reduction in CT are predominantly based on physical and mathematical principles associated with image formation. Barrett and Keat[13] provide a detailed description of the origin of the main artifacts in CT, including beam hardening, photon starvation, scattering, and geometric effects, as well as classical strategies for their mitigation.

Reconstruction techniques such as FBP were widely used due to their computational efficiency, but they are highly sensitive to noise and metallic artifacts. More advanced methods, such as Iterative Reconstruction (IR) and MBIR, incorporate statistical models of the acquisition system and noise, allowing for partial artifact reduction. However, these approaches often introduce artificial textures and have limitations in complex clinical scenarios [11].

Recent revisions indicate that commercial algorithms for MAR, such as Orthopedic Metal Artifact Reduction (O-MAR), Iterative Metal Artifact Reduction (iMAR), and Single Energy Metal Artifact Reduction (SEMAR), although effective in specific situations, rely on proprietary parameters and exhibit inconsistent performance in cases of dense or multiple implants [9, 14]. These limitations have driven the investigation of deep learning-based approaches.

3.2 Artifact Reduction based on Deep Learning

The First applications of Deep Learning (DL) para MAR focused on the image domain, exploring convolutional networks to map degraded images to corrected versions. Gjestebj et al. [15] investigated metal artifact reduction in the image domain based on CNN and demonstrated significant quantitative improvements compared to conventional techniques.

Zhang e Yu [16] also purposed a supervised model based on Convolutional Neural Network (CNN) for metal artifact reduction in CT, achieving consistent gains in PSNR and Root Mean

Square Error (RMSE). These works helped consolidate the use of convolutional networks for **MAR** in the image domain. In particular, Zhang and Yu used a shallow fully convolutional **CNN** for fusing information from multiple pre-corrected images. Subsequent works increasingly adopted encoder-decoder architectures, especially those based on **U-shaped Network (U-Net)**, for correction/restoration tasks. **U-Net**-type networks and their variants are capable of capturing global contextual information through the contraction path, and recovering fine spatial details through the expansion path and *Skip Connections*[17].

Recent Systematic reviews have highlighted these advances, emphasizing that most supervised methods in the image domain exhibit competitive performance, especially when trained with high-quality paired data [9, 11].

In addition to image domain, some studies explored the sinogram domain, with linear interpolation and **Normalized Metal Artifact Reduction (NMAR)** methods. These approaches operate directly on the projection data and act directly on the physical origin of metallic artifacts[18]. However, access to raw projection data is often restricted in commercial **CT** systems, limiting the applicability of such approaches in clinical settings [15].

Beyond that, hybrid models have been purposed to leverage the advantages of each approach. The method purposed by Zhang and Yu [16] seeks to merge **CNN** in the image domain and classical **MAR** in the sinogram domain. In the adopted approach, the initial refinement occurs in the image domain, but the complete method uses the image generated by the **CNN** as a prior for replacement of affected regions in the sinogram. This characterizes a hybrid approach, but still does not employ **CNN** in both domains. More recent models, such as DuDoNet[19], integrate deep networks in both domains, demonstrating high performance and characterizing what we call Dual Domain. However, these methods present greater computational complexity and dependence on access to raw sinogram, which motivates the continuous exploration of robust solutions in the image domain.

To address the scarcity of anatomically paired data with metal artifact/metal artifact-free, self-supervised learning-based approaches have emerged. Yu et al. [20] proposed a method capable of reducing metal artifacts without the need for fully clean reference images, expanding the clinical applicability of these techniques.

Others works explored the use of **Generative Adversarial Network (GAN)** for **MAR**. Huang et al. [21] used multimodal fusion and **GANs** to improve texture preservation and reduce excessive smoothing. Despite good visual results, **GAN**-based can introduce training instability and a higher risk of structural hallucination[22], raising clinical concerns.

3.3 Reproducible Evaluation and Generalization

The evaluation of DL models for CT is typically performed through quantitative metrics such as PSNR, RMSE, and structural similarity-based indices. Traditional error-based metrics, such as RMSE and PSNR, quantify pixel-wise discrepancies but do not adequately capture structural information relevant to visual perception and clinical interpretation. In this context, Wang et al. [23] introduced the SSIM as a perceptual metric that explicitly models luminance, contrast, and structure. Subsequently, the Multi-Scale Structural Similarity Index Measure (MS-SSIM) was proposed to incorporate scale-dependent structural variations, extending SSIM to multiple resolution levels [24]. Horé and Ziou [25] demonstrated that both PSNR and SSIM have limitations depending on the type of distortion considered, suggesting that the choice of metric may depend on the application context. Given that metallic artifacts manifest primarily as structural distortions affecting anatomical boundaries and long-range streak patterns, metrics sensitive to structural preservation, such as SSIM and MS-SSIM, are particularly suitable for evaluating the performance of MAR methods, as they explicitly consider structural components at different spatial scales [23, 24].

Additionally, a critical challenge identified in the literature is the models generalization. Zech et al. [26] demonstrated that models with high performance on internal datasets can fail significantly when applied to external data, highlighting the impact of Domain Shift. Recent reviews reinforce the need for rigorous external and clinical validation to ensure safety, robustness and real applicability [27, 28].

The reviewed literature demonstrates significant advancements in artifact reduction in CT through DL, but also evidences persistent gaps: lack of experimental standardization, limited external validation, and risk of anatomical hallucination.

Chapter 4

Materials and Methods

4.1 Dados, curadoria e rastreabilidade

4.1.1 Conjunto CT-MAR e fontes de referência

O *dataset* principal utilizado neste trabalho provém do [CT Metal Artifact Reduction Challenge \(CT-MAR\)](#) [29, 30] promovido pela *American Association of Physicists in Medicine* e consiste em 14.000 pares de treino contendo imagens de CT com artefatos metálicos simulados e suas versões originais sem artefatos. Os dados foram gerados através de um *framework* de simulação híbrida [31], que incorpora imagens clínicas publicamente disponíveis e objetos metálicos simulados com o simulador CatSim, integrado na *toolkit* de código aberto XCIST [32]. O conjunto é distribuído em duas categorias anatômicas:

- **Head:** 1.626 (11.61%) amostras derivadas da base *UCLH Stroke EIT Data* [33, 34];
- **Body:** 12.374 (88.38%) amostras derivadas da base *NIH DeepLesion Data* [35].

Onde as pastas da categoria *body* apresentavam CTs de tronco, abrangendo fatias axiais, torácica e abdominal. Os dados estão organizados em subpastas, cada uma contendo até 1.000 amostras. Foram utilizados apenas os seguintes ficheiros para treino e validação:

1. **Imagens sem metal (referência):** Ficheiros contidos na pasta *Target* de dimensão 512×512×1 pixels;
2. **Imagens com artefatos metálicos (corrompidas):** Ficheiros contidos na pasta *Baseline* de dimensão 512×512×1 pixels;

Todos os ficheiros de imagem (.raw) do *dataset* são apresentados em formato binário sem cabeçalho, com precisão *float32* em ordem *little endian*. As imagens já vieram convertidas de coeficientes de atenuação linear (em unidades mm^{-1}) para [Unidade Hounsfield](#)

(HU), utilizando o valor de normalização de 0.02 mm^{-1} para água. Não havia no conjunto de dados informações adicionais sobre a que exame cada *slice* pertencia, se eram de um mesmo paciente, ou quais regiões anatômicas específicas estavam representadas. A única informação disponível era a organização por pasta, que indicava a categoria anatômica (Head ou Body). A falta de metadados detalhados impôs a necessidade de uma abordagem de pré-processamento cuidadosa para garantir que os dados fossem adequadamente organizados e utilizados durante o treino e validação dos modelos. Dessa forma, um esforço significativo foi dedicado ao rastreamento das imagens aos conjuntos de dados originais (UCLH Stroke EIT Data e NIH DeepLesion Data) para obter informações adicionais sobre os exames e pacientes, permitindo um particionamento adequado dos dados.

4.1.2 Particionamento ao nível do paciente

O particionamento dos dados foi estratificado por pacientes, garantindo que os *slices* de um mesmo paciente não fossem distribuídos entre os conjuntos de treino, validação e teste. Esta abordagem evita vazamento de informações e assegura uma avaliação mais realista da capacidade de generalização dos modelos.

Dado que os dados do CT-MAR dataset não continham metadados clínicos detalhados, foi necessário realizar um rastreamento algorítmico dos *slices* até aos conjuntos de dados originais (UCLH Stroke EIT e NIH DeepLesion Data) para tornar possível a associação dos metadados fornecidos aos *slices* do CT-MAR. Este processo permitiu identificar a qual exame e paciente do DeepLesion/UCLH Stroke EIT cada imagem CT-MAR pertencia. Essas informações foram posteriormente utilizadas para realizar o particionamento dos dados em treino, validação e teste ao nível do paciente, reduzindo o risco de *data leakage* entre conjuntos experimentais.

A correta separação dos dados é particularmente importante em estudos de imagem médica baseados em *deep learning*, uma vez que *slices* pertencentes ao mesmo exame frequentemente apresentam elevada similaridade anatômica. Dessa forma, a presença simultânea de imagens do mesmo paciente em treino e teste pode inflacionar artificialmente o desempenho do modelo e comprometer a avaliação da sua capacidade de generalização [36].

As imagens do dataset DeepLesion [35] encontram-se armazenadas em formato PNG de 16 bits, enquanto as imagens do CT-MAR são disponibilizadas em formato `.raw` diretamente em unidades de Hounsfield (HU). Já o UCLH Stroke EIT [33] disponibiliza os exames em formato DICOM. Assim, independentemente do formato original, todas as imagens foram convertidas para HU antes da comparação, garantindo uniformidade entre os diferentes conjuntos de dados.

Após a conversão, todas as imagens foram representadas numa mesma escala de intensidade para permitir comparação direta.

O algoritmo utilizado baseia-se no facto de que imagens CT preservam informação quantitativa em unidades de Hounsfield (HU), refletindo diretamente as propriedades de atenuação dos diferentes tecidos. Como as estruturas anatómicas apresentam elevada continuidade espacial entre *slices* consecutivos de uma mesma aquisição, imagens correspondentes à mesma fatia anatómica tendem a apresentar distribuições semelhantes de HU e padrões estruturais globais altamente consistentes [23, 37].

Dessa forma, o método não procura verificar igualdade absoluta pixel-a-pixel entre imagens, mas sim determinar se a organização estrutural global da anatomia permanece extremamente semelhante entre diferentes representações da mesma fatia. Esse comportamento é particularmente importante porque pequenas variações locais de intensidade, discretização numérica e transformações lineares associadas à conversão entre formatos de armazenamento tendem a preservar a estrutura anatómica global da imagem mesmo quando ocorrem pequenas variações locais de intensidade [23, 37].

Assim, a metodologia adotada procura identificar correspondências entre imagens com base na similaridade estrutural global, permitindo uma margem de variação local que não comprometa a identificação correta do exame e paciente de origem. Inicialmente, cada imagem foi reduzida para uma representação compacta através de *downsampling*, preservando principalmente a informação anatómica global relevante. Essa etapa reduz significativamente o custo computacional sem comprometer a estrutura geral da imagem.

Em seguida, foi calculado um vetor representativo (*fingerprint*) para cada imagem. Os *fingerprints* das imagens CT-MAR foram então comparados com os *fingerprints* das imagens DeepLesion e UCLH Stroke EIT através de uma métrica de similaridade vetorial baseada em produto escalar normalizado (similaridade de cosseno), escolhida por ser invariante a diferenças de escala global entre os vetores — propriedade relevante dado que as imagens provêm de formatos distintos com diferentes normalizações de intensidade. Para cada imagem CT-MAR, foi selecionada a imagem com maior score de similaridade.

Como a maior parte das imagens do CT-MAR teve origem no DeepLesion, o processo de rastreio foi inicialmente priorizado nesse dataset. Posteriormente, a mesma metodologia foi aplicada aos exames DICOM do UCLH Stroke EIT para identificação das imagens restantes. Dessa forma, foi possível implementar uma estratégia unificada de rastreabilidade independentemente do formato de armazenamento dos datasets de origem.

As correspondências foram consideradas válidas apenas quando o score de similaridade excedia um limiar previamente definido empiricamente. Casos com scores muito elevados foram automaticamente marcados como correspondências seguras, pois observou-se que todos os pares analisados visualmente com pontuação superior a 0.993 correspondiam efetivamente à mesma imagem. Para manter uma margem adicional de segurança, a correspondência foi considerada automaticamente válida apenas quando a pontuação excedia 0.994.

Pontuações inferiores a esse limiar indicavam correspondências potencialmente ambíguas e eram submetidas à inspeção visual manual. Já pontuações inferiores a aproximadamente 0.98 indicavam correspondências claramente incorretas e eram automaticamente descartadas sem necessidade de revisão manual. Dessa forma, todos os pares que apresentavam pontuações entre 0.98 e 0.994 foram analisados visualmente para confirmação da validade da correspondência. A fim de evitar a exclusão de pares de forma desnecessária, todos os pares com pontuação inferior a 0.98 para ambos os datasets (DeepLesion e UCLH Stroke EIT) foram submetidos a inspeção visual para garantir que não fossem erroneamente descartados.

Para os 530 pares que permaneceram sem correspondência aprovada após a busca direta nos dois datasets de origem, foi aplicada uma etapa complementar de correspondência indireta. Nessa etapa, cada imagem **CT-MAR** não correspondida foi comparada com imagens **CT-MAR** já rastreadas; os vizinhos mais semelhantes foram usados para selecionar exames candidatos do DeepLesion e, em seguida, todos os *slices* desses exames foram pesquisados com *fingerprints* de dimensão 64×64 . As 530 propostas foram inspecionadas visualmente: 95 correspondências foram aprovadas e incorporadas ao manifesto consolidado, enquanto 435 permaneceram sem correspondência segura e foram excluídas.

Além disso, o método foi concebido para ignorar automaticamente imagens previamente verificadas como correspondências corretas, reduzindo redundâncias e acelerando reprocessamentos futuros. Devido ao elevado número de imagens presentes nos datasets, o processamento foi paralelizado e otimizado através da utilização de operações matriciais vetorizadas. Quando disponível, o algoritmo utiliza aceleração por **GPU** para reduzir o tempo de execução. Os *fingerprints* calculados também foram armazenados em cache para evitar recomputação desnecessária em execuções subsequentes.

Embora a representação compacta baseada exclusivamente na média de intensidades dos blocos (HU) seja eficiente, ela pode, em teoria, gerar falsos positivos quando exames de pacientes diferentes são adquiridos com protocolos de aquisição idênticos ou apresentam estruturas anatómicas muito semelhantes, uma vez que essas condições tendem a produzir distribuições de intensidade similares e, conseqüentemente, *fingerprints* com pontuação elevada.

Para mitigar esse risco, adotou-se um limiar de aceitação automática conservador (0,994) e a validação visual sistemática de todos os pares com scores entre 0,98 e 0,994. Adicionalmente, como salvaguarda complementar, todos os *matches* automáticos foram analisados em termos de [MS-SSIM](#), onde os pares com pontuações mais críticas foram submetidos a uma revisão visual adicional para garantir a confiabilidade das correspondências.

Apesar disso, essa limitação não compromete o objetivo principal da metodologia. Pois, mesmo que *Slices* consecutivos de um mesmo exame frequentemente apresentem elevada redundância espacial e podem, portanto, obter scores de similaridade muito próximos entre si. O propósito do algoritmo não foi realizar alinhamento voxel-a-voxel rigoroso, mas sim identificar corretamente o exame e o paciente de origem de cada imagem [CT-MAR](#). Dessa forma, mesmo eventuais ambiguidades entre *slices* adjacentes permanecem restritas ao mesmo volume anatómico e não introduzem risco relevante de *data leakage* entre treino, validação e teste.

A literatura demonstra que a qualidade dos pares utilizados em estudos supervisionados influencia diretamente o desempenho e a capacidade de generalização dos modelos de MAR [9, 19]. Além disso, métricas estruturais de qualidade de imagem, como o [SSIM](#), têm sido amplamente utilizadas em imagem médica devido à sua maior sensibilidade à preservação estrutural [23]. Embora o método implementado não utilize diretamente [SSIM](#), a estratégia adotada procura preservar precisamente a informação estrutural global da imagem durante o processo de correspondência.

Mais ainda, a utilização dos dados sem qualquer tratamento de rastreo desse tipo, condicionaria todo o projeto a um vazamento de dados inerente ao dataset, comprometendo a avaliação do desempenho dos modelos e a validade dos resultados. Assim, mesmo que o método de rastreo não seja perfeito, ele representa uma melhoria significativa em relação à ausência total de rastreo, garantindo uma base mais confiável.

Tendo isso em conta, essa etapa constituiu um importante procedimento de controle de qualidade do dataset experimental e foi fundamental para garantir um particionamento adequado dos dados utilizados no treino, validação e teste dos modelos, assegurando que os subconjuntos fossem estratificados por paciente e evitando vazamento de informação entre conjuntos experimentais.

4.1.3 Coorte final e Exclusões

Nem todas as fatias puderam ser rastreadas, mas a maioria dos dados foi associado com sucesso aos exames originais. Ao final das etapas de correspondência direta e indireta, e

antes da análise complementar com [MS-SSIM](#), dos 14.000 pares disponibilizados pelo [CT-MAR](#) Dataset, 11.942 foram rastreados até ao DeepLesion (incluindo os 95 recuperados pela correspondência indireta) e 1.623 até ao UCLH Stroke EIT, totalizando 13.565 pares com metadados associados [4.1](#).

Table 4.1 Resultados do rastreio antes da análise complementar com [MS-SSIM](#).

Dataset	Rastreados	Correspondidos	Não correspondidos
DeepLesion	12.374	11.942	432
UCLH Stroke	1.626	1.623	3
Total	14.000	13.565	435

Na etapa de avaliação via [MS-SSIM](#), dentre todos os pares com pontuação abaixo de 0.90, apenas 3, anteriormente associados ao Deep Lesion, foram reprovados na inspeção visual [4.2](#).

Table 4.2 Resultados do rastreio depois da análise complementar com [MS-SSIM](#).

Dataset	Rastreados	Correspondidos	Não correspondidos
DeepLesion	12.374	11.939	435
UCLH Stroke	1.626	1.623	3
Total	14.000	13.562	438

Dado que uma quantidade significativa dos dados pôde ser rastreada com elevada confiabilidade, os casos restantes que não puderam ser agrupados de forma segura foram excluídos do processo de treino e validação. No total, 438 pares foram removidos por não apresentarem informação suficiente para garantir agrupamento seguro ao nível do paciente. Entre eles, os 3 pares reprovados por ser falso positivo na etapa de avaliação via [MS-SSIM](#). Todos os pares removidos desse estudo foram inspecionados visualmente para confirmar a ausência de correspondência, garantindo que a exclusão foi justificada.

Table 4.3 Dados dos pares sem correspondência que foram excluídos antes e após a análise complementar com [MS-SSIM](#).

Excluídos		
	Antes	Depois
Total	435	438

Assim, dos 14.000 pares originalmente disponibilizados pelo [CT-MAR Dataset](#), 13.562 foram incluídos neste trabalho, enquanto 438 foram excluídos para preservar a integridade do particionamento experimental e minimizar o risco de *data leakage*.

4.1.4 Estratificação Anatômica

A proporção anatômica dos 14.000 pares do [CT-MAR Dataset](#), mudou pouco após o processo de rastreo e exclusão dos pares com baixa confiabilidade. Dos 438 casos removidos 435 eram do tipo *body*, 3 do tipo *head*. A distribuição anatômica dos pares incluídos no estudo é a seguinte:

- **Body:** aproximadamente 88.03% ;
- **Head:** aproximadamente 11.97% .

A estratificação foi implementada dentro de cada subconjunto (train/val/test) de modo a manter a proporção anatômica ao nível de pacientes, garantindo que a proporção relativa entre categorias seja preservada em todos os subconjuntos. Dessa forma, o balanceamento anatômico é preservado, garantindo que os modelos sejam treinados e avaliados em uma representação adequada da diversidade anatômica presente no conjunto de dados original.

A nível de pacientes, a distribuição anatômica é a seguinte:

- **Body:** aproximadamente 95.9% (258/269 pacientes);
- **Head:** aproximadamente 4.1% (11/269 pacientes).

Após o particionamento, os subconjuntos de treino, validação e teste apresentaram a seguinte distribuição:

Table 4.4 Distribuição anatômica por subconjunto ao nível de pacientes.

Split	Body	Head	% Body	% Head
Train	180	7	96.3%	3.7%
Val	39	2	95.1%	4.9%
Test	39	2	95.1%	4.9%
Total	258	11	—	—

A partição paciente-nível foi definida uma única vez, com semente aleatória fixa, mantendo aproximadamente 70% dos pacientes para treino, 15% para validação e 15% para teste. Esta partição fixa garantiu subconjuntos independentes para validação e teste e foi mantida inalterada em todas as repetições experimentais.

Table 4.5 Distribuição percentual dos pacientes por subconjunto.

Split	Pacientes	% Total
Train	187	69.52%
Val	41	15.24%
Test	41	15.24%
Total	269	100%

Devido a grande variação na quantidade de fatias por paciente, a distribuição anatômica ao nível de pares é bastante diferente da distribuição ao nível de pacientes (Tabelas 4.6 e 4.7). O mesmo ocorre para a distribuição dos pares totais. Dessa forma, a proporção $\sim 70/15/15$ foi mantida ao nível de pacientes mas ao nível dos pares não segue exatamente a mesma proporção.

Table 4.6 Distribuição dos pares por subconjunto e categoria anatômica.

Split	Body	Head	% Body	% Head
Train	8 563	953	89.98%	10.02%
Val	2 147	385	84.79%	15.21%
Test	1 229	285	81.17%	18.83%
Total	11 939	1 623	–	–

Table 4.7 Distribuição percentual dos pares por subconjunto.

Split	Pares	% Total
Train	9 516	70.17%
Val	2 532	18.67%
Test	1 514	11.16%
Total	13 562	100%

4.2 Pré-processamento

4.2.1 Verificação de integridade

Todos os pares foram validados através de um relatório de integridade, que verifica a existência de ambos os lados do par (imagem com artefacto e imagem limpa). Não houve nenhum par com dados faltantes, garantindo que o conjunto de dados estava completo e pronto para as etapas subsequentes de pré-processamento e treino dos modelos.

4.2.2 Máscara Corporal

As imagens de CT frequentemente contêm grandes áreas de fundo que não contribuem para a tarefa de remoção de artefatos metálicos. Isso cria um desequilíbrio de classes nos dados de treino que predomina voxels de fundo irrelevantes sobre as regiões anatómicas de interesse. Esse desequilíbrio, por sua vez, dificulta a aprendizagem e desvia o foco do modelo das estruturas clinicamente relevantes [38, 39]. Para abordar esse desafio, foi implementada uma etapa de pré-processamento também baseada em Deep Learning (DL). Uma U-Net foi treinada para segmentar o tecido corporal do fundo, gerando máscaras binárias que foram aplicadas às imagens originais para isolar as regiões de interesse. Esse modelo foi treinado utilizando ~ 1.500 amostras do próprio CT-MAR dataset, onde as máscaras de segmentação foram geradas automaticamente através de um processo de limiarização. Além disso, um refinamento manual foi feito nas máscaras obtidas para garantir a qualidade dos dados de treino e consequentemente a eficácia do modelo de segmentação.

Esta etapa foi crucial para reduzir a influência de artefatos de fundo e melhorar a qualidade das *features* extraídas durante o treino.

4.2.3 Janela de intensidade e normalização

As intensidades das imagens vêm expressas em HU do CT-MAR dataset. Para reduzir variações extremas foi aplicada uma janela de intensidade adequada ao contexto anatômico. Após o janelamento, os valores foram normalizados para o intervalo $[0, 1]$ e são gerados tensores NPY de dimensão 256×256 2D para cada fatia e seu par.

4.2.4 Máscara de artefacto para supervisão auxiliar

Foram produzidas máscaras binárias de diferença das regiões afetadas por artefatos que foram utilizadas como sinal de supervisão adicional na arquitetura com dupla supervisão. Essas máscaras são utilizadas exclusivamente durante o treino, não sendo necessárias durante a inferência. A máscara binária de diferenças é definida formalmente como:

$$M_{diff}(i, j) = \begin{cases} 1; & \text{se } |I_{artifact}(i, j) - I_{clean}(i, j)| > \tau \\ 0; & \text{caso contrário} \end{cases} \quad (4.1)$$

onde $I_{artifact}$ representa a imagem com artefatos, I_{clean} a imagem de referência limpa, e τ é o limiar de diferença normalizada. O valor desse limiar foi definido empiricamente para capturar regiões com diferenças perceptíveis mantendo robustez a ruído de baixa amplitude.

4.3 Arquiteturas em comparação

4.3.1 U-Net

O primeiro modelo consiste em uma arquitetura baseada em U-Net [17], composta por *encoder-decoder* com conexões de atalho (*skip connections*). Li et al [40], aplicam blocos de *Batch Normalization* (BN) e funções de ativação *Rectified Linear Unit* (ReLU) após cada convolução dinâmica. Esse trabalho faz algo semelhante, mas opta por utilizar convoluções padrão com *kernel* 3×3 , seguida dos blocos de BN e funções de ativação *ReLU*. A escolha por convoluções padrão é justificada pela simplicidade e eficiência computacional, além de manter a abordagem utilizada por Ronneberger et al [17]. Assim como Li et al [40], o *decoder* também utiliza *bilinear upsampling*. Essa arquitetura possui apenas um *output*.




Fig.4.1 Diagrama da arquitetura Single Supervision.

4.3.2 U-Net Dual Supervision

Uma variação do modelo acima descrito foi concebida, mantendo-se o *encoder* e o *decoder* compartilhados e acrescentando-se uma saída independente na última camada. Dessa forma, há duas saídas distintas no decoder, cada uma com sua própria função de perda. A primeira

saída é responsável pela reconstrução da imagem corrigida, enquanto a segunda saída é dedicada à predição da máscara de artefatos.

A justificativa para a adição da supervisão auxiliar da máscara de artefatos baseia-se na premissa de que a presença de uma perda adicional focada na segmentação de regiões afetadas por artefatos pode fornecer informações complementares ao modelo, auxiliando na aprendizagem de representações mais robustas e discriminativas. Essa abordagem é inspirada em trabalhos anteriores que demonstraram que a supervisão multi-tarefa pode melhorar o desempenho em tarefas relacionadas [41, 42].

As duas arquiteturas foram avaliadas entre si para determinar o impacto da supervisão adicional com máscara de artefatos na qualidade da reconstrução e na capacidade de redução de artefatos. Toda a base de ambos os modelos são iguais, sendo a única diferença a presença da saída de predição da máscara de artefatos na segunda versão. Dessa forma, a comparação entre as duas arquiteturas é justa e isolada, permitindo avaliar exclusivamente o impacto da supervisão adicional da máscara de artefatos.




Fig.4.2 Diagrama da arquitetura Dual Supervision.

4.4 Treino reprodutível

4.4.1 Configuração, determinismo e seleção de checkpoint

Os dois modelos foram treinados sob a mesma configuração, com precisão *float32*. Para avaliar a estabilidade face às diferentes inicializações e ordens de apresentação dos lotes, cada arquitetura foi treinada com operações determinísticas e com as sementes 1337, 42 e 2024, sempre sobre a mesma partição dos pacientes. A precisão mista foi desativada e os lotes foram mantidos completos, incluindo o último lote de cada época, de modo a evitar que amostras fossem excluídas do treino, validação ou avaliação.

Foi utilizado o otimizador AdamW, com taxa de aprendizagem inicial de 2.26×10^{-4} , *weight decay* de 1.00×10^{-4} e *gradient clipping* com norma 1.00, idênticos para as duas arquiteturas. A taxa de aprendizagem foi ajustada pelo scheduler *ReduceLROnPlateau*, com fator de redução 0.50, paciência de duas épocas, *cooldown* de uma época e valor mínimo de 1.00×10^{-6} , monitorizando a métrica **SSIM** da imagem reconstruída no conjunto de validação, em ambos os modelos. O treino tinha um limite máximo de 300 épocas e a paragem antecipada só podia ser acionada após, no mínimo, cinco épocas e ocorria quando a métrica monitorizada não melhorava pelo menos 1.00×10^{-4} durante 15 épocas consecutivas. Em cada execução, foi retido o checkpoint correspondente ao melhor valor da métrica de validação monitorizada.

Durante o treino, foram monitorizadas as seguintes quantidades:

- **Perda de reconstrução**, para acompanhar a otimização da imagem corrigida;
- **Perda de segmentação**, apenas no modelo dual, para acompanhar a supervisão auxiliar da máscara;
- **SSIM, PSNR e MAE na escala HU**, calculados na região corporal para acompanhar a fidelidade estrutural e radiométrica das reconstruções.

4.4.2 Função de Perda

- **Reconstrução**: Apesar de L2 ser amplamente utilizada para restauração de imagem, Zhao et al. [43] destacam os melhores resultados de L1 ao estudar diferentes funções de perda para essa tarefa. Os autores também estudaram funções de perda baseadas em **SSIM** e **MS-SSIM**, sendo que a primeira alcança resultados igual ou levemente inferior a L1, enquanto a segunda apresenta desempenho melhor que **SSIM** mas ainda não supera L1 de forma clara. O trabalho também testa um mix de L1 e **MS-SSIM**, e

obteve-se resultados superiores em todas as métricas avaliadas pelos autores. Essa combinação é justificada pela complementaridade entre as duas funções, onde L1 favorece fidelidade local e MS-SSIM promove preservação estrutural, resultando em uma correção mais equilibrada dos artefatos. Embora o melhor resultado relatado pelos autores tenha envolvido L1 e MS-SSIM, neste trabalho adotou-se a soma ponderada de L1 e SSIM. Esta escolha mantém o princípio geral de combinar uma componente de fidelidade por píxel com uma componente estrutural, sem reproduzir a formulação específica nem os pesos utilizados por Zhao et al. Os pesos utilizados para o protocolo experimental foram 0.7 para L1 e 0.3 para SSIM. A relação adotada para a combinação das funções de perda é a seguinte:

$$\mathcal{L}_{Recon} = 0.7 \cdot \mathcal{L}_{L1} + 0.3 \cdot (1 - \text{SSIM})$$

Na perda híbrida, Zhao et al. [43] aplicam uma ponderação espacial Gaussiana à componente L1, de modo a compatibilizá-la com a distribuição espacial dos gradientes da componente MS-SSIM. Neste trabalho, a componente L1 foi calculada diretamente como o erro absoluto médio na região corporal, sem ponderação Gaussiana adicional. Como a normalização utilizada é linear em relação aos valores de HU, esta componente mantém uma penalização diretamente proporcional ao erro radiométrico, enquanto o SSIM contribui para a preservação estrutural local. Essa combinação de função de perda é adotada para a arquitetura *single task* e também para a cabeça de reconstrução da arquitetura *dual*. Dessa forma, garante-se que a ablação entre as duas versões seja justa, isolando o impacto da supervisão adicional da máscara.

- **Supervisão auxiliar da máscara:** A cabeça de predição da máscara de artefatos, presente na arquitetura *dual*, foi treinada com a soma da perda Dice e da Binary Cross-Entropy (BCE). Essa combinação fornece simultaneamente supervisão para a sobreposição global entre as máscaras e para a classificação por píxel, sendo adequada a problemas de segmentação com desequilíbrio de classes [38]. A relação adotada para a combinação das funções de perda é a seguinte:

$$\mathcal{L}_{Seg} = \mathcal{L}_{Dice} + \mathcal{L}_{BCE}$$

A função de perda total para a versão *dual-head* é composta pela ponderação das perdas de reconstrução e segmentação, e é definida como:

$$\mathcal{L} = 1.0 \cdot \mathcal{L}_{Recon} + 0.045 \cdot \mathcal{L}_{Seg}$$

Os experimentos foram executados numa GPU NVIDIA RTX A4500, utilizando Python e TensorFlow/Keras.

4.5 Avaliação interna

Na fase de inferência, os modelos foram avaliados utilizando métricas quantitativas amplamente adotadas na literatura, em comparação com o *Ground Truth*. As métricas utilizadas para a avaliação da qualidade da imagem reconstruída global e por ROI foram:

- **PSNR** ;
- **SSIM** ;
- **MAE**.

Wang et al. [24] descrevem **MS-SSIM** como um método de avaliação de qualidade de imagem através de cinco escalas com *downsampling* iterativo por fator 2, resultando em uma redução de resolução de até 1/16 do tamanho original. O método foi validado em bases de dados de imagens completas, sem considerar aplicação em regiões fragmentadas ou espacialmente seletivas. Devido ao *downsampling* progressivo, a aplicação **MS-SSIM** em **ROIs** pequenas ou fragmentadas (como a zona distante em nossa análise) resultaria na mistura de pixels de **ROI** e não-ROI nas escalas reduzidas, comprometendo a interpretabilidade dos resultados. Por isso, utilizou-se **SSIM** regular em vez de **MS-SSIM** nesse trabalho. De fato, as literaturas recentes tem demonstrado performance estatisticamente muito melhor em fidelidade para **MS-SSIM** e **SSIM** comparado a outras métricas de avaliação de qualidade de imagem[44]. Especialmente para imagens médicas, onde a fidelidade das imagens preditas é crucial, a escolha de métricas que refletem a percepção humana de qualidade e preservação estrutural é fundamental. Portanto, **SSIM** foi selecionado como a principal métrica para avaliação quantitativa da qualidade das imagens reconstruídas, garantindo uma análise robusta e relevante para o contexto clínico. E o **PSNR** foi utilizado como métrica complementar para avaliar a fidelidade radiométrica das reconstruções, especialmente importante em tomografias computadorizadas onde a precisão dos valores de **HU** é essencial para diagnóstico e planejamento clínico.

A validação interna foi conduzida nos conjuntos de validação e teste, avaliando consistência, estabilidade e capacidade de generalização intra-*dataset*.

Após a seleção do melhor checkpoint de cada uma das seis corridas na validação, os checkpoints foram comparados na partição de teste interna para selecionar a candidata à avaliação externa. A decisão privilegiou a maior melhoria de **SSIM** na Zona de Artefacto e

globalmente, seguida de melhor PSNR e MAE na Zona de Artefacto e globalmente como forma de desempate. Após essa comparação, a corrida selecionada foi congelada, sem novo treino, ajuste de hiperparâmetros ou alteração dos pesos antes da avaliação externa.

4.5.1 Métricas globais

Para a avaliação global, as imagens preditas e de referência são desnormalizadas para a janela $[-1000, 400]$ HU, correspondendo a uma amplitude $MAX = 1400$ HU. Adicionalmente, a região de avaliação é recortada ao menor retângulo envolvente (*bounding box*) da máscara corporal antes da avaliação de SSIM, eliminando janelas de varredura compostas exclusivamente por fundo — que pontuariam $SSIM = 1,0$ artificialmente e inflariam a métrica global.

Como verificação descritiva complementar de possível deslocamento radiométrico global, foi construído um diagrama de Bland–Altman entre a reconstrução e a referência limpa. Para cada paciente, a média em HU de cada imagem foi calculada sobre todos os pixels válidos da máscara corporal das respectivas fatias, ponderada pelo número de pixels de cada fatia. O gráfico apresenta a diferença média por paciente ($Model - GT$) em função da média das duas medidas, bem como o viés médio e os limites de concordância $\bar{d} \pm 1,96 SD_d$. Esta análise tem caráter exclusivamente descritivo, com o paciente como unidade do gráfico, e não substitui as métricas de fidelidade nem a avaliação regional da redução de artefactos.

4.5.2 Avaliação por regiões de interesse

A avaliação global não distingue o comportamento do modelo nas regiões diretamente afetadas pelos artefatos daquele nas regiões corporais distantes do implante. Por isso, cada fatia foi dividida em duas zonas complementares a partir da diferença entre a entrada com artefatos e a referência limpa. Sejam I_{in} a imagem de entrada, I_{ref} a referência limpa e M_{body} a máscara corporal. Calculou-se a diferença assinada $d = I_{ref} - I_{in}$ e removeu-se o seu valor mediano no corpo, $b = \text{mediana}(d \mid M_{body})$, evitando que um desvio global associado ao endurecimento de feixe fosse interpretado como artefato local.

A Zona de Artefato ($\mathcal{R}_{art}$) foi definida por

$$M_{art} = [|d - b| > \tau] \cap M_{body}, \quad \tau = 0,03,$$

valor equivalente a aproximadamente 42 HU na escala normalizada utilizada. Componentes conectados com menos de 20 pixels foram removidos. Não foi aplicada dilatação morfológica adicional ($r = 0$), preservando a geometria observada dos *streaks*. A Zona Distante ($\mathcal{R}_{dist}$) foi

definida como o complemento da zona de artefato na região corporal,

$$M_{\text{dist}} = M_{\text{body}} \setminus M_{\text{art}}.$$

Esta zona quantifica alterações fora da região diretamente afetada; a interpretação clínica da preservação anatômica foi reservada à avaliação externa por leitores.

A [Figure 4.3](#) ilustra a aplicação das duas zonas em fatias representativas do conjunto de dados, cobrindo diferentes regiões anatômicas e padrões de artefato.




Fig.4.3 Exemplos de zonas de ROI em fatias de CT com artefatos metálicos. Em cada par, a imagem da esquerda mostra a Zona de Artefato ($\mathcal{R}_{art}$, sobreposição a vermelho) e a da direita a Zona Distante ($\mathcal{R}_{dist}$, sobreposição a verde). As fatias cobrem anatomias torácica (topo), abdominal (meio) e torácica com implante unilateral (base), ilustrando a variabilidade da extensão e forma da zona de artefato em função da localização e número de implantes metálicos.

Em todos os contextos de avaliação, as métricas foram expressas como variações relativamente ao desempenho da entrada corrompida. Seja Ω o domínio de avaliação, que pode corresponder à região global definida acima (Ω_{global}), à Zona de Artefato ($\mathcal{R}_{\text{art}}$) ou à Zona Distante ($\mathcal{R}_{\text{dist}}$), e seja $\hat{I}$ a reconstrução produzida pelo modelo. As variações foram definidas por:

$$\Delta\text{PSNR}_{\Omega} = \text{PSNR}(\hat{I} \mid_{\Omega}, I_{\text{ref}} \mid_{\Omega}) - \text{PSNR}(I_{\text{in}} \mid_{\Omega}, I_{\text{ref}} \mid_{\Omega})$$

$$\Delta\text{SSIM}_{\Omega} = \text{SSIM}(\hat{I} \mid_{\Omega}, I_{\text{ref}} \mid_{\Omega}) - \text{SSIM}(I_{\text{in}} \mid_{\Omega}, I_{\text{ref}} \mid_{\Omega})$$

$$\Delta\text{MAE}_{\Omega} = \text{MAE}(I_{\text{in}} \mid_{\Omega}, I_{\text{ref}} \mid_{\Omega}) - \text{MAE}(\hat{I} \mid_{\Omega}, I_{\text{ref}} \mid_{\Omega}).$$

Assim, $\Delta\text{PSNR} > 0$ e $\Delta\text{SSIM} > 0$ indicam melhoria face à entrada corrompida. Como menor **MAE** representa melhor fidelidade, a ordem da subtração foi invertida para essa métrica: $\Delta\text{MAE} > 0$ indica redução do erro e, portanto, melhoria; $\Delta\text{MAE} < 0$ indica aumento do erro. Utilizou-se **SSIM** regular, calculado com janela local de 11×11 pixels e recorte com contexto em redor da região avaliada.

Table 4.8 Métricas utilizadas por contexto de avaliação.

Métrica	Treino	Global	ROI Artefato	ROI Distante
PSNR	✓	✓	✓	✓
SSIM	✓	✓	✓	✓
MAE	✓	✓	✓	✓

4.5.3 Análise estatística

Em todas as análises inferenciais, o paciente constituiu a unidade experimental independente. Para evitar pseudorreplacação decorrente da inclusão de múltiplas fatias de um mesmo paciente, as métricas calculadas por fatia foram primeiro agregadas pela média dentro de cada paciente. Assim, para cada métrica m e paciente p , foram comparados valores pareados da entrada e da reconstrução, ou das duas arquiteturas, conforme a análise.

Para avaliar a melhoria face à entrada corrompida, foram calculadas as diferenças pareadas por paciente $d_p = m_{\text{Model},p} - m_{\text{Input},p}$ para **PSNR** e **SSIM**. Para **MAE**, cuja redução representa melhor desempenho, utilizou-se $d_p = m_{\text{Input},p} - m_{\text{Model},p}$. A hipótese nula em cada teste foi que a mediana das diferenças pareadas era igual a zero. A comparação direta entre arquiteturas

utilizou $d_p = m_{\text{Dual},p} - m_{\text{Single},p}$, de modo que valores negativos favorecem o Single Model. Os valores de p brutos foram obtidos pelo teste de postos sinalizados de Wilcoxon bilateral, com nível de significância $\alpha = 0,05$.

Os valores de p apresentados nas tabelas de comparação foram ajustados pelo procedimento sequencial de Holm, que controla a taxa de erro familiar sem pressupor independência entre os testes. Para os m valores de p brutos ordenados, $p_{(1)} \leq \dots \leq p_{(m)}$, o valor ajustado na posição i foi calculado como

$$p_{(i)}^{\text{Holm}} = \max_{j \leq i} \left\{ \min \left[1, (m - j + 1)p_{(j)} \right] \right\}.$$

Na tabela de melhoria da reconstrução, a correção foi aplicada conjuntamente aos quatro testes correspondentes a **PSNR** e **SSIM** para cada uma das duas arquiteturas. Na comparação pareada Single Model versus Dual Model, a correção foi aplicada conjuntamente aos dois testes, um para **PSNR** e outro para **SSIM**.

Os intervalos de confiança de 95% reportados para as diferenças médias foram obtidos por *bootstrap* percentil ao nível do paciente. Para cada métrica, o vetor de $n = 41$ diferenças pareadas por paciente foi reamostrado com reposição, mantendo n observações em cada reamostra; a média da diferença foi então calculada em cada uma das 10 000 reamostragens. Os limites inferior e superior do intervalo correspondem, respetivamente, aos percentis 2,5 e 97,5 da distribuição empírica dessas médias. Este procedimento não pressupõe normalidade das diferenças e preserva o paciente, e não a fatia, como unidade de inferência. Foi utilizada a semente 1337 para tornar as reamostragens determinísticas. As análises por **ROI** foram apresentadas de forma descritiva, mantendo a interpretação clínica da preservação anatômica para a avaliação externa por leitores.

4.6 Avaliação externa por médicos

A validação externa foi realizada em dados independentes provenientes do **The Cancer Imaging Archive (TCIA)**, permitindo avaliar o impacto de *domain shift* e a robustez do modelo em cenários não vistos durante o treino.

4.6.1 Desenho e casos

[A preencher: estudo observacional, transversal, multileitor e cego quanto à condição A/B; conjunto TCIA, 2 casos de treino excluídos da análise, 15 casos principais e 2 repetições ocultas.]

4.6.2 Caracterização quantitativa entrada–saída

Como caracterização complementar da alteração introduzida pelo modelo nos casos externos, foram calculados **SSIM**, **PSNR** e **MAE** diretamente entre a imagem de entrada e a respetiva saída do *Single Model*, seed 2024. As métricas foram avaliadas apenas nos 15 casos principais do conjunto externo congelado; os dois casos de treino foram excluídos. O domínio de cálculo foi a máscara corporal efetiva, corrigida manualmente durante a preparação dos casos. Para **PSNR**, utilizou-se a janela de intensidade $[-1000, 400]$ HU, com amplitude de 1400 HU.

Não existe referência limpa para estes casos reais. Assim, **SSIM** e **PSNR** maiores, bem como **MAE** menor, descrevem menor alteração global entre entrada e saída, e não maior acurácia de remoção de artefactos nem melhoria face a uma referência. As estatísticas foram resumidas por caso, como média e desvio-padrão, e os intervalos de confiança de 95% para a média foram obtidos por *bootstrap* percentil com 10 000 reamostragens e semente 1337. A interpretação da aceitabilidade clínica dessas alterações permaneceu reservada para a avaliação cega por leitores.

4.6.3 Participantes e proteção de dados

[A preencher: recrutamento direto, autodeclaração de uso mensal de CT, categorias profissionais retidas e ausência de identificadores diretos.]

4.6.4 Apresentação e instrumento de avaliação

[A preencher: apresentação simultânea e contrabalanceada de entrada/saída como Imagem A/B; escalas ordinais para interferência do artefacto e visualização anatómica, preferência pareada e sinalização de possível dano.]

4.6.5 Desfechos e análise

[A preencher: desfecho primário de diferença pareada na visualização de tecidos e limites anatómicos; desfechos secundários, consistência intraleitor e análise ordinal compatível com amostra pequena.]

4.6.6 Estado operacional

[A preencher: distinguir claramente pré-produção, piloto e recolha concluída; não apresentar resultados clínicos antes da recolha aprovada e concluída.]

Chapter 5

Resultados

5.1 Coorte final e integridade experimental

5.1.1 Resultados da Aprovação Automática x Inspeção Manual

É importante deixar claro como ficou a distribuição dos dados que foram aprovados e reprovados automaticamente, e também quais foram avaliados manualmente. O gráfico abaixo, mapeia todos os pares do [CT-MAR](#) Dataset, destacando os que foram aprovados automaticamente, os que foram reprovados e os que foram sujeitos a inspeção visual humana. A distribuição anatômica dos pares é representada por cores, permitindo uma análise visual da relação entre a aprovação automática e a localização anatômica dos artefatos metálicos.

5.1.2 Análise Complementar com [MS-SSIM](#)

Antes de avançar para a análise dos resultados dos modelos de redução de artefatos, foi realizada mais uma avaliação dos resultados [CT-MAR](#) x DeepLesion/Stroke EIT para verificar a qualidade das correspondências automáticas. Esta etapa é crucial para garantir uma camada extra de confiança nos resultados obtidos pelo algoritmo de comparação de similaridade estrutural. Todos os pares que tiveram a correspondência aprovada automaticamente pelo fato de seu score ser acima de 0.994 foram revisados por um novo algoritmo que calcula o [MS-SSIM](#) entre as imagens correspondentes. Um histograma da distribuição dos [MS-SSIM](#) foi gerado, e os pares com pontuação menor que 0.9 foram revisados manualmente sendo aprovado ou recusado com base em avaliação humana.




Fig.5.1 Distribuição de MS-SSIM entre pares correspondentes (CT-MAR vs DL/Stroke, aprovados automaticamente). Acima: histograma com os percentis P1 e P5, mediana, média e limiar de 0.9. Abaixo: zoom do histograma para a região de maior interesse, com destaque para os pares com MS-SSIM inferior a 0.9, que foram sujeitos a revisão manual.

A análise da distribuição entre os pares correspondentes revela que a maioria dos pares apresenta alta similaridade estrutural, com um valor médio de 0.9694 e uma mediana de 0.9830, indicando que o processo de correspondência automática é, em geral, confiável e eficaz na identificação de pares correspondentes entre os datasets CT-MAR e DeepLesion/Stroke EIT.

Os pares com pontuação de **MS-SSIM** abaixo de 0.9 eram 340 no total, apenas 3 foram reprovados após inspeção visual humana 5.2. Nessa inspeção, percebe-se que mesmo os casos com pontuações bastante baixas de **MS-SSIM** não eram falsos positivos e sim devido a diferenças no pós-processamento ou tratamento geral das imagens que geram alterações locais no qual o **MS-SSIM** é mais sensível. Isso pode ser visualizado na figura 5.3. Esse fato evidencia a eficácia da estratégia de correspondência por similaridade estrutural global adotada, que conseguiu identificar os pares com precisão, com apenas 3 falsos positivos identificados, mesmo após análise rigorosa 5.4. Mostrando que a metodologia é robusta e teve desempenho superior em detectar slices nesse trabalho do que uso do próprio **MS-SSIM**. Pois, enquanto as diferenças locais afetaram o **MS-SSIM** de forma mais significativa, a metodologia baseada em similaridade de cosseno conseguiu identificar as correspondências corretas com pontuação global elevada, mesmo em casos de diferenças locais acentuadas.




Fig.5.2 Distribuição de MS-SSIM entre pares correspondentes (**CT-MAR** vs DL/Stroke, aprovados automaticamente). À esquerda: histograma com os percentis P1 e P5, mediana, média e limiar de 0.9. À direita: ECDF correspondente. Os pares com MS-SSIM inferior a 0.9 foram sujeitos a revisão manual.




Fig.5.3 Exemplos de pares correspondentes com valores de **MS-SSIM** (0.7597, 0.7694 e 0.7717, respetivamente) aprovados após revisão visual humana mesmo com pontuações baixas.

Os pares reprovados apresentavam **MS-SSIM** claramente fora do padrão (< 0.61), com valores extremamente baixos, como podem ver na figura 5.4. Além disso, representaram os pares com pontuação mais próximas do limiar de aceitação automática de 0.994 5.5. Demonstrando que os casos em que o método falha são outliers claros em **MS-SSIM** e permanecem justamente na zona cinzenta e propensa a erros da determinação empírica do limiar de aceitação

automática. Além disso, os pares reprovados possuem características visuais bastante particulares com fundo dominando a imagem e poucas estruturas anatômicas visíveis, o que torna a avaliação de similaridade estrutural mais desafiadora devido a grande homogeneidade das características visuais.




Fig.5.4 3 pares reprovados após inspeção visual humana com valores de MS-SSIM (head_1159: 0.4573, head_369: 0.5652 e head_763: 0.6009, respetivamente). As pontuações desses pares na similaridade de cosseno foram head_1159: 0.9960, head_369: 0.9952 e head_763: 0.9951.




Fig.5.5 Distribuição dos valores de similaridade de cosseno para os pares inspecionados visualmente.

Os pares com **MS-SSIM** mais críticos logo acima dos reprovados tinham valores maiores que 0.75 [5.3](#), demonstrando uma distancia clara entre os falsos positivos e os aprovados visualmente. Todos os pares inspecionados com pontuação acima desse valor de **MS-SSIM** passaram no teste de inspeção visual [5.6](#). Como os pares que não passaram por esse escrutínio tinham pontuação acima de 0.90 em **MS-SSIM**, é seguro assumir que os pares automaticamente aprovados com pontuação acima desse limiar são confiáveis.




Fig.5.6 Distribuição dos valores de **MS-SSIM** para os pares inspecionados visualmente.

Na busca direta, 530 pares não obtiveram correspondência aprovada em nenhum dos dois datasets de origem. A etapa complementar de correspondência indireta recuperou 95 desses casos após inspeção visual, restando 435 pares sem correspondência segura.

Com relação aos possíveis falsos negativos que poderiam ter resultado em exclusão de pares de forma injusta nesse estudo, a metodologia adotada foi ainda mais robusta. Já que eram poucos os pares que não tiveram aprovação em nenhum dos dois datasets de origem, ficou fácil verificar visualmente cada um desses casos para confirmar se realmente não havia correspondência ou se o método falhou em identificá-la. Dos 435 pares excluídos 245 foram excluídos devido ao critério automatizado baseado no limiar de 0.98. Nenhum desses casos eram realmente falsos negativos, confirmando mais uma vez a eficácia do método de correspondência automática adotado. Os outros 190 pares caíram na faixa de pontuação pouco confiável (0.98 – 0.994) e foram marcados como falsa correspondência nessa etapa evidenciando a importância de ter-se determinado uma zona cinzenta de pontuação para a qual o método de correspondência automática não é eficiente, e que a revisão visual humana torna-se indispensável 5.7.




Fig.5.7 Distribuição dos *scores* de similaridade de cosseno (DL vs Stroke EIT) para os pares sem correspondência aprovada em nenhum dos dois *datasets* de origem (N=435). Histograma laranja mostra a distribuição das pontuações dos 435 pares reprovados no Stroke EIT Dataset. O histograma em azul, mostra a distribuição dos mesmos 435 pares reprovados no Deep Lesion Dataset.

5.2 Treino dos modelos

5.2.1 Convergência e seleção dos checkpoints

A seleção do *checkpoint* para avaliação final foi baseada na melhor versão do **SSIM** calculado na partição de validação. Obviamente, no modelo Dual, esse critério foi aplicado na saída de reconstrução. Apenas o melhor checkpoint por corrida foi preservado, em formato .keras, com nome que contém arquitetura, época e métrica monitorizada. O CSV de treino marca explicitamente a linha correspondente com `best_checkpoint=1`.

A regra de paragem definia um máximo de épocas de 300 e um mínimo de 5, com *Early Stopping* após 15 épocas sem melhoria mínima de 0.0001 no **SSIM** da partição de validação. Consequentemente, devido à restauração dos pesos da melhor época, a época final de treino não é necessariamente a selecionada.

O otimizador monitoriza a mesma métrica, reduzindo o *learning rate* em 0.5 após 2 épocas sem melhoria relevante (`ReduceLROnPlateau`), até 1×10^{-6} com uma época de *cooldown*. O mesmo valor de variação mínima de 0.0001 foi usado no *Scheduler* e no *Early Stopping*.




Fig.5.8 Curvas de convergência para `seed_1337/training_001_dualhead`. Linhas verticais laranja pontilhadas: reduções da taxa de aprendizagem; linha roxa tracejada: época do melhor checkpoint segundo o SSIM de validação; linha preta traço-ponto: interrupção do treino. O painel de *generalization gap* representa validação menos treino para o SSIM e permite identificar divergência persistente compatível com sobreajuste.




Fig.5.9 Curvas de convergência para `seed_1337/training_008_singlehead`. Linhas verticais laranjas pontilhadas: reduções da taxa de aprendizagem; linha roxa tracejada: época do melhor checkpoint segundo o SSIM de validação; linha preta traço-ponto: interrupção do treino. O painel de *generalization gap* representa validação menos treino para o SSIM e permite identificar divergência persistente compatível com sobreajuste.




Fig.5.10 Curvas de convergência para `seed_2024/training_001_dualhead`. Linhas verticais laranjas pontilhadas: reduções da taxa de aprendizagem; linha roxa tracejada: época do melhor checkpoint segundo o SSIM de validação; linha preta traço-ponto: interrupção do treino. O painel de *generalization gap* representa validação menos treino para o SSIM e permite identificar divergência persistente compatível com sobreajuste.




Fig.5.11 Curvas de convergência para `seed_2024/training_001_singlehead`. Linhas verticais laranjas pontilhadas: reduções da taxa de aprendizagem; linha roxa tracejada: época do melhor checkpoint segundo o SSIM de validação; linha preta traço-ponto: interrupção do treino. O painel de *generalization gap* representa validação menos treino para o SSIM e permite identificar divergência persistente compatível com sobreajuste.




Fig.5.12 Curvas de convergência para `seed_42/training_001_dualhead`. Linhas verticais laranjas pontilhadas: reduções da taxa de aprendizagem; linha roxa tracejada: época do melhor checkpoint segundo o SSIM de validação; linha preta traço-ponto: interrupção do treino. O painel de *generalization gap* representa validação menos treino para o SSIM e permite identificar divergência persistente compatível com sobreajuste.




Fig.5.13 Curvas de convergência para `seed_42/training_001_singlehead`. Linhas verticais laranja pontilhadas: reduções da taxa de aprendizagem; linha roxa tracejada: época do melhor checkpoint segundo o SSIM de validação; linha preta traço-ponto: interrupção do treino. O painel de *generalization gap* representa validação menos treino para o SSIM e permite identificar divergência persistente compatível com sobreajuste.

Nas 6 corridas, todas terminaram entre 38 e 47 épocas, após a taxa de aprendizagem atingir o limite mínimo. Os melhores **SSIMs** de validação ocorreram nas épocas 23–44, antes da paragem, o que sustenta o uso de restauração dos melhores pesos.

O maior valor de **SSIM** foi 0.95113 do Single Model, seed 2024, na época 33. O valor de **PSNR** variou entre ~ 35.0 dB - 35.3 dB, com o maior valor de 35.3009 dB do Single Model, seed 2024, na mesma época 33. Os resultados detalhados podem ser visualizados nas Tabelas 5.1, 5.2 e 5.3.

Seed	Best SSIM (HU)		
	42	1337	2024
Single Model	0.95096 (31)*	0.95106 (44)	0.95113 (33)
Dual Model	0.94938 (41)	0.94895 (28)	0.95025 (23)

*Valores entre parênteses indicam a época correspondente.

Table 5.1 Maior SSIM de validação por modelo e seed, com a época correspondente. No Dual Model, o SSIM é calculado na saída de reconstrução de imagem.

Seed	PSNR (dB) - Same Best SSIM Epoch		
	42	1337	2024
Single Model	35.16365 (31)	35.20020 (44)	35.30099 (33)
Dual Model	35.10422 (41)	35.00705 (28)	35.23622 (23)

Table 5.2 PSNR de validação na época selecionada pelo melhor SSIM de validação, por modelo e seed. No Dual Model, ambas as métricas são calculadas na saída de reconstrução de imagem.

Seed	MAE (HU) - Same Best SSIM Epoch		
	42	1337	2024
Single Model	17.52002 (31)	17.36296 (44)	17.19180 (33)
Dual Model	17.58006 (41)	17.73584 (28)	17.35387 (23)

Table 5.3 MAE de validação na época selecionada pelo melhor SSIM de validação, por modelo e seed. No Dual Model, ambas as métricas são calculadas na saída de reconstrução de imagem.

O melhor resultado de **MAE** foi 17.1918 HU também do Single Model, seed 2024, na época 33. Podemos notar que o Single Model teve desempenho superior nas 3 métricas.

O **PSNR** e **MAE** são apenas métricas complementares, mas não são o foco principal de seleção do melhor checkpoint que considera apenas o **SSIM** isoladamente. Além disso, as métricas separadas por **ROI**, análises visuais, e métricas de teste interno são avaliações feitas após a seleção do melhor checkpoint e portanto não alteram o checkpoint escolhido.

A escolha da corrida que avançará para a avaliação externa é uma decisão distinta da seleção do checkpoint. Entre os checkpoints já selecionados, a comparação é efetuada na partição de teste, buscando equilíbrio entre a maior melhoria de **SSIM** na Zona de Artefacto e menor mudança de **SSIM** na Zona Distante. Após essa seleção não houve novo treino, ajuste de hiperparâmetros ou alterações nos pesos antes da avaliação externa.

5.2.2 Rastreabilidade das execuções

A rastreabilidade das execuções foi assegurada através de *snapshots* de reprodutibilidade em formato JSON, preservados em `outputs/reproducibility/`. Foram congeladas seis avaliações internas finais, correspondentes às três inicializações aleatórias (seeds 42, 1337 e 2024) dos modelos Single Model e Dual Model. Todos os snapshots foram gerados a partir do commit `a950be7276a5585de45e8ae874c59c065a1985be`, no ramo `projeto_final`, com árvore de trabalho limpa (`is_dirty: false`).

Cada snapshot registra o sistema operativo, a versão do Python e as versões das dependências relevantes. O ambiente de execução utilizou Python 3.11.9 em Windows 10, incluindo TensorFlow 2.15.0, NumPy 1.26.4, Pandas 2.2.2, scikit-image 0.21.0 e Matplotlib 3.7.5. Além disso, foram calculados hashes SHA-256 dos ficheiros de configuração, do manifesto canónico de pares, da definição da partição por paciente, dos metadados de geração dos tensores e do ficheiro de requisitos do ambiente.

Para cada execução, o snapshot preserva o caminho, tamanho e hash SHA-256 do checkpoint, o comando completo usado na avaliação no conjunto de teste e os hashes dos ficheiros de saída, incluindo as métricas agregadas e as métricas por amostra. Assim, cada valor, tabela ou figura reportado pode ser associado de forma inequívoca ao código, ambiente, dados de entrada, checkpoint e resultados que o originaram.

A seleção dos checkpoints foi efetuada exclusivamente com base na métrica de validação pré-especificada: `val_ssim_hu` no Single Model e `val_img_out_ssim_hu` na saída de reconstrução do Dual Model.

5.3 Avaliação interna no conjunto de teste

5.3.1 Desfechos globais

A avaliação interna foi realizada na partição de teste fixa, composta por 1478 fatias de 41 pacientes independentes. Para cada checkpoint previamente selecionado na validação, foram calculados PSNR, SSIM e MAE entre a reconstrução e a referência limpa. A unidade de agregação para a inferência estatística foi o paciente: as métricas foram primeiro resumidas dentro de cada paciente e os intervalos de confiança de 95% foram obtidos por *bootstrap* percentil com 10000 reamostragens. O conjunto de teste não foi utilizado para escolher checkpoints.

A [Table 5.5](#), [a Table 5.4](#) e [a Table 5.6](#) apresentam as médias por fatia. Como todas as corridas foram avaliadas na mesma partição de teste, o valor da entrada é comum aos dois

modelos em cada seed. Em todas as corridas, a reconstrução aumentou o PSNR global de 27,39 dB para 34,95–35,20 dB, aumentou o SSIM de 0,8361 para 0,9421–0,9442 e reduziu o MAE de 36,6 HU para 17,3–17,8 HU.

SSIM global

Seed	Input	Single Model	Dual Model
42	0.8361 ± 0.0880	0.9439 ± 0.0289	0.9424 ± 0.0292
1337	0.8361 ± 0.0880	0.9441 ± 0.0286	0.9421 ± 0.0289
2024	0.8361 ± 0.0880	0.9442 ± 0.0288	0.9432 ± 0.0292

All input and model values are computed against the clean reference (*ground truth*).

Table 5.4 SSIM global por fatia no conjunto de teste ($n = 1478$), expresso como média $\pm$ desvio padrão.

PSNR global (dB)

Seed	Input	Single Model	Dual Model
42	27.39 ± 4.14	35.09 ± 2.82	35.06 ± 2.84
1337	27.39 ± 4.14	35.13 ± 2.81	34.95 ± 2.82
2024	27.39 ± 4.14	35.20 ± 2.84	35.16 ± 2.82

All input and model values are computed against the clean reference (*ground truth*).

Table 5.5 PSNR global por fatia no conjunto de teste ($n = 1478$), expresso como média $\pm$ desvio padrão.

MAE global (HU)

Seed	Input	Single Model	Dual Model
42	36.569 ± 21.906	17.649 ± 5.689	17.654 ± 5.905
1337	36.569 ± 21.906	17.485 ± 5.624	17.842 ± 5.789
2024	36.569 ± 21.906	17.341 ± 5.573	17.475 ± 5.563

All input and model values are computed against the clean reference (*ground truth*).

Table 5.6 MAE global por fatia no conjunto de teste ($n = 1478$), expresso como média $\pm$ desvio padrão.

Embora a seleção do extitSingle Model, seed 2024, tenha sido definida na validação, as tabelas por semente mostram que esta não corresponde a um resultado isolado: as três execuções do Single Model apresentaram desempenho global muito próximo e superior ao das execuções Dual Model. A seed 2024 ficou no extremo favorável para acrshortssim e acrshort-psnr, e apresentou o menor acrshortmae. Esta comparação entre sementes é descritiva, não constituindo um teste de hipótese entre inicializações.

Os deltas e respetivos intervalos de confiança por paciente são apresentados na Table 5.8, na Table 5.7 e na Table 5.9. Todas as corridas melhoraram as três métricas; os testes de Wilcoxon bilaterais foram significativos para os três desfechos em todas as corridas ($p < 0,001$). Os intervalos de confiança não incluem o valor nulo, sustentando a melhoria global face à entrada com artefactos.

Para a corrida selecionada, Single Model com seed 2024, os histogramas da Figure 5.14 mostram a distribuição dos deltas globais por fatia. Embora estes gráficos sejam descritivos e as fatias de um mesmo paciente não sejam independentes, eles tornam visíveis os poucos

Δ SSIM Global (IC 95%)

Seed	Single Model	Dual Model
42	0.0887 [0.0728; 0.1063]	0.0870 [0.0713; 0.1043]
1337	0.0891 [0.0734; 0.1065]	0.0867 [0.0710; 0.1041]
2024	0.0891 [0.0732; 0.1066]	0.0879 [0.0719; 0.1053]

Note: Δ SSIM = SSIM(Model, GT) – SSIM(Input, GT).

Table 5.7 Δ SSIM global agregado por paciente no conjunto de teste ($n = 41$). IC: intervalo de confiança de 95%.

 Δ PSNR Global (dB, IC 95%)

Seed	Single Model	Dual Model
42	6.96 [6.22; 7.68]	6.96 [6.24; 7.65]
1337	7.05 [6.33; 7.75]	6.85 [6.12; 7.55]
2024	7.11 [6.36; 7.83]	7.06 [6.31; 7.78]

Note: Δ PSNR = PSNR(Model, GT) – PSNR(Input, GT).

Table 5.8 Δ PSNR global agregado por paciente no conjunto de teste ($n = 41$). IC: intervalo de confiança de 95%.

 Δ MAE Global (HU, IC 95%)


Seed	Single Model	Dual Model
42	15.3 [12.2; 19.0]	15.3 [12.3; 18.9]
1337	15.6 [12.4; 19.3]	15.2 [12.1; 18.8]
2024	15.7 [12.5; 19.5]	15.5 [12.4; 19.3]

Note: Δ MAE = MAE(Input, GT) – MAE(Model, GT); positive values indicate error reduction.

Table 5.9 Δ MAE global agregado por paciente no conjunto de teste ($n = 41$). Valores > 0 representam melhoria; IC: intervalo de confiança de 95%.

casos desfavoráveis: 12 de 1478 fatias (0,8%) apresentaram Δ PSNR negativo e 24 (1,6%) apresentaram Δ SSIM negativo. A inferência estatística permanece baseada nas médias por paciente apresentadas nas tabelas anteriores.

Single Model — Global per Image Improvement



Single Model — Global per Image Improvement




Fig.5.14 Per-image global improvement over the corrupted input for the Single Model, seed 2024: Δ SSIM (top) and Δ PSNR (bottom). Green bars indicate improvement and red bars indicate degradation. The distributions are descriptive; inferential analyses used patient-level aggregation.

Nota-se que o Single Model para as sementes 1337 e 2024 apresentam praticamente o mesmo desempenho em **SSIM**. No entanto, em **PSNR** e **MAE** o mesmo modelo se sai melhor com a seed 2024. Isso já coloca a versão Single com semente 2024 em evidência para ser o candidato selecionado para a avaliação externa. Porém, ainda é necessário verificar o desempenho por **ROI**, já que essas métricas são muito mais informativas a respeito de onde o modelo está realmente melhorando a imagem.

Como verificação descritiva complementar da calibração global em unidades HU, a **Figure 5.15** apresenta a concordância entre a média de HU da reconstrução e a da referência limpa, agregada por paciente. Cada ponto corresponde a um dos 41 pacientes, a média de cada paciente foi calculada sobre todos os pixels válidos da máscara corporal, ponderada pelo número de pixels em cada fatia. O viés médio foi de +4.19 HU, com limites de concordância de 95% entre +1.45 e +6.93 HU. Esta análise descreve um pequeno deslocamento positivo da intensidade média global, mas não quantifica a remoção local de artefactos nem substitui as métricas globais e por **ROI**.




Fig.5.15 Bland-Altman agreement between the Single Model reconstruction and the clean reference for patient-level mean HU ($n = 41$). Each patient mean was calculated over all valid body-mask pixels; positive differences indicate higher mean HU in the reconstruction. The limits of agreement are descriptive.

5.3.2 Avaliação por regiões de interesse

As regiões de interesse e o cálculo das métricas por zona seguiram o procedimento descrito na [subsection 4.5.2](#). Esta estratificação permite quantificar separadamente a correção na região diretamente afetada pelos artefactos e as alterações introduzidas nas regiões corporais distantes do implante.

Os resultados finais, agregados primeiro por paciente e depois resumidos em 41 pacientes independentes, são apresentados nas [Table 5.11](#), [Table 5.10](#) e [Table 5.12](#). Todas as seis corridas apresentaram melhoria substancial na Zona de Artefacto: Δ PSNR entre 11,47 e 11,86 dB, Δ SSIM entre 0,322 e 0,328 e redução de [MAE](#) entre 96,9 e 98,5 HU. Na Zona Distante, as alterações médias foram menores (Δ PSNR entre 1,36 e 1,61 dB; Δ SSIM entre 0,057 e 0,058; redução de [MAE](#) entre 3,2 e 3,6 HU), devendo ser interpretadas como descrição quantitativa e não como validação clínica de preservação anatômica.

Δ SSIM			
Seed	Model	Artifact ROI	Clean ROI
42	Single Model	0.3276 ± 0.0954	0.0579 ± 0.0426
	Dual Model	0.3233 ± 0.0937	0.0568 ± 0.0421
1337	Single Model	0.3278 ± 0.0933	0.0582 ± 0.0421
	Dual Model	0.3224 ± 0.0953	0.0566 ± 0.0422
2024	Single Model	0.3279 ± 0.0955	0.0581 ± 0.0422
	Dual Model	0.3266 ± 0.0954	0.0576 ± 0.0422

Note: Δ SSIM = SSIM(Model, GT) – SSIM(Input, GT) within the indicated ROI.

Table 5.10 Δ SSIM por ROI no conjunto de teste. Os valores são média $\pm$ desvio-padrão entre pacientes ($n = 41$).

Δ PSNR (dB)			
Seed	Model	Artifact ROI	Clean ROI
42	Single Model	11.75 ± 2.59	1.46 ± 1.43
	Dual Model	11.65 ± 2.53	1.48 ± 1.43
1337	Single Model	11.84 ± 2.54	1.53 ± 1.35
	Dual Model	11.47 ± 2.57	1.36 ± 1.52
2024	Single Model	11.86 ± 2.69	1.61 ± 1.41
	Dual Model	11.84 ± 2.62	1.53 ± 1.48

Note: Δ PSNR = PSNR(Model, GT) – PSNR(Input, GT) within the indicated ROI.

Table 5.11 Δ PSNR por ROI no conjunto de teste. Os valores são média $\pm$ desvio-padrão entre pacientes ($n = 41$).

Novamente, o Single Model com sementes 1337 e 2024 apresentam desempenhos muito semelhantes em [SSIM](#), com a semente 2024 levando uma minúscula vantagem. Já na análise por ROI, o melhor desempenho em [PSNR](#) e [MAE](#) com a semente 2024 fica menos evidente do que na análise global, especialmente quando considera-se as alterações na Zona Limpa. Mesmo assim, as alterações na Zona Limpa são pequenas e varia pouco entre os modelos e sementes. Dessa forma, foi decidido priorizar o desempenho da semente na análise Global e por ROI (mesmo que muito pequena) para selecionar o modelo que seguirá para a avaliação

$\Delta\text{MAE (HU)}$

Seed	Model	Artifact ROI	Clean ROI
42	Single Model	97.8 ± 19.6	3.3 ± 3.2
	Dual Model	97.5 ± 19.1	3.4 ± 3.1
1337	Single Model	98.5 ± 19.6	3.5 ± 3.1
	Dual Model	96.9 ± 19.9	3.2 ± 3.3
2024	Single Model	98.4 ± 20.2	3.6 ± 3.1
	Dual Model	98.3 ± 19.8	3.5 ± 3.3

Note: $\Delta\text{MAE} = \text{MAE}(\text{Input}, \text{GT}) - \text{MAE}(\text{Model}, \text{GT})$ within the indicated ROI; positive values indicate error reduction.

Table 5.12 Redução de MAE por ROI no conjunto de teste. Os valores são média $\pm$ desvio-padrão entre pacientes ($n = 41$); valores positivos correspondem a redução do erro.

externa. A escolha final recaiu sobre o Single Model, seed 2024, que apresentou o melhor desempenho global e por ROI. As [Figure 5.16](#) e [Figure 5.17](#) mostram a distribuição por imagem para a corrida selecionada. Por simplicidade, os gráficos de agora em diante são apresentados apenas para o modelo selecionado, mas os dados de todas as corridas estão disponíveis no apêndice A.

Os diagramas de caixa evidenciam a separação entre a correção na Zona de Artefacto e a alteração menor na Zona Limpa. O diagrama de dispersão permite identificar heterogeneidade entre fatias, incluindo casos individuais com alterações desfavoráveis na Zona Limpa.

Single Model — ROI metrics







Fig.5.16 Distribuições por imagem das variações de **SSIM**, **PSNR** e **MAE** nas zonas de artefacto e limpa para o Single Model, seed 2024.




Fig.5.17 Relação por imagem entre a melhoria de **SSIM** \ **PSNR** na Zona de Artefacto e a alteração de **SSIM** \ **PSNR** na Zona Limpa para o Single Model, seed 2024. A cor codifica a redução de **MAE** na Zona Limpa.

5.3.3 Mapas de resíduos em casos extremos

Para complementar os resultados, foram inspecionados seis casos individuais do Single Model, seed 2024, na partição de teste. A seleção foi feita exclusivamente pelo Δ SSIM na Zona de Artefacto por fatia: os três maiores valores correspondem à maior melhoria estrutural nessa região face à entrada e os três menores valores à menor melhoria estrutural. Assim, os termos “maior” e “menor” melhoria nesta subseção referem-se apenas a esse critério quantitativo e não constituem uma classificação clínica dos casos.

Em cada mapa, a primeira linha apresenta a alteração necessária em relação à referência limpa ($r_{\text{target}} = \text{GT} - \text{Input}$), a alteração produzida pelo modelo ($r_{\text{model}} = \text{Output} - \text{Input}$) e o erro residual remanescente ($r_{\text{diff}} = r_{\text{model}} - r_{\text{target}} = \text{Output} - \text{GT}$). A segunda linha mostra o erro absoluto da entrada, o erro absoluto da saída e a respetiva diferença, em que verde indica redução do erro e vermelho indica agravamento. O contorno amarelo delimita a Zona de Artefacto. As escalas de cor são ajustadas individualmente a cada fatia para preservar os detalhes em casos com resíduos pequenos. No entanto, a comparação entre casos deve privilegiar os padrões espaciais e as estatísticas apresentadas em cada painel, e não apenas a intensidade aparente das cores. Abaixo de cada mapa é apresentada a visualização correspondente da entrada com artefactos, da saída do modelo e da referência limpa.





Fig.5.18 Residual map (top) and reconstruction visualization (bottom) for case head_1147 (test-set index 1250), selected among the three highest artifact-ROI $\Delta SSIM$ values ($\Delta SSIM_{ROI} = +0.7220$; global $\Delta SSIM = +0.1649$; $\Delta PSNR = +15.99$ dB). The yellow contour delimits the artifact ROI; all error maps are restricted to the body mask.




Fig.5.19 Residual map (top) and reconstruction visualization (bottom) for case head_1274 (test-set index 1364), selected among the three highest artifact-ROI ΔSSIM values ($\Delta\text{SSIM}_{\text{ROI}} = +0.7164$; global $\Delta\text{SSIM} = +0.3752$; $\Delta\text{PSNR} = +19.48$ dB). The yellow contour delimits the artifact ROI; all error maps are restricted to the body mask.





Fig.5.20 Residual map (top) and reconstruction visualization (bottom) for case head_1280 (test-set index 1369), selected among the three highest artifact-ROI ΔSSIM values ($\Delta\text{SSIM}_{\text{ROI}} = +0.7068$; global $\Delta\text{SSIM} = +0.3837$; $\Delta\text{PSNR} = +16.53$ dB). The yellow contour delimits the artifact ROI; all error maps are restricted to the body mask.





Fig.5.21 Residual map (top) and reconstruction visualization (bottom) for case body_11949 (test-set index 0716), selected among the three lowest artifact-ROI ΔSSIM values ($\Delta\text{SSIM}_{\text{ROI}} = -0.0466$; global $\Delta\text{SSIM} = -0.0497$; $\Delta\text{PSNR} = -4.31$ dB). The yellow contour delimits the artifact ROI; all error maps are restricted to the body mask.





Fig.5.22 Residual map (top) and reconstruction visualization (bottom) for case body_2906 (test-set index 1122), selected among the three lowest artifact-ROI ΔSSIM values ($\Delta\text{SSIM}_{\text{ROI}} = -0.0200$; global $\Delta\text{SSIM} = +0.0740$; $\Delta\text{PSNR} = +0.38$ dB). The yellow contour delimits the artifact ROI; all error maps are restricted to the body mask.




Fig.5.23 Residual map (top) and reconstruction visualization (bottom) for case body_11956 (test-set index 0723), selected among the three lowest artifact-ROI $\Delta SSIM$ values ($\Delta SSIM_{ROI} = -0.0141$; global $\Delta SSIM = -0.0345$; $\Delta PSNR = -0.64$ dB). The yellow contour delimits the artifact ROI; all error maps are restricted to the body mask.

5.4 Comparação pareada Single x Dual Model

5.4.1 Análises Estatísticas Globais

Esta análise compara exclusivamente os dois *checkpoints* finais treinados com a seed 2024, um por arquitetura. A seleção do Single Model, seed 2024, para prosseguir para a avaliação externa já havia sido definida com base no desempenho de validação. Portanto, os resultados no conjunto de teste apresentados nesta secção têm caráter de avaliação interna final: não foram utilizados para escolher novos *checkpoints*, ajustar hiperparâmetros ou alterar a arquitetura a avaliar externamente.

As métricas por fatia foram agregadas por paciente antes de todos os resumos e testes de hipótese, resultando em $n = 41$ observações independentes. Assim, as médias, os intervalos de confiança de 95% e os valores de p apresentados nas tabelas desta secção referem-se às médias por paciente, atribuindo o mesmo peso a cada indivíduo.

As tabelas desta secção apresentam a análise das métricas globais, calculadas em todos os píxeis da máscara corporal de cada fatia (píxeis de fundo excluídos), como confirmação complementar da hipótese primária de melhoria estrutural, testada formalmente na Zona de Artefacto na secção seguinte.

Os diagnósticos por paciente mostraram assimetria e desvio da normalidade para ΔSSIM e ΔMAE . Assim, a evidência primária para essas métricas foi baseada no teste de sinais binomial exato, que avalia a predominância de melhorias sem pressupor simetria das diferenças. Para ΔPSNR , cuja distribuição por paciente não mostrou evidência de afastamento da normalidade, foi utilizado o teste t bilateral de uma amostra para a melhoria média.

Os diagnósticos de distribuição foram verificados separadamente para ambos os modelos antes de aplicar esta regra comum por métrica. Para ΔSSIM , o teste de Shapiro–Wilk indicou desvio da normalidade no Single Model ($W = 0.9158$; $p = 0.0050$; assimetria = 1.087) e no Dual Model ($W = 0.9162$; $p = 0.0052$; assimetria = 1.056), sustentando o uso do teste de sinais em ambas as arquiteturas. Para ΔMAE , observou-se o mesmo padrão no Single Model ($W = 0.7607$; $p = 8.95 \times 10^{-7}$; assimetria = 2.281) e no Dual Model ($W = 0.7686$; $p = 1.27 \times 10^{-6}$; assimetria = 2.200). Para ΔPSNR , não houve evidência de afastamento da normalidade nos diagnósticos do Single Model ($W = 0.9742$; $p = 0.4675$) ou do Dual Model ($W = 0.9734$; $p = 0.4427$), o que foi compatível com o uso do teste t para a melhoria média em ambos os modelos.

A [Table 5.13](#), a [Table 5.14](#) e a [Table 5.15](#) mostram que ambas as arquiteturas melhoraram substancialmente a qualidade global da reconstrução face à entrada corrompida. O

Reconstruction Quality: SSIM

Model	Mean improvement	95% BCa CI	p (Holm)
Single Model	0.0891	[0.0744; 0.1075]	7.64×10^{-11}
Dual Model	0.0879	[0.0731; 0.1062]	7.64×10^{-11}

Global body-mask-aware metric, aggregated at the patient level ($n = 41$); no ROI restriction. Two-sided exact binomial sign-test p -values, Holm-adjusted separately within each model across SSIM, PSNR, and MAE.

Table 5.13 Global SSIM improvement over the corrupted input on the test set.

Reconstruction Quality: PSNR

Model	Mean improvement (dB)	95% t CI	p (Holm)
Single Model	7.11	[6.35; 7.87]	4.53×10^{-21}
Dual Model	7.06	[6.30; 7.81]	4.42×10^{-21}

Global body-mask-aware metric, aggregated at the patient level ($n = 41$); no ROI restriction. Two-sided one-sample t -test p -values, Holm-adjusted separately within each model across SSIM, PSNR, and MAE.

Table 5.14 Global PSNR improvement over the corrupted input on the test set.

Reconstruction Quality: MAE

Model	Mean reduction (HU)	95% BCa CI	p (Holm)
Single Model	15.72	[12.94; 20.14]	7.64×10^{-11}
Dual Model	15.54	[12.79; 19.88]	7.64×10^{-11}

Global body-mask-aware metric, aggregated at the patient level ($n = 41$); no ROI restriction. Positive Δ MAE denotes error reduction. Two-sided exact binomial sign-test p -values, Holm-adjusted separately within each model across SSIM, PSNR, and MAE.

Table 5.15 Global MAE reduction over the corrupted input on the test set.

Single Model apresentou Δ SSIM médio de 0.0891 (IC 95% BCa: [0.0744; 0.1075]), Δ PSNR médio de 7.11 dB (IC 95% t : [6.35; 7.87]) e redução média de MAE de 15.72 HU (IC 95% BCa: [12.94; 20.14]). O Dual Model apresentou Δ SSIM de 0.0879 (IC 95% BCa: [0.0731; 0.1062]), Δ PSNR de 7.06 dB (IC 95% t : [6.30; 7.81]) e redução média de MAE de 15.54 HU (IC 95% BCa: [12.79; 19.88]). Todos os seis testes de melhoria global face à entrada permaneceram significativos após o ajuste de Holm aplicado separadamente dentro de cada arquitetura. Os valores de p de Δ SSIM e Δ MAE avaliam a predominância de melhoria, enquanto os de Δ PSNR avaliam a melhoria média, por isso, não devem ser comparados em magnitude.

Estes testes confirmam que cada arquitetura melhora a entrada corrompida, mas não constituem uma comparação direta entre arquiteturas. Esta distinção é essencial: valores de p pequenos nas tabelas Table 5.13, Table 5.14, Table 5.15 não permitem, por si só, afirmar que uma arquitetura é superior à outra.

Os deltas de melhoria subjacentes à comparação pareada são igualmente agregados por paciente, atribuindo o mesmo peso a cada um dos 41 pacientes.

Dual Model – Single Model: Improvement Deltas

Metric	Mean Difference	95% BCa CI	<i>p</i> (sign test; Holm)
Δ SSIM	−0.0012	[−0.0015; −0.0010]	2.35×10^{-9}
Δ PSNR (dB)	−0.054	[−0.107; −0.017]	2.75×10^{-2}
Δ MAE (HU)	−0.186	[−0.338; −0.091]	8.62×10^{-4}

Differences of patient-level input-to-output improvement deltas (Dual Model – Single Model), with 95% BCa bootstrap CIs (10 000 resamples). Two-sided exact binomial sign-test *p*-values are Holm-adjusted across PSNR, SSIM, and MAE. Negative differences favor the Single Model for all three metrics.

Table 5.16 Patient-level paired comparison of improvement deltas between architectures ($n = 41$).

A comparação direta entre arquiteturas é apresentada na [Table 5.16](#). Para esta análise, calculou-se, em cada paciente, a diferença de melhoria Dual Model menos Single Model para Δ SSIM, Δ PSNR e Δ MAE. Foram aplicados testes binomiais exatos de sinais bilaterais, excluindo diferenças nulas e com correção de Holm conjunta para os três testes. Esta análise testa se uma arquitetura melhora mais em mais pacientes do que o esperado ao acaso, sem pressupor simetria das diferenças. Os intervalos de confiança de 95% obtidos por *bootstrap* BCa com 10 000 reamostragens quantificam a diferença média, enquanto os valores de *p* avaliam a predominância direcional. Em todas as métricas, valores negativos favorecem o Single Model.

O Single Model apresentou vantagem média de 0.054 dB em Δ PSNR, de 0.0012 em Δ SSIM e de 0.186 HU em Δ MAE. Os intervalos de confiança não incluíram zero e os valores de *p* ajustados foram 2.75×10^{-2} para [PSNR](#), 2.35×10^{-9} para [SSIM](#) e 8.62×10^{-4} para [MAE](#). As diferenças favoreceram o Single Model em 28 dos 41 pacientes para [PSNR](#), em 39 para [SSIM](#) e em 32 para [MAE](#). Embora estas diferenças sejam estatisticamente significativas, a sua magnitude absoluta é pequena. Portanto, os resultados fornecem evidência de uma vantagem quantitativa global discreta do Single Model, mas não justificam, isoladamente, uma inferência de superioridade clínica. O gráfico de barras resume a melhoria global semelhante obtida pelas duas arquiteturas.




Fig.5.24 Global PSNR and SSIM improvement over the corrupted input for the Single and Dual Models on the test set.

5.4.2 Análise Estatística por ROI

Esta secção testa formalmente a hipótese primária deste estudo – a melhoria estrutural na Zona de Artefacto – e caracteriza de forma complementar a preservação na Zona Distante. As métricas por fatia foram sempre agregadas por paciente antes dos resumos e testes ($n = 41$), e os intervalos de confiança de 95% foram obtidos por *bootstrap* BCa com 10 000 reamostragens. Na Zona de Artefacto, a questão é a melhoria face à entrada corrompida, por isso, foram analisados os deltas com sinal de PSNR, SSIM e MAE. Em cada modelo, foi aplicado o teste de sinais binomial exato bilateral, com correção de Holm na família das três métricas.

Artifact ROI: SSIM

Model	Mean improvement	95% BCa CI	p (Holm)
Single Model	0.3279	[0.2963;0.3548]	2.73×10^{-12}
Dual Model	0.3266	[0.2947;0.3534]	2.73×10^{-12}

Patient-level Artifact-ROI improvement ($n = 41$). Two-sided exact binomial sign-test p -values, Holm-adjusted across PSNR, SSIM, and MAE separately for each model.

Table 5.17 SSIM improvement over the corrupted input in the Artifact ROI.

Artifact ROI: PSNR

Model	Mean improvement (dB)	95% BCa CI	p (Holm)
Single Model	11.86	[10.90;12.59]	2.73×10^{-12}
Dual Model	11.84	[10.91;12.55]	2.73×10^{-12}

Patient-level Artifact-ROI improvement ($n = 41$). Two-sided exact binomial sign-test p -values, Holm-adjusted across PSNR, SSIM, and MAE separately for each model.

Table 5.18 PSNR improvement over the corrupted input in the Artifact ROI.

Artifact ROI: MAE

Model	Mean reduction (HU)	95% BCa CI	p (Holm)
Single Model	98.38	[91.75; 104.24]	2.73×10^{-12}
Dual Model	98.33	[91.84; 104.06]	2.73×10^{-12}

Patient-level Artifact-ROI improvement ($n = 41$). Positive Δ MAE denotes error reduction. Two-sided exact binomial sign-test p -values, Holm-adjusted across PSNR, SSIM, and MAE separately for each model.

Table 5.19 MAE reduction over the corrupted input in the Artifact ROI.

As Table 5.17, Table 5.18, Table 5.19 mostram melhoria nas três métricas na Zona de Artefacto para ambos os modelos. Os ganhos médios foram aproximadamente de 0.32 para SSIM, 11.8 dB para PSNR e 98 HU para MAE. Estes resultados confirmam, para ambas as arquiteturas, a hipótese primária deste estudo de melhoria estrutural estatisticamente significativa na Zona de Artefacto.

Metric	$\Delta_{\text{Dual}} - \Delta_{\text{Single}}$	95% BCa CI	p (Holm)
Δ SSIM	-0.0013	[-0.0025; 0.0002]	0.0345
Δ PSNR (dB)	-0.019	[-0.085; 0.060]	0.533
Δ MAE (HU)	-0.049	[-0.318; 0.345]	0.422

Patient-level paired comparison of input-to-output improvement deltas ($n = 41$). Differences are $\Delta_{\text{Dual}} - \Delta_{\text{Single}}$; negative differences favor the Single Model for all metrics. The 95% BCa bootstrap CIs use 10 000 reamostragens; two-sided exact binomial sign-test p -values are Holm-adjusted across the three Artifact-ROI metrics.

Table 5.20 Patient-level paired comparison of improvement deltas in the Artifact ROI.

Na comparação direta dos deltas de melhoria na Zona de Artefacto (Table 5.20), a diferença em SSIM foi pequena, mas permaneceu significativa após a correção de Holm ($p_{\text{Holm}} = 0.0345$), favorecendo o Single Model. As diferenças nos deltas de PSNR e MAE não foram significativas após o ajuste.

Na região distante, a pergunta é distinta: pretende-se caracterizar a preservação do tecido fora da zona de artefacto, cujo alvo é alteração nula em relação à entrada. Por isso, foi calculado, em cada paciente, o valor médio de $|\Delta|$ por fatia. Valores menores representam uma reconstrução mais próxima da entrada. Como não foi pré-especificada uma margem de equivalência clinicamente justificada, não é possível testar nem concluir equivalência a zero. Assim, as Table 5.21, Table 5.22, Table 5.23 reportam a magnitude da alteração e os seus intervalos de confiança, sem valor de p contra zero.

Distant ROI: SSIM

Model	Mean $ \Delta $	95% BCa CI
Single Model	0.0599	[0.0503; 0.0754]
Dual Model	0.0595	[0.0499; 0.0748]

Patient-level mean absolute per-slice input-to-output change ($n = 41$). Lower values are closer to zero. No equivalence margin or hypothesis test against zero was prespecified.

Table 5.21 Magnitude of SSIM input-to-output change in the Distant ROI.

Distant ROI: PSNR

Model	Mean $ \Delta $ (dB)	95% BCa CI
Single Model	1.99	[1.66; 2.34]
Dual Model	1.97	[1.64; 2.33]

Patient-level mean absolute per-slice input-to-output change ($n = 41$). Lower values are closer to zero. No equivalence margin or hypothesis test against zero was prespecified.

Table 5.22 Magnitude of PSNR input-to-output change in the Distant ROI.

Distant ROI: MAE

Model	Mean $ \Delta $ (HU)	95% BCa CI
Single Model	4.30	[3.60; 5.16]
Dual Model	4.24	[3.54; 5.08]

Patient-level mean absolute per-slice input-to-output change ($n = 41$). Lower values are closer to zero. No equivalence margin or hypothesis test against zero was prespecified.

Table 5.23 Magnitude of MAE input-to-output change in the Distant ROI.

Para comparar as arquiteturas quanto à preservação relativa da região distante, foi definida, para cada paciente, a vantagem de preservação do Dual Model, $|\Delta|_{\text{Single}} - |\Delta|_{\text{Dual}}$, e aplicado o teste de sinais binomial exato bilateral, com correção de Holm na família das três métricas. Esta parametrização é mantida separada da comparação dos deltas de melhoria da Zona de Artefacto: aqui, o desfecho é a magnitude da alteração e o melhor valor é o mais próximo de zero. Valores positivos indicam menor alteração pelo Dual Model. Este teste responde apenas qual modelo introduziu menor alteração, e não se essa alteração é clinicamente desprezível.

Metric	Dual preservation advantage	95% BCa CI	p (Holm)
SSIM	0.000390	[0.000056; 0.000642]	3.37×10^{-4}
PSNR (dB)	0.020	[-0.104; 0.069]	0.0275
MAE (HU)	0.066	[-0.050; 0.155]	0.00865

Patient-level paired preservation advantage ($n = 41$), defined as $|\Delta|_{\text{Single}} - |\Delta|_{\text{Dual}}$. Positive values favor the Dual Model because its mean absolute input-to-output change is smaller. The 95% BCa bootstrap CIs use 10 000 reamostragens, two-sided exact binomial sign-test p -values are Holm-adjusted across the three Distant-ROI metrics.

Table 5.24 Relative preservation advantage of the Dual Model in the Distant ROI.

Na comparação relativa (Table 5.24), o Dual Model apresentou menor alteração absoluta em PSNR, SSIM e MAE após a correção de Holm. Esta evidência indica preservação relativa superior ao Single Model na região distante, mas não demonstra equivalência a alteração nula.

O desempenho computacional (latência e débito de inferência) do modelo selecionado para a avaliação externa é caracterizado no section A.2.

5.5 Avaliação externa por médicos

5.5.1 Estado da recolha e participantes

A avaliação externa consiste numa comparação pareada cega ao rótulo de processamento: em cada caso, os leitores visualizam simultaneamente a entrada com artefacto e a saída do modelo, identificadas apenas como “Imagem A” e “Imagem B”. A posição esquerda/direita é contrabalançada entre leitores e mantida constante entre um caso e a sua repetição oculta. Cada sessão apresenta 19 comparações: 2 casos de treino (excluídos da análise), 15 casos principais e 2 repetições ocultas de casos já apresentados, usadas exclusivamente para avaliar a consistência intraleitor. Os médicos foram recrutados diretamente pela investigadora, com autodeclaração do uso clínico de CT com frequência mínima mensal. Não foram recolhidos nome, contacto, número de registo profissional ou qualquer comprovativo de qualificação.

A [Table 5.25](#) resume o estado do recrutamento e da conclusão das respostas.

Indicador	Valor
Total de Leitores	[a preencher]
Respostas totais válidas (leitores × 15 casos principais)	[a preencher]
Data de início da recolha	2026-08-27
Data de fecho da recolha	[a preencher]

Table 5.25 Estado do recrutamento e da conclusão das respostas da avaliação externa.

As características autodeclaradas dos leitores que completaram a avaliação são apresentadas na [Table 5.26](#). Nenhuma destas variáveis permite identificar individualmente um participante.

Variável	Categoria	N	%
Jurisdição	Brasil	[a preencher]	[a preencher]
	Portugal	[a preencher]	[a preencher]
Frequência de uso de CT	Mensal	[a preencher]	[a preencher]
	Semanal	[a preencher]	[a preencher]
	Diária	[a preencher]	[a preencher]
Experiência com CT (anos)	< 2	[a preencher]	[a preencher]
	2–5	[a preencher]	[a preencher]
	6–10	[a preencher]	[a preencher]
	> 10	[a preencher]	[a preencher]
Experiência com redução de artefactos	Nenhuma	[a preencher]	[a preencher]
	Ocasional	[a preencher]	[a preencher]
	Frequente	[a preencher]	[a preencher]
Tipo de monitor	Diagnóstico	[a preencher]	[a preencher]
	Convencional	[a preencher]	[a preencher]
	Desconhecido	[a preencher]	[a preencher]

Table 5.26 Características autodeclaradas dos leitores que completaram a avaliação externa.

A distribuição por especialidade médica é apresentada separadamente na [Table 5.27](#), dado o maior número de categorias.

Especialidade	N	%
Radiologia e Diagnóstico por Imagem	[a preencher]	[a preencher]
Pneumologia	[a preencher]	[a preencher]
Cirurgia Torácica ou Cardiorádica	[a preencher]	[a preencher]
Oncologia	[a preencher]	[a preencher]
Medicina Interna ou Clínica Médica	[a preencher]	[a preencher]
Medicina Intensiva	[a preencher]	[a preencher]
Medicina de Emergência	[a preencher]	[a preencher]
Cardiologia	[a preencher]	[a preencher]
Gastroenterologia ou Hepatologia	[a preencher]	[a preencher]
Cirurgia Geral ou outra especialidade cirúrgica	[a preencher]	[a preencher]
Urologia	[a preencher]	[a preencher]
Ortopedia ou Traumatologia	[a preencher]	[a preencher]
Doenças Infecciosas ou Infectologia	[a preencher]	[a preencher]
Outra especialidade médica	[a preencher]	[a preencher]

Table 5.27 Distribuição por especialidade médica dos leitores que completaram a avaliação externa.

5.5.2 Caracterização quantitativa entrada – saída

Antes da avaliação por profissionais, a alteração global produzida pelo *Single Model* foi caracterizada nos 15 casos principais do conjunto externo. Os dois casos de treino foram excluídos desta síntese. Como estes exames reais não dispõem de referência limpa, as métricas da [Table 5.28](#) comparam exclusivamente a imagem de entrada com a saída do modelo, dentro da máscara corporal.

Input–Output Similarity and Change		
Metric	Mean $\pm$ SD	95% CI
SSIM (Input, Output)	0.8953 $\pm$ 0.0729	[0.8572; 0.9290]
PSNR (Input, Output) (dB)	33.14 $\pm$ 6.49	[29.95; 36.21]
MAE (Input, Output) (HU)	21.12 $\pm$ 15.26	[14.54; 29.26]

No artifact-free reference is available. Metrics were calculated within the manually corrected effective body mask and quantify input–output similarity or change; they do not measure artifact-removal accuracy or improvement.

Table 5.28 Global input–output metrics in the frozen external main set ($n = 15$) for `singlehead-033-0.9511-ssim_hu.keras`. Values are mean $\pm$ standard deviation; 95% CIs are percentile bootstrap intervals for the mean.

No conjunto externo, a similaridade média entrada–saída foi de 0.8953 para **SSIM** e 33.14 dB para **PSNR**, enquanto a magnitude média da alteração foi de 21.12 HU em **MAE**. A dispersão entre casos, expressa pelos desvios-padrão e intervalos de confiança da tabela, evidencia heterogeneidade no grau de alteração produzido pela reconstrução. Estes resultados descrevem a preservação e a modificação global das imagens externas, mas não permitem inferir, sem referência limpa, acurácia de remoção de artefactos ou benefício clínico. Essa interpretação é abordada pela avaliação cega por médicos nas subseções seguintes.

Para tornar visível esta heterogeneidade, selecionou-se de forma descritiva os três casos com maior e os três com menor **SSIM** entre entrada e saída. Os primeiros representam os pares com menor alteração estrutural global, enquanto os segundos representam aqueles com maior alteração.

Illustrative External Cases Selected by Input–Output SSIM

Group	Case	SSIM	PSNR (dB)	MAE (HU)
Least changed	Case 003	0.9809	41.19	8.76
	Case 002	0.9756	42.35	8.10
	Case 012	0.9586	37.91	9.64
Most changed	Case 015	0.7278	23.32	43.10
	Case 005	0.7770	20.77	63.90
	Case 008	0.8334	33.53	20.39

Cases were selected only by the extremes of SSIM(Input, Output). High SSIM denotes less structural change between input and output; this ranking does not define artifact-removal quality or clinical acceptability.


Table 5.29 Descriptive external cases with the highest and lowest input–output SSIM values.

Case 003 — Input-Output Pair
SSIM=0.9809; PSNR=41.19 dB; MAE=8.76 HU

Input




Single Model output




Case 002 — Input-Output Pair
SSIM=0.9756; PSNR=42.35 dB; MAE=8.10 HU

Input



Single Model output



Case 012 — Input-Output Pair
SSIM=0.9586; PSNR=37.91 dB; MAE=9.64 HU
Input **Single Model output**





Fig.5.25 External input-output pairs with the three highest SSIM values, representing the least structural change. The soft-tissue window is identical for input and output within each case.

Case 015 — Input-Output Pair
SSIM=0.7278; PSNR=23.32 dB; MAE=43.10 HU
Input **Single Model output**






Fig.5.26 External input-output pairs with the three lowest SSIM values, representing the greatest structural change. The soft-tissue window is identical for input and output within each case.

5.5.3 Desfecho primário: visualização anatômica

O desfecho primário é a preferência pareada, por caso, quanto a qual imagem preserva melhor a região anatômica subjacente ao artefacto metálico (“Imagem A” / “Imagem B” / “Sem diferença”). As respostas são recodificadas para entrada/saída de acordo com a alocação de posição registrada para cada apresentação, sem que os leitores tenham conhecimento dessa alocação durante a resposta. Casos de treino e repetições ocultas não integram esta análise ($n = 15$ casos principais por leitor).

A associação entre a condição preferida (entrada vs. saída) e o tipo de imagem foi estimada por um modelo ordinal de efeitos mistos, com efeitos aleatórios para leitor e para caso, de modo

a contabilizar a estrutura de medições repetidas (múltiplos casos por leitor e múltiplos leitores por caso). Os intervalos de confiança de 95% são priorizados na interpretação, em detrimento de valores de p isolados.

Resposta	N	%	IC 95%
Preferiu a saída (Single Model)	[a preencher]	[a preencher]	[a preencher]
Preferiu a entrada (com artefacto)	[a preencher]	[a preencher]	[a preencher]
Sem diferença	[a preencher]	[a preencher]	[a preencher]

Frequências agrupadas sobre todas as respostas válidas (leitores $\times$ 15 casos principais); IC 95% por *bootstrap* ou método exato a especificar.

Table 5.30 Preferência pareada quanto à preservação da região anatómica subjacente ao artefacto metálico.

Efeito	Estimativa	IC 95%	p
Condição (saída vs. entrada)	[a preencher]	[a preencher]	[a preencher]

Modelo ordinal de efeitos mistos com efeitos aleatórios para leitor e caso; escala e parametrização do coeficiente a especificar (por exemplo, *log-odds* ou proporção marginal prevista).

Table 5.31 Estimativa do modelo ordinal de efeitos mistos para o desfecho primário.

5.5.4 Desfechos secundários e segurança percebida

Os desfechos secundários seguem o mesmo formato de comparação pareada por caso (“Imagem A” / “Imagem B” / “Sem diferença”), recodificado para entrada/saída, reportando-se frequências e intervalos de confiança de 95% por pergunta, sem ajuste conjunto de multiplicidade, dado o carácter descritivo desta síntese.

Resposta	N	%	IC 95%
Preferiu a saída (menor intensidade de artefacto)	[a preencher]	[a preencher]	[a preencher]
Preferiu a entrada	[a preencher]	[a preencher]	[a preencher]
Sem diferença	[a preencher]	[a preencher]	[a preencher]

Table 5.32 Preferência pareada quanto à intensidade percebida de artefactos metálicos.

Resposta	N	%	IC 95%
Preferiu a saída (menos distorção)	[a preencher]	[a preencher]	[a preencher]
Preferiu a entrada	[a preencher]	[a preencher]	[a preencher]
Sem diferença	[a preencher]	[a preencher]	[a preencher]

Este item funciona como sinal exploratório de possível dano: preferência pela entrada sugere percepção de distorções ou artefactos introduzidos pelo modelo fora da zona de artefacto.

Table 5.33 Preferência pareada quanto a artefactos ou distorções anatómicas introduzidas nas regiões distantes do artefacto.

Adicionalmente, no final da sessão, cada leitor respondeu uma vez a uma questão ordinal de 5 pontos sobre a utilidade complementar de uma versão processada com este padrão face ao exame de CT original (Table 5.35).

Resposta	N	%	IC 95%
Preferiu a saída para interpretação clínica	[a preencher]	[a preencher]	[a preencher]
Preferiu a entrada	[a preencher]	[a preencher]	[a preencher]
Sem diferença	[a preencher]	[a preencher]	[a preencher]

Table 5.34 Preferência pareada quanto à imagem escolhida para interpretação clínica.

Categoria	N	%
Definitivamente não	[a preencher]	[a preencher]
Provavelmente não	[a preencher]	[a preencher]
Incerto	[a preencher]	[a preencher]
Provavelmente sim	[a preencher]	[a preencher]
Definitivamente sim	[a preencher]	[a preencher]

Uma resposta por leitor (não por caso); n = número de leitores que completaram a avaliação.

Table 5.35 Utilidade complementar percebida de uma versão processada face ao exame de CT original.

A consistência intraleitor foi avaliada através de duas repetições ocultas por leitor: o mesmo caso é reapresentado mais tarde na sessão, sem sinalização, na mesma posição esquerda/direita da primeira apresentação. A concordância entre a resposta original e a da repetição foi quantificada pelo coeficiente de correlação intraclasse ICC(2,1) (Shrout & Fleiss, modelo de efeitos mistos, medida única, concordância absoluta) e, para a preferência binária saída/entrada, pelo coeficiente κ de Fleiss (Table 5.36).

Estatística	Valor	IC 95%	Interpretação
ICC(2,1)	[a preencher]	[a preencher]	[a preencher]
κ de Fleiss (saída vs. entrada)	[a preencher]	—	[a preencher]

n = 2 repetições ocultas por leitor. IC 95% do ICC(2,1) pelo método baseado na distribuição F (Shrout & Fleiss, 1979).

Table 5.36 Consistência intraleitor nas repetições ocultas.

5.5.5 Interpretação limitada ao desenho observacional

O desenho dessa avaliação permite concluir, quando os dados estiverem disponíveis, qual imagem os leitores preferem em cada dimensão avaliada, mas não permite inferir causalidade sobre desfechos clínicos (por exemplo, impacto diagnóstico ou terapêutico), nem generalizar além do conjunto de 15 casos e do painel de leitores efetivamente recrutado. A ausência de uma referência limpa nestes casos externos significa que a avaliação de exatidão anatómica depende inteiramente do julgamento dos leitores, e não de uma métrica objetiva de erro. Por fim, o número de leitores recrutados limita a precisão das estimativas e a possibilidade de análises de subgrupo por especialidade ou experiência.

Chapter 6

Discussão

6.1 Síntese dos achados principais

O objetivo geral desta dissertação era desenvolver, avaliar e comparar de forma rigorosa uma abordagem baseada em **CNNs** para redução de artefactos metálicos em **CT**, privilegiando a preservação anatômica, a robustez à variação de domínio e a interpretabilidade da correção. Os resultados da avaliação interna sustentam a hipótese primária de melhoria estrutural na Zona de Artefacto face à entrada corrompida: nas seis corridas (duas arquiteturas, três sementes), o **SSIM** nessa zona aumentou entre 0.322 e 0.328 (**Table 5.10**), e para a corrida selecionada para a avaliação externa (Single Model, seed 2024) esta melhoria foi estatisticamente significativa ao nível do paciente ($\Delta \text{SSIM} = 0.3279$, IC 95% BCa [0.2963; 0.3548], $p_{\text{Holm}} = 2.73 \times 10^{-12}$; **Table 5.17**), com um padrão equivalente no Dual Model ($\Delta \text{SSIM} = 0.3266$, $p_{\text{Holm}} = 2.73 \times 10^{-12}$). Esta melhoria estrutural localizada foi acompanhada por uma melhoria global consistente e igualmente significativa: em todas as seis corridas, a reconstrução aumentou o **PSNR** global de 27.39 dB para 34.95–35.20 dB, o **SSIM** global de 0.8361 para 0.9421–0.9442 e reduziu o **MAE** global de 36.6 HU para 17.3–17.8 HU (**Table 5.4**, **Table 5.5**, **Table 5.6**). Ao nível do paciente, os testes secundários de melhoria global foram significativos para as três métricas em todas as corridas ($p < 0.001$; **Table 5.7**, **Table 5.8**, **Table 5.9**), com os intervalos de confiança de 95% a excluir o valor nulo.

A inspeção descritiva ao nível da fatia (**Figure 5.14**) mostrou que os casos desfavoráveis são raros: apenas 0.8% das fatias apresentaram ΔPSNR negativo e 1.6% apresentaram ΔSSIM negativo, num total de 1478 fatias de teste. Esta consistência é reforçada pela análise por **ROI** (**subsection 5.3.2**), que mostra que a correção está concentrada na Zona de Artefacto ($\Delta \text{PSNR} \approx 11.8$ dB, $\Delta \text{SSIM} \approx 0.33$, redução de **MAE** ≈ 98 HU), com alterações substancialmente menores na Zona Distante ($|\Delta \text{PSNR}| \approx 2$ dB, $|\Delta \text{SSIM}| \approx 0.06$, $|\Delta \text{MAE}| \approx 4$ HU). Este

contraste indica que o modelo não aplica uma suavização indiscriminada da imagem, mas concentra a alteração onde o artefacto está presente.

A seleção do *checkpoint* final (Single Model, seed 2024, época 33) baseou-se exclusivamente no **SSIM** da partição de validação, sem uso do conjunto de teste para essa decisão. Os resultados de teste aqui sintetizados desempenham, portanto, um papel confirmatório e não de seleção, em linha com o objetivo de construir um *pipeline* reproduzível com separação rigorosa entre treino, validação e teste.

6.2 Interpretação da comparação arquitetural

A comparação pareada entre arquiteturas (section 5.4) permite responder ao segundo objetivo específico – se a supervisão auxiliar da máscara de artefacto melhora a reconstrução face à versão sem supervisão de máscara – de forma matizada. Ao nível global, o Single Model apresentou uma vantagem pequena mas estatisticamente significativa nas três métricas ($\Delta\text{PSNR} +0.054$ dB, $\Delta\text{SSIM} +0.0012$, $\Delta\text{MAE} +0.186$ HU; $p_{\text{Holm}} = 2.75 \times 10^{-2}$, 2.35×10^{-9} e 8.62×10^{-4} , respetivamente; Table 5.16), favorecendo o Single Model em 28, 39 e 32 dos 41 pacientes. Na Zona de Artefacto, essa vantagem restringiu-se ao **SSIM** ($p_{\text{Holm}} = 0.0345$), sem diferença significativa em **PSNR** ou **MAE** (Table 5.20).

Por outro lado, na Zona Distante, foi o Dual Model que apresentou menor alteração absoluta face à entrada nas três métricas, com vantagem de preservação estatisticamente significativa após a correção de Holm ($p_{\text{Holm}} = 3.37 \times 10^{-4}$ para **SSIM**, 0.0275 para **PSNR** e 0.00865 para **MAE**; Table 5.24). Interpreta-se este padrão como um compromisso: a supervisão adicional de segmentação parece disciplinar espacialmente a correção, tornando o Dual Model marginalmente mais conservador fora da Zona de Artefacto, ao custo de uma magnitude de correção ligeiramente menor tanto globalmente como na própria Zona de Artefacto. No entanto, nesse trabalho o decoder foi mantido quase inteiramente compartilhado, e somente na última camada acrescenta-se a saída de segmentação. Uma separação mais profunda entre os decoders de reconstrução e de segmentação poderia permitir explorar melhor este compromisso, mas não foi testada neste trabalho.

Em nenhum dos dois sentidos as diferenças observadas parecem, isoladamente, clinicamente distinguíveis – décimas de dB em **PSNR**, milésimas em **SSIM** e frações de HU em **MAE**. A significância estatística decorre sobretudo da consistência direcional entre pacientes (testes de sinais com $n = 41$), não da magnitude do efeito. Assim, a resposta ao objetivo de comparação arquitetural é que a supervisão auxiliar da máscara não produz uma reconstrução decisivamente superior, mas redistribui o compromisso entre correção e preservação de forma

mensurável. Como a seleção do candidato para a avaliação externa já havia sido decidida na validação (Single Model, seed 2024, superior nas três métricas de validação), estas diferenças de teste, embora relevantes para caracterizar o compromisso arquitetural, não tiveram de alterar – nem alteraram – essa decisão.

6.3 Preservação anatómica e segurança da reconstrução

A leitura conjunta das análises descritivas complementares converge para um quadro consistente, embora não conclusivo do ponto de vista clínico. A divisão por ROI já mostrou que a alteração na Zona Distante é uma pequena fração da correção observada na Zona de Artefacto (Figure 5.16, Figure 5.17). A concordância de Bland–Altman ao nível do paciente para a média de HU corporal (Figure 5.15) mostrou um viés positivo pequeno mas não nulo, de +4.19 HU, com limites de concordância de 95% entre +1.45 e +6.93 HU – um ligeiro deslocamento sistemático da intensidade média que deve ser monitorizado em trabalho futuro, ainda que pequeno face à amplitude da janela de HU utilizada.

Como caracterização adicional da cauda de pior desempenho, os 74 de 1478 fatias de teste (5%) com menor ΔPSNR (limiar de 2.59 dB) mantiveram, em média, melhoria positiva nas três métricas (ΔPSNR médio = 1.23 dB; ΔSSIM médio = 0.0071; ΔMAE médio na Zona de Artefacto = 62.0 HU; Figure A.6), apesar de dispersão elevada e de casos individuais de degradação face à entrada. Isto sugere que os casos desfavoráveis tendem a ser de gravidade graduada, e não catastrófica, embora existam e mereçam inspeção qualitativa – disponível para os casos extremos de ΔSSIM na Zona de Artefacto na subsection 5.3.3.

Uma análise exploratória complementar (Figure A.3) relacionou a carga de artefacto (fração área de artefacto/área corporal, média por paciente) com a melhoria global, tendo-se observado associação positiva: $\rho = 0.479$ para ΔPSNR (IC 95% [0.156;0.717], $p = 0.00154$) e $\rho = 0.569$ para ΔSSIM (IC 95% [0.225;0.794], $p = 0.000104$). Ou seja, o modelo tende a corrigir proporcionalmente mais nos pacientes com maior carga de artefacto – um resultado tranquilizador do ponto de vista de uma correção direccionada, mas que, por não integrar a família de testes de hipótese primários nem ter recebido ajuste de Holm, deve ser lido como gerador de hipótese e não como confirmação estatística independente.

Em conjunto, a estratificação por ROI, a calibração de Bland–Altman, a caracterização da cauda de pior desempenho e a associação com a carga de artefacto compõem um retrato convergente, mas ainda descritivo: a correção concentra-se onde é necessária, o tecido distante é maioritariamente preservado com um pequeno desvio de calibração, e as fatias com pior

desempenho não evidenciam distorção anatômica sistemática. A avaliação definitiva de segurança clínica, contudo, permanece reservada à avaliação externa por leitores ([section 5.5](#)).

6.4 Generalização e avaliação externa

O quarto objetivo específico – investigar a capacidade de generalização da versão selecionada em dados reais e externos ao treino, provenientes do **TCIA** – só pode ser respondido parcialmente com a evidência técnica atualmente disponível. Os 15 casos principais do conjunto externo não dispõem de referência limpa, pelo que apenas foi possível caracterizar a magnitude da alteração entre a entrada e a saída ([Table 5.28](#)): **SSIM** médio de 0.8953, **PSNR** médio de 33.14 dB e **MAE** médio de 21.12 HU, com dispersão relevante entre casos.

Estes valores não são diretamente comparáveis aos deltas de melhoria internos, que dependem de uma referência limpa para quantificar acurácia de correção. Descrevem apenas que o modelo produz alterações de magnitude plausível e não colapsa para a identidade nem produz distorções extremas nos casos externos amostrados. A seleção descritiva dos três casos com maior e três com menor **SSIM** entrada-saída ilustrou essa heterogeneidade, sem constituir comparação inferencial.

Assim, a evidência técnica externa disponível sustenta apenas que o comportamento do modelo em dados reais e fora do domínio de treino é qualitativamente plausível e consistente em ordem de grandeza com o observado internamente, mas não permite concluir acurácia de remoção de artefactos nem generalização validada sem referência limpa. A resposta decisiva a essa questão – se leitores humanos julgam a correção externa como precisa e segura – depende da avaliação cega por médicos discutida na secção seguinte.

6.5 Avaliação por médicos

A avaliação multileitor cega ([section 5.5](#)) foi desenhada com um desfecho primário de visualização anatômica e desfechos secundários de interferência do artefacto, preferência pareada, sinalização de possível dano, utilidade complementar e consistência intraleitor, num desenho observacional adequado a um painel de leitores pequeno e propositadamente construído para comparação pareada entrada-saída.

À data desta redação, a recolha de dados e a caracterização dos participantes para esta avaliação ainda não estavam concluídas (section 5.5). Por essa razão, esta secção não interpreta melhoria percebida, segurança percebida ou eficácia clínica: fazê-lo antes de os desfechos primário e secundários estarem disponíveis arriscaria conclusões que excedem a evidência técnica reunida até este ponto. Quando concluída, a avaliação deverá ser lida em conjunto com a secção anterior sobre preservação anatômica, e interpretada estritamente dentro dos limites do desenho observacional em que foi construída – isto é, como comparação pareada entrada-saída por um painel de leitores, sem inferência causal de superioridade clínica para além desse desenho.

6.6 Limitações

Natureza da referência limpa. O CT-MAR Dataset fornece fatias reais com artefactos metálicos, mas sem referência limpa emparelhada da mesma aquisição. A referência utilizada neste trabalho foi obtida por correspondência de similaridade estrutural (*fingerprint* e similaridade de cosseno, limiar de aprovação automática de 0.994) com fatias independentes e livres de artefacto do DeepLesion e do UCLH Stroke EIT, auditada por MS-SSIM e revisão visual humana (apenas 3 falsos positivos confirmados entre 340 pares limítrofes inspecionados). Esta estratégia permite treinar e avaliar contra artefactos reais, em vez de simulados, mas a correspondência é de recuperação por similaridade, não um registo pixel-a-pixel garantido da mesma aquisição; pequenas diferenças anatômicas residuais entre os pares emparelhados não podem ser inteiramente excluídas apesar da auditoria.

Desequilíbrio anatômico. A distribuição anatômica manteve-se aproximadamente 88% *body* e 12% *head* ao nível dos pares, e 95.9% *body* e apenas 4.1% *head* (11 de 269 pacientes) ao nível dos pacientes. Conclusões específicas sobre a região da cabeça assentam, portanto, num subconjunto pequeno de pacientes e devem ser interpretadas com cautela.

Dimensão amostral ao nível do paciente. A unidade de inferência do conjunto de teste interno foi o paciente ($n = 41$), adequada às comparações pareadas primárias realizadas, mas limitada para análises de subgrupo mais finas (por região anatômica, gravidade do artefacto ou tipo de implante) além da associação exploratória com a carga de artefacto já sinalizada como não primária.

Desempenho computacional de ambiente único. O *benchmark* de latência caracteriza apenas a configuração experimental utilizada (uma GPU, lote unitário, um ambiente de execução) e não generaliza automaticamente para outro *hardware*, configurações de lote ou latência de um fluxo clínico completo.

Avaliação externa. O conjunto externo é pequeno e propositadamente curado (15 casos principais), sem referência limpa e restrito a um único modelo e semente selecionados na validação interna; os resultados descrevem magnitude de alteração, não acurácia de correção.

Desenho observacional da avaliação por médicos. A avaliação multileitor é uma comparação pareada observacional com um painel de leitores pequeno, cuja recolha de dados não estava concluída à data desta redação, conforme discutido na secção anterior.

6.7 Implicações e trabalho futuro

As implicações práticas mais imediatas decorrem diretamente das limitações identificadas. Primeiro, a conclusão e o relato completo da avaliação cega por médicos são um pré-requisito para qualquer afirmação sobre benefício clínico percebido ou segurança percebida da reconstrução; nenhuma conclusão desta natureza deve preceder esses resultados. Segundo, a validação prospetiva em coortes externas maiores e mais diversas – em particular com maior representação da região da cabeça – permitiria testar a generalização de forma mais robusta do que os 15 casos externos atualmente disponíveis. Terceiro, complementar a estratégia de referência por correspondência de similaridade estrutural com fontes de referência emparelhada da mesma aquisição (por exemplo, inserção sintética de artefacto em domínio de projeção ou dados de dupla energia) poderia reduzir a dependência de correspondência entre *datasets* distintos, ainda que ao custo de artefactos potencialmente menos realistas.

Do ponto de vista arquitetural, o compromisso identificado entre o Single Model (ligeira vantagem de magnitude de correção) e o Dual Model (ligeira vantagem de preservação na Zona Distante) sugere que trabalho futuro poderia explorar formas de combinar os dois efeitos – por exemplo, ponderação adaptativa da perda de reconstrução pela máscara de artefacto prevista, em vez de supervisão auxiliar independente – para tentar obter simultaneamente maior correção e maior preservação. Por fim, a expansão do protocolo de observadores (mais leitores, rondas de calibração ou treino prévio, e ampliação do painel de casos externos) deverá acompanhar qualquer extensão futura da avaliação clínica, mantendo a mesma disciplina de separação entre evidência exploratória e confirmatória adotada ao longo desta dissertação.

Chapter 7

Conclusões

7.1 Conclusões do estudo

[A preencher: conclusão proporcional às evidências finais e aos resultados confirmatórios.]

7.2 Contribuições da dissertação

- *[A preencher: curadoria rastreável e partição por paciente.]*
- *[A preencher: comparação controlada entre duas arquiteturas U-Net.]*
- *[A preencher: avaliação por paciente e produção reprodutível de resultados.]*
- *[A preencher: protocolo de avaliação externa por médicos e respetivo estado de execução.]*

7.3 Perspetivas futuras

[A preencher: validação externa concluída, extensão multicêntrica e avaliação clínica prospetiva.]

Bibliography

- [1] November 8, 1895: Roentgen's Discovery of X-Rays. <https://www.aps.org/apsnews/2001/11/1895-roentgens-discovery-xrays>. [Cited on page 1.]
- [2] Emico Okuno and Elisabeth Yoshimura. *Física das Radiações*. Oficina de Textos, 2010. [Cited on page 1.]
- [3] JOEL D. HOWELL. EARLY CLINICAL USE OF THE X-RAY. *Transactions of the American Clinical and Climatological Association*, 127:341–349, 2016. [Cited on page 1.]
- [4] Allen Taylor. Illuminating Health: The Evolution and Significance of X-ray Imaging. *Imaging in Medicine*, 15(6):133–134, December 2023. [Cited on page 1.]
- [5] Reza Vali. Unveiling the Marvels of Computed Tomography (CT) Imaging. *Imaging in Medicine*, 16(1):150–151, February 2024. [Cited on page 1.]
- [6] Mohd Noor. An Overview of Computed Tomography: What it is and How it Works? Applications of Computed Tomography. *Imaging in Medicine*, 15(5):93–94, October 2023. [Cited on page 1.]
- [7] Raymond A. Schulz, Jay A. Stein, and Norbert J. Pelc. How CT happened: The early development of medical computed tomography. *Journal of Medical Imaging*, 8(5):052110, September 2021. [Cited on page 2.]
- [8] F. Edward Boas and Dominik Fleischmann. CT artifacts: Causes and reduction techniques. *Imaging in Medicine*, 4(2):229–240, April 2012. [Cited on page 2.]
- [9] Cecile E.J. Kleber, Ramez Karius, Lucas E. Naessens, Coen O. Van Toledo, Jochen A. C. Van Osch, Martijn F. Boomsma, Jan W.T. Heemskerk, and Aart J. Van Der Molen. Advancements in supervised deep learning for metal artifact reduction in computed tomography: A systematic review. *European Journal of Radiology*, 181:111732, December 2024. [Cited on pages 2, 6, 7, and 13.]

- [10] Sathyathas Puvanasunthararajah, Davide Fontanarosa, Marie-Luise Wille, and Saskia M. Camps. The application of metal artifact reduction methods on computed tomography scans for radiotherapy applications: A literature review. *Journal of Applied Clinical Medical Physics*, 22(6):198–223, May 2021. [Cited on page 2.]
- [11] Asutosh Sahu, Shobhit Mathur, Hiroyuki Takaoka, Joji Ota, Felix G. Meinel, Benjamin Böttcher, Benoît Magnin, Ankush Jajodia, and Corey T. Jensen. Transforming CT imaging with deep learning: Noise reduction, artifact management, and clinical applications – A comprehensive review. *European Journal of Radiology Artificial Intelligence*, 4:100042, December 2025. [Cited on pages 2, 6, and 7.]
- [12] Mohanad Alkhodari, Eman Alefishat, Herbert F. Jelinek, Ahmed Kaabneh, and Panos Liatsis. Enhancing CCTA image quality: A review of deep learning approaches for advanced artifact correction and denoising. *Artificial Intelligence Review*, 58(10):331, August 2025. [Cited on page 3.]
- [13] Julia F. Barrett and Nicholas Keat. Artifacts in CT: Recognition and Avoidance. *RadioGraphics*, 24(6):1679–1691, November 2004. [Cited on page 6.]
- [14] Mark Selles, Jochen A.C. Van Osch, Mario Maas, Martijn F. Boomsma, and Ruud H.H. Wellenberg. Advances in metal artifact reduction in CT images: A review of traditional and novel metal artifact reduction techniques. *European Journal of Radiology*, 170:111276, January 2024. [Cited on page 6.]
- [15] Lars Gjestebj, Qingsong Yang, Yan Xi, Bernhard E. H. Claus, Yannan Jin, Bruno De Man, Ge Wang, and Hongming Shan. Deep learning methods for CT image-domain metal artifact reduction. In Bert Müller and Ge Wang, editors, *Developments in X-Ray Tomography XI*, page 31, San Diego, United States, September 2017. SPIE. [Cited on pages 6 and 7.]
- [16] Yanbo Zhang and Hengyong Yu. Convolutional Neural Network Based Metal Artifact Reduction in X-Ray Computed Tomography. *IEEE Transactions on Medical Imaging*, 37(6):1370–1381, June 2018. [Cited on pages 6 and 7.]
- [17] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-Net: Convolutional Networks for Biomedical Image Segmentation, May 2015. [Cited on pages 7 and 18.]
- [18] Esther Meyer, Frank Bergner, Rainer Raupach, Thomas Flohr, and Marc Kachelriess. Normalized metal artifact reduction (NMAR) in computed tomography. In *2009 IEEE Nuclear Science Symposium Conference Record (NSS/MIC)*, pages 3251–3255, Orlando, FL, October 2009. IEEE. [Cited on page 7.]

- [19] Wei-An Lin, Haofu Liao, Cheng Peng, Xiaohang Sun, Jingdan Zhang, Jiebo Luo, Rama Chellappa, and Shaohua Kevin Zhou. DuDoNet: Dual Domain Network for CT Metal Artifact Reduction. In *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 10504–10513, Long Beach, CA, USA, June 2019. IEEE. [Cited on pages 7 and 13.]
- [20] Lequan Yu, Zhicheng Zhang, Xiaomeng Li, Hongyi Ren, Wei Zhao, and Lei Xing. Metal Artifact Reduction in 2D CT Images with Self-supervised Cross-domain Learning. *Physics in Medicine & Biology*, 66(17):175003, September 2021. [Cited on page 7.]
- [21] Zhiwei Huang, Guo Zhang, Jinzhao Lin, Yu Pang, Huiqian Wang, Tong Bai, and Lisha Zhong. Multi-modal feature-fusion for CT metal artifact reduction using edge-enhanced generative adversarial networks. *Computer Methods and Programs in Biomedicine*, 217:106700, April 2022. [Cited on page 7.]
- [22] Xin Yi, Ekta Walia, and Paul Babyn. Generative Adversarial Network in Medical Imaging: A Review. *Medical Image Analysis*, 58:101552, December 2019. [Cited on page 7.]
- [23] Zhou Wang, A.C. Bovik, H.R. Sheikh, and E.P. Simoncelli. Image quality assessment: From error visibility to structural similarity. *IEEE Transactions on Image Processing*, 13(4):600–612, April 2004. [Cited on pages 8, 11, and 13.]
- [24] Z. Wang, E.P. Simoncelli, and A.C. Bovik. Multiscale structural similarity for image quality assessment. In *The Thrity-Seventh Asilomar Conference on Signals, Systems & Computers, 2003*, pages 1398–1402, Pacific Grove, CA, USA, 2003. IEEE. [Cited on pages 8 and 22.]
- [25] Alain Hore and Djemel Ziou. Image Quality Metrics: PSNR vs. SSIM. In *2010 20th International Conference on Pattern Recognition*, pages 2366–2369, Istanbul, Turkey, August 2010. IEEE. [Cited on page 8.]
- [26] John R. Zech, Marcus A. Badgeley, Manway Liu, Anthony B. Costa, Joseph J. Titano, and Eric Karl Oermann. Variable generalization performance of a deep learning model to detect pneumonia in chest radiographs: A cross-sectional study. *PLOS Medicine*, 15(11):e1002683, November 2018. [Cited on page 8.]
- [27] Martin J. Willemink, Wojciech A. Koszek, Cailin Hardell, Jie Wu, Dominik Fleischmann, Hugh Harvey, Les R. Folio, Ronald M. Summers, Daniel L. Rubin, and Matthew P. Lungren. Preparing Medical Imaging Data for Machine Learning. *Radiology*, 295(1):4–15, April 2020. [Cited on page 8.]

- [28] Christopher J. Kelly, Alan Karthikesalingam, Mustafa Suleyman, Greg Corrado, and Dominic King. Key challenges for delivering clinical impact with artificial intelligence. *BMC Medicine*, 17(1):195, December 2019. [Cited on page 8.]
- [29] Eri Haneda, Nils Peters, Jiayong Zhang, Grigorios Karageorgos, Wenjun Xia, Harald Paganetti, Ge Wang, Yi Guo, Jianhua Ma, Hyoung Suk Park, Kiwan Jeon, Fuxin Fan, Mareike Thies, and Bruno De Man. AAPM CT metal artifact reduction grand challenge. *Medical Physics*, 52(10):e70050, October 2025. [Cited on page 9.]
- [30] xcist. AAPM CT Metal Artifact Reduction (CT-MAR) Grand Challenge Benchmark Tool. https://github.com/xcist/example/tree/main/AAPM_datachallenge/. [Cited on page 9.]
- [31] Nils Peters, Eri Haneda, Jiayong Zhang, Grigorios Karageorgos, Wenjun Xia, Joost Verburg, Ge Wang, Harald Paganetti, and Bruno De Man. A hybrid training database and evaluation benchmark for assessing metal artifact reduction methods for X-ray CT imaging. *Medical Physics*, 52(10):e70020, October 2025. [Cited on page 9.]
- [32] Mingye Wu, Paul FitzGerald, Jiayong Zhang, W. Paul Segars, Hengyong Yu, Yongshun Xu, and Bruno De Man. XCIST – An Open Access X-ray/CT Simulation Toolkit. *Physics in medicine and biology*, 67(19):10.1088/1361-6560/ac9174, September 2022. [Cited on page 9.]
- [33] Nir Goren, James Avery, Thomas Dowrick, Eleanor Mackle, Anna Witkowska-Wrobel, David Werring, and David Holder. Multi-frequency electrical impedance tomography and neuroimaging data in stroke patients. *Scientific Data*, 5:180112, July 2018. [Cited on pages 9 and 10.]
- [34] Nir Goren, Thomas Dowrick, James Avery, and David Holder. UCLH Stroke EIT Dataset - Radiology Data, August 2017. [Cited on page 9.]
- [35] Ke Yan, Xiaosong Wang, Le Lu, and Ronald M. Summers. DeepLesion: Automated mining of large-scale lesion annotations and universal lesion detection with deep learning. *Journal of Medical Imaging*, 5(3):036501, July 2018. [Cited on pages 9 and 10.]
- [36] Mustafa Umit Oner, Yi-Chih Cheng, Hwee Kuan Lee, and Wing-Kin Sung. Training machine learning models on patient level data segregation is crucial in practical clinical applications, April 2020. [Cited on page 10.]

- [37] Jiang Hsieh. *Computed Tomography: Principles, Design, Artifacts, and Recent Advances*. Wiley Interscience ; SPIE Press, Hoboken, N.J. : Bellingham, Wash, 2nd ed edition, 2009. [Cited on page 11.]
- [38] Saeid Asgari Taghanaki, Yefeng Zheng, S. Kevin Zhou, Bogdan Georgescu, Puneet Sharma, Daguang Xu, Dorin Comaniciu, and Ghassan Hamarneh. Combo Loss: Handling Input and Output Imbalance in Multi-Organ Segmentation, September 2021. [Cited on pages 17 and 21.]
- [39] Uğur Kesimal, Habip Eser Akkaya, Önder Polat, and Murat Sağlam. Use of Deep Learning Models in the Diagnosis of Proptosis Through Orbital Magnetic Resonance Imaging. *Medical Science Monitor*, 32, April 2026. [Cited on page 17.]
- [40] Yang Li, Bobo Yan, Jianxin Hou, Bingyang Bai, Xiaoyu Huang, Canfei Xu, and Limei Fang. UNet based on dynamic convolution decomposition and triplet attention. *Scientific Reports*, 14(1):271, January 2024. [Cited on page 18.]
- [41] Rich Caruana. Multitask Learning. [Cited on page 19.]
- [42] Sebastian Ruder. An Overview of Multi-Task Learning in Deep Neural Networks, June 2017. [Cited on page 19.]
- [43] Hang Zhao, Orazio Gallo, Iuri Frosio, and Jan Kautz. Loss Functions for Image Restoration With Neural Networks. *IEEE Transactions on Computational Imaging*, 3(1):47–57, March 2017. [Cited on pages 20 and 21.]
- [44] Lin Zhang, Lei Zhang, Xuanqin Mou, and D. Zhang. FSIM: A Feature Similarity Index for Image Quality Assessment. *IEEE Transactions on Image Processing*, 20(8):2378–2386, August 2011. [Cited on page 22.]

Appendix A

Supplementary Internal Evaluation

Este apêndice reúne verificações quantitativas complementares da avaliação interna. A figura seguinte é apresentada apenas como diagnóstico visual da concordância radiométrica ao nível de pixel e não constitui análise inferencial, pois os pixels amostrados não são observações independentes.





Fig.A.1 Pixel-level HU agreement between the Single Model reconstruction and the clean reference. The hexbin uses a fixed equal-patient stratified sample of 100,000 valid body-mask pixels from 41 test-set patients. It is a descriptive calibration diagnostic; no hypothesis test or confidence interval is derived from the sampled pixels.

Os gráficos seguintes complementam os histogramas de deltas globais apresentados no corpo do texto. Cada ponto corresponde a uma fatia de teste e, portanto, estes gráficos não são utilizados para inferência estatística.






Fig.A.2 Per-image global SSIM (top) and PSNR (bottom) for the corrupted input and the Single Model reconstruction, seed 2024. The identity line denotes no change, marker color encodes the corresponding global delta. These slice-level relationships are descriptive, whereas statistical inference used patient-level aggregation.

Como análise exploratória de heterogeneidade, a [Figure A.3](#) relaciona a carga de artefato com a melhoria global. Cada ponto corresponde à média de todas as fatias de um paciente ($n = 41$), atribuindo o mesmo peso a cada paciente. A carga foi definida como a média da fração área de artefato/área corporal por fatia; os deltas correspondem à métrica da reconstrução menos a métrica da entrada, ambas contra a referência limpa. Foram calculadas correlações de Spearman bilaterais, com IC de 95% por *bootstrap* BCa pareado (10 000 reamostragens; semente 1337), e a curva de tendência é uma estimacão LOWESS da biblioteca *Statsmodels*. Esta análise não integra a família de testes de hipótese primários nem recebeu ajuste de Holm. Observou-se associação positiva entre a carga de artefato e a melhoria: $\rho = 0,479$ para ΔPSNR (IC 95% [0,156; 0,717], $p = 0,00154$) e $\rho = 0,569$ para ΔSSIM (IC 95% [0,225; 0,794], $p = 0,000104$).




Fig.A.3 Exploratory patient-level association between mean artifact fraction and global improvement for the Single Model, seed 2024: Δ SSIM (top) and Δ PSNR (bottom). Each point is one patient's mean across its test-set slices ($n = 41$). Lines show Statsmodels LOWESS trends; annotations report two-sided Spearman correlations and paired BCa bootstrap 95% confidence intervals.

A.1 Casos de pior desempenho

Como caracterização complementar das fatias com pior desempenho, identificaram-se dois grupos por fatia para o Single Model, seed 2024, no conjunto de teste: primeiro pelo percentil 5 inferior de ΔSSIM , a métrica utilizada para a seleção do *checkpoint*, e depois, de forma complementar, pelo percentil 5 inferior de ΔPSNR . Esta seleção é puramente descritiva: não constitui um teste de hipótese e serve apenas para situar, em termos quantitativos, os grupos de fatias cujos exemplos visuais individuais são discutidos na [subsection 5.3.3](#).

Pelo critério de ΔSSIM ($N = 74/1478$ fatias; limiar = 0,0146), a melhoria média de ΔPSNR manteve-se positiva (1,88 dB), mas a melhoria média de ΔSSIM foi ligeiramente negativa ($-0,0019$), com redução média de MAE na Zona de Artefacto de 65,2 HU ([Figure A.4](#)). Ou seja, o subconjunto mais desfavorável segundo a métrica principal de seleção inclui, em média, uma pequena degradação de SSIM , ainda que a maioria das restantes fatias continue a melhorar substancialmente.




Fig.A.4 Bottom 5th-percentile slices by global ΔSSIM for the Single Model, seed 2024, test split ($N = 74/1478$, threshold = 0.0146, highlighted in red). Descriptive; no inferential test is derived from this subset.

Pelo critério complementar de ΔPSNR ($N = 74/1478$ fatias; limiar = 2,59 dB), este grupo não é idêntico ao definido por ΔSSIM : a melhoria média permaneceu positiva nas três métricas

(ΔPSNR médio = 1,23 dB; ΔSSIM médio = 0,0071; ΔMAE médio na Zona de Artefacto = 62,0 HU), embora com dispersão elevada e alguns casos individuais de degradação face à entrada, visíveis na cauda esquerda da [Figure A.5](#).




Fig.A.5 Bottom 5th-percentile slices by global ΔPSNR for the Single Model, seed 2024, test split ($N = 74/1478$, threshold = 2.59 dB, highlighted in red). Descriptive; no inferential test is derived from this subset.

Por fim, a [Figure A.6](#) relaciona conjuntamente ΔPSNR e ΔSSIM por fatia, destacando a cauda de pior desempenho definida por ΔPSNR do parágrafo anterior, permitindo visualizar a dispersão bivariada dos casos desfavoráveis.




Fig.A.6 Bottom 5th-percentile slices by global ΔPSNR for the Single Model, seed 2024, test split ($N = 74/1478$, threshold = 2.59 dB, highlighted in red). ΔPSNR vs. ΔSSIM scatter. Descriptive; no inferential test is derived from this subset.

A.2 Desempenho computacional

O desempenho temporal foi quantificado para o checkpoint do modelo selecionado para a avaliação externa, na partição de teste interna ($n = 1478$ fatias). O benchmark foi executado no ambiente descrito em Materiais e Métodos, com GPU NVIDIA RTX A4500, utilizando lote unitário, após cinco passagens de aquecimento. Para cada fatia, a latência foi medida desde a chamada do modelo até à sincronização explícita da saída com a CPU. Consequentemente, esta medição inclui a execução da inferência e a sincronização da saída, mas não inclui o carregamento das imagens nem as etapas externas de pré-processamento ou de apresentação dos resultados.

A latência média foi de 24,13 ms por fatia (desvio-padrão: 0,69 ms; mediana: 24,30 ms), correspondendo a um débito de 41,4 fatias por segundo. Os percentis 95 e 99 foram, respetivamente, 24,66 ms e 27,53 ms por fatia. A proximidade entre a média, a mediana e o percentil 95 indica estabilidade da latência na maior parte das execuções; a distribuição completa e a variação por fatia são apresentadas na [Figure A.7](#). Estes valores caracterizam a configuração

experimental utilizada e não representam, por si só, o tempo de resposta de um fluxo clínico completo ou de outro ambiente computacional.




Fig.A.7 Inference benchmark: latency histogram and latency per slice.