

Deep Learning for Metal Artifact Reduction in Computed Tomography



Ludmila Montorsi Queiroz

Mestrado em Física Médica

Departamento de Física e Astronomia

Faculdade de Ciências da Universidade do Porto

2026



UNIVERSIDADE DO PORTO

MASTERS THESIS

Deep Learning for Metal Artifact Reduction in Computed Tomography

Author:

Ludmila MONTORSI QUEIROZ

Supervisor:

Hélder Filipe PINTO DE OLIVEIRA

Co-supervisor:

Eduardo MATOS RODRIGUES

*A thesis submitted in fulfilment of the requirements
for the degree of MSc. Medical Physics*

at the

Faculdade de Ciências da Universidade do Porto
Departamento de Ciência de Computadores
Departamento de Física e Astronomia
INESC TEC

September 7, 2026

"The Universe is under no obligation to make sense to you."

Neil deGrasse Tyson, *Astrophysics for People in a Hurry* (2017)

"Nothing in life is to be feared; it is only to be understood."

Marie Curie, *Madame Curie: A Biography* (1937)

Acknowledgements

I would like to express my deepest gratitude to my supervisor, Helder Filipe Pinto de Oliveira, for his invaluable guidance, support, and encouragement throughout this research journey. His expertise and insights have been instrumental in shaping this thesis. I am also grateful to my co-supervisor, Eduardo Matos Rodrigues, for his constructive feedback and encouragement, which have greatly contributed to the development of this work.

UNIVERSIDADE DO PORTO

Abstract

Faculdade de Ciências da Universidade do Porto

Departamento de Ciência de Computadores

Departamento de Física e Astronomia

INESC TEC

MSc. Medical Physics

Deep Learning for Metal Artifact Reduction in Computed Tomography

by [Ludmila MONTORSI QUEIROZ](#)

Metal artifacts remain a common and clinically significant source of image degradation in computed tomography (CT), affecting an estimated 21% of scans and potentially obscuring or mimicking pathology. This thesis develops and rigorously evaluates a reproducible deep learning pipeline for image-domain metal artifact reduction, comparing a conventional U-Net against a dual-supervision variant that adds an auxiliary artifact-mask prediction head to a shared encoder-decoder. Using the AAPM CT-MAR benchmark dataset (14,000 image pairs derived from DeepLesion and UCLH Stroke EIT), a patient-level traceability procedure was implemented to recover exam and patient identity absent from the original metadata, enabling a leakage-free patient-level split (187/41/41 patients) across three deterministic training seeds per architecture. On the internal test set (41 patients, 1,478 slices), both architectures significantly improved PSNR (27.4 to ~ 35.1 dB), SSIM (0.836 to ~ 0.944) and MAE (36.6 to ~ 17.5 HU) relative to the corrupted input (patient-level Wilcoxon/sign tests, $p < 0.001$), with the correction concentrated in the artifact region and comparatively small change in distant tissue. A direct paired comparison showed a small but statistically significant global advantage for the single-head model and a small but significant distant-region preservation advantage for the dual-head model, indicating a correction-versus-preservation trade-off rather than a clear superiority of either design. The single-head model (seed 2024) was frozen and characterized on an independent external cohort from The Cancer Imaging Archive, where, in the absence of a clean reference, only the magnitude of input-to-output change could be quantified. A blinded, paired multi-reader evaluation by physicians was designed to assess perceived anatomical preservation and safety on these external cases; data collection was still ongoing at the time

of writing, so this thesis reports the technical evidence supporting internal validity and reproducibility, while clinical benefit and external safety remain to be established by that evaluation.

Keywords: Computed Tomography, Metal Artifact Reduction, Deep Learning, U-Net, Multi-task Learning, Reproducibility, Patient-level Data Partitioning, External Validation, Image Quality Assessment

UNIVERSIDADE DO PORTO

Resumo

Faculdade de Ciências da Universidade do Porto

Departamento de Ciência de Computadores

Departamento de Física e Astronomia

INESC TEC

MSc. Medical Physics

Aprendizado Profundo para Redução de Artefatos de Metal em Tomografia Computadorizada

por [Ludmila MONTORSI QUEIROZ](#)

Artefatos metálicos permanecem uma causa comum e clinicamente relevante de degradação de imagem em tomografia computadorizada (CT), estimados em cerca de 21% dos exames, podendo esconder ou simular patologias. Esta dissertação desenvolve e avalia rigorosamente um *pipeline* reproduzível de aprendizagem profunda para redução de artefatos metálicos no domínio da imagem, comparando uma U-Net convencional com uma variante de dupla supervisão que acrescenta uma saída auxiliar de predição da máscara de artefacto a um *encoder-decoder* partilhado. Utilizando o *dataset* de referência CT-MAR da AAPM (14.000 pares de imagens derivados do DeepLesion e do UCLH Stroke EIT), foi implementado um procedimento de rastreabilidade ao nível do paciente para recuperar a identidade do exame e do paciente, ausente nos metadados originais, permitindo um particionamento por paciente sem vazamento de dados (187/41/41 pacientes) ao longo de três sementes de treino determinísticas por arquitetura. No conjunto de teste interno (41 pacientes, 1.478 fatias), ambas as arquiteturas melhoraram significativamente o PSNR (27,4 para $\sim 35,1$ dB), o SSIM (0,836 para $\sim 0,944$) e o MAE (36,6 para $\sim 17,5$ HU) face à entrada corrompida (testes de Wilcoxon/sinais ao nível do paciente, $p < 0,001$), com a correção concentrada na região do artefacto e alteração comparativamente pequena no tecido distante. Uma comparação pareada direta mostrou uma pequena mas estatisticamente significativa vantagem global do modelo de supervisão única e uma pequena mas significativa vantagem de preservação na região distante do modelo de dupla supervisão, indicando um compromisso entre correção e preservação, e não uma superioridade clara de nenhuma das arquiteturas. O modelo de supervisão única (semente 2024)

foi congelado e caracterizado numa coorte externa independente proveniente do The Cancer Imaging Archive, onde, na ausência de referência limpa, apenas foi possível quantificar a magnitude da alteração entrada-saída. Uma avaliação cega e pareada por múltiplos médicos foi desenhada para avaliar a preservação anatômica percebida e a segurança nesses casos externos; a recolha de dados ainda estava em curso à data de redação, pelo que esta dissertação relata a evidência técnica que sustenta a validade interna e a reprodutibilidade, ficando o benefício clínico e a segurança externa por confirmar por essa avaliação.

Palavras-chave: Tomografia Computadorizada, Redução de Artefatos Metálicos, Aprendizagem Profunda, U-Net, Aprendizagem Multitarefa, Reprodutibilidade, Particionamento por Paciente, Validação Externa, Avaliação da Qualidade de Imagem

Contents

Acknowledgements	ii
Abstract	iii
Resumo	v
Contents	vii
List of Figures	x
Lista de Gráficos	xi
List of Tables	xii
1 Introduction	1
1.1 Clinical and Technical Context	3
1.2 Work Motivation	3
2 Objectives and Investigation Question	4
2.1 General Objective	4
2.2 Specific Objectives	4
2.3 Hypothesis and Outcomes	5
3 Related Works	6
3.1 Metallic Artifacts in CT	6
3.2 Artifact Reduction based on Deep Learning	6
3.3 Reproducible Evaluation and Generalization	8
4 Materials and Methods	9
4.1 Data, curation and traceability	9
4.1.1 CT-MAR Dataset and Reference Sources	9
4.1.2 Partitioning at patient level	10
4.1.3 Final Cohort and Exclusion of Unmatched Pairs	13
4.1.4 Anatomical Distribution and Stratification	14
4.2 Pre-processing	16
4.2.1 Integrity Verification	16
4.2.2 Background Removal through Body Mask	16
4.2.3 Intensity Window and Normalization	17
4.2.4 Artifact Mask for Auxiliary Supervision	17
4.3 Compared Architectures	17

4.3.1	U-Net Single Supervision	17
4.3.2	U-Net Dual Supervision	18
4.4	Reproducible Training	19
4.4.1	Settings, determinism and checkpoint selection	19
4.4.2	Loss Functions	21
4.5	Internal Evaluation	22
4.5.1	Global Metrics	23
4.5.2	ROI Metrics	23
4.5.3	Statistical Analysis	26
4.6	External Evaluation	26
4.6.1	Design and Cases	27
4.6.2	Quantitative Characterization of Input–Output	27
4.6.3	Presentation and Evaluation Instrument	27
4.6.4	Outcomes and Analysis	27
4.6.5	Operational Status	27
5	Results	28
5.1	Final Cohort and Experimental Integrity	28
5.1.1	Automatic Approval x Manually Inspection Results	28
5.1.2	Complementary Analysis with MS-SSIM	28
5.2	Model Training	35
5.2.1	Convergence and Checkpoint Selection	35
5.3	Internal Evaluation in Test Subset	43
5.3.1	Global Outcomes	43
5.3.2	Region of Interest Evaluation	47
5.3.3	Residual Maps in Extreme Cases	51
5.4	Paired Comparison Single x Dual Model	58
5.4.1	Global Statistical Analysis	58
5.4.2	Statistical Analysis per ROI	61
5.5	External Evaluation for Doctors	64
5.5.1	Capture Status and Participants	64
5.5.2	Quantitative Characterization of Input–Output	65
5.5.3	Primary Outcome: Anatomical Visualization	68
5.5.4	Secondary Outcomes and Safety Perception	69
5.5.5	Limited Interpretation to the Observational Design	70
6	Discussion	71
6.1	Summary of the main Findings	71
6.2	Architectural Comparison Interpretation	72
6.3	Anatomical Preservation and Reconstruction Safety	73
6.4	Generalization and External Evaluation	74
6.5	Evaluation for Doctors and Clinical Implications	74
6.6	Limitations	75
6.7	Implications and Future Work	76
7	Conclusions	77
7.1	Study Conclusions	77
7.2	Dissertation Contributions	77
7.3	Future Perspectives	77

Bibliography	77
A Supplementary Internal Evaluation	83
A.1 Worst Performance Cases	87
A.2 Computational Performance	89

List of Figures

4.1	Single Supervision U-Net architecture	18
4.2	Dual Supervision U-Net architecture	19
4.3	Artifact and distant ROI examples	25
5.3	Visually approved low MS-SSIM pairs	31
5.4	Visually rejected pairs	32
5.18	Greatest Artifact-ROI Δ SSIM: head_1147	52
5.19	Greatest Artifact-ROI Δ SSIM: head_1274	53
5.20	Greatest Artifact-ROI Δ SSIM: head_1280	54
5.21	Least Artifact-ROI Δ SSIM: body_11949	55
5.22	Least Artifact-ROI Δ SSIM: body_2906	56
5.23	Least Artifact-ROI Δ SSIM: body_11956	57
5.25	Least structurally changed external cases	67
5.26	Most structurally changed external cases	68

Lista de Gráficos

5.1	MS-SSIM distribution and zoom (clean CT-MAR vs DL/Stroke)	29
5.2	MS-SSIM ECDF (clean CT-MAR vs DL/Stroke)	30
5.5	Cosine similarity of MS-SSIM-audited pairs	33
5.6	MS-SSIM distribution of audited pairs	33
5.7	Score distribution of excluded pairs: DL vs Stroke EIT	34
5.8	Training curves: Dual Model, seed 1337	36
5.9	Training curves: Single Model, seed 1337	37
5.10	Training curves: Dual Model, seed 2024	38
5.11	Training curves: Single Model, seed 2024	39
5.12	Training curves: Dual Model, seed 42	40
5.13	Training curves: Single Model, seed 42	41
5.14	Per-image global PSNR and SSIM improvement	46
5.15	Patient-level Bland–Altman agreement of mean HU	47
5.16	Per-image ROI metric improvements	50
5.17	Artifact-ROI correction versus distant-ROI change	51
5.24	Global PSNR and SSIM improvement	61
A.1	Pixel-level HU agreement	83
A.2	Per-image input-output global metrics	85
A.3	Patient-level artifact load and improvement	86
A.4	Worst-case slices by global Δ SSIM	87
A.5	Worst-case slices by global Δ PSNR	88
A.6	Worst-case slices: joint Δ PSNR vs. Δ SSIM	89
A.7	Benchmark Latency	90

List of Tables

4.1	Initial pair-matching screening	13
4.2	Pair matching after MS-SSIM review	14
4.3	Excluded unmatched pairs before and after MS-SSIM review	14
4.4	Patient-level anatomical distribution by split	15
4.5	Patient distribution by split	15
4.6	Pair distribution by split and anatomical category	16
4.7	Pair distribution by split	16
4.8	Evaluation metrics by context	25
5.1	Best validation SSIM by model and seed	42
5.2	Validation PSNR at best validation SSIM	42
5.3	Validation MAE at best validation SSIM	42
5.4	Per-slice global SSIM on the test set	43
5.5	Per-slice global PSNR on the test set	43
5.6	Per-slice global MAE on the test set	43
5.7	Patient-level global Δ SSIM	44
5.8	Patient-level global Δ PSNR	44
5.9	Patient-level global Δ MAE	44
5.10	ROI Δ SSIM	48
5.11	ROI Δ PSNR	48
5.12	ROI MAE reduction	48
5.13	SSIM improvement over corrupted input	59
5.14	PSNR improvement over corrupted input	59
5.15	MAE reduction over corrupted input	59
5.16	Paired Single vs Dual Model comparison	60
5.17	Artifact-ROI SSIM improvement	61
5.18	Artifact-ROI PSNR improvement	61
5.19	Artifact-ROI MAE reduction	62
5.20	Paired Artifact-ROI improvement comparison	62
5.21	Distant-ROI SSIM preservation magnitude	62
5.22	Distant-ROI PSNR preservation magnitude	63
5.23	Distant-ROI MAE preservation magnitude	63
5.24	Paired Distant-ROI preservation advantage	63
5.25	Recruitment and completion status	64
5.26	Reader profile characteristics	64
5.27	Reader specialty distribution	65
5.28	External input-output global metrics	65
5.29	Illustrative external cases by input-output SSIM	66
5.30	Primary outcome: anatomical preservation preference	69
5.31	Primary outcome: mixed-effects model estimate	69

5.32 Secondary outcome: artifact intensity	69
5.33 Secondary outcome: distortion in other regions	69
5.34 Secondary outcome: clinical preference	70
5.35 Secondary outcome: complementary utility	70
5.36 Intra-reader reliability	70

This thesis is dedicated to my husband, for his love and support.

Chapter 1

Introduction

When Wilhelm Conrad Röntgen, University of Würzburg's physics teacher, in Germany, decided to repeat the experiment done by Philipp Lenard with a modified Crookes tube to study cathode rays, no one could foresee the impact of his discoveries on medicine.

It didn't take long for his experiments to present surprising results that demonstrated that the observed behavior was not compatible with cathode rays, but rather with a kind of more penetrating ray that did not suffer deflections in the presence of a magnetic field. During the handling of the pieces used in his experiments, he noticed that the outline of his bones was being imprinted on the fluorescent screen he was using.

Like that, on December 22, 1895, he invited his wife, Anna Bertha, to make a 15-minute exposure to these rays, obtaining what would be the first radiography of the human body. In this same year, Röntgen published the article "On a new kind of rays", in which he named the responsible agent as "X-rays". Already in January 1896, newspapers announced on the front page the discovery as a revolutionary way to observe the interior of the human body without the need for surgical incisions, pointing out its potential use in medical diagnosis [1, 2].

On February 1896, in Massachusetts (USA), Edwin Brant Frost produced a radiograph of a Colles fracture of a patient for his brother, a local doctor, marking the beginning of the incorporation of X-rays into medical practice [1]. Thus, less than a year after the announcement of Röntgen's discovery, X-rays quickly moved from laboratories to extensive use in diagnosis and therapy [1]. Since that, the techniques have undergone successive modernizations and diversified into multiple modalities and devices, consolidating themselves as an indispensable tool in modern healthcare [3, 4].

From these successive modernizations emerged, in 1971, the first computerized tomography scanner. This technology is based on the principle of x-rays attenuation, in which the amount of radiation absorbed or scattered by the material is related to its density [5, 6].

Computed Tomography (CT) was the first medical imaging modality to provide quantitative information about tissue attenuation, something that was not possible with conventional radiography [7]. Furthermore, allowing sectional visualization of the human body, it eliminated the overlap of anatomical structures inherent to two-dimensional images, enabling precise localization and assessment of the extent of lesions [7].

However, these advances brought a significant increase in technological complexity. The acquisition of multiple projections, combined with computational reconstruction and digital image processing, introduced new forms of degradation that were nonexistent or of little relevance in conventional radiography. Thus, computed tomography became particularly susceptible to the presence of artifacts, which can compromise the diagnostic quality and clinical reliability of images [7].

Various types of artifacts can be observed in computed tomography, including noise, beam hardening, motion, ring artifacts, and metal artifacts, which can obscure or simulate pathologies [8]. The causes of these artifacts are varied, ranging from detector failures or miscalibration, statistical limitations associated with low photon counts, to physical phenomena such as beam hardening and scattering, which produce dark streaks between high-attenuation objects such as metal, bone, or iodinated contrast media [7].

Specifically, streak artifacts caused by metallic implants are observed in approximately 21% of computed tomography scans, being considered extremely common in clinical practice [7]. The high attenuation or even total blockage of X-rays by these implants prevents the radiation from adequately reaching the detectors, resulting in low-quality projection data and compromising image reconstruction [9].

The increase use of metallic implants, driven by the evolution of healthcare, has intensified concerns regarding the negative impact of these artifacts on image quality and the reliability of diagnostic analyses [9]. Traditionally, various **Metal Artifact Reduction (MAR)** algorithms have been proposed, including image inpainting techniques, sinogram inpainting, and **Model-Based Iterative Reconstruction (MBIR)** or combinations of these approaches [10].

Although analytical methods such as **Filtered Back Projection (FBP)** have dominated tomographic reconstruction for decades due to their computational efficiency and conceptual simplicity, their limitations become evident under non-ideal clinical conditions, requiring higher radiation doses to ensure image quality [11]. **MBIR** methods emerged as an alternative to overcome these limitations, at the cost of higher computational demand and the introduction of artificial textures in the reconstructed image [11].

Recently, deep learning-based approaches have been widely investigated for artifact correction in computed tomography, demonstrating superior performance and greater clinical applicability compared to conventional methods [12]. In particular, [Convolutional Neural Networks \(CNNs\)](#) have been proposed for metal artifact reduction, enabling noise suppression and preservation of anatomical and soft tissue details [12].

1.1 Clinical and Technical Context

Due to the fact that artifacts in [CT](#) can hide or simulate pathologies, its presence can compromise the diagnostic quality and clinical reliability of images. A diagnostic mistake can have serious consequences for the patient, including treatment delays, inadequations or unnecessary, and even life-threatening risks. Additionally, the presence of artifacts can lead to increased radiation exposure, as additional scans may be required to obtain a clear image, which can increase the risk of radiation-induced complications. The constant technological evolution has made the use of metallic implants increasingly common in the medical context, which significantly increases the presence of this type of artifact and also the associated diagnostic mistakes.

Therefore, the reduction of artifacts in [CT](#) is a research area with significant clinical importance, and the development of effective methods to reduce artifacts gains high value in medical practice.

1.2 Work Motivation

Although studies using deep learning for metal artifact reduction are not new, a lot of the work published to date does not present a rigorous and detailed evaluation of the performance of the proposed models. In particular, the evaluation of the performance of models on external datasets (which were not used during model training) or evaluation of images by qualified professionals is often lacking. Moreover, the training of supervised models depends on reference images, which are difficult to obtain in a clinical context, creating a dependency on synthetic or simulated images. This lacking turns out to be still more relevant when considering that the performance of models trained on synthetic images may not be representative of their performance on real images, which can lead to overestimation of their effectiveness and limit their clinical applicability.

In this sense, the present study proposes a more rigorous and detailed evaluation of the performance of deep learning models for this purpose.

Chapter 2

Objectives and Investigation Question

2.1 General Objective

The general objective of this dissertation is to develop, evaluate and rigourously compare a CNN model for metal artifact reduction in CT, prioritizing anatomical preservation, robustness to domain variation and interpretability of the correction process. Additionally, the study aims to investigate the generalization of the best performing model to real and external data, with a focus on clinical applicability. Healthcare professionals will be involved in the evaluation of the model's performance on real data, providing a comprehensive assessment of its effectiveness and potential for clinical use.

2.2 Specific Objectives

The specific objectives of this study include:

- Develop a reproducible pipeline for training and evaluating metal artifact reduction models in CT in the image domain, with rigorous separation between training, validation, and test data.
- Evaluate the performance of a U-shaped Network (U-Net) to image reconstruction for metal artifact reduction and compare it with a version of itself with an additional supervision of artifact mask.
- Evaluate the performance of the two versions using quantitative metrics like: Peak Signal-to-Noise Ratio (PSNR), Structural Similarity Index Measure (SSIM), Mean Absolute Error (MAE), Binary Cross-Entropy (BCE) and Dice Similarity Coefficient (DICE). Besides, performing error maps, statistical and qualitative analysis to assess the quality of the reconstructed images.

- Investigate the generalization capability of the best performing version in the internal evaluation stage on real and external data from the [The Cancer Imaging Archive \(TCIA\)](#).

2.3 Hypothesis and Outcomes

The primary hypothesis of this study is that the reconstruction produced by each architecture significantly improves the structural quality of the image compared to the artifact input, in the internal test partition. This hypothesis is operationalized through the [SSIM](#), calculated in the [Region of Interest \(ROI\)](#) where the metal artifact is inserted and the clean [ROI](#) (where there is no artifact) would need to remain unchanged or poorly changed. The analyses were aggregated at the patient level ($n = 41$), with a null hypothesis of median paired differences input–model equal to zero.

The secondary hypothesis include: (i) the improvement of [PSNR](#) and [MAE](#), in HU, compared to the input, under the same patient-level aggregation; (ii) the same triad of metrics ([SSIM](#), [PSNR](#) and [MAE](#)) calculated in global image; and (iii) a direct paired comparison between the Single Model and the Dual Model on the same three metrics, addressing the architectural comparison objective.

As a criterion for anatomical preservation, it was defined that the change introduced in the Clean Zone should be substantially smaller, in magnitude, than the correction observed in the Artifact Zone, and that the global radiometric calibration bias, evaluated by Bland–Altman at the patient level, should be small relative to the amplitude of the [HU](#) window used. A formal equivalence margin for the Distant Zone was not pre-specified. Preservation is therefore characterized descriptively, and not tested for statistical equivalence.

Finally, as the external [TCIA](#) set does not have a clean reference, the generalization hypothesis is necessarily more limited: it is expected that the selected architecture produces, in the external cases, changes of plausible magnitude and without collapse to identity, but confirmation of artifact removal accuracy and clinical safety depends on blinded reader evaluation ([section 4.6](#)), and not on a reference metric.

Chapter 3

Related Works

3.1 Metallic Artifacts in CT

The traditional methods of artifact reduction in CT are predominantly based on physical and mathematical principles associated with image formation. Barrett and Keat[13] provide a detailed description of the origin of the main artifacts in CT, including beam hardening, photon starvation, scattering, and geometric effects, as well as classical strategies for their mitigation.

Reconstruction techniques such as FBP were widely used due to their computational efficiency, but they are highly sensitive to noise and metallic artifacts. More advanced methods, such as Iterative Reconstruction (IR) and MBIR, incorporate statistical models of the acquisition system and noise, allowing for partial artifact reduction. However, these approaches often introduce artificial textures and have limitations in complex clinical scenarios [11].

Recent revisions indicate that commercial algorithms for MAR, such as Orthopedic Metal Artifact Reduction (O-MAR), Iterative Metal Artifact Reduction (iMAR), and Single Energy Metal Artifact Reduction (SEMAR), although effective in specific situations, rely on proprietary parameters and exhibit inconsistent performance in cases of dense or multiple implants [9, 14]. These limitations have driven the investigation of deep learning-based approaches.

3.2 Artifact Reduction based on Deep Learning

The First applications of Deep Learning (DL) para MAR focused on the image domain, exploring convolutional networks to map degraded images to corrected versions. Gjestebj et al. [15] investigated metal artifact reduction in the image domain based on CNN and demonstrated significant quantitative improvements compared to conventional techniques.

Zhang e Yu [16] also purposed a supervised model based on Convolutional Neural Network (CNN) for metal artifact reduction in CT, achieving consistent gains in PSNR and Root Mean

Square Error (RMSE). These works helped consolidate the use of convolutional networks for **MAR** in the image domain. In particular, Zhang and Yu used a shallow fully convolutional **CNN** for fusing information from multiple pre-corrected images. Subsequent works increasingly adopted encoder-decoder architectures, especially those based on **U-shaped Network (U-Net)**, for correction/restoration tasks. **U-Net**-type networks and their variants are capable of capturing global contextual information through the contraction path, and recovering fine spatial details through the expansion path and *Skip Connections*[17].

Recent Systematic reviews have highlighted these advances, emphasizing that most supervised methods in the image domain exhibit competitive performance, especially when trained with high-quality paired data [9, 11].

In addition to image domain, some studies explored the sinogram domain, with linear interpolation and **Normalized Metal Artifact Reduction (NMAR)** methods. These approaches operate directly on the projection data and act directly on the physical origin of metallic artifacts[18]. However, access to raw projection data is often restricted in commercial **CT** systems, limiting the applicability of such approaches in clinical settings [15].

Beyond that, hybrid models have been purposed to leverage the advantages of each approach. The method purposed by Zhang and Yu [16] seeks to merge **CNN** in the image domain and classical **MAR** in the sinogram domain. In the adopted approach, the initial refinement occurs in the image domain, but the complete method uses the image generated by the **CNN** as a prior for replacement of affected regions in the sinogram. This characterizes a hybrid approach, but still does not employ **CNN** in both domains. More recent models, such as DuDoNet[19], integrate deep networks in both domains, demonstrating high performance and characterizing what we call Dual Domain. However, these methods present greater computational complexity and dependence on access to raw sinogram, which motivates the continuous exploration of robust solutions in the image domain.

To address the scarcity of anatomically paired data with metal artifact/metal artifact-free, self-supervised learning-based approaches have emerged. Yu et al. [20] proposed a method capable of reducing metal artifacts without the need for fully clean reference images, expanding the clinical applicability of these techniques.

Others works explored the use of **Generative Adversarial Network (GAN)** for **MAR**. Huang et al. [21] used multimodal fusion and **GANs** to improve texture preservation and reduce excessive smoothing. Despite good visual results, **GAN**-based can introduce training instability and a higher risk of structural hallucination[22], raising clinical concerns.

3.3 Reproducible Evaluation and Generalization

The evaluation of DL models for CT is typically performed through quantitative metrics such as PSNR, RMSE, and structural similarity-based indices. Traditional error-based metrics, such as RMSE and PSNR, quantify pixel-wise discrepancies but do not adequately capture structural information relevant to visual perception and clinical interpretation. In this context, Wang et al. [23] introduced the SSIM as a perceptual metric that explicitly models luminance, contrast, and structure. Subsequently, the Multi-Scale Structural Similarity Index Measure (MS-SSIM) was proposed to incorporate scale-dependent structural variations, extending SSIM to multiple resolution levels [24]. Horé and Ziou [25] demonstrated that both PSNR and SSIM have limitations depending on the type of distortion considered, suggesting that the choice of metric may depend on the application context. Given that metallic artifacts manifest primarily as structural distortions affecting anatomical boundaries and long-range streak patterns, metrics sensitive to structural preservation, such as SSIM and MS-SSIM, are particularly suitable for evaluating the performance of MAR methods, as they explicitly consider structural components at different spatial scales [23, 24].

Additionally, a critical challenge identified in the literature is the models generalization. Zech et al. [26] demonstrated that models with high performance on internal datasets can fail significantly when applied to external data, highlighting the impact of Domain Shift. Recent reviews reinforce the need for rigorous external and clinical validation to ensure safety, robustness and real applicability [27, 28].

The reviewed literature demonstrates significant advancements in artifact reduction in CT through DL, but also evidences persistent gaps: lack of experimental standardization, limited external validation, and risk of anatomical hallucination.

Chapter 4

Materials and Methods

4.1 Data, curation and traceability

4.1.1 CT-MAR Dataset and Reference Sources

The main dataset used in this work comes from the [CT Metal Artifact Reduction Challenge \(CT-MAR\)](#) [29, 30] promoted by the [American Association of Physicists in Medicine \(AAPM\)](#) and consists of 14,000 training pairs containing [CT](#) images with simulated metal artifacts and their original artifact-free versions. The data was generated through a hybrid simulation framework [31], which incorporates publicly available clinical images and simulated metallic objects with the CatSim simulator, integrated into the open-source XCIST toolkit [32]. The dataset is distributed into two anatomical categories:

- **Head:** 1.626 (11.61%) samples derived from the *UCLH Stroke EIT Data* [33, 34];
- **Body:** 12.374 (88.38%) samples derived from the *NIH DeepLesion Data* [35].

Where the folders in the *body* category contained trunk [CTs](#), covering axial, thoracic, and abdominal slices. The data is organized into subfolders, each containing up to 1,000 samples. Only the following files were used for training and validation:

1. **Metal-free images (reference):** Files contained in the *Target* folder of size 512×512×1 pixels;
2. **Images with metal artifacts (corrupted):** Files contained in the *Baseline* folder of size 512×512×1 pixels;

All image files (.raw) in the dataset are presented in binary format without a header, with float32 precision in little-endian order. The images were already converted from linear attenuation coefficients (in mm^{-1} units) to [Unidade Hounsfield \(HU\)](#), using the normalization value of

0.02 mm^{-1} for water. There was not additional information about which exam each slice belonged to, if they were from the same patient, or which specific anatomical regions were represented. The only available information was the organization by folder, indicating the anatomical category (Head or Body). The lack of detailed metadata imposed the need for a careful pre-processing approach to ensure that the data was properly organized and used during model training and validation. Therefore, a significant effort was dedicated to tracking the images to the original datasets (UCLH Stroke EIT Data and NIH DeepLesion Data) to obtain additional information about the exams and patients, allowing for an appropriate partitioning of the data.

4.1.2 Partitioning at patient level

The data partitioning was stratified by patients, ensuring that slices from the same patient were not distributed across training, validation, and test sets. This approach prevents information leakage and ensures a more realistic assessment of the models generalization capability.

Due to the lack of detailed clinical metadata in the [CT-MAR](#) dataset, an algorithmic screening of the slices to the original datasets (UCLH Stroke EIT and NIH DeepLesion Data) was necessary to enable the association of the provided metadata with the [CT-MAR](#) slices. This process allowed for the identification of which exam and patient from DeepLesion/UCLH Stroke EIT each [CT-MAR](#) image belonged to. This information was subsequently used to perform patient-level partitioning of the data into training, validation, and test sets, reducing the risk of data leakage between experimental sets.

The correct separation of the data is particularly important in medical imaging studies based on [DL](#), once slices belonging to the same exam often present high anatomical similarity. Thus, the simultaneous presence of images from the same patient in training and testing can artificially inflate the model's performance and compromise the assessment of its generalization capability [36].

The Deep Lesion images [35] are stored in 16-bit PNG format, while the [CT-MAR](#) images are provided in .raw format directly in Hounsfield units (HU). The UCLH Stroke EIT [33] provides the exams in DICOM format. Therefore, regardless of the original format, all images were converted to HU before comparison, ensuring uniformity across the different datasets.

After the conversion, all images was represented on the same intensity scale to allow direct comparison.

The screening algorithm was based on fact that [CT](#) images preserve quantitative information in [HU](#), which directly reflects the tissue attenuation properties. Since anatomical structures

exhibit high spatial continuity between consecutive slices of the same acquisition, images corresponding to the same anatomical slice tend to present similar HU distributions and highly consistent global structural patterns [23, 37].

That way, the method was not designed to verify absolute pixel-to-pixel equality between images, but rather to determine whether the overall structural organization of the anatomy remains extremely similar across different representations of the same slice. This behavior is particularly important because small local variations in intensity, numerical discretization, and linear transformations associated with storage format conversion tend to preserve the global anatomical structure of the image even when small local intensity variations occur [23, 37].

Thus, the adopted methodology seeks to identify correspondences between images based on global structural similarity, allowing for a margin of local variation that does not compromise the correct identification of the exam and patient of origin. Initially, each image was reduced to a compact representation through *downsampling*, preserving mainly the relevant global anatomical information. This step significantly reduces the computational cost without compromising the overall structure of the image.

Subsequently, a representative vector (*fingerprint*) was calculated for each image. The fingerprints of the CT-MAR images were then compared with the fingerprints of the DeepLesion and UCLH Stroke EIT images using a normalized dot product-based vector similarity metric (cosine similarity). It was chosen for being invariant to global scale differences between vectors — a relevant property given that the images come from different formats with different intensity normalizations. For each CT-MAR image, the image with the highest similarity score was selected.

Since the majority of the CT-MAR images originated from DeepLesion, the screening process was initially prioritized on that dataset. Subsequently, the same methodology was applied to the DICOM exams from UCLH Stroke EIT to identify the remaining images. In this way, it was possible to implement a unified traceability strategy regardless of the storage format of the original datasets.

The matching was considered valid only when the score of similarity exceeded a previously defined empirically threshold. Cases with very high scores were automatically marked as safe matches, as it was observed that all pairs visually analyzed with a score above 0.993 effectively corresponded to the same image. To maintain an additional safety margin, the match was considered automatically valid only when the score exceeded 0.994.

Scores below this threshold indicated potentially ambiguous matches and were subjected to manual visual inspection. Scores below approximately 0.98 indicated clearly incorrect matches

and were automatically discarded without the need for manual review. Thus, all pairs with scores between 0.98 and 0.994 were visually analyzed to confirm the validity of the match. In order to avoid unnecessary exclusion of pairs, all pairs with a score below 0.98 for both datasets (DeepLesion and UCLH Stroke EIT) were subjected to visual inspection to ensure they were not erroneously discarded.

For the 530 pairs that remained without approved matches after direct search in both source datasets, a complementary indirect matching step was applied. In this step, each unmatched CT-MAR image was compared with already traced CT-MAR images; the most similar neighbors were used to select candidate exams from DeepLesion and then all *slices* of those exams were searched with 64×64 dimension *fingerprints*. The 530 proposals were visually inspected: 95 matches were approved and incorporated into the consolidated manifest, while 435 remained without a safe match and were excluded.

Moreover, the algorithm was designed to automatically ignore images that had already been verified as correct matches, reducing redundancies and accelerating future reprocessing. Given the high number of images present in the datasets, the processing was parallelized and optimized through the use of vectorized matrix operations. When available, the algorithm utilizes GPU acceleration to reduce execution time. The calculated fingerprints were also cached to avoid unnecessary recomputation in subsequent runs.

Although, the compact representation based exclusively on the mean of block intensities HU is efficient, it can theoretically generate false positives when different patients exams are acquired with identical acquisition protocols or present very similar anatomical structures. Since these conditions tend to produce similar intensity distributions and, consequently, fingerprints with high scores. To mitigate this risk, a conservative automatic acceptance threshold (0.994) was adopted and a systematic visual validation of all pairs with scores between 0.98 and 0.994 was performed. Additionally, as a complementary safeguard, all automatic matches were analyzed in terms of MS-SSIM, where the pairs with the most critical scores were subjected to an additional visual review to ensure the reliability of the matches.

Despite that, this limitation does not compromise the main objective of the methodology. Even though consecutive slices from the same exam often present high spatial redundancy and can therefore obtain very similar similarity scores. The purpose of the algorithm was not to perform rigorous voxel-to-voxel alignment, but rather to correctly identify the exam and patient of origin of each CT-MAR image. In this way, even potential ambiguities between adjacent slices remain restricted to the same anatomical volume and do not introduce a relevant risk of data leakage between training, validation, and test sets.

The literature demonstrates that the quality of the pairs used in supervised studies directly influences the performance and generalization capability of [MAR](#) models [9, 19]. In addition, structural metrics of image quality, such as [SSIM](#), have been widely used in medical imaging due to their higher sensitivity to structural preservation [23]. Although the implemented method does not directly use [SSIM](#), the adopted strategy seeks to precisely preserve the global structural information of the image during the matching process.

Moreover, the data utilization without any screening treatment would condition the entire project to an inherent data leakage from the dataset, compromising the evaluation of the models performance and the validity of the results. Thus, even if the screening method is not perfect, it represents a significant improvement over the total absence of screening, ensuring a more reliable basis.

Taking this into account, this step constituted an important quality control procedure for the experimental dataset and was fundamental to ensure an appropriate partitioning of the data used in this work.

4.1.3 Final Cohort and Exclusion of Unmatched Pairs

Not all slices could be traced, but most of the data was successfully associated with the original exams. At the end of the direct and indirect matching steps, and before the complementary analysis with [MS-SSIM](#), out of the 14,000 pairs provided by the [CT-MAR](#) Dataset, 11,942 were traced to DeepLesion (including the 95 recovered by indirect matching) and 1,623 to UCLH Stroke EIT, totaling 13,565 pairs with associated metadata [4.1](#).

Table 4.1 Resultados do rastreio antes da análise complementar com [MS-SSIM](#).

Dataset	Traced	Matched	Unmatched
DeepLesion	12,374	11,942	432
UCLH Stroke	1,626	1,623	3
Total	14,000	13,565	435

In the evaluation step through [MS-SSIM](#), among all pairs with a score below 0.90, only 3, previously associated with Deep Lesion, were rejected in the visual inspection [4.2](#).

Table 4.2 Pair matching results after the complementary MS-SSIM analysis.

Dataset	Traced	Matched	Unmatched
DeepLesion	12,374	11,939	435
UCLH Stroke	1,626	1,623	3
Total	14,000	13,562	438

Due to the fact that a significant amount of the data could be traced with high reliability, the remaining cases that could not be safely grouped were excluded from the training and validation process. In total, 438 pairs were removed for not having sufficient information to ensure safe grouping at the patient level. Among them, the 3 pairs rejected for being false positives in the evaluation step via [MS-SSIM](#). All pairs removed from this study were visually inspected to confirm the absence of correspondence, ensuring that the exclusion was justified.

Table 4.3 Unmatched pairs data that was excluded before and after the complementary MS-SSIM analysis.

	Excluded	
	Before	After
Total	435	438

Thus, out of the 14,000 pairs originally provided by the [CT-MAR](#) Dataset, 13,562 were included in this work, while 438 were excluded to preserve the integrity of the experimental partitioning and minimize the risk of data leakage.

4.1.4 Anatomical Distribution and Stratification

The anatomical proportion of 14,000 pairs in the [CT-MAR](#) Dataset changed little after the screening and exclusion process of pairs with low reliability. Of the 438 removed cases, 435 were of the *body* type and 3 of the *head* type. The anatomical distribution of the pairs included in the study is as follows:

- **Body:** approximately 88.03% ;
- **Head:** approximately 11.97% .

Stratification was implemented within each subset (train/val/test) to maintain the anatomical proportion at the patient level, ensuring that the relative proportion between categories is preserved across all subsets. In this way, the anatomical balance is preserved, ensuring that the

models are trained and evaluated on an appropriate representation of the anatomical diversity present in the original dataset.

At the patient level, the anatomical distribution is as follows:

- **Body:** approximately 95.9% (258/269 patients);
- **Head:** approximately 4.1% (11/269 patients).

After partitioning, the train, validation, and test subsets had the following distribution:

Table 4.4 Patient-level anatomical distribution by split.

Split	Body	Head	% Body	% Head
Train	180	7	96.3%	3.7%
Val	39	2	95.1%	4.9%
Test	39	2	95.1%	4.9%
Total	258	11	–	–

The patient-level partition was defined only once, with a fixed random seed, maintaining approximately 70% of the patients for training, 15% for validation, and 15% for testing. This fixed partition ensured independent subsets for validation and testing and was kept unchanged across all experimental repetitions.

Table 4.5 Patient distribution by split.

Split	Patients	% Total
Train	187	69.52%
Val	41	15.24%
Test	41	15.24%
Total	269	100%

Due to the large variation in the number of slices per patient, the anatomical distribution at the pair level is quite different from the distribution at the patient level (4.6 and 4.7). The same occurs for the total pairs distribution. Thus, the proportion of $\sim 70/15/15$ was maintained at the patient level, but at the pair level it does not follow exactly the same proportion.

Table 4.6 Pair distribution by split and anatomical category.

Split	Body	Head	% Body	% Head
Train	8 563	953	89.98%	10.02%
Val	2 147	385	84.79%	15.21%
Test	1 229	285	81.17%	18.83%
Total	11 939	1 623	–	–

Table 4.7 Pair distribution by split.

Split	Pairs	% Total
Train	9 516	70.17%
Val	2 532	18.67%
Test	1 514	11.16%
Total	13 562	100%

4.2 Pre-processing

4.2.1 Integrity Verification

All pairs were validated through an integrity report, which checks for the existence of both sides of the pair (artifact image and clean image). There were no pairs with missing data, ensuring that the dataset was complete and ready for subsequent pre-processing and model training steps.

4.2.2 Background Removal through Body Mask

The [CT](#) images often contain large background areas that do not contribute to the task of metal artifact removal. That creates a class imbalance in the training data, where irrelevant background voxels dominate over the anatomical regions of interest. This imbalance, in turn, hinders the learning and deviates the model focus from clinically relevant structures [38, 39]. To address this challenge, a pre-processing step also based on [DL](#) was implemented. A [U-Net](#) was trained to segment the body tissue from the background, generating binary masks that were applied to the original images to isolate the regions of interest. This model was trained using $\sim 1,500$ samples from the [CT-MAR](#), where the segmentation masks were automatically generated through a thresholding process. Additionally, a manual refinement was performed on

the obtained masks to ensure the quality of the training data and consequently the effectiveness of the segmentation model.

This step was essential to reduce the influence of background artifacts and improve the quality of features extraction during training.

4.2.3 Intensity Window and Normalization

The image intensities are expressed in HU from the CT-MAR. To reduce extreme variations, an intensity window appropriate to the anatomical context was applied. After windowing, the values were normalized to the range $[0, 1]$ and 2D tensors of dimension 256×256 were generated for each slice and its pair.

4.2.4 Artifact Mask for Auxiliary Supervision

Binary difference masks of the affected regions by artifacts were produced and used as an additional supervision signal in the dual architecture. These masks are exclusively used during the training and are not required during inference. The binary difference mask is formally defined as:

$$M_{diff}(i, j) = \begin{cases} 1; & \text{if } |I_{artifact}(i, j) - I_{clean}(i, j)| > \tau \\ 0; & \text{otherwise} \end{cases} \quad (4.1)$$

where $I_{artifact}$ represents the image with artifacts, I_{clean} the clean reference image, and τ is the normalized difference threshold. The value of this threshold was empirically defined to capture regions with perceptible differences while maintaining robustness to low-amplitude noise.

4.3 Compared Architectures

4.3.1 U-Net Single Supervision

The first model consist of an architecture based on U-Net [17], composed of encoder-decoder with skip connections. Li et al [40], apply blocks of Batch Normalization (BN) and Rectified Linear Unit (ReLU) activation functions after each dynamic convolution. This work does something similar, but chooses to use standard convolutions with 3×3 kernel, followed by BN blocks and ReLU activation functions. The choice for standard convolutions is justified by simplicity and computational efficiency, in addition to maintaining the approach used by Ronneberger et

al [17]. Like Li et al [40], the decoder also uses bilinear upsampling. This architecture has only one output.




Fig.4.1 Single supervision architecture diagram.

4.3.2 U-Net Dual Supervision

A variation of the model described above was conceived, maintaining the shared *encoder* and *decoder* and adding an independent output in the last layer. Thus, there are two distinct outputs in the decoder, each with its own loss function. The first output is responsible for reconstructing the corrected image, while the second output is dedicated to predicting the artifact mask.

The rationale for adding the auxiliary supervision of the artifact mask is based on the premise that the presence of an additional loss focused on segmenting regions affected by artifacts can provide complementary information to the model, aiding in learning more robust and discriminative representations. This approach is inspired by previous works that have shown that multi-task supervision can improve performance in related tasks [41, 42].

The two architectures were evaluated against each other to determine the impact of the additional supervision with artifact mask on reconstruction quality and artifact reduction capability. All model bases are identical, with the presence of the artifact mask prediction output being the only difference in the second version. Thus, the comparison between the two architectures is

fair and isolated, allowing for an exclusive evaluation of the impact of the additional supervision of the artifact mask.




Fig.4.2 Dual supervision architecture diagram.

4.4 Reproducible Training

4.4.1 Settings, determinism and checkpoint selection

Both models were trained under the same settings, with *float32* precision. To assess stability against different initializations and batch presentation orders, each architecture was trained with deterministic operations and with seeds 1337, 42, and 2024, always on the same patient partition. **Automatic Mixed Precision (AMP)** was disabled and batches were kept complete, including the last batch of each epoch, to avoid samples being excluded from training, validation, or evaluation.

The AdamW optimizer was used, with an initial learning rate of 2.26×10^{-4} , weight decay of 1.00×10^{-4} and gradient clipping with norm 1.00, identical for both architectures. The learning rate was adjusted by the ReduceLROnPlateau scheduler, with a reduction factor of 0.50, patience of two epochs, cooldown of one epoch and minimum value of 1.00×10^{-6} , monitoring the reconstructed image **SSIM** on the validation set in both models. The training had a maximum

limit of 300 epochs and early stopping could only be triggered after at least five epochs and occurred when the monitored metric did not improve by at least 1.00×10^{-4} for 15 consecutive epochs. In each run, the checkpoint corresponding to the best value of the monitored validation metric was retained.

Only the best checkpoint per run was preserved, saved in `.keras` format with a filename encoding the architecture, epoch, and monitored metric; the training CSV explicitly flags the corresponding row with `best_checkpoint=1`. Checkpoint selection relied exclusively on the pre-specified validation metric: `val_ssim_hu` for the Single Model and `val_img_out_ssim_hu` for the reconstruction output of the Dual Model.

Run traceability was ensured through reproducibility snapshots in JSON format, preserved in `outputs/reproducibility/`. Six final internal evaluations were frozen, corresponding to the three random initializations (seeds 42, 1337, and 2024) of the Single Model and Dual Model. All snapshots were generated from commit `a950be7276a5585de45e8ae874c59c065a1985be`, on branch `projeto_final`, with a clean working tree (`is_dirty: false`).

Each snapshot records the operating system, Python version, and relevant dependency versions. The execution environment used Python 3.11.9 on Windows 10, including TensorFlow 2.15.0, NumPy 1.26.4, Pandas 2.2.2, scikit-image 0.21.0, and Matplotlib 3.7.5. In addition, SHA-256 hashes were computed for the configuration files, the canonical pair manifest, the patient-level partition definition, the tensor generation metadata, and the environment requirements file.

For each run, the snapshot preserves the path, size, and SHA-256 hash of the checkpoint, the full command used for evaluation on the test set, and the hashes of the output files, including aggregated and per-sample metrics. Thus, every value, table, or figure reported can be unambiguously traced to the code, environment, input data, checkpoint, and results that produced it.

During the training, the following quantities were monitored:

- **Reconstruction loss**, to track the optimization of the corrected image;
- **Segmentation loss**, only in the dual model, to track the auxiliary supervision of the artifact mask;
- **SSIM, PSNR, and MAE in HU scale**, calculated in the body region to track the structural and radiometric fidelity of the reconstructions.

4.4.2 Loss Functions

- **Reconstruction:** Despite L2 being widely used for image restoration, Zhao et al. [43] highlight the best results studying different loss functions for this task and show that it consistently underperforms perceptually-motivated alternatives. The authors studied loss functions based on L1, SSIM and MS-SSIM, being that second achieves equal or tiny inferior results than L1, while the third achieves better performance than SSIM but still does not clearly outperform L1. The paper also tests a mix of L1 and MS-SSIM, and obtained superior results in all metrics evaluated by the authors. This combination is justified by the complementarity between the two functions, where L1 favors local fidelity and MS-SSIM promotes structural preservation, resulting in a more balanced correction of artifacts. Although the best result reported by the authors involved L1 and MS-SSIM, in this work the weighted sum of L1 and SSIM was adopted. This choice maintains the general principle of combining a pixel fidelity component with a structural component, without reproducing the specific formulation or weights used by Zhao et al.

The weights used for the experimental protocol were 0.7 for L1 and 0.3 for SSIM. The relation adopted for the combination of the loss functions is as follows:

$$\mathcal{L}_{Recon} = 0.7 \cdot \mathcal{L}_{L1} + 0.3 \cdot (1 - \text{SSIM})$$

Zhao et al. [43] applied a Gaussian spatial weighting to the L1 component in the hybrid loss, in order to make it compatible with the spatial distribution of the gradients of the MS-SSIM component. In this work, the L1 component was calculated directly as the mean absolute error in the body region, without additional Gaussian weighting. Since the normalization used is linear with respect to HU values, this component maintains a penalty directly proportional to the radiometric error, while SSIM contributes to local structural preservation.

This combination of loss function is adopted for the Single Model and also for the reconstruction output of the Dual Model. In this way, it is ensured that the ablation between the two versions is fair, isolating the impact of the additional supervision of the mask.

- **Mask auxiliary supervision:** The mask artifact prediction output, present in Dual Model, was trained with the sum of Dice Similarity Coefficient (DICE) loss and Binary Cross-Entropy (BCE). This combination provides simultaneous supervision for global overlap between masks and pixel-wise classification, being suitable for segmentation problems with class imbalance [38]. The relation adopted for the combination of the loss functions

is as follows:

$$\mathcal{L}_{Seg} = \mathcal{L}_{Dice} + \mathcal{L}_{BCE}$$

The total loss function for the dual-head version is composed of the weighted sum of the reconstruction and segmentation losses, and is defined as:

$$\mathcal{L} = 1.0 \cdot \mathcal{L}_{Recon} + 0.045 \cdot \mathcal{L}_{Seg}$$

4.5 Internal Evaluation

In the inference phase, the models were evaluated using quantitative metrics widely adopted in the literature, in comparison with the Ground Truth. The metrics used to evaluate reconstructed image quality were:

- **PSNR** ;
- **SSIM** ;
- **MAE**.

The recent literature have demonstrated statistically superior performance in fidelity for **MS-SSIM** and **SSIM** compared to other image quality assessment metrics [44]. Especially for medical images, where the fidelity of predicted images is crucial, the choice of metrics that reflect human perception of quality and structural preservation is fundamental. Therefore, **SSIM** was selected as the primary metric for quantitative evaluation of the quality of reconstructed images, ensuring a robust and relevant analysis for the clinical context. And **PSNR** was used as a complementary metric to assess the radiometric fidelity of reconstructions, especially important in computed tomography where the accuracy of **HU** values is essential for diagnosis and clinical planning.

The internal validation was conducted on the validation and test subsets, evaluating consistency, stability, and intra-dataset generalization capability.

After the selection of the best checkpoint from each of the six runs in validation, the checkpoints were compared on the internal test partition to select the best architecture for external evaluation. The decision favored the greatest improvement in **SSIM** in the Artifact Zone and globally, followed by better **PSNR** and **MAE** in the Artifact Zone and globally as a tiebreaker. After this comparison, the selected architecture was frozen, without further training, hyperparameter tuning, or weight adjustment before external evaluation.

4.5.1 Global Metrics

For global evaluation, the predicted and reference images are denormalized to the window $[-1000, 400]$ HU, corresponding to a range $\text{MAX} = 1400$ HU. Additionally, the evaluation region is cropped to the smallest bounding box of the body mask before SSIM evaluation, eliminating scan windows composed exclusively of background — which would artificially score $\text{SSIM} = 1,0$ and inflate the global metric.

As a complementary descriptive verification of possible global radiometric shift, a Bland–Altman diagram was constructed between the reconstruction and the clean reference. For each patient, the mean in HU of each image was calculated over all valid pixels of the body mask of the respective slices, weighted by the number of pixels in each slice. The graph presents the mean difference per patient ($\text{Model} - \text{GT}$) as a function of the mean of the two measures, as well as the mean bias and limits of agreement $\bar{d} \pm 1,96 SD_d$. This analysis is purely descriptive, with the patient as the unit of the graph, and does not replace fidelity metrics or regional evaluation of artifact reduction.

4.5.2 ROI Metrics

The global evaluation does not distinguish the model's behavior in regions directly affected by artifacts from that in body regions distant from the implant. Therefore, each slice was divided into two complementary zones based on the difference between the artifact-corrupted input and the clean reference. Let I_{in} be the input image, I_{ref} the clean reference, and M_{body} the body mask. The signed difference $d = I_{\text{ref}} - I_{\text{in}}$ was calculated, and its median value in the body, $b = \text{median}(d \mid M_{\text{body}})$, was removed to avoid interpreting a global deviation associated with beam hardening as a local artifact.

The artifact Zone ($\mathcal{R}_{\text{art}}$) was defined as:


$$M_{\text{art}} = [|d - b| > \tau] \cap M_{\text{body}}, \quad \tau = 0,03.$$

which is approximately 42 HU in the normalized scale used. Connected components with fewer than 20 pixels were removed. No additional morphological dilation was applied ($r = 0$), preserving the observed geometry of the *streaks*. The Distant Zone ($\mathcal{R}_{\text{dist}}$) was defined as the complement of the artifact zone in the body region.

$$M_{\text{dist}} = M_{\text{body}} \setminus M_{\text{art}}.$$

This zone quantifies changes outside the directly affected region; the clinical interpretation of anatomical preservation was reserved for external evaluation by readers.

The [Figure 4.5.2](#) illustrates the application of the two zones in representative slices of the dataset, covering different anatomical regions and artifact patterns.






Fig.4.3 Artifact Zone ROI (left) and Clean Zone ROI (right) examples.

In every evaluation context, the metrics were expressed as variations relative to the performance of the corrupted input. Let Ω be the evaluation domain, which can correspond to the global region defined above (Ω_{global}), the Artifact Zone ($\mathcal{R}_{\text{art}}$), or the Distant Zone ($\mathcal{R}_{\text{dist}}$), and let $\hat{I}$ be the reconstruction produced by the model. The variations were defined by:

$$\Delta\text{PSNR}_{\Omega} = \text{PSNR}(\hat{I} |_{\Omega}, I_{\text{ref}} |_{\Omega}) - \text{PSNR}(I_{\text{in}} |_{\Omega}, I_{\text{ref}} |_{\Omega})$$

$$\Delta\text{SSIM}_{\Omega} = \text{SSIM}(\hat{I} |_{\Omega}, I_{\text{ref}} |_{\Omega}) - \text{SSIM}(I_{\text{in}} |_{\Omega}, I_{\text{ref}} |_{\Omega})$$

$$\Delta\text{MAE}_{\Omega} = \text{MAE}(I_{\text{in}} |_{\Omega}, I_{\text{ref}} |_{\Omega}) - \text{MAE}(\hat{I} |_{\Omega}, I_{\text{ref}} |_{\Omega}).$$

Thus, $\Delta\text{PSNR} > 0$ and $\Delta\text{SSIM} > 0$ indicate improvement over the corrupted input. Since lower MAE represents better fidelity, the order of subtraction was reversed for this metric: $\Delta\text{MAE} > 0$ indicates error reduction and, therefore, improvement; $\Delta\text{MAE} < 0$ indicates error increase. Regular SSIM was used, calculated with a local window of 11×11 pixels and cropping with context around the evaluated region.

Table 4.8 Evaluation metrics by context.

Metric	Train	Global	Artifact Zone	Clean Zone
PSNR	✓	✓	✓	✓
SSIM	✓	✓	✓	✓
MAE	✓	✓	✓	✓

4.5.3 Statistical Analysis

In all inferential analysis, the patient constituted the independent experimental unit. To avoid pseudoreplication resulting from the inclusion of multiple slices from the same patient, the metrics calculated per slice were first aggregated by mean within each patient. Thus, for each metric m and patient p , paired values of the input and reconstruction, or of the two architectures, were compared according to the analysis.

To evaluate the improvement over the corrupted input, paired differences per patient $d_p = m_{\text{Model},p} - m_{\text{Input},p}$ were calculated for **PSNR** and **SSIM**. For **MAE**, whose reduction represents better performance, $d_p = m_{\text{Input},p} - m_{\text{Model},p}$ was used. The null hypothesis in each test was that the median of the paired differences was equal to zero. The direct comparison between architectures used $d_p = m_{\text{Dual},p} - m_{\text{Single},p}$, so that negative values favor the Single Model.

The values of p presented in the comparison tables were adjusted using the Holm sequential procedure, which controls the family-wise error rate without assuming independence between tests. For the m raw p values ordered as $p_{(1)} \leq \dots \leq p_{(m)}$, the adjusted value at position i was calculated as:

$$p_{(i)}^{\text{Holm}} = \max_{j \leq i} \left\{ \min \left[1, (m - j + 1)p_{(j)} \right] \right\}.$$

In the reconstruction improvement table, the correction was applied jointly to the four corresponding tests for **PSNR** and **SSIM** for each of the two architectures. In the paired comparison Single Model versus Dual Model, the correction was applied jointly to the two tests, one for **PSNR** and another for **SSIM**.

The confidence interval of 95% reported for the mean differences was obtained by patient-level percentile *bootstrap*. For each metric, the vector of $n = 41$ paired differences per patient was resampled with replacement, maintaining n observations in each resample; the mean difference was then calculated in each of the 10,000 resamples. The lower and upper limits of the interval correspond, respectively, to the 2.5 and 97.5 percentiles of the empirical distribution of these means. This procedure does not assume normality of the differences and preserves the patient, rather than the slice, as the unit of inference. Seed 1337 was used to make the resampling deterministic.

4.6 External Evaluation

The external evaluation was realized in independent data provided by the [The Cancer Imaging Archive \(TCIA\)](#), allowing to assess the impact of domain shift and the robustness of the model

in scenarios not seen during training.

4.6.1 Design and Cases

4.6.2 Quantitative Characterization of Input–Output

As a complementary characterization of the alteration introduced by the model in external cases, **SSIM**, **PSNR**, and **MAE** were calculated directly between the input image and the respective output of the model selected for that. The metrics was evaluated only in the 15 main cases of the frozen external set; the two training cases were excluded. The calculation domain was the effective body mask, manually corrected during case preparation. For **PSNR**, the intensity window $[-1000, 400]$ **HU** with amplitude 1400 **HU** was used.

There is no clean reference for these real cases. Thus, higher **SSIM** and **PSNR**, as well as lower **MAE**, describe less global alteration between input and output, and not greater accuracy of artifact removal or improvement compared to a reference. The statistics were summarized per case, such as mean and standard deviation, and the 95% confidence intervals for the mean were obtained by percentile *bootstrap* with 10,000 resamplings and seed 1337. The interpretation of the clinical acceptability of these alterations remained reserved for blind evaluation by readers.

4.6.3 Presentation and Evaluation Instrument

4.6.4 Outcomes and Analysis

4.6.5 Operational Status

Chapter 5

Results

5.1 Final Cohort and Experimental Integrity

5.1.1 Automatic Approval x Manually Inspection Results

É importante deixar claro como ficou a distribuição dos dados que foram aprovados e reprovados automaticamente, e também quais foram avaliados manualmente. O gráfico abaixo, mapeia todos os pares do [CT-MAR](#) Dataset, destacando os que foram aprovados automaticamente, os que foram reprovados e os que foram sujeitos a inspeção visual humana. A distribuição anatômica dos pares é representada por cores, permitindo uma análise visual da relação entre a aprovação automática e a localização anatômica dos artefatos metálicos.

5.1.2 Complementary Analysis with [MS-SSIM](#)

Antes de avançar para a análise dos resultados dos modelos de redução de artefatos, foi realizada mais uma avaliação dos resultados [CT-MAR](#) x DeepLesion/Stroke EIT para verificar a qualidade das correspondências automáticas. Esta etapa é crucial para garantir uma camada extra de confiança nos resultados obtidos pelo algoritmo de comparação de similaridade estrutural. Todos os pares que tiveram a correspondência aprovada automaticamente pelo fato de seu score ser acima de 0.994 foram revisados por um novo algoritmo que calcula o [MS-SSIM](#) entre as imagens correspondentes. Um histograma da distribuição dos [MS-SSIM](#) foi gerado, e os pares com pontuação menor que 0.9 foram revisados manualmente sendo aprovado ou recusado com base em avaliação humana.




Fig.5.1 Distribuição de MS-SSIM entre pares correspondentes (**CT-MAR** vs DL/Stroke, aprovados automaticamente). Acima: histograma com os percentis P1 e P5, mediana, média e limiar de 0.9. Abaixo: zoom do histograma para a região de maior interesse, com destaque para os pares com MS-SSIM inferior a 0.9, que foram sujeitos a revisão manual.

A análise da distribuição entre os pares correspondentes revela que a maioria dos pares apresenta alta similaridade estrutural, com um valor médio de 0.9694 e uma mediana de 0.9830, indicando que o processo de correspondência automática é, em geral, confiável e eficaz na identificação de pares correspondentes entre os datasets **CT-MAR** e DeepLesion/Stroke EIT.

Os pares com pontuação de **MS-SSIM** abaixo de 0.9 eram 340 no total, apenas 3 foram reprovados após inspeção visual humana 5.2. Nessa inspeção, percebe-se que mesmo os casos com pontuações bastante baixas de **MS-SSIM** não eram falsos positivos e sim devido a diferenças no pós-processamento ou tratamento geral das imagens que geram alterações locais no qual o **MS-SSIM** é mais sensível. Isso pode ser visualizado na figura 5.3. Esse fato evidencia a eficácia da estratégia de correspondência por similaridade estrutural global adotada, que conseguiu identificar os pares com precisão, com apenas 3 falsos positivos identificados, mesmo após análise rigorosa 5.4. Mostrando que a metodologia é robusta e teve desempenho superior em detectar slices nesse trabalho do que uso do próprio **MS-SSIM**. Pois, enquanto as diferenças locais afetaram o **MS-SSIM** de forma mais significativa, a metodologia baseada em similaridade de cosseno conseguiu identificar as correspondências corretas com pontuação global elevada, mesmo em casos de diferenças locais acentuadas.




Fig.5.2 Distribuição de MS-SSIM entre pares correspondentes (**CT-MAR** vs DL/Stroke, aprovados automaticamente). À esquerda: histograma com os percentis P1 e P5, mediana, média e limiar de 0.9. À direita: ECDF correspondente. Os pares com MS-SSIM inferior a 0.9 foram sujeitos a revisão manual.




Fig.5.3 Exemplos de pares correspondentes com valores de **MS-SSIM** (0.7597, 0.7694 e 0.7717, respetivamente) aprovados após revisão visual humana mesmo com pontuações baixas.

Os pares reprovados apresentavam **MS-SSIM** claramente fora do padrão (< 0.61), com valores extremamente baixos, como podem ver na figura 5.4. Além disso, representaram os pares com pontuação mais próximas do limiar de aceitação automática de 0.994 5.5. Demonstrando que os casos em que o método falha são outliers claros em **MS-SSIM** e permanecem justamente na zona cinzenta e propensa a erros da determinação empírica do limiar de aceitação

automática. Além disso, os pares reprovados possuem características visuais bastante particulares com fundo dominando a imagem e poucas estruturas anatômicas visíveis, o que torna a avaliação de similaridade estrutural mais desafiadora devido a grande homogeneidade das características visuais.




Fig.5.4 3 pares reprovados após inspeção visual humana com valores de MS-SSIM (head_1159: 0.4573, head_369: 0.5652 e head_763: 0.6009, respetivamente). As pontuações desses pares na similaridade de cosseno foram head_1159: 0.9960, head_369: 0.9952 e head_763: 0.9951.




Fig.5.5 Distribuição dos valores de similaridade de cosseno para os pares inspecionados visualmente.

Os pares com **MS-SSIM** mais críticos logo acima dos reprovados tinham valores maiores que 0.75 5.3, demonstrando uma distancia clara entre os falsos positivos e os aprovados visualmente. Todos os pares inspecionados com pontuação acima desse valor de **MS-SSIM** passaram no teste de inspeção visual 5.6. Como os pares que não passaram por esse escrutínio tinham pontuação acima de 0.90 em **MS-SSIM**, é seguro assumir que os pares automaticamente aprovados com pontuação acima desse limiar são confiáveis.




Fig.5.6 Distribuição dos valores de **MS-SSIM** para os pares inspecionados visualmente.

Na busca direta, 530 pares não obtiveram correspondência aprovada em nenhum dos dois datasets de origem. A etapa complementar de correspondência indireta recuperou 95 desses casos após inspeção visual, restando 435 pares sem correspondência segura.

Com relação aos possíveis falsos negativos que poderiam ter resultado em exclusão de pares de forma injusta nesse estudo, a metodologia adotada foi ainda mais robusta. Já que eram poucos os pares que não tiveram aprovação em nenhum dos dois datasets de origem, ficou fácil verificar visualmente cada um desses casos para confirmar se realmente não havia correspondência ou se o método falhou em identificá-la. Dos 435 pares excluídos 245 foram excluídos devido ao critério automatizado baseado no limiar de 0.98. Nenhum desses casos eram realmente falsos negativos, confirmando mais uma vez a eficácia do método de correspondência automática adotado. Os outros 190 pares caíram na faixa de pontuação pouco confiável (0.98 – 0.994) e foram marcados como falsa correspondência nessa etapa evidenciando a importância de ter-se determinado uma zona cinzenta de pontuação para a qual o método de correspondência automática não é eficiente, e que a revisão visual humana torna-se indispensável 5.7.




Fig.5.7 Distribuição dos *scores* de similaridade de cosseno (DL vs Stroke EIT) para os pares sem correspondência aprovada em nenhum dos dois *datasets* de origem (N=435). Histograma laranja mostra a distribuição das pontuações dos 435 pares reprovados no Stroke EIT Dataset. O histograma em azul, mostra a distribuição dos mesmos 435 pares reprovados no Deep Lesion Dataset.

5.2 Model Training

5.2.1 Convergence and Checkpoint Selection

A seleção do *checkpoint* para avaliação final foi baseada na melhor versão do **SSIM** calculado na partição de validação. Obviamente, no modelo Dual, esse critério foi aplicado na saída de reconstrução.

A regra de paragem definia um máximo de épocas de 300 e um mínimo de 5, com *Early Stopping* após 15 épocas sem melhoria mínima de 0.0001 no **SSIM** da partição de validação. Consequentemente, devido à restauração dos pesos da melhor época, a época final de treino não é necessariamente a selecionada.

O otimizador monitoriza a mesma métrica, reduzindo o *learning rate* em 0.5 após 2 épocas sem melhoria relevante (*ReduceLROnPlateau*), até 1×10^{-6} com uma época de *cooldown*. O mesmo valor de variação mínima de 0.0001 foi usado no *Scheduler* e no *Early Stopping*.




Fig.5.8 Curvas de convergência para `seed_1337/training_001_dualhead`. Linhas verticais laranja pontilhadas: reduções da taxa de aprendizagem; linha roxa tracejada: época do melhor checkpoint segundo o SSIM de validação; linha preta traço-ponto: interrupção do treino. O painel de *generalization gap* representa validação menos treino para o SSIM e permite identificar divergência persistente compatível com sobreajuste.




Fig.5.9 Curvas de convergência para `seed_1337/training_008_singlehead`. Linhas verticais laranjas pontilhadas: reduções da taxa de aprendizagem; linha roxa tracejada: época do melhor checkpoint segundo o SSIM de validação; linha preta traço-ponto: interrupção do treino. O painel de *generalization gap* representa validação menos treino para o SSIM e permite identificar divergência persistente compatível com sobreajuste.




Fig.5.10 Curvas de convergência para `seed_2024/training_001_dualhead`. Linhas verticais laranjas pontilhadas: reduções da taxa de aprendizagem; linha roxa tracejada: época do melhor checkpoint segundo o SSIM de validação; linha preta traço-ponto: interrupção do treino. O painel de *generalization gap* representa validação menos treino para o SSIM e permite identificar divergência persistente compatível com sobreajuste.




Fig.5.11 Curvas de convergência para `seed_2024/training_001_singlehead`. Linhas verticais laranjas pontilhadas: reduções da taxa de aprendizagem; linha roxa tracejada: época do melhor checkpoint segundo o SSIM de validação; linha preta traço-ponto: interrupção do treino. O painel de *generalization gap* representa validação menos treino para o SSIM e permite identificar divergência persistente compatível com sobreajuste.




Fig.5.12 Curvas de convergência para `seed_42/training_001_dualhead`. Linhas verticais laranjas pontilhadas: reduções da taxa de aprendizagem; linha roxa tracejada: época do melhor checkpoint segundo o SSIM de validação; linha preta traço-ponto: interrupção do treino. O painel de *generalization gap* representa validação menos treino para o SSIM e permite identificar divergência persistente compatível com sobreajuste.




Fig.5.13 Curvas de convergência para `seed_42/training_001_singlehead`. Linhas verticais laranja pontilhadas: reduções da taxa de aprendizagem; linha roxa tracejada: época do melhor checkpoint segundo o SSIM de validação; linha preta traço-ponto: interrupção do treino. O painel de *generalization gap* representa validação menos treino para o SSIM e permite identificar divergência persistente compatível com sobreajuste.

Nas 6 corridas, todas terminaram entre 38 e 47 épocas, após a taxa de aprendizagem atingir o limite mínimo. Os melhores **SSIMs** de validação ocorreram nas épocas 23–44, antes da paragem, o que sustenta o uso de restauração dos melhores pesos.

O maior valor de **SSIM** foi 0.95113 do Single Model, seed 2024, na época 33. O valor de **PSNR** variou entre ~ 35.0 dB - 35.3 dB, com o maior valor de 35.3009 dB do Single Model, seed 2024, na mesma época 33. Os resultados detalhados podem ser visualizados nas Tabelas 5.1, 5.2 e 5.3.

Seed	Best SSIM (HU)		
	42	1337	2024
Single Model	0.95096 (31)*	0.95106 (44)	0.95113 (33)
Dual Model	0.94938 (41)	0.94895 (28)	0.95025 (23)

*Valores entre parênteses indicam a época correspondente.

Table 5.1 Maior SSIM de validação por modelo e seed, com a época correspondente. No Dual Model, o SSIM é calculado na saída de reconstrução de imagem.

Seed	PSNR (dB) - Same Best SSIM Epoch		
	42	1337	2024
Single Model	35.16365 (31)	35.20020 (44)	35.30099 (33)
Dual Model	35.10422 (41)	35.00705 (28)	35.23622 (23)

Table 5.2 PSNR de validação na época selecionada pelo melhor SSIM de validação, por modelo e seed. No Dual Model, ambas as métricas são calculadas na saída de reconstrução de imagem.

Seed	MAE (HU) - Same Best SSIM Epoch		
	42	1337	2024
Single Model	17.52002 (31)	17.36296 (44)	17.19180 (33)
Dual Model	17.58006 (41)	17.73584 (28)	17.35387 (23)

Table 5.3 MAE de validação na época selecionada pelo melhor SSIM de validação, por modelo e seed. No Dual Model, ambas as métricas são calculadas na saída de reconstrução de imagem.

O melhor resultado de **MAE** foi 17.1918 HU também do Single Model, seed 2024, na época 33. Podemos notar que o Single Model teve desempenho superior nas 3 métricas.

O **PSNR** e **MAE** são apenas métricas complementares, mas não são o foco principal de seleção do melhor checkpoint que considera apenas o **SSIM** isoladamente. Além disso, as métricas separadas por **ROI**, análises visuais, e métricas de teste interno são avaliações feitas após a seleção do melhor checkpoint e portanto não alteram o checkpoint escolhido.

A escolha da corrida que avançará para a avaliação externa é uma decisão distinta da seleção do checkpoint. Entre os checkpoints já selecionados, a comparação é efetuada na partição de teste, buscando equilíbrio entre a maior melhoria de **SSIM** na Zona de Artefacto e menor mudança de **SSIM** na Zona Distante. Após essa seleção não houve novo treino, ajuste de hiperparâmetros ou alterações nos pesos antes da avaliação externa.

5.3 Internal Evaluation in Test Subset

5.3.1 Global Outcomes

A avaliação interna foi realizada na partição de teste fixa, composta por 1478 fatias de 41 pacientes independentes. Para cada checkpoint previamente selecionado na validação, foram calculados PSNR, SSIM e MAE entre a reconstrução e a referência limpa. A unidade de agregação para a inferência estatística foi o paciente: as métricas foram primeiro resumidas dentro de cada paciente e os intervalos de confiança de 95% foram obtidos por *bootstrap* percentil com 10000 reamostragens. O conjunto de teste não foi utilizado para escolher checkpoints.

A Table 5.5, a Table 5.4 e a Table 5.6 apresentam as médias por fatia. Como todas as corridas foram avaliadas na mesma partição de teste, o valor da entrada é comum aos dois modelos em cada seed. Em todas as corridas, a reconstrução aumentou o PSNR global de 27,39 dB para 34,95–35,20 dB, aumentou o SSIM de 0,8361 para 0,9421–0,9442 e reduziu o MAE de 36,6 HU para 17,3–17,8 HU.

SSIM global

Seed	Input	Single Model	Dual Model
42	0.8361 ± 0.0880	0.9439 ± 0.0289	0.9424 ± 0.0292
1337	0.8361 ± 0.0880	0.9441 ± 0.0286	0.9421 ± 0.0289
2024	0.8361 ± 0.0880	0.9442 ± 0.0288	0.9432 ± 0.0292

All input and model values are computed against the clean reference (*ground truth*).

Table 5.4 SSIM global por fatia no conjunto de teste ($n = 1478$), expresso como média $\pm$ desvio padrão.

PSNR global (dB)

Seed	Input	Single Model	Dual Model
42	27.39 ± 4.14	35.09 ± 2.82	35.06 ± 2.84
1337	27.39 ± 4.14	35.13 ± 2.81	34.95 ± 2.82
2024	27.39 ± 4.14	35.20 ± 2.84	35.16 ± 2.82

All input and model values are computed against the clean reference (*ground truth*).

Table 5.5 PSNR global por fatia no conjunto de teste ($n = 1478$), expresso como média $\pm$ desvio padrão.

MAE global (HU)

Seed	Input	Single Model	Dual Model
42	36.569 ± 21.906	17.649 ± 5.689	17.654 ± 5.905
1337	36.569 ± 21.906	17.485 ± 5.624	17.842 ± 5.789
2024	36.569 ± 21.906	17.341 ± 5.573	17.475 ± 5.563

All input and model values are computed against the clean reference (*ground truth*).

Table 5.6 MAE global por fatia no conjunto de teste ($n = 1478$), expresso como média $\pm$ desvio padrão.

Embora a seleção do extitSingle Model, seed 2024, tenha sido definida na validação, as tabelas por semente mostram que esta não corresponde a um resultado isolado: as três execuções do Single Model apresentaram desempenho global muito próximo e superior ao das execuções Dual Model. A seed 2024 ficou no extremo favorável para acrshortssim e acrshort-psnr, e apresentou o menor acrshortmae. Esta comparação entre sementes é descritiva, não constituindo um teste de hipótese entre inicializações.

Os deltas e respetivos intervalos de confiança por paciente são apresentados na Table 5.8, na Table 5.7 e na Table 5.9. Todas as corridas melhoraram as três métricas; os testes de Wilcoxon bilaterais foram significativos para os três desfechos em todas as corridas ($p < 0,001$). Os intervalos de confiança não incluem o valor nulo, sustentando a melhoria global face à entrada com artefactos.

Δ SSIM Global (IC 95%)

Seed	Single Model	Dual Model
42	0.0887 [0.0728; 0.1063]	0.0870 [0.0713; 0.1043]
1337	0.0891 [0.0734; 0.1065]	0.0867 [0.0710; 0.1041]
2024	0.0891 [0.0732; 0.1066]	0.0879 [0.0719; 0.1053]

Note: Δ SSIM = SSIM(Model, GT) – SSIM(Input, GT).

Table 5.7 Δ SSIM global agregado por paciente no conjunto de teste ($n = 41$). IC: intervalo de confiança de 95%.

Δ PSNR Global (dB, IC 95%)

Seed	Single Model	Dual Model
42	6.96 [6.22; 7.68]	6.96 [6.24; 7.65]
1337	7.05 [6.33; 7.75]	6.85 [6.12; 7.55]
2024	7.11 [6.36; 7.83]	7.06 [6.31; 7.78]

Note: Δ PSNR = PSNR(Model, GT) – PSNR(Input, GT).

Table 5.8 Δ PSNR global agregado por paciente no conjunto de teste ($n = 41$). IC: intervalo de confiança de 95%.

Δ MAE Global (HU, IC 95%)


Seed	Single Model	Dual Model
42	15.3 [12.2; 19.0]	15.3 [12.3; 18.9]
1337	15.6 [12.4; 19.3]	15.2 [12.1; 18.8]
2024	15.7 [12.5; 19.5]	15.5 [12.4; 19.3]

Note: Δ MAE = MAE(Input, GT) – MAE(Model, GT); positive values indicate error reduction.

Table 5.9 Δ MAE global agregado por paciente no conjunto de teste ($n = 41$). Valores > 0 representam melhoria; IC: intervalo de confiança de 95%.

Para a corrida seleccionada, Single Model com seed 2024, os histogramas da Figure 5.14 mostram a distribuição dos deltas globais por fatia. Embora estes gráficos sejam descritivos e as fatias de um mesmo paciente não sejam independentes, eles tornam visíveis os poucos casos desfavoráveis: 12 de 1478 fatias (0,8%) apresentaram Δ PSNR negativo e 24 (1,6%)

apresentaram ΔSSIM negativo. A inferência estatística permanece baseada nas médias por paciente apresentadas nas tabelas anteriores.






Fig.5.14 Per-image global improvement over the corrupted input for the Single Model, seed 2024: Δ SSIM (top) and Δ PSNR (bottom). Green bars indicate improvement and red bars indicate degradation. The distributions are descriptive; inferential analyses used patient-level aggregation.

Nota-se que o Single Model para as sementes 1337 e 2024 apresentam praticamente o mesmo desempenho em [SSIM](#). No entanto, em [PSNR](#) e [MAE](#) o mesmo modelo se sai melhor com a seed 2024. Isso já coloca a versão Single com semente 2024 em evidência para ser o candidato selecionado para a avaliação externa. Porém, ainda é necessário verificar o desempenho por [ROI](#), já que essas métricas são muito mais informativas a respeito de onde o modelo está realmente melhorando a imagem.

Como verificação descritiva complementar da calibração global em unidades HU, a [Figure 5.15](#) apresenta a concordância entre a média de HU da reconstrução e a da referência limpa, agregada por paciente. Cada ponto corresponde a um dos 41 pacientes, a média de cada paciente foi calculada sobre todos os pixels válidos da máscara corporal, ponderada pelo número de pixels em cada fatia. O viés médio foi de +4.19 HU, com limites de concordância de 95% entre +1.45 e +6.93 HU. Esta análise descreve um pequeno deslocamento positivo da intensidade média global, mas não quantifica a remoção local de artefactos nem substitui as métricas globais e por [ROI](#).




Fig.5.15 Bland-Altman agreement between the Single Model reconstruction and the clean reference for patient-level mean HU ($n = 41$). Each patient mean was calculated over all valid body-mask pixels; positive differences indicate higher mean HU in the reconstruction. The limits of agreement are descriptive.

5.3.2 Region of Interest Evaluation

As regiões de interesse e o cálculo das métricas por zona seguiram o procedimento descrito na ???. Esta estratificação permite quantificar separadamente a correção na região diretamente afetada pelos artefactos e as alterações introduzidas nas regiões corporais distantes do implante.

Os resultados finais, agregados primeiro por paciente e depois resumidos em 41 pacientes independentes, são apresentados nas Table 5.11, Table 5.10 e Table 5.12. Todas as seis corridas apresentaram melhoria substancial na Zona de Artefacto: Δ PSNR entre 11,47 e 11,86 dB, Δ SSIM entre 0,322 e 0,328 e redução de MAE entre 96,9 e 98,5 HU. Na Zona Distante, as alterações médias foram menores (Δ PSNR entre 1,36 e 1,61 dB; Δ SSIM entre 0,057 e 0,058; redução de MAE entre 3,2 e 3,6 HU), devendo ser interpretadas como descrição quantitativa e não como validação clínica de preservação anatômica.

Novamente, o Single Model com sementes 1337 e 2024 apresentam desempenhos muito semelhantes em SSIM, com a semente 2024 levando uma minúscula vantagem. Já na análise por ROI, o melhor desempenho em PSNR e MAE com a semente 2024 fica menos evidente do que na análise global, especialmente quando considera-se as alterações na Zona Limpa. Mesmo assim, as alterações na Zona Limpa são pequenas e varia pouco entre os modelos e sementes. Dessa forma, foi decidido priorizar o desempenho da semente na análise Global e

Δ SSIM

Seed	Model	Artifact ROI	Clean ROI
42	Single Model	0.3276 ± 0.0954	0.0579 ± 0.0426
	Dual Model	0.3233 ± 0.0937	0.0568 ± 0.0421
1337	Single Model	0.3278 ± 0.0933	0.0582 ± 0.0421
	Dual Model	0.3224 ± 0.0953	0.0566 ± 0.0422
2024	Single Model	0.3279 ± 0.0955	0.0581 ± 0.0422
	Dual Model	0.3266 ± 0.0954	0.0576 ± 0.0422

Note: Δ SSIM = SSIM(Model, GT) – SSIM(Input, GT) within the indicated ROI.

Table 5.10 Δ SSIM por ROI no conjunto de teste. Os valores são média $\pm$ desvio-padrão entre pacientes ($n = 41$).

 Δ PSNR (dB)

Seed	Model	Artifact ROI	Clean ROI
42	Single Model	11.75 ± 2.59	1.46 ± 1.43
	Dual Model	11.65 ± 2.53	1.48 ± 1.43
1337	Single Model	11.84 ± 2.54	1.53 ± 1.35
	Dual Model	11.47 ± 2.57	1.36 ± 1.52
2024	Single Model	11.86 ± 2.69	1.61 ± 1.41
	Dual Model	11.84 ± 2.62	1.53 ± 1.48

Note: Δ PSNR = PSNR(Model, GT) – PSNR(Input, GT) within the indicated ROI.

Table 5.11 Δ PSNR por ROI no conjunto de teste. Os valores são média $\pm$ desvio-padrão entre pacientes ($n = 41$).

 Δ MAE (HU)



Seed	Model	Artifact ROI	Clean ROI
42	Single Model	97.8 ± 19.6	3.3 ± 3.2
	Dual Model	97.5 ± 19.1	3.4 ± 3.1
1337	Single Model	98.5 ± 19.6	3.5 ± 3.1
	Dual Model	96.9 ± 19.9	3.2 ± 3.3
2024	Single Model	98.4 ± 20.2	3.6 ± 3.1
	Dual Model	98.3 ± 19.8	3.5 ± 3.3

Note: Δ MAE = MAE(Input, GT) – MAE(Model, GT) within the indicated ROI; positive values indicate error reduction.

Table 5.12 Redução de MAE por ROI no conjunto de teste. Os valores são média $\pm$ desvio-padrão entre pacientes ($n = 41$); valores positivos correspondem a redução do erro.

por ROI (mesmo que muito pequena) para selecionar o modelo que seguirá para a avaliação externa. A escolha final recaiu sobre o Single Model, seed 2024, que apresentou o melhor desempenho global e por ROI. As [Figure 5.16](#) e [Figure 5.17](#) mostram a distribuição por imagem para a corrida selecionada. Por simplicidade, os gráficos de agora em diante são apresentados apenas para o modelo selecionado, mas os dados de todas as corridas estão disponíveis no apêndice ??.

Os diagramas de caixa evidenciam a separação entre a correção na Zona de Artefacto e a alteração menor na Zona Limpa. O diagrama de dispersão permite identificar heterogeneidade entre fatias, incluindo casos individuais com alterações desfavoráveis na Zona Limpa.







Fig.5.16 Distribuições por imagem das variações de SSIM, PSNR e MAE nas zonas de artefacto e limpa para o Single Model, seed 2024.






Fig.5.17 Relação por imagem entre a melhoria de $\Delta SSIM \setminus \Delta PSNR$ na Zona de Artefacto e a alteração de $\Delta SSIM \setminus \Delta PSNR$ na Zona Limpa para o Single Model, seed 2024. A cor codifica a redução de ΔMAE na Zona Limpa.

5.3.3 Residual Maps in Extreme Cases

Para complementar os resultados, foram inspecionados seis casos individuais do Single Model, seed 2024, na partição de teste. A seleção foi feita exclusivamente pelo $\Delta SSIM$ na Zona de Artefacto por fatia: os três maiores valores correspondem à maior melhoria estrutural nessa região face à entrada e os três menores valores à menor melhoria estrutural. Assim, os termos “maior” e “menor” melhoria nesta subseção referem-se apenas a esse critério quantitativo e não constituem uma classificação clínica dos casos.

Em cada mapa, a primeira linha apresenta a alteração necessária em relação à referência limpa ($r_{\text{target}} = \text{GT} - \text{Input}$), a alteração produzida pelo modelo ($r_{\text{model}} = \text{Output} - \text{Input}$) e o erro residual remanescente ($r_{\text{diff}} = r_{\text{model}} - r_{\text{target}} = \text{Output} - \text{GT}$). A segunda linha mostra o erro absoluto da entrada, o erro absoluto da saída e a respetiva diferença, em que verde indica redução do erro e vermelho indica agravamento. O contorno amarelo delimita a Zona de Artefacto. As escalas de cor são ajustadas individualmente a cada fatia para preservar os detalhes em casos com resíduos pequenos. No entanto, a comparação entre casos deve privilegiar os padrões espaciais e as estatísticas apresentadas em cada painel, e não apenas a intensidade

aparente das cores. Abaixo de cada mapa é apresentada a visualização correspondente da entrada com artefactos, da saída do modelo e da referência limpa.





Fig.5.18 Residual map (top) and reconstruction visualization (bottom) for case head_1147 (test-set index 1250), selected among the three highest artifact-ROI ΔSSIM values ($\Delta\text{SSIM}_{\text{ROI}} = +0.7220$; global $\Delta\text{SSIM} = +0.1649$; $\Delta\text{PSNR} = +15.99$ dB). The yellow contour delimits the artifact ROI; all error maps are restricted to the body mask.




Fig.5.19 Residual map (top) and reconstruction visualization (bottom) for case head_1274 (test-set index 1364), selected among the three highest artifact-ROI ΔSSIM values ($\Delta\text{SSIM}_{\text{ROI}} = +0.7164$; global $\Delta\text{SSIM} = +0.3752$; $\Delta\text{PSNR} = +19.48$ dB). The yellow contour delimits the artifact ROI; all error maps are restricted to the body mask.





Fig.5.20 Residual map (top) and reconstruction visualization (bottom) for case head_1280 (test-set index 1369), selected among the three highest artifact-ROI $\Delta SSIM$ values ($\Delta SSIM_{ROI} = +0.7068$; global $\Delta SSIM = +0.3837$; $\Delta PSNR = +16.53$ dB). The yellow contour delimits the artifact ROI; all error maps are restricted to the body mask.





Fig.5.21 Residual map (top) and reconstruction visualization (bottom) for case body_11949 (test-set index 0716), selected among the three lowest artifact-ROI ΔSSIM values ($\Delta\text{SSIM}_{\text{ROI}} = -0.0466$; global $\Delta\text{SSIM} = -0.0497$; $\Delta\text{PSNR} = -4.31$ dB). The yellow contour delimits the artifact ROI; all error maps are restricted to the body mask.





Fig.5.22 Residual map (top) and reconstruction visualization (bottom) for case body_2906 (test-set index 1122), selected among the three lowest artifact-ROI ΔSSIM values ($\Delta\text{SSIM}_{\text{ROI}} = -0.0200$; global $\Delta\text{SSIM} = +0.0740$; $\Delta\text{PSNR} = +0.38$ dB). The yellow contour delimits the artifact ROI; all error maps are restricted to the body mask.




Fig.5.23 Residual map (top) and reconstruction visualization (bottom) for case body_11956 (test-set index 0723), selected among the three lowest artifact-ROI $\Delta SSIM$ values ($\Delta SSIM_{ROI} = -0.0141$; global $\Delta SSIM = -0.0345$; $\Delta PSNR = -0.64$ dB). The yellow contour delimits the artifact ROI; all error maps are restricted to the body mask.

5.4 Paired Comparison Single x Dual Model

5.4.1 Global Statistical Analysis

Esta análise compara exclusivamente os dois *checkpoints* finais treinados com a seed 2024, um por arquitetura. A seleção do Single Model, seed 2024, para prosseguir para a avaliação externa já havia sido definida com base no desempenho de validação. Portanto, os resultados no conjunto de teste apresentados nesta secção têm caráter de avaliação interna final: não foram utilizados para escolher novos *checkpoints*, ajustar hiperparâmetros ou alterar a arquitetura a avaliar externamente.

As métricas por fatia foram agregadas por paciente antes de todos os resumos e testes de hipótese, resultando em $n = 41$ observações independentes. Assim, as médias, os intervalos de confiança de 95% e os valores de p apresentados nas tabelas desta secção referem-se às médias por paciente, atribuindo o mesmo peso a cada indivíduo.

As tabelas desta secção apresentam a análise das métricas globais, calculadas em todos os píxeis da máscara corporal de cada fatia (píxeis de fundo excluídos), como confirmação complementar da hipótese primária de melhoria estrutural, testada formalmente na Zona de Artefacto na secção seguinte.

Os diagnósticos por paciente mostraram assimetria e desvio da normalidade para ΔSSIM e ΔMAE . Assim, a evidência primária para essas métricas foi baseada no teste de sinais binomial exato, que avalia a predominância de melhorias sem pressupor simetria das diferenças. Para ΔPSNR , cuja distribuição por paciente não mostrou evidência de afastamento da normalidade, foi utilizado o teste t bilateral de uma amostra para a melhoria média.

Os diagnósticos de distribuição foram verificados separadamente para ambos os modelos antes de aplicar esta regra comum por métrica. Para ΔSSIM , o teste de Shapiro–Wilk indicou desvio da normalidade no Single Model ($W = 0.9158$; $p = 0.0050$; assimetria = 1.087) e no Dual Model ($W = 0.9162$; $p = 0.0052$; assimetria = 1.056), sustentando o uso do teste de sinais em ambas as arquiteturas. Para ΔMAE , observou-se o mesmo padrão no Single Model ($W = 0.7607$; $p = 8.95 \times 10^{-7}$; assimetria = 2.281) e no Dual Model ($W = 0.7686$; $p = 1.27 \times 10^{-6}$; assimetria = 2.200). Para ΔPSNR , não houve evidência de afastamento da normalidade nos diagnósticos do Single Model ($W = 0.9742$; $p = 0.4675$) ou do Dual Model ($W = 0.9734$; $p = 0.4427$), o que foi compatível com o uso do teste t para a melhoria média em ambos os modelos.

A [Table 5.13](#), a [Table 5.14](#) e a [Table 5.15](#) mostram que ambas as arquiteturas melhoraram substancialmente a qualidade global da reconstrução face à entrada corrompida. O

Reconstruction Quality: SSIM

Model	Mean improvement	95% BCa CI	p (Holm)
Single Model	0.0891	[0.0744; 0.1075]	7.64×10^{-11}
Dual Model	0.0879	[0.0731; 0.1062]	7.64×10^{-11}

Global body-mask-aware metric, aggregated at the patient level ($n = 41$); no ROI restriction. Two-sided exact binomial sign-test p -values, Holm-adjusted separately within each model across SSIM, PSNR, and MAE.

Table 5.13 Global SSIM improvement over the corrupted input on the test set.

Reconstruction Quality: PSNR

Model	Mean improvement (dB)	95% t CI	p (Holm)
Single Model	7.11	[6.35; 7.87]	4.53×10^{-21}
Dual Model	7.06	[6.30; 7.81]	4.42×10^{-21}

Global body-mask-aware metric, aggregated at the patient level ($n = 41$); no ROI restriction. Two-sided one-sample t -test p -values, Holm-adjusted separately within each model across SSIM, PSNR, and MAE.

Table 5.14 Global PSNR improvement over the corrupted input on the test set.

Reconstruction Quality: MAE

Model	Mean reduction (HU)	95% BCa CI	p (Holm)
Single Model	15.72	[12.94; 20.14]	7.64×10^{-11}
Dual Model	15.54	[12.79; 19.88]	7.64×10^{-11}

Global body-mask-aware metric, aggregated at the patient level ($n = 41$); no ROI restriction. Positive Δ MAE denotes error reduction. Two-sided exact binomial sign-test p -values, Holm-adjusted separately within each model across SSIM, PSNR, and MAE.

Table 5.15 Global MAE reduction over the corrupted input on the test set.

Single Model apresentou Δ SSIM médio de 0.0891 (IC 95% BCa: [0.0744; 0.1075]), Δ PSNR médio de 7.11 dB (IC 95% t : [6.35; 7.87]) e redução média de MAE de 15.72 HU (IC 95% BCa: [12.94; 20.14]). O Dual Model apresentou Δ SSIM de 0.0879 (IC 95% BCa: [0.0731; 0.1062]), Δ PSNR de 7.06 dB (IC 95% t : [6.30; 7.81]) e redução média de MAE de 15.54 HU (IC 95% BCa: [12.79; 19.88]). Todos os seis testes de melhoria global face à entrada permaneceram significativos após o ajuste de Holm aplicado separadamente dentro de cada arquitetura. Os valores de p de Δ SSIM e Δ MAE avaliam a predominância de melhoria, enquanto os de Δ PSNR avaliam a melhoria média, por isso, não devem ser comparados em magnitude.

Estes testes confirmam que cada arquitetura melhora a entrada corrompida, mas não constituem uma comparação direta entre arquiteturas. Esta distinção é essencial: valores de p pequenos nas tabelas Table 5.13, Table 5.14, Table 5.15 não permitem, por si só, afirmar que uma arquitetura é superior à outra.

Os deltas de melhoria subjacentes à comparação pareada são igualmente agregados por paciente, atribuindo o mesmo peso a cada um dos 41 pacientes.

Dual Model – Single Model: Improvement Deltas

Metric	Mean Difference	95% BCa CI	p (sign test; Holm)
Δ SSIM	−0.0012	[−0.0015; −0.0010]	2.35×10^{-9}
Δ PSNR (dB)	−0.054	[−0.107; −0.017]	2.75×10^{-2}
Δ MAE (HU)	−0.186	[−0.338; −0.091]	8.62×10^{-4}

Differences of patient-level input-to-output improvement deltas (Dual Model – Single Model), with 95% BCa bootstrap CIs (10 000 resamples). Two-sided exact binomial sign-test p -values are Holm-adjusted across PSNR, SSIM, and MAE. Negative differences favor the Single Model for all three metrics.

Table 5.16 Patient-level paired comparison of improvement deltas between architectures ($n = 41$).

A comparação direta entre arquiteturas é apresentada na [Table 5.16](#). Para esta análise, calculou-se, em cada paciente, a diferença de melhoria Dual Model menos Single Model para Δ SSIM, Δ PSNR e Δ MAE. Foram aplicados testes binomiais exatos de sinais bilaterais, excluindo diferenças nulas e com correção de Holm conjunta para os três testes. Esta análise testa se uma arquitetura melhora mais em mais pacientes do que o esperado ao acaso, sem pressupor simetria das diferenças. Os intervalos de confiança de 95% obtidos por *bootstrap* BCa com 10 000 reamostragens quantificam a diferença média, enquanto os valores de p avaliam a predominância direcional. Em todas as métricas, valores negativos favorecem o Single Model.

O Single Model apresentou vantagem média de 0.054 dB em Δ PSNR, de 0.0012 em Δ SSIM e de 0.186 HU em Δ MAE. Os intervalos de confiança não incluíram zero e os valores de p ajustados foram 2.75×10^{-2} para [PSNR](#), 2.35×10^{-9} para [SSIM](#) e 8.62×10^{-4} para [MAE](#). As diferenças favoreceram o Single Model em 28 dos 41 pacientes para [PSNR](#), em 39 para [SSIM](#) e em 32 para [MAE](#). Embora estas diferenças sejam estatisticamente significativas, a sua magnitude absoluta é pequena. Portanto, os resultados fornecem evidência de uma vantagem quantitativa global discreta do Single Model, mas não justificam, isoladamente, uma inferência de superioridade clínica. O gráfico de barras resume a melhoria global semelhante obtida pelas duas arquiteturas.




Fig.5.24 Global PSNR and SSIM improvement over the corrupted input for the Single and Dual Models on the test set.

5.4.2 Statistical Analysis per ROI

Esta secção testa formalmente a hipótese primária deste estudo – a melhoria estrutural na Zona de Artefacto – e caracteriza de forma complementar a preservação na Zona Distante. As métricas por fatia foram sempre agregadas por paciente antes dos resumos e testes ($n = 41$), e os intervalos de confiança de 95% foram obtidos por *bootstrap* BCa com 10 000 reamostragens. Na Zona de Artefacto, a questão é a melhoria face à entrada corrompida, por isso, foram analisados os deltas com sinal de PSNR, SSIM e MAE. Em cada modelo, foi aplicado o teste de sinais binomial exato bilateral, com correção de Holm na família das três métricas.

Artifact ROI: SSIM

Model	Mean improvement	95% BCa CI	p (Holm)
Single Model	0.3279	[0.2963;0.3548]	2.73×10^{-12}
Dual Model	0.3266	[0.2947;0.3534]	2.73×10^{-12}

Patient-level Artifact-ROI improvement ($n = 41$). Two-sided exact binomial sign-test p -values, Holm-adjusted across PSNR, SSIM, and MAE separately for each model.

Table 5.17 SSIM improvement over the corrupted input in the Artifact ROI.

Artifact ROI: PSNR

Model	Mean improvement (dB)	95% BCa CI	p (Holm)
Single Model	11.86	[10.90;12.59]	2.73×10^{-12}
Dual Model	11.84	[10.91;12.55]	2.73×10^{-12}

Patient-level Artifact-ROI improvement ($n = 41$). Two-sided exact binomial sign-test p -values, Holm-adjusted across PSNR, SSIM, and MAE separately for each model.

Table 5.18 PSNR improvement over the corrupted input in the Artifact ROI.

Artifact ROI: MAE

Model	Mean reduction (HU)	95% BCa CI	p (Holm)
Single Model	98.38	[91.75; 104.24]	2.73×10^{-12}
Dual Model	98.33	[91.84; 104.06]	2.73×10^{-12}

Patient-level Artifact-ROI improvement ($n = 41$). Positive Δ MAE denotes error reduction. Two-sided exact binomial sign-test p -values, Holm-adjusted across PSNR, SSIM, and MAE separately for each model.

Table 5.19 MAE reduction over the corrupted input in the Artifact ROI.

As Table 5.17, Table 5.18, Table 5.19 mostram melhoria nas três métricas na Zona de Artefacto para ambos os modelos. Os ganhos médios foram aproximadamente de 0.32 para SSIM, 11.8 dB para PSNR e 98 HU para MAE. Estes resultados confirmam, para ambas as arquiteturas, a hipótese primária deste estudo de melhoria estrutural estatisticamente significativa na Zona de Artefacto.

Metric	$\Delta_{\text{Dual}} - \Delta_{\text{Single}}$	95% BCa CI	p (Holm)
Δ SSIM	-0.0013	[-0.0025; 0.0002]	0.0345
Δ PSNR (dB)	-0.019	[-0.085; 0.060]	0.533
Δ MAE (HU)	-0.049	[-0.318; 0.345]	0.422

Patient-level paired comparison of input-to-output improvement deltas ($n = 41$). Differences are $\Delta_{\text{Dual}} - \Delta_{\text{Single}}$; negative differences favor the Single Model for all metrics. The 95% BCa bootstrap CIs use 10 000 reamostragens; two-sided exact binomial sign-test p -values are Holm-adjusted across the three Artifact-ROI metrics.

Table 5.20 Patient-level paired comparison of improvement deltas in the Artifact ROI.

Na comparação direta dos deltas de melhoria na Zona de Artefacto (Table 5.20), a diferença em SSIM foi pequena, mas permaneceu significativa após a correção de Holm ($p_{\text{Holm}} = 0.0345$), favorecendo o Single Model. As diferenças nos deltas de PSNR e MAE não foram significativas após o ajuste.

Na região distante, a pergunta é distinta: pretende-se caracterizar a preservação do tecido fora da zona de artefacto, cujo alvo é alteração nula em relação à entrada. Por isso, foi calculado, em cada paciente, o valor médio de $|\Delta|$ por fatia. Valores menores representam uma reconstrução mais próxima da entrada. Como não foi pré-especificada uma margem de equivalência clinicamente justificada, não é possível testar nem concluir equivalência a zero. Assim, as Table 5.21, Table 5.22, Table 5.23 reportam a magnitude da alteração e os seus intervalos de confiança, sem valor de p contra zero.

Distant ROI: SSIM

Model	Mean $ \Delta $	95% BCa CI
Single Model	0.0599	[0.0503; 0.0754]
Dual Model	0.0595	[0.0499; 0.0748]

Patient-level mean absolute per-slice input-to-output change ($n = 41$). Lower values are closer to zero. No equivalence margin or hypothesis test against zero was prespecified.

Table 5.21 Magnitude of SSIM input-to-output change in the Distant ROI.

Distant ROI: PSNR

Model	Mean $ \Delta $ (dB)	95% BCa CI
Single Model	1.99	[1.66; 2.34]
Dual Model	1.97	[1.64; 2.33]

Patient-level mean absolute per-slice input-to-output change ($n = 41$). Lower values are closer to zero. No equivalence margin or hypothesis test against zero was prespecified.

Table 5.22 Magnitude of PSNR input-to-output change in the Distant ROI.

Distant ROI: MAE

Model	Mean $ \Delta $ (HU)	95% BCa CI
Single Model	4.30	[3.60; 5.16]
Dual Model	4.24	[3.54; 5.08]

Patient-level mean absolute per-slice input-to-output change ($n = 41$). Lower values are closer to zero. No equivalence margin or hypothesis test against zero was prespecified.

Table 5.23 Magnitude of MAE input-to-output change in the Distant ROI.

Para comparar as arquiteturas quanto à preservação relativa da região distante, foi definida, para cada paciente, a vantagem de preservação do Dual Model, $|\Delta|_{\text{Single}} - |\Delta|_{\text{Dual}}$, e aplicado o teste de sinais binomial exato bilateral, com correção de Holm na família das três métricas. Esta parametrização é mantida separada da comparação dos deltas de melhoria da Zona de Artefacto: aqui, o desfecho é a magnitude da alteração e o melhor valor é o mais próximo de zero. Valores positivos indicam menor alteração pelo Dual Model. Este teste responde apenas qual modelo introduziu menor alteração, e não se essa alteração é clinicamente desprezível.

Metric	Dual preservation advantage	95% BCa CI	p (Holm)
SSIM	0.000390	[0.000056; 0.000642]	3.37×10^{-4}
PSNR (dB)	0.020	[-0.104; 0.069]	0.0275
MAE (HU)	0.066	[-0.050; 0.155]	0.00865

Patient-level paired preservation advantage ($n = 41$), defined as $|\Delta|_{\text{Single}} - |\Delta|_{\text{Dual}}$. Positive values favor the Dual Model because its mean absolute input-to-output change is smaller. The 95% BCa bootstrap CIs use 10 000 reamostragens, two-sided exact binomial sign-test p -values are Holm-adjusted across the three Distant-ROI metrics.

Table 5.24 Relative preservation advantage of the Dual Model in the Distant ROI.

Na comparação relativa (Table 5.24), o Dual Model apresentou menor alteração absoluta em PSNR, SSIM e MAE após a correção de Holm. Esta evidência indica preservação relativa superior ao Single Model na região distante, mas não demonstra equivalência a alteração nula.

O desempenho computacional (latência e débito de inferência) do modelo selecionado para a avaliação externa é caracterizado no section A.2.

5.5 External Evaluation for Doctors

5.5.1 Capture Status and Participants

A avaliação externa consiste numa comparação pareada cega ao rótulo de processamento: em cada caso, os leitores visualizam simultaneamente a entrada com artefacto e a saída do modelo, identificadas apenas como “Imagem A” e “Imagem B”. A posição esquerda/direita é contrabalançada entre leitores e mantida constante entre um caso e a sua repetição oculta. Cada sessão apresenta 19 comparações: 2 casos de treino (excluídos da análise), 15 casos principais e 2 repetições ocultas de casos já apresentados, usadas exclusivamente para avaliar a consistência intraleitor. Os médicos foram recrutados diretamente pela investigadora, com autodeclaração do uso clínico de CT com frequência mínima mensal. Não foram recolhidos nome, contacto, número de registo profissional ou qualquer comprovativo de qualificação.

A [Table 5.25](#) resume o estado do recrutamento e da conclusão das respostas.

Indicador	Valor
Total de Leitores	[a preencher]
Respostas totais válidas (leitores $\times$ 15 casos principais)	[a preencher]
Data de início da recolha	2026-08-27
Data de fecho da recolha	[a preencher]

Table 5.25 Estado do recrutamento e da conclusão das respostas da avaliação externa.

As características autodeclaradas dos leitores que completaram a avaliação são apresentadas na [Table 5.26](#). Nenhuma destas variáveis permite identificar individualmente um participante.

Variável	Categoria	N	%
Jurisdição	Brasil	[a preencher]	[a preencher]
	Portugal	[a preencher]	[a preencher]
Frequência de uso de CT	Mensal	[a preencher]	[a preencher]
	Semanal	[a preencher]	[a preencher]
	Diária	[a preencher]	[a preencher]
Experiência com CT (anos)	< 2	[a preencher]	[a preencher]
	2–5	[a preencher]	[a preencher]
	6–10	[a preencher]	[a preencher]
	> 10	[a preencher]	[a preencher]
Experiência com redução de artefactos	Nenhuma	[a preencher]	[a preencher]
	Ocasional	[a preencher]	[a preencher]
	Frequente	[a preencher]	[a preencher]
Tipo de monitor	Diagnóstico	[a preencher]	[a preencher]
	Convencional	[a preencher]	[a preencher]
	Desconhecido	[a preencher]	[a preencher]

Table 5.26 Características autodeclaradas dos leitores que completaram a avaliação externa.

A distribuição por especialidade médica é apresentada separadamente na [Table 5.27](#), dado o maior número de categorias.

Especialidade	N	%
Radiologia e Diagnóstico por Imagem	[a preencher]	[a preencher]
Pneumologia	[a preencher]	[a preencher]
Cirurgia Torácica ou Cardiorádica	[a preencher]	[a preencher]
Oncologia	[a preencher]	[a preencher]
Medicina Interna ou Clínica Médica	[a preencher]	[a preencher]
Medicina Intensiva	[a preencher]	[a preencher]
Medicina de Emergência	[a preencher]	[a preencher]
Cardiologia	[a preencher]	[a preencher]
Gastroenterologia ou Hepatologia	[a preencher]	[a preencher]
Cirurgia Geral ou outra especialidade cirúrgica	[a preencher]	[a preencher]
Urologia	[a preencher]	[a preencher]
Ortopedia ou Traumatologia	[a preencher]	[a preencher]
Doenças Infecciosas ou Infectologia	[a preencher]	[a preencher]
Outra especialidade médica	[a preencher]	[a preencher]

Table 5.27 Distribuição por especialidade médica dos leitores que completaram a avaliação externa.

5.5.2 Quantitative Characterization of Input–Output

Antes da avaliação por profissionais, a alteração global produzida pelo *Single Model* foi caracterizada nos 15 casos principais do conjunto externo. Os dois casos de treino foram excluídos desta síntese. Como estes exames reais não dispõem de referência limpa, as métricas da [Table 5.28](#) comparam exclusivamente a imagem de entrada com a saída do modelo, dentro da máscara corporal.

Input–Output Similarity and Change		
Metric	Mean $\pm$ SD	95% CI
SSIM (Input, Output)	0.8953 $\pm$ 0.0729	[0.8572; 0.9290]
PSNR (Input, Output) (dB)	33.14 $\pm$ 6.49	[29.95; 36.21]
MAE (Input, Output) (HU)	21.12 $\pm$ 15.26	[14.54; 29.26]

No artifact-free reference is available. Metrics were calculated within the manually corrected effective body mask and quantify input–output similarity or change; they do not measure artifact-removal accuracy or improvement.

Table 5.28 Global input–output metrics in the frozen external main set ($n = 15$) for `singlehead-033-0.9511-ssim_hu.keras`. Values are mean $\pm$ standard deviation; 95% CIs are percentile bootstrap intervals for the mean.

No conjunto externo, a similaridade média entrada–saída foi de 0.8953 para **SSIM** e 33.14 dB para **PSNR**, enquanto a magnitude média da alteração foi de 21.12 HU em **MAE**. A dispersão entre casos, expressa pelos desvios-padrão e intervalos de confiança da tabela, evidencia heterogeneidade no grau de alteração produzido pela reconstrução. Estes resultados descrevem a preservação e a modificação global das imagens externas, mas não permitem inferir, sem referência limpa, acurácia de remoção de artefactos ou benefício clínico. Essa interpretação é abordada pela avaliação cega por médicos nas subseções seguintes.

Para tornar visível esta heterogeneidade, selecionou-se de forma descritiva os três casos com maior e os três com menor **SSIM** entre entrada e saída. Os primeiros representam os pares com menor alteração estrutural global, enquanto os segundos representam aqueles com maior alteração.

Illustrative External Cases Selected by Input–Output SSIM

Group	Case	SSIM	PSNR (dB)	MAE (HU)
Least changed	Case 003	0.9809	41.19	8.76
	Case 002	0.9756	42.35	8.10
	Case 012	0.9586	37.91	9.64
Most changed	Case 015	0.7278	23.32	43.10
	Case 005	0.7770	20.77	63.90
	Case 008	0.8334	33.53	20.39

Cases were selected only by the extremes of SSIM(Input, Output). High SSIM denotes less structural change between input and output; this ranking does not define artifact-removal quality or clinical acceptability.


Table 5.29 Descriptive external cases with the highest and lowest input–output SSIM values.

Case 003 — Input-Output Pair
SSIM=0.9809; PSNR=41.19 dB; MAE=8.76 HU

Input




Single Model output




Case 002 — Input-Output Pair
SSIM=0.9756; PSNR=42.35 dB; MAE=8.10 HU

Input



Single Model output



Case 012 — Input-Output Pair
SSIM=0.9586; PSNR=37.91 dB; MAE=9.64 HU
Input **Single Model output**





Fig.5.25 External input-output pairs with the three highest SSIM values, representing the least structural change. The soft-tissue window is identical for input and output within each case.

Case 015 — Input-Output Pair
SSIM=0.7278; PSNR=23.32 dB; MAE=43.10 HU
Input **Single Model output**






Fig.5.26 External input-output pairs with the three lowest SSIM values, representing the greatest structural change. The soft-tissue window is identical for input and output within each case.

5.5.3 Primary Outcome: Anatomical Visualization

O desfecho primário é a preferência pareada, por caso, quanto a qual imagem preserva melhor a região anatômica subjacente ao artefacto metálico (“Imagem A” / “Imagem B” / “Sem diferença”). As respostas são recodificadas para entrada/saída de acordo com a alocação de posição registrada para cada apresentação, sem que os leitores tenham conhecimento dessa alocação durante a resposta. Casos de treino e repetições ocultas não integram esta análise ($n = 15$ casos principais por leitor).

A associação entre a condição preferida (entrada vs. saída) e o tipo de imagem foi estimada por um modelo ordinal de efeitos mistos, com efeitos aleatórios para leitor e para caso, de modo

a contabilizar a estrutura de medições repetidas (múltiplos casos por leitor e múltiplos leitores por caso). Os intervalos de confiança de 95% são priorizados na interpretação, em detrimento de valores de p isolados.

Resposta	N	%	IC 95%
Preferiu a saída (Single Model)	[a preencher]	[a preencher]	[a preencher]
Preferiu a entrada (com artefacto)	[a preencher]	[a preencher]	[a preencher]
Sem diferença	[a preencher]	[a preencher]	[a preencher]

Frequências agrupadas sobre todas as respostas válidas (leitores $\times$ 15 casos principais); IC 95% por *bootstrap* ou método exato a especificar.

Table 5.30 Preferência pareada quanto à preservação da região anatómica subjacente ao artefacto metálico.

Efeito	Estimativa	IC 95%	p
Condição (saída vs. entrada)	[a preencher]	[a preencher]	[a preencher]

Modelo ordinal de efeitos mistos com efeitos aleatórios para leitor e caso; escala e parametrização do coeficiente a especificar (por exemplo, *log-odds* ou proporção marginal prevista).

Table 5.31 Estimativa do modelo ordinal de efeitos mistos para o desfecho primário.

5.5.4 Secondary Outcomes and Safety Perception

Os desfechos secundários seguem o mesmo formato de comparação pareada por caso (“Imagem A” / “Imagem B” / “Sem diferença”), recodificado para entrada/saída, reportando-se frequências e intervalos de confiança de 95% por pergunta, sem ajuste conjunto de multiplicidade, dado o carácter descritivo desta síntese.

Resposta	N	%	IC 95%
Preferiu a saída (menor intensidade de artefacto)	[a preencher]	[a preencher]	[a preencher]
Preferiu a entrada	[a preencher]	[a preencher]	[a preencher]
Sem diferença	[a preencher]	[a preencher]	[a preencher]

Table 5.32 Preferência pareada quanto à intensidade percebida de artefactos metálicos.

Resposta	N	%	IC 95%
Preferiu a saída (menos distorção)	[a preencher]	[a preencher]	[a preencher]
Preferiu a entrada	[a preencher]	[a preencher]	[a preencher]
Sem diferença	[a preencher]	[a preencher]	[a preencher]

Este item funciona como sinal exploratório de possível dano: preferência pela entrada sugere percepção de distorções ou artefactos introduzidos pelo modelo fora da zona de artefacto.

Table 5.33 Preferência pareada quanto a artefactos ou distorções anatómicas introduzidas nas regiões distantes do artefacto.

Adicionalmente, no final da sessão, cada leitor respondeu uma vez a uma questão ordinal de 5 pontos sobre a utilidade complementar de uma versão processada com este padrão face ao exame de CT original (Table 5.35).

Resposta	N	%	IC 95%
Preferiu a saída para interpretação clínica	[a preencher]	[a preencher]	[a preencher]
Preferiu a entrada	[a preencher]	[a preencher]	[a preencher]
Sem diferença	[a preencher]	[a preencher]	[a preencher]

Table 5.34 Preferência pareada quanto à imagem escolhida para interpretação clínica.

Categoria	N	%
Definitivamente não	[a preencher]	[a preencher]
Provavelmente não	[a preencher]	[a preencher]
Incerto	[a preencher]	[a preencher]
Provavelmente sim	[a preencher]	[a preencher]
Definitivamente sim	[a preencher]	[a preencher]

Uma resposta por leitor (não por caso); n = número de leitores que completaram a avaliação.

Table 5.35 Utilidade complementar percebida de uma versão processada face ao exame de CT original.

A consistência intraleitor foi avaliada através de duas repetições ocultas por leitor: o mesmo caso é reapresentado mais tarde na sessão, sem sinalização, na mesma posição esquerda/direita da primeira apresentação. A concordância entre a resposta original e a da repetição foi quantificada pelo coeficiente de correlação intraclasse ICC(2,1) (Shrout & Fleiss, modelo de efeitos mistos, medida única, concordância absoluta) e, para a preferência binária saída/entrada, pelo coeficiente κ de Fleiss (Table 5.36).

Estatística	Valor	IC 95%	Interpretação
ICC(2,1)	[a preencher]	[a preencher]	[a preencher]
κ de Fleiss (saída vs. entrada)	[a preencher]	—	[a preencher]

n = 2 repetições ocultas por leitor. IC 95% do ICC(2,1) pelo método baseado na distribuição F (Shrout & Fleiss, 1979).

Table 5.36 Consistência intraleitor nas repetições ocultas.

5.5.5 Limited Interpretation to the Observational Design

O desenho dessa avaliação permite concluir, quando os dados estiverem disponíveis, qual imagem os leitores preferem em cada dimensão avaliada, mas não permite inferir causalidade sobre desfechos clínicos (por exemplo, impacto diagnóstico ou terapêutico), nem generalizar além do conjunto de 15 casos e do painel de leitores efetivamente recrutado. A ausência de uma referência limpa nestes casos externos significa que a avaliação de exatidão anatómica depende inteiramente do julgamento dos leitores, e não de uma métrica objetiva de erro. Por fim, o número de leitores recrutados limita a precisão das estimativas e a possibilidade de análises de subgrupo por especialidade ou experiência.

Chapter 6

Discussion

6.1 Summary of the main Findings

O objetivo geral desta dissertação era desenvolver, avaliar e comparar de forma rigorosa uma abordagem baseada em **CNNs** para redução de artefactos metálicos em **CT**, privilegiando a preservação anatômica, a robustez à variação de domínio e a interpretabilidade da correção. Os resultados da avaliação interna sustentam a hipótese primária de melhoria estrutural na Zona de Artefacto face à entrada corrompida: nas seis corridas (duas arquiteturas, três sementes), o **SSIM** nessa zona aumentou entre 0.322 e 0.328 (**Table 5.10**), e para a corrida selecionada para a avaliação externa (Single Model, seed 2024) esta melhoria foi estatisticamente significativa ao nível do paciente ($\Delta \text{SSIM} = 0.3279$, IC 95% BCa [0.2963; 0.3548], $p_{\text{Holm}} = 2.73 \times 10^{-12}$; **Table 5.17**), com um padrão equivalente no Dual Model ($\Delta \text{SSIM} = 0.3266$, $p_{\text{Holm}} = 2.73 \times 10^{-12}$). Esta melhoria estrutural localizada foi acompanhada por uma melhoria global consistente e igualmente significativa: em todas as seis corridas, a reconstrução aumentou o **PSNR** global de 27.39 dB para 34.95–35.20 dB, o **SSIM** global de 0.8361 para 0.9421–0.9442 e reduziu o **MAE** global de 36.6 HU para 17.3–17.8 HU (**Table 5.4**, **Table 5.5**, **Table 5.6**). Ao nível do paciente, os testes secundários de melhoria global foram significativos para as três métricas em todas as corridas ($p < 0.001$; **Table 5.7**, **Table 5.8**, **Table 5.9**), com os intervalos de confiança de 95% a excluir o valor nulo.

A inspeção descritiva ao nível da fatia (**Figure 5.14**) mostrou que os casos desfavoráveis são raros: apenas 0.8% das fatias apresentaram ΔPSNR negativo e 1.6% apresentaram ΔSSIM negativo, num total de 1478 fatias de teste. Esta consistência é reforçada pela análise por **ROI** (**??**), que mostra que a correção está concentrada na Zona de Artefacto ($\Delta \text{PSNR} \approx 11.8$ dB, $\Delta \text{SSIM} \approx 0.33$, redução de **MAE** ≈ 98 HU), com alterações substancialmente menores na Zona Distante ($|\Delta \text{PSNR}| \approx 2$ dB, $|\Delta \text{SSIM}| \approx 0.06$, $|\Delta \text{MAE}| \approx 4$ HU). Este contraste indica que

o modelo não aplica uma suavização indiscriminada da imagem, mas concentra a alteração onde o artefacto está presente.

A seleção do *checkpoint* final (Single Model, seed 2024, época 33) baseou-se exclusivamente no **SSIM** da partição de validação, sem uso do conjunto de teste para essa decisão. Os resultados de teste aqui sintetizados desempenham, portanto, um papel confirmatório e não de seleção, em linha com o objetivo de construir um *pipeline* reproduzível com separação rigorosa entre treino, validação e teste.

6.2 Architectural Comparison Interpretation

A comparação pareada entre arquiteturas (??) permite responder ao segundo objetivo específico – se a supervisão auxiliar da máscara de artefacto melhora a reconstrução face à versão sem supervisão de máscara – de forma matizada. Ao nível global, o Single Model apresentou uma vantagem pequena mas estatisticamente significativa nas três métricas ($\Delta\text{PSNR} +0.054$ dB, $\Delta\text{SSIM} +0.0012$, $\Delta\text{MAE} +0.186$ HU; $p_{\text{Holm}} = 2.75 \times 10^{-2}$, 2.35×10^{-9} e 8.62×10^{-4} , respetivamente; Table 5.16), favorecendo o Single Model em 28, 39 e 32 dos 41 pacientes. Na Zona de Artefacto, essa vantagem restringiu-se ao **SSIM** ($p_{\text{Holm}} = 0.0345$), sem diferença significativa em **PSNR** ou **MAE** (Table 5.20).

Por outro lado, na Zona Distante, foi o Dual Model que apresentou menor alteração absoluta face à entrada nas três métricas, com vantagem de preservação estatisticamente significativa após a correção de Holm ($p_{\text{Holm}} = 3.37 \times 10^{-4}$ para **SSIM**, 0.0275 para **PSNR** e 0.00865 para **MAE**; Table 5.24). Interpreta-se este padrão como um compromisso: a supervisão adicional de segmentação parece disciplinar espacialmente a correção, tornando o Dual Model marginalmente mais conservador fora da Zona de Artefacto, ao custo de uma magnitude de correção ligeiramente menor tanto globalmente como na própria Zona de Artefacto. No entanto, nesse trabalho o decoder foi mantido quase inteiramente compartilhado, e somente na última camada acrescenta-se a saída de segmentação. Uma separação mais profunda entre os decoders de reconstrução e de segmentação poderia permitir explorar melhor este compromisso, mas não foi testada neste trabalho.

Em nenhum dos dois sentidos as diferenças observadas parecem, isoladamente, clinicamente distinguíveis – décimas de dB em **PSNR**, milésimas em **SSIM** e frações de HU em **MAE**. A significância estatística decorre sobretudo da consistência direcional entre pacientes (testes de sinais com $n = 41$), não da magnitude do efeito. Assim, a resposta ao objetivo de comparação arquitetural é que a supervisão auxiliar da máscara não produz uma reconstrução decisivamente superior, mas redistribui o compromisso entre correção e preservação de forma

mensurável. Como a seleção do candidato para a avaliação externa já havia sido decidida na validação (Single Model, seed 2024, superior nas três métricas de validação), estas diferenças de teste, embora relevantes para caracterizar o compromisso arquitetural, não tiveram de alterar – nem alteraram – essa decisão.

6.3 Anatomical Preservation and Reconstruction Safety

A leitura conjunta das análises descritivas complementares converge para um quadro consistente, embora não conclusivo do ponto de vista clínico. A divisão por ROI já mostrou que a alteração na Zona Distante é uma pequena fração da correção observada na Zona de Artefacto (Figure 5.16, Figure 5.17). A concordância de Bland–Altman ao nível do paciente para a média de HU corporal (Figure 5.15) mostrou um viés positivo pequeno mas não nulo, de +4.19 HU, com limites de concordância de 95% entre +1.45 e +6.93 HU – um ligeiro deslocamento sistemático da intensidade média que deve ser monitorizado em trabalho futuro, ainda que pequeno face à amplitude da janela de HU utilizada.

Como caracterização adicional da cauda de pior desempenho, os 74 de 1478 fatias de teste (5%) com menor ΔPSNR (limiar de 2.59 dB) mantiveram, em média, melhoria positiva nas três métricas (ΔPSNR médio = 1.23 dB; ΔSSIM médio = 0.0071; ΔMAE médio na Zona de Artefacto = 62.0 HU; Figure A.6), apesar de dispersão elevada e de casos individuais de degradação face à entrada. Isto sugere que os casos desfavoráveis tendem a ser de gravidade graduada, e não catastrófica, embora existam e mereçam inspeção qualitativa – disponível para os casos extremos de ΔSSIM na Zona de Artefacto na ??.

Uma análise exploratória complementar (Figure A.3) relacionou a carga de artefacto (fração área de artefacto/área corporal, média por paciente) com a melhoria global, tendo-se observado associação positiva: $\rho = 0.479$ para ΔPSNR (IC 95% [0.156;0.717], $p = 0.00154$) e $\rho = 0.569$ para ΔSSIM (IC 95% [0.225;0.794], $p = 0.000104$). Ou seja, o modelo tende a corrigir proporcionalmente mais nos pacientes com maior carga de artefacto – um resultado tranquilizador do ponto de vista de uma correção direccionada, mas que, por não integrar a família de testes de hipótese primários nem ter recebido ajuste de Holm, deve ser lido como gerador de hipótese e não como confirmação estatística independente.

Em conjunto, a estratificação por ROI, a calibração de Bland–Altman, a caracterização da cauda de pior desempenho e a associação com a carga de artefacto compõem um retrato convergente, mas ainda descritivo: a correção concentra-se onde é necessária, o tecido distante é maioritariamente preservado com um pequeno desvio de calibração, e as fatias com

pior desempenho não evidenciam distorção anatômica sistemática. A avaliação definitiva de segurança clínica, contudo, permanece reservada à avaliação externa por leitores (??).

6.4 Generalization and External Evaluation

O quarto objetivo específico – investigar a capacidade de generalização da versão selecionada em dados reais e externos ao treino, provenientes do TCIA – só pode ser respondido parcialmente com a evidência técnica atualmente disponível. Os 15 casos principais do conjunto externo não dispõem de referência limpa, pelo que apenas foi possível caracterizar a magnitude da alteração entre a entrada e a saída (Table 5.28): SSIM médio de 0.8953, PSNR médio de 33.14 dB e MAE médio de 21.12 HU, com dispersão relevante entre casos.

Estes valores não são diretamente comparáveis aos deltas de melhoria internos, que dependem de uma referência limpa para quantificar acurácia de correção. Descrevem apenas que o modelo produz alterações de magnitude plausível e não colapsa para a identidade nem produz distorções extremas nos casos externos amostrados. A seleção descritiva dos três casos com maior e três com menor SSIM entrada-saída ilustrou essa heterogeneidade, sem constituir comparação inferencial.

Assim, a evidência técnica externa disponível sustenta apenas que o comportamento do modelo em dados reais e fora do domínio de treino é qualitativamente plausível e consistente em ordem de grandeza com o observado internamente, mas não permite concluir acurácia de remoção de artefactos nem generalização validada sem referência limpa. A resposta decisiva a essa questão – se leitores humanos julgam a correção externa como precisa e segura – depende da avaliação cega por médicos discutida na secção seguinte.

6.5 Evaluation for Doctors and Clinical Implications

A avaliação multileitor cega (??) foi desenhada com um desfecho primário de visualização anatômica e desfechos secundários de interferência do artefacto, preferência pareada, sinalização de possível dano, utilidade complementar e consistência intraleitor, num desenho observacional adequado a um painel de leitores pequeno e propositadamente construído para comparação pareada entrada-saída.

À data desta redação, a recolha de dados e a caracterização dos participantes para esta avaliação ainda não estavam concluídas (??). Por essa razão, esta secção não interpreta melhoria percebida, segurança percebida ou eficácia clínica: fazê-lo antes de os desfechos primário e secundários estarem disponíveis arriscaria conclusões que excedem a evidência

técnica reunida até este ponto. Quando concluída, a avaliação deverá ser lida em conjunto com a secção anterior sobre preservação anatómica, e interpretada estritamente dentro dos limites do desenho observacional em que foi construída – isto é, como comparação pareada entrada-saída por um painel de leitores, sem inferência causal de superioridade clínica para além desse desenho.

6.6 Limitations

Natureza da referência limpa. O [CT-MAR](#) Dataset fornece fatias reais com artefactos metálicos, mas sem referência limpa emparelhada da mesma aquisição. A referência utilizada neste trabalho foi obtida por correspondência de similaridade estrutural (*fingerprint* e similaridade de cosseno, limiar de aprovação automática de 0.994) com fatias independentes e livres de artefacto do DeepLesion e do UCLH Stroke EIT, auditada por [MS-SSIM](#) e revisão visual humana (apenas 3 falsos positivos confirmados entre 340 pares limítrofes inspecionados). Esta estratégia permite treinar e avaliar contra artefactos reais, em vez de simulados, mas a correspondência é de recuperação por similaridade, não um registo pixel-a-pixel garantido da mesma aquisição; pequenas diferenças anatómicas residuais entre os pares emparelhados não podem ser inteiramente excluídas apesar da auditoria.

Desequilíbrio anatómico. A distribuição anatómica manteve-se aproximadamente 88% *body* e 12% *head* ao nível dos pares, e 95.9% *body* e apenas 4.1% *head* (11 de 269 pacientes) ao nível dos pacientes. Conclusões específicas sobre a região da cabeça assentam, portanto, num subconjunto pequeno de pacientes e devem ser interpretadas com cautela.

Dimensão amostral ao nível do paciente. A unidade de inferência do conjunto de teste interno foi o paciente ($n = 41$), adequada às comparações pareadas primárias realizadas, mas limitada para análises de subgrupo mais finas (por região anatómica, gravidade do artefacto ou tipo de implante) além da associação exploratória com a carga de artefacto já sinalizada como não primária.

Desempenho computacional de ambiente único. O *benchmark* de latência caracteriza apenas a configuração experimental utilizada (uma GPU, lote unitário, um ambiente de execução) e não generaliza automaticamente para outro *hardware*, configurações de lote ou latência de um fluxo clínico completo.

Avaliação externa. O conjunto externo é pequeno e propositadamente curado (15 casos principais), sem referência limpa e restrito a um único modelo e semente selecionados na validação interna; os resultados descrevem magnitude de alteração, não acurácia de correção.

Desenho observacional da avaliação por médicos. A avaliação multileitor é uma comparação pareada observacional com um painel de leitores pequeno, cuja recolha de dados não estava concluída à data desta redação, conforme discutido na secção anterior.

6.7 Implications and Future Work

As implicações práticas mais imediatas decorrem diretamente das limitações identificadas. Primeiro, a conclusão e o relato completo da avaliação cega por médicos são um pré-requisito para qualquer afirmação sobre benefício clínico percebido ou segurança percebida da reconstrução; nenhuma conclusão desta natureza deve preceder esses resultados. Segundo, a validação prospetiva em coortes externas maiores e mais diversas – em particular com maior representação da região da cabeça – permitiria testar a generalização de forma mais robusta do que os 15 casos externos atualmente disponíveis. Terceiro, complementar a estratégia de referência por correspondência de similaridade estrutural com fontes de referência emparelhada da mesma aquisição (por exemplo, inserção sintética de artefacto em domínio de projeção ou dados de dupla energia) poderia reduzir a dependência de correspondência entre *datasets* distintos, ainda que ao custo de artefactos potencialmente menos realistas.

Do ponto de vista arquitetural, o compromisso identificado entre o Single Model (ligeira vantagem de magnitude de correção) e o Dual Model (ligeira vantagem de preservação na Zona Distante) sugere que trabalho futuro poderia explorar formas de combinar os dois efeitos – por exemplo, ponderação adaptativa da perda de reconstrução pela máscara de artefacto prevista, em vez de supervisão auxiliar independente – para tentar obter simultaneamente maior correção e maior preservação. Por fim, a expansão do protocolo de observadores (mais leitores, rondas de calibração ou treino prévio, e ampliação do painel de casos externos) deverá acompanhar qualquer extensão futura da avaliação clínica, mantendo a mesma disciplina de separação entre evidência exploratória e confirmatória adotada ao longo desta dissertação.

Chapter 7

Conclusions

7.1 Study Conclusions

[A preencher: conclusão proporcional às evidências finais e aos resultados confirmatórios.]

7.2 Dissertation Contributions

- *[A preencher: curadoria rastreável e partição por paciente.]*
- *[A preencher: comparação controlada entre duas arquiteturas U-Net.]*
- *[A preencher: avaliação por paciente e produção reprodutível de resultados.]*
- *[A preencher: protocolo de avaliação externa por médicos e respetivo estado de execução.]*

7.3 Future Perspectives

[A preencher: validação externa concluída, extensão multicêntrica e avaliação clínica prospetiva.]

Bibliography

- [1] November 8, 1895: Roentgen's Discovery of X-Rays. <https://www.aps.org/apsnews/2001/11/1895-roentgens-discovery-xrays>. [Cited on page 1.]
- [2] Emico Okuno and Elisabeth Yoshimura. *Física das Radiações*. Oficina de Textos, 2010. [Cited on page 1.]
- [3] JOEL D. HOWELL. EARLY CLINICAL USE OF THE X-RAY. *Transactions of the American Clinical and Climatological Association*, 127:341–349, 2016. [Cited on page 1.]
- [4] Allen Taylor. Illuminating Health: The Evolution and Significance of X-ray Imaging. *Imaging in Medicine*, 15(6):133–134, December 2023. [Cited on page 1.]
- [5] Reza Vali. Unveiling the Marvels of Computed Tomography (CT) Imaging. *Imaging in Medicine*, 16(1):150–151, February 2024. [Cited on page 1.]
- [6] Mohd Noor. An Overview of Computed Tomography: What it is and How it Works? Applications of Computed Tomography. *Imaging in Medicine*, 15(5):93–94, October 2023. [Cited on page 1.]
- [7] Raymond A. Schulz, Jay A. Stein, and Norbert J. Pelc. How CT happened: The early development of medical computed tomography. *Journal of Medical Imaging*, 8(5):052110, September 2021. [Cited on page 2.]
- [8] F. Edward Boas and Dominik Fleischmann. CT artifacts: Causes and reduction techniques. *Imaging in Medicine*, 4(2):229–240, April 2012. [Cited on page 2.]
- [9] Cecile E.J. Kleber, Ramez Karius, Lucas E. Naessens, Coen O. Van Toledo, Jochen A. C. Van Osch, Martijn F. Boomsma, Jan W.T. Heemskerk, and Aart J. Van Der Molen. Advancements in supervised deep learning for metal artifact reduction in computed tomography: A systematic review. *European Journal of Radiology*, 181:111732, December 2024. [Cited on pages 2, 6, 7, and 13.]

- [10] Sathyathas Puvanasunthararajah, Davide Fontanarosa, Marie-Luise Wille, and Saskia M. Camps. The application of metal artifact reduction methods on computed tomography scans for radiotherapy applications: A literature review. *Journal of Applied Clinical Medical Physics*, 22(6):198–223, May 2021. [Cited on page 2.]
- [11] Asutosh Sahu, Shobhit Mathur, Hiroyuki Takaoka, Joji Ota, Felix G. Meinel, Benjamin Böttcher, Benoît Magnin, Ankush Jajodia, and Corey T. Jensen. Transforming CT imaging with deep learning: Noise reduction, artifact management, and clinical applications – A comprehensive review. *European Journal of Radiology Artificial Intelligence*, 4:100042, December 2025. [Cited on pages 2, 6, and 7.]
- [12] Mohanad Alkhodari, Eman Alefishat, Herbert F. Jelinek, Ahmed Kaabneh, and Panos Liatsis. Enhancing CCTA image quality: A review of deep learning approaches for advanced artifact correction and denoising. *Artificial Intelligence Review*, 58(10):331, August 2025. [Cited on page 3.]
- [13] Julia F. Barrett and Nicholas Keat. Artifacts in CT: Recognition and Avoidance. *RadioGraphics*, 24(6):1679–1691, November 2004. [Cited on page 6.]
- [14] Mark Selles, Jochen A.C. Van Osch, Mario Maas, Martijn F. Boomsma, and Ruud H.H. Wellenberg. Advances in metal artifact reduction in CT images: A review of traditional and novel metal artifact reduction techniques. *European Journal of Radiology*, 170:111276, January 2024. [Cited on page 6.]
- [15] Lars Gjestebj, Qingsong Yang, Yan Xi, Bernhard E. H. Claus, Yannan Jin, Bruno De Man, Ge Wang, and Hongming Shan. Deep learning methods for CT image-domain metal artifact reduction. In Bert Müller and Ge Wang, editors, *Developments in X-Ray Tomography XI*, page 31, San Diego, United States, September 2017. SPIE. [Cited on pages 6 and 7.]
- [16] Yanbo Zhang and Hengyong Yu. Convolutional Neural Network Based Metal Artifact Reduction in X-Ray Computed Tomography. *IEEE Transactions on Medical Imaging*, 37(6):1370–1381, June 2018. [Cited on pages 6 and 7.]
- [17] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-Net: Convolutional Networks for Biomedical Image Segmentation, May 2015. [Cited on pages 7, 17, and 18.]
- [18] Esther Meyer, Frank Bergner, Rainer Raupach, Thomas Flohr, and Marc Kachelriess. Normalized metal artifact reduction (NMAR) in computed tomography. In *2009 IEEE Nuclear Science Symposium Conference Record (NSS/MIC)*, pages 3251–3255, Orlando, FL, October 2009. IEEE. [Cited on page 7.]

- [19] Wei-An Lin, Haofu Liao, Cheng Peng, Xiaohang Sun, Jingdan Zhang, Jiebo Luo, Rama Chellappa, and Shaohua Kevin Zhou. DuDoNet: Dual Domain Network for CT Metal Artifact Reduction. In *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 10504–10513, Long Beach, CA, USA, June 2019. IEEE. [Cited on pages 7 and 13.]
- [20] Lequan Yu, Zhicheng Zhang, Xiaomeng Li, Hongyi Ren, Wei Zhao, and Lei Xing. Metal Artifact Reduction in 2D CT Images with Self-supervised Cross-domain Learning. *Physics in Medicine & Biology*, 66(17):175003, September 2021. [Cited on page 7.]
- [21] Zhiwei Huang, Guo Zhang, Jinzhao Lin, Yu Pang, Huiqian Wang, Tong Bai, and Lisha Zhong. Multi-modal feature-fusion for CT metal artifact reduction using edge-enhanced generative adversarial networks. *Computer Methods and Programs in Biomedicine*, 217:106700, April 2022. [Cited on page 7.]
- [22] Xin Yi, Ekta Walia, and Paul Babyn. Generative Adversarial Network in Medical Imaging: A Review. *Medical Image Analysis*, 58:101552, December 2019. [Cited on page 7.]
- [23] Zhou Wang, A.C. Bovik, H.R. Sheikh, and E.P. Simoncelli. Image quality assessment: From error visibility to structural similarity. *IEEE Transactions on Image Processing*, 13(4):600–612, April 2004. [Cited on pages 8, 11, and 13.]
- [24] Z. Wang, E.P. Simoncelli, and A.C. Bovik. Multiscale structural similarity for image quality assessment. In *The Thrity-Seventh Asilomar Conference on Signals, Systems & Computers, 2003*, pages 1398–1402, Pacific Grove, CA, USA, 2003. IEEE. [Cited on page 8.]
- [25] Alain Hore and Djemel Ziou. Image Quality Metrics: PSNR vs. SSIM. In *2010 20th International Conference on Pattern Recognition*, pages 2366–2369, Istanbul, Turkey, August 2010. IEEE. [Cited on page 8.]
- [26] John R. Zech, Marcus A. Badgeley, Manway Liu, Anthony B. Costa, Joseph J. Titano, and Eric Karl Oermann. Variable generalization performance of a deep learning model to detect pneumonia in chest radiographs: A cross-sectional study. *PLOS Medicine*, 15(11):e1002683, November 2018. [Cited on page 8.]
- [27] Martin J. Willemink, Wojciech A. Koszek, Cailin Hardell, Jie Wu, Dominik Fleischmann, Hugh Harvey, Les R. Folio, Ronald M. Summers, Daniel L. Rubin, and Matthew P. Lungren. Preparing Medical Imaging Data for Machine Learning. *Radiology*, 295(1):4–15, April 2020. [Cited on page 8.]

- [28] Christopher J. Kelly, Alan Karthikesalingam, Mustafa Suleyman, Greg Corrado, and Dominic King. Key challenges for delivering clinical impact with artificial intelligence. *BMC Medicine*, 17(1):195, December 2019. [Cited on page 8.]
- [29] Eri Haneda, Nils Peters, Jiayong Zhang, Grigorios Karageorgos, Wenjun Xia, Harald Paganetti, Ge Wang, Yi Guo, Jianhua Ma, Hyoung Suk Park, Kiwan Jeon, Fuxin Fan, Mareike Thies, and Bruno De Man. AAPM CT metal artifact reduction grand challenge. *Medical Physics*, 52(10):e70050, October 2025. [Cited on page 9.]
- [30] xcist. AAPM CT Metal Artifact Reduction (CT-MAR) Grand Challenge Benchmark Tool. https://github.com/xcist/example/tree/main/AAPM_datachallenge/. [Cited on page 9.]
- [31] Nils Peters, Eri Haneda, Jiayong Zhang, Grigorios Karageorgos, Wenjun Xia, Joost Verburg, Ge Wang, Harald Paganetti, and Bruno De Man. A hybrid training database and evaluation benchmark for assessing metal artifact reduction methods for X-ray CT imaging. *Medical Physics*, 52(10):e70020, October 2025. [Cited on page 9.]
- [32] Mingye Wu, Paul FitzGerald, Jiayong Zhang, W. Paul Segars, Hengyong Yu, Yongshun Xu, and Bruno De Man. XCIST – An Open Access X-ray/CT Simulation Toolkit. *Physics in medicine and biology*, 67(19):10.1088/1361-6560/ac9174, September 2022. [Cited on page 9.]
- [33] Nir Goren, James Avery, Thomas Dowrick, Eleanor Mackle, Anna Witkowska-Wrobel, David Werring, and David Holder. Multi-frequency electrical impedance tomography and neuroimaging data in stroke patients. *Scientific Data*, 5:180112, July 2018. [Cited on pages 9 and 10.]
- [34] Nir Goren, Thomas Dowrick, James Avery, and David Holder. UCLH Stroke EIT Dataset - Radiology Data, August 2017. [Cited on page 9.]
- [35] Ke Yan, Xiaosong Wang, Le Lu, and Ronald M. Summers. DeepLesion: Automated mining of large-scale lesion annotations and universal lesion detection with deep learning. *Journal of Medical Imaging*, 5(3):036501, July 2018. [Cited on pages 9 and 10.]
- [36] Mustafa Umit Oner, Yi-Chih Cheng, Hwee Kuan Lee, and Wing-Kin Sung. Training machine learning models on patient level data segregation is crucial in practical clinical applications, April 2020. [Cited on page 10.]

- [37] Jiang Hsieh. *Computed Tomography: Principles, Design, Artifacts, and Recent Advances*. Wiley Interscience ; SPIE Press, Hoboken, N.J. : Bellingham, Wash, 2nd ed edition, 2009. [Cited on page 11.]
- [38] Saeid Asgari Taghanaki, Yefeng Zheng, S. Kevin Zhou, Bogdan Georgescu, Puneet Sharma, Daguang Xu, Dorin Comaniciu, and Ghassan Hamarneh. Combo Loss: Handling Input and Output Imbalance in Multi-Organ Segmentation, September 2021. [Cited on pages 16 and 21.]
- [39] Uğur Kesimal, Habip Eser Akkaya, Önder Polat, and Murat Sağlam. Use of Deep Learning Models in the Diagnosis of Proptosis Through Orbital Magnetic Resonance Imaging. *Medical Science Monitor*, 32, April 2026. [Cited on page 16.]
- [40] Yang Li, Bobo Yan, Jianxin Hou, Bingyang Bai, Xiaoyu Huang, Canfei Xu, and Limei Fang. UNet based on dynamic convolution decomposition and triplet attention. *Scientific Reports*, 14(1):271, January 2024. [Cited on pages 17 and 18.]
- [41] Rich Caruana. Multitask Learning. [Cited on page 18.]
- [42] Sebastian Ruder. An Overview of Multi-Task Learning in Deep Neural Networks, June 2017. [Cited on page 18.]
- [43] Hang Zhao, Orazio Gallo, Iuri Frosio, and Jan Kautz. Loss Functions for Image Restoration With Neural Networks. *IEEE Transactions on Computational Imaging*, 3(1):47–57, March 2017. [Cited on page 21.]
- [44] Lin Zhang, Lei Zhang, Xuanqin Mou, and D. Zhang. FSIM: A Feature Similarity Index for Image Quality Assessment. *IEEE Transactions on Image Processing*, 20(8):2378–2386, August 2011. [Cited on page 22.]

Appendix A

Supplementary Internal Evaluation

Este apêndice reúne verificações quantitativas complementares da avaliação interna. A figura seguinte é apresentada apenas como diagnóstico visual da concordância radiométrica ao nível de pixel e não constitui análise inferencial, pois os pixels amostrados não são observações independentes.





Fig.A.1 Pixel-level HU agreement between the Single Model reconstruction and the clean reference. The hexbin uses a fixed equal-patient stratified sample of 100,000 valid body-mask pixels from 41 test-set patients. It is a descriptive calibration diagnostic; no hypothesis test or confidence interval is derived from the sampled pixels.

Os gráficos seguintes complementam os histogramas de deltas globais apresentados no corpo do texto. Cada ponto corresponde a uma fatia de teste e, portanto, estes gráficos não são utilizados para inferência estatística.






Fig.A.2 Per-image global SSIM (top) and PSNR (bottom) for the corrupted input and the Single Model reconstruction, seed 2024. The identity line denotes no change, marker color encodes the corresponding global delta. These slice-level relationships are descriptive, whereas statistical inference used patient-level aggregation.

Como análise exploratória de heterogeneidade, a [Figure A.3](#) relaciona a carga de artefato com a melhoria global. Cada ponto corresponde à média de todas as fatias de um paciente ($n = 41$), atribuindo o mesmo peso a cada paciente. A carga foi definida como a média da fração área de artefato/área corporal por fatia; os deltas correspondem à métrica da reconstrução menos a métrica da entrada, ambas contra a referência limpa. Foram calculadas correlações de Spearman bilaterais, com IC de 95% por *bootstrap* BCa pareado (10 000 reamostragens; semente 1337), e a curva de tendência é uma estimação LOWESS da biblioteca *Statsmodels*. Esta análise não integra a família de testes de hipótese primários nem recebeu ajuste de Holm. Observou-se associação positiva entre a carga de artefato e a melhoria: $\rho = 0,479$ para ΔPSNR (IC 95% [0,156; 0,717], $p = 0,00154$) e $\rho = 0,569$ para ΔSSIM (IC 95% [0,225; 0,794], $p = 0,000104$).




Fig.A.3 Exploratory patient-level association between mean artifact fraction and global improvement for the Single Model, seed 2024: Δ SSIM (top) and Δ PSNR (bottom). Each point is one patient's mean across its test-set slices ($n = 41$). Lines show Statsmodels LOWESS trends; annotations report two-sided Spearman correlations and paired BCa bootstrap 95% confidence intervals.

A.1 Worst Performance Cases

Como caracterização complementar das fatias com pior desempenho, identificaram-se dois grupos por fatia para o Single Model, seed 2024, no conjunto de teste: primeiro pelo percentil 5 inferior de ΔSSIM , a métrica utilizada para a seleção do *checkpoint*, e depois, de forma complementar, pelo percentil 5 inferior de ΔPSNR . Esta seleção é puramente descritiva: não constitui um teste de hipótese e serve apenas para situar, em termos quantitativos, os grupos de fatias cujos exemplos visuais individuais são discutidos na ??.

Pelo critério de ΔSSIM ($N = 74/1478$ fatias; limiar = 0,0146), a melhoria média de ΔPSNR manteve-se positiva (1,88 dB), mas a melhoria média de ΔSSIM foi ligeiramente negativa ($-0,0019$), com redução média de MAE na Zona de Artefacto de 65,2 HU (Figure A.4). Ou seja, o subconjunto mais desfavorável segundo a métrica principal de seleção inclui, em média, uma pequena degradação de SSIM, ainda que a maioria das restantes fatias continue a melhorar substancialmente.




Fig.A.4 Bottom 5th-percentile slices by global ΔSSIM for the Single Model, seed 2024, test split ($N = 74/1478$, threshold = 0.0146, highlighted in red). Descriptive; no inferential test is derived from this subset.

Pelo critério complementar de ΔPSNR ($N = 74/1478$ fatias; limiar = 2,59 dB), este grupo não é idêntico ao definido por ΔSSIM : a melhoria média permaneceu positiva nas três métricas

(ΔPSNR médio = 1,23 dB; ΔSSIM médio = 0,0071; ΔMAE médio na Zona de Artefacto = 62,0 HU), embora com dispersão elevada e alguns casos individuais de degradação face à entrada, visíveis na cauda esquerda da [Figure A.5](#).




Fig.A.5 Bottom 5th-percentile slices by global ΔPSNR for the Single Model, seed 2024, test split ($N = 74/1478$, threshold = 2.59 dB, highlighted in red). Descriptive; no inferential test is derived from this subset.

Por fim, a [Figure A.6](#) relaciona conjuntamente ΔPSNR e ΔSSIM por fatia, destacando a cauda de pior desempenho definida por ΔPSNR do parágrafo anterior, permitindo visualizar a dispersão bivariada dos casos desfavoráveis.




Fig.A.6 Bottom 5th-percentile slices by global ΔPSNR for the Single Model, seed 2024, test split ($N = 74/1478$, threshold = 2.59 dB, highlighted in red). ΔPSNR vs. ΔSSIM scatter. Descriptive; no inferential test is derived from this subset.

A.2 Computational Performance

O desempenho temporal foi quantificado para o checkpoint do modelo selecionado para a avaliação externa, na partição de teste interna ($n = 1478$ fatias). O benchmark foi executado no ambiente descrito em Materiais e Métodos, com GPU NVIDIA RTX A4500, utilizando lote unitário, após cinco passagens de aquecimento. Para cada fatia, a latência foi medida desde a chamada do modelo até à sincronização explícita da saída com a CPU. Consequentemente, esta medição inclui a execução da inferência e a sincronização da saída, mas não inclui o carregamento das imagens nem as etapas externas de pré-processamento ou de apresentação dos resultados.

A latência média foi de 24,13 ms por fatia (desvio-padrão: 0,69 ms; mediana: 24,30 ms), correspondendo a um débito de 41,4 fatias por segundo. Os percentis 95 e 99 foram, respetivamente, 24,66 ms e 27,53 ms por fatia. A proximidade entre a média, a mediana e o percentil 95 indica estabilidade da latência na maior parte das execuções; a distribuição completa e a variação por fatia são apresentadas na [Figure A.7](#). Estes valores caracterizam a configuração

experimental utilizada e não representam, por si só, o tempo de resposta de um fluxo clínico completo ou de outro ambiente computacional.




Fig.A.7 Inference benchmark: latency histogram and latency per slice.