

Deep Learning for Metal Artifact Reduction in Computed Tomography



Ludmila Montorsi Queiroz

Mestrado em Física Médica

Departamento de Física e Astronomia

Faculdade de Ciências da Universidade do Porto

2026



UNIVERSIDADE DO PORTO

MASTERS THESIS

Deep Learning for Metal Artifact Reduction in Computed Tomography

Author:

Ludmila MONTORSI QUEIROZ

Supervisor:

Hélder Filipe PINTO DE OLIVEIRA

Co-supervisor:

Eduardo MATOS RODRIGUES

*A thesis submitted in fulfilment of the requirements
for the degree of MSc. Medical Physics*

at the

Faculdade de Ciências da Universidade do Porto
Departamento de Ciência de Computadores
Departamento de Física e Astronomia
INESC TEC

29 de agosto de 2026

"The Universe is under no obligation to make sense to you."

Neil deGrasse Tyson, *Astrophysics for People in a Hurry* (2017)

"Nothing in life is to be feared; it is only to be understood."

Marie Curie, *Madame Curie: A Biography* (1937)

Acknowledgements

I would like to express my deepest gratitude to my supervisor, Helder Filipe Pinto de Oliveira, for his invaluable guidance, support, and encouragement throughout this research journey. His expertise and insights have been instrumental in shaping this thesis. I am also grateful to my co-supervisor, Eduardo Matos Rodrigues, for his constructive feedback and encouragement, which have greatly contributed to the development of this work.

UNIVERSIDADE DO PORTO

Abstract

Faculdade de Ciências da Universidade do Porto

Departamento de Ciência de Computadores

Departamento de Física e Astronomia

INESC TEC

MSc. Medical Physics

Deep Learning for Metal Artifact Reduction in Computed Tomography

by [Ludmila MONTORSI QUEIROZ](#)

This thesis addresses deep learning approaches for metal artifact reduction in computed tomography images, presenting a comparative study of the different techniques proposed in the literature and measuring their performance in a rigorous and reproducible manner.

Keywords: Computed Tomography, Metal Artifact Reduction, Medical Physics, Medical Imaging, Deep Learning, Artefact, Medical Diagnostics, Physics

UNIVERSIDADE DO PORTO

Resumo

Faculdade de Ciências da Universidade do Porto

Departamento de Ciência de Computadores

Departamento de Física e Astronomia

INESC TEC

MSc. Medical Physics

Aprendizado Profundo para Redução de Artefatos de Metal em Tomografia Computadorizada

por [Ludmila MONTORSI QUEIROZ](#)

Esta tese aborda abordagens de aprendizado profundo para a redução de artefatos de metal em imagens de tomografia computadorizada, apresentando um estudo comparativo das diferentes técnicas propostas na literatura e avaliando seu desempenho de maneira rigorosa e reprodutível.

Palavras-chave: Tomografia Computadorizada, Redução de Artefatos de Metal, Física Médica, Imagem Médica, Aprendizado Profundo, Artefato, Diagnóstico Médico, Física

Índice

Acknowledgements	ii
Abstract	iii
Resumo	iv
Índice	v
Lista de Figuras	viii
Lista de Gráficos	ix
Lista de Tabelas	x
Lista de Abreviaturas	xi
1 Introdução	1
1.1 Contexto clínico e técnico	3
1.2 Problema de investigação	3
1.3 Contribuições e organização da dissertação	4
2 Objetivos e Questões de Investigação	5
2.1 Objetivo geral	5
2.2 Objetivos específicos	5
2.3 Hipóteses e desfechos	6
3 Enquadramento e Trabalhos Relacionados	7
3.1 Artefactos metálicos em tomografia computadorizada	7
3.2 Redução de artefactos baseada em aprendizagem profunda	7
3.3 Avaliação reprodutível e generalização	9
4 Materiais e Métodos	10
4.1 Dados, curadoria e rastreabilidade	10
4.1.1 Conjunto CT-MAR e fontes de referência	10
4.1.2 Particionamento ao nível do paciente	11
4.1.3 Coorte final e Exclusões	15
4.1.4 Estratificação Anatómica	16
4.2 Pré-processamento	18
4.2.1 Verificação de integridade	18
4.2.2 Máscara Corporal	18

4.2.3	Janela de intensidade e normalização	19
4.2.4	Máscara de artefacto para supervisão auxiliar	19
4.3	Arquiteturas em comparação	19
4.3.1	U-Net	19
4.3.2	U-Net Dual Supervision	20
4.4	Treino reprodutível	21
4.4.1	Configuração, determinismo e seleção de checkpoint	21
4.4.2	Função de Perda	22
4.5	Avaliação interna	23
4.5.1	Métricas globais	24
4.5.2	Avaliação por regiões de interesse	24
4.5.3	Análise estatística	27
4.6	Avaliação externa por médicos	27
4.6.1	Desenho e casos	28
4.6.2	Participantes e proteção de dados	28
4.6.3	Apresentação e instrumento de avaliação	28
4.6.4	Desfechos e análise	28
4.6.5	Estado operacional	28
5	Resultados	29
5.1	Coorte final e integridade experimental	29
5.1.1	Resultados da Aprovação Automática x Inspeção Manual	29
5.1.2	Análise Complementar com MS-SSIM	29
5.2	Treino dos modelos	36
5.2.1	Convergência e seleção dos checkpoints	36
5.2.2	Rastreabilidade das execuções	44
5.3	Avaliação interna no conjunto de teste	44
5.3.1	Desfechos globais	44
5.3.2	Avaliação por regiões de interesse	47
5.4	Comparação pareada Single x Dual Model	51
5.5	Desempenho computacional	54
5.6	Avaliação externa por médicos	55
5.6.1	Estado da recolha e participantes	55
5.6.2	Desfecho primário: visualização anatómica	55
5.6.3	Desfechos secundários e segurança percebida	55
5.6.4	Interpretação limitada ao desenho observacional	55
6	Discussão	56
6.1	Síntese dos achados principais	56
6.2	Interpretação da comparação arquitetural	56
6.3	Preservação anatómica e segurança da reconstrução	56
6.4	Generalização e avaliação externa	56
6.5	Avaliação por médicos	56
6.6	Limitações	57
6.7	Implicações e trabalho futuro	57
7	Conclusões	58
7.1	Conclusões do estudo	58
7.2	Contribuições da dissertação	58

7.3 Perspetivas futuras	58
Bibliography	58
A Appendix Title Here	64

Lista de Figuras

4.1	Single Supervision U-Net architecture	20
4.2	Dual Supervision U-Net architecture	21
4.3	Artifact and distant ROI examples	26
5.3	Visually approved low MS-SSIM pairs	32
5.4	Visually rejected pairs	33

Lista de Gráficos

5.1	MS-SSIM distribution and zoom (clean CT-MAR vs DL/Stroke)	30
5.2	MS-SSIM ECDF (clean CT-MAR vs DL/Stroke)	31
5.5	Cosine similarity of MS-SSIM-audited pairs	34
5.6	MS-SSIM distribution of audited pairs	34
5.7	Score distribution of excluded pairs: DL vs Stroke EIT	35
5.8	Training curves: Dual Model, seed 1337	37
5.9	Training curves: Single Model, seed 1337	38
5.10	Training curves: Dual Model, seed 2024	39
5.11	Training curves: Single Model, seed 2024	40
5.12	Training curves: Dual Model, seed 42	41
5.13	Training curves: Single Model, seed 42	42
5.14	Per-image global PSNR and SSIM	47
5.15	Per-image ROI metric improvements	50
5.16	Artifact-ROI correction versus distant-ROI change	51
5.17	Global PSNR and SSIM improvement	52
5.18	Global structural improvement and preservation trade-offs	53
5.19	Artifact-ROI structural improvement and preservation trade-offs	54
5.20	Inference per Slice Latency (batch=1)	54

Lista de Tabelas

4.1	Initial pair-matching screening	15
4.2	Pair matching after MS-SSIM review	15
4.3	Excluded unmatched pairs before and after MS-SSIM review	16
4.4	Patient-level anatomical distribution by split	17
4.5	Patient distribution by split	17
4.6	Pair distribution by split and anatomical category	17
4.7	Pair distribution by split	18
4.8	Evaluation metrics by context	27
5.1	Best validation SSIM by model and seed	43
5.2	Validation PSNR at best validation SSIM	43
5.3	Validation MAE at best validation SSIM	43
5.4	Per-slice global SSIM on the test set	45
5.5	Per-slice global PSNR on the test set	45
5.6	Per-slice global MAE on the test set	45
5.7	Patient-level global Δ SSIM	45
5.8	Patient-level global Δ PSNR	45
5.9	Patient-level global Δ MAE	46
5.10	ROI Δ SSIM	48
5.11	ROI Δ PSNR	48
5.12	ROI MAE reduction	48
5.13	Improvement over corrupted input	51
5.14	Structural preservation metrics	51
5.15	Paired Single vs Dual Model comparison	52

Lista de Abreviaturas

AMP Automatic Mixed Precision.

BCE Binary Cross-Entropy.

BN Batch Normalization.

CNN Convolutional Neural Network.

CT Computed Tomography.

CT-MAR CT Metal Artifact Reduction Challenge.

DICE Dice Similarity Coefficient.

DL Deep Learning.

FBP Filtered Back Projection.

FCUP Faculdade de Ciências da Universidade do Porto.

GAN Generative Adversarial Network.

GPU Graphics Processing Unit.

HU Unidade Hounsfield.

iMAR Iterative Metal Artifact Reduction.

IR Iterative Reconstruction.

MAE Mean Absolute Error.

MAR Metal Artifact Reduction.

MBIR Model-Based Iterative Reconstruction.

MS-SSIM Multi-Scale Structural Similarity Index Measure.

NMAR Normalized Metal Artifact Reduction.

NPY NumPy Array.

O-MAR Orthopedic Metal Artifact Reduction.

PSNR Peak Signal-to-Noise Ratio.

ReLU Rectified Linear Unit.

RMSE Root Mean Square Error.

ROI Region of Interest.

SEMAR Single Energy Metal Artifact Reduction.

SSIM Structural Similarity Index Measure.

TCIA The Cancer Imaging Archive.

U-Net U-shaped Network.

UP Universidade do Porto.

This thesis is dedicated to my husband, for his love and support.

Capítulo 1

Introdução

Quando Wilhelm Conrad Röntgen, professor de Física da Universidade de Würzburg, na Alemanha, decidiu repetir o experimento feito por Philipp Lenard com um tubo de Crookes modificado para estudar raios catódicos, ninguém podia prever o impacto de suas descobertas na medicina. Não demorou muito para que seus experimentos apresentassem resultados surpreendentes que demonstravam que o comportamento observado não era compatível com raios catódicos, mas sim com uma espécie de raio mais penetrante e que não sofria desvios na presença de um campo magnético. Durante o manuseio das peças usadas nos seus experimentos, percebeu que o contorno dos seus ossos estava sendo estampado na tela fluorescente que utilizava.

Assim, em 22 de dezembro de 1895, convidou sua esposa, Anna Bertha, a fazer uma exposição de 15 minutos a esses raios, obtendo-se o que seria a primeira radiografia do corpo humano. Nesse mesmo ano, Röntgen publicou o artigo "On a new kind of rays", no qual batiza o agente responsável como "raios-X". Já em janeiro de 1896, os jornais anunciavam em primeira página a descoberta como uma forma revolucionária de observar o interior do corpo humano sem a necessidade de incisões cirúrgicas, apontando seu potencial uso no diagnóstico médico [1, 2].

Em fevereiro de 1896, em Massachusetts (EUA), Edwin Brant Frost produziu uma radiografia da fratura de Colles de um paciente para seu irmão, um médico local, marcando o início da incorporação dos raios-X à prática médica [1]. Assim, em menos de um ano após o anúncio da descoberta por Röntgen, os raios-X rapidamente saíram dos laboratórios e passaram a ser utilizados de forma extensiva no diagnóstico e na terapia [1]. Desde então, a técnica passou por sucessivas modernizações e diversificou-se em múltiplas modalidades e dispositivos, consolidando-se como ferramenta indispensável na saúde moderna [3, 4].

Dessas sucessivas modernizações surgiu, em 1971, o primeiro tomógrafo computadorizado. Essa tecnologia baseia-se no princípio de atenuação dos raios-X, em que a quantidade

de radiação absorvida ou dispersa pelo material relaciona-se à sua densidade [5, 6]. A tomografia computadorizada (CT) foi a primeira modalidade de imagem médica a fornecer informações quantitativas sobre a atenuação dos tecidos, algo que não era possível com a radiografia convencional [7]. Além disso, ao permitir a visualização seccional do corpo humano, a tomografia computadorizada eliminou a sobreposição de estruturas anatômicas inerente às imagens bidimensionais, possibilitando a localização precisa e a avaliação da extensão de lesões[7].

Entretanto, esses avanços trouxeram um aumento significativo da complexidade tecnológica. A aquisição de múltiplas projeções, aliada à reconstrução computacional e ao processamento digital da imagem, introduziu novas formas de degradação que eram inexistentes ou pouco relevantes na radiografia convencional. Dessa forma, a tomografia computadorizada tornou-se particularmente suscetível à presença de artefatos, os quais podem comprometer a qualidade diagnóstica e a confiabilidade clínica das imagens [7].

Diversos tipos de artefatos podem ser observados em tomografia computadorizada, incluindo ruído, endurecimento do feixe, movimento, artefatos de anel e artefatos metálicos, os quais podem obscurecer ou simular patologias [8]. As causas desses artefatos são variadas, podendo incluir desde falhas ou descalibração dos detectores, limitações estatísticas associadas a baixas contagens de fótons, até fenômenos físicos como endurecimento e dispersão do feixe, que produzem estrias escuras entre objetos de alta atenuação, como metal, osso ou meios de contraste iodados [7].

Especificamente, artefatos de estrias causados por implantes metálicos são observados em aproximadamente 21% das varreduras tomográficas, sendo considerados extremamente comuns na prática clínica [7]. A elevada atenuação ou mesmo o bloqueio total dos raios-X por esses implantes impede que a radiação alcance adequadamente os detectores, resultando em dados de projeção de baixa qualidade e comprometendo a reconstrução da imagem [9].

O aumento do uso de implantes metálicos, impulsionado pela evolução dos cuidados de saúde, intensificou as preocupações relacionadas ao impacto negativo desses artefatos na qualidade de imagem e na confiabilidade das análises diagnósticas [9]. Tradicionalmente, diversos algoritmos de redução de artefatos de metal (MAR) foram propostos, incluindo técnicas de preenchimento de imagem, preenchimento de sinogramas e métodos de reconstrução iterativa baseada em modelo (MBIR) ou combinações dessas abordagens [10].

Embora métodos analíticos como a *Filtered Back Projection (FBP)* tenham dominado a reconstrução tomográfica por décadas devido à sua eficiência computacional e simplicidade conceitual, suas limitações tornam-se evidentes em condições clínicas não ideais, exigindo doses

de radiação mais elevadas para garantir qualidade de imagem [11]. Métodos MBIR surgiram como alternativa para superar essas limitações, ao custo de maior demanda computacional e da introdução de texturas artificiais na imagem reconstruída [11].

Mais recentemente, abordagens baseadas em aprendizado profundo têm sido amplamente investigadas para a correção de artefatos em tomografia computadorizada, demonstrando desempenho superior e maior aplicabilidade clínica em comparação com métodos convencionais [12]. Em particular, redes neurais convolucionais (CNNs) têm sido propostas para a redução de artefatos metálicos, permitindo a supressão de ruído e a preservação de detalhes anatômicos e de tecidos moles [12].

1.1 Contexto clínico e técnico

Devido ao fato de que artefatos em CT podem esconder ou simular patologias, a sua presença pode comprometer a qualidade diagnóstica e a confiabilidade clínica das imagens. Um erro de diagnóstico pode trazer consequências graves para o paciente, incluindo atrasos no tratamento, tratamentos inadequados ou desnecessários, e até mesmo risco de vida. Além disso, devido a constante evolução tecnológica, torna-se cada vez mais comum o uso de implantes metálicos no contexto médico, o que aumenta consideravelmente a presença desse tipo de artefato especificamente e também os erros de diagnóstico associados. Sendo assim, a redução de artefatos em CT é uma área de pesquisa com importância clínica significativa e o desenvolvimento de métodos eficazes para reduzir artefatos ganha elevado valor na prática médica.

1.2 Problema de investigação

Embora estudos utilizando *Deep Learning* para redução de artefatos metálicos não seja novidade, a maioria dos trabalhos publicados até o momento não apresenta uma avaliação rigorosa e detalhada do desempenho dos modelos propostos. Principalmente, no que se trata a avaliação do desempenho dos modelos em conjunto de dados externos, que não foram utilizados durante o treino do modelo ou avaliação das imagens por médicos qualificados. Além de que, os treinos de modelos supervisionados dependem de imagens de referência, que são difíceis de obter em contexto clínico, o que cria dependência de imagens sintéticas ou simuladas, que pode limitar a generalização dos modelos treinados para o contexto de imagens reais. Nesse sentido, o presente estudo propõe uma avaliação mais rigorosa e detalhada do desempenho de modelos de *Deep Learning* para essa finalidade.

1.3 Contribuições e organização da dissertação

Esse trabalho visa avaliar o desempenho de duas versões de uma [U-shaped Network \(U-Net\)](#), comparando seus resultados. Ao final, foi realizada uma avaliação externa com imagens reais, que foi então avaliadas por médicos qualificados, para validar a eficácia dos modelos propostos e sua eventual aplicabilidade clínica.

Capítulo 2

Objetivos e Questões de Investigação

2.1 Objetivo geral

O objetivo geral desta dissertação é desenvolver, avaliar e comparar de forma rigorosa um modelo baseado em *Convolutional Neural Networks (CNNs)* para deteção e redução de artefatos em imagens de Tomografia Computorizada, privilegiando a preservação anatómica, a robustez à variação de domínio e a interpretabilidade do processo de correção.

2.2 Objetivos específicos

Os objetivos específicos deste trabalho incluem:

- Desenvolver um *pipeline* reproduzível para treino e avaliação de modelos de redução de artefatos em CT no domínio da imagem, com separação rigorosa entre dados de treino, validação e teste.
- Avaliar o desempenho de uma arquitetura U-Net convencional para reconstrução de imagem na redução de artefatos metálicos e compará-la com uma versão dela mesma com acréscimo de uma supervisão extra de máscara de artefato.
- Avaliar o desempenho das duas versões utilizando métricas quantitativas (PSNR, MS-SSIM, SSIM, BCE e DICE), análise qualitativa e mapas de erro.
- Investigar a capacidade de generalização da versão que se sair melhor na etapa de avaliação interna em dados reais e externos ao treino provenientes do *The Cancer Imaging Archive (TCIA)*.

2.3 Hipóteses e desfechos

Capítulo 3

Enquadramento e Trabalhos Relacionados

3.1 Artefactos metálicos em tomografia computadorizada

Os métodos tradicionais de redução de artefatos em [CT](#) baseiam-se predominantemente em princípios físicos e matemáticos associados à formação da imagem. Barrett e Keat[13] descrevem detalhadamente a origem dos principais artefatos em [CT](#), incluindo endurecimento de feixe, *photon starvation*, dispersão e efeitos geométricos, bem como estratégias clássicas para sua mitigação.

Técnicas de reconstrução como a Retroprojeção Filtrada ([FBP](#)) foram amplamente utilizadas devido à sua eficiência computacional, porém apresentam elevada sensibilidade ao ruído e aos artefatos metálicos. Métodos mais avançados, como *Iterative Reconstruction (IR)* e *Model-Based Iterative Reconstruction (MBIR)*, incorporam modelos estatísticos do sistema de aquisição e do ruído, permitindo redução parcial de artefatos. Contudo, essas abordagens frequentemente introduzem texturas artificiais e apresentam limitações em cenários clínicos complexos [11].

Revisões recentes indicam que algoritmos comerciais de *Metal Artifact Reduction (MAR)*, como [O-MAR](#), [iMAR](#) e [SEMAR](#), embora eficazes em situações específicas, dependem de parâmetros proprietários e exibem desempenho inconsistente em casos de implantes densos ou múltiplos [9, 14]. Essas limitações impulsionaram a investigação de abordagens baseadas em aprendizagem profunda.

3.2 Redução de artefactos baseada em aprendizagem profunda

As primeiras aplicações de [DL](#) para [MAR](#) concentraram-se no domínio da imagem, explorando redes convolucionais para mapear imagens degradadas para versões corrigidas. Gjestebj et al. [15] investigaram a redução de artefatos metálicos no domínio da imagem baseada em

CNN e demonstraram melhorias quantitativas significativas em comparação com as técnicas convencionais.

Zhang e Yu [16] também propuseram um modelo supervisionado baseado em *Convolutional Neural Network (CNN)* para redução de artefatos metálicos em CT, obtendo ganhos consistentes em *Peak Signal-to-Noise Ratio (PSNR)* e *Root Mean Square Error (RMSE)*. Esses trabalhos ajudaram a consolidar o uso de redes convolucionais para MAR no domínio da imagem. Em particular, Zhang e Yu utilizaram uma CNN rasa totalmente convolucional para fusão de informação de múltiplas imagens pré-corrigidas. Os trabalhos subsequentes adotaram cada vez mais arquiteturas de codificador-decodificador, especialmente as baseadas em *U-Net*, para tarefas de correção/restauração. Redes do tipo *U-Net* e suas variantes são capazes de capturar informações contextuais globais por meio do caminho de contração, e recuperar detalhes espaciais finos por meio do caminho de expansão e *Skip Connections*[17].

Revisões sistemáticas mais recentes consolidam esses avanços, destacando que a maioria dos métodos supervisionados no domínio da imagem apresenta desempenho competitivo, especialmente quando treinados com dados pareados de alta qualidade [9, 11].

Além do domínio da imagem, alguns estudos exploraram o domínio do sinograma, com métodos de interpolação linear e *Normalized Metal Artifact Reduction (NMAR)*. Essas abordagens operam diretamente nos dados de projeção e atuam diretamente na origem física dos artefatos metálicos[18]. No entanto, o acesso aos dados de projeção brutos é frequentemente restrito em sistemas de CT comerciais, limitando a aplicabilidade de tais abordagens em ambientes clínicos [15].

Além disso, modelos híbridos têm sido propostos para aproveitar as vantagens de cada abordagem. O método proposto por Zhang e Yu [16] procura mesclar CNN no domínio de imagem e MAR clássico no domínio do sinograma. Na abordagem adotada, o refinamento inicial ocorre no domínio da imagem, mas o método completo utiliza a imagem gerada pela CNN como *prior* para substituição de regiões afetadas no sinograma. Isso caracteriza uma abordagem híbrida, mas ainda não emprega CNN nos dois domínios. Modelos mais recentes, como o DuDoNet[19], integram redes profundas em ambos os domínios, demonstrando desempenho elevado e caracterizando o que chamamos de *Dual Domain*. No entanto, esses métodos apresentam maior complexidade computacional e dependência do acesso ao sinograma bruto, o que motiva a exploração contínua de soluções robustas no domínio da imagem.

Para contornar a escassez de dados pareados anatomicamente idênticas com artefato de metal/Livre de artefato de metal, surgiram abordagens baseadas em aprendizagem auto-supervisionada. Yu et al. [20] propuseram um método capaz de reduzir artefatos metálicos

sem a necessidade de imagens de referência totalmente limpas, ampliando a aplicabilidade clínica dessas técnicas.

Outros trabalhos exploraram o uso de *Generative Adversarial Network (GAN)* para MAR. Huang et al. [21] utilizaram fusão multimodal e GANs para melhorar a preservação de textura e reduzir suavização excessiva. Apesar dos bons resultados visuais, métodos baseados em GAN podem introduzir instabilidade no treino e maior risco de alucinação estrutural[22], o que levanta preocupações clínicas.

3.3 Avaliação reprodutível e generalização

A avaliação de modelos de DL para CT é tipicamente realizada por meio de métricas quantitativas como PSNR, RMSE e índices baseados em similaridade estrutural. Métricas tradicionais baseadas em erro, como RMSE e PSNR, quantificam discrepâncias pixel a pixel, mas não capturam adequadamente informações estruturais relevantes para a percepção visual e interpretação clínica. Nesse contexto, Wang et al. [23] introduziram o *Structural Similarity Index Measure (SSIM)* como uma métrica perceptual que modela explicitamente luminância, contraste e estrutura. Posteriormente, o *Multi-Scale Structural Similarity Index Measure (MS-SSIM)* foi proposto para incorporar variações estruturais dependentes de escala, estendendo o SSIM para múltiplos níveis de resolução [24]. Horé e Ziou [25] demonstraram que tanto PSNR quanto SSIM apresentam limitações dependendo do tipo de distorção considerada, sugerindo que a escolha da métrica pode depender do contexto de aplicação. Dado que os artefatos metálicos se manifestam principalmente como distorções estruturais que afetam limites anatômicos e padrões de estrias de longo alcance, métricas sensíveis à preservação estrutural, como SSIM e MS-SSIM, mostram-se particularmente adequadas para avaliar o desempenho de métodos de MAR, pois consideram explicitamente componentes estruturais em diferentes escalas espaciais [23, 24]. Além disso, um desafio crítico identificado na literatura é a generalização dos modelos. Zech et al. [26] demonstraram que modelos com elevado desempenho em bases internas podem falhar significativamente quando aplicados a dados externos, evidenciando o impacto do *domain shift*. Revisões recentes reforçam a necessidade de validação externa e avaliação clínica rigorosa para garantir segurança, robustez e aplicabilidade real [27, 28]. A literatura revisada demonstra avanços significativos na redução de artefatos em CT por meio de DL, mas também evidencia lacunas persistentes: falta de padronização experimental, validação externa limitada e risco de alucinação anatômica.

Capítulo 4

Materiais e Métodos

4.1 Dados, curadoria e rastreabilidade

4.1.1 Conjunto CT-MAR e fontes de referência

O *dataset* principal utilizado neste trabalho provém do [CT Metal Artifact Reduction Challenge \(CT-MAR\)](#) [29, 30] promovido pela *American Association of Physicists in Medicine* e consiste em 14.000 pares de treino contendo imagens de CT com artefatos metálicos simulados e suas versões originais sem artefatos. Os dados foram gerados através de um *framework* de simulação híbrida [31], que incorpora imagens clínicas publicamente disponíveis e objetos metálicos simulados com o simulador CatSim, integrado na *toolkit* de código aberto XCIST [32]. O conjunto é distribuído em duas categorias anatômicas:

- **Head:** 1.626 (11.61%) amostras derivadas da base *UCLH Stroke EIT Data* [33, 34];
- **Body:** 12.374 (88.38%) amostras derivadas da base *NIH DeepLesion Data* [35].

Onde as pastas da categoria *body* apresentavam CTs de tronco, abrangendo fatias axiais, torácica e abdominal. Os dados estão organizados em subpastas, cada uma contendo até 1.000 amostras. Foram utilizados apenas os seguintes ficheiros para treino e validação:

1. **Imagens sem metal (referência):** Ficheiros contidos na pasta *Target* de dimensão 512×512×1 pixels;
2. **Imagens com artefatos metálicos (corrompidas):** Ficheiros contidos na pasta *Baseline* de dimensão 512×512×1 pixels;

Todos os ficheiros de imagem (.raw) do *dataset* são apresentados em formato binário sem cabeçalho, com precisão *float32* em ordem *little endian*. As imagens já vieram convertidas

de coeficientes de atenuação linear (em unidades mm^{-1}) para [Unidade Hounsfield \(HU\)](#), utilizando o valor de normalização de 0.02 mm^{-1} para água. Não havia no conjunto de dados informações adicionais sobre a que exame cada *slice* pertencia, se eram de um mesmo paciente, ou quais regiões anatómicas específicas estavam representadas. A única informação disponível era a organização por pasta, que indicava a categoria anatómica (Head ou Body). A falta de metadados detalhados impôs a necessidade de uma abordagem de pré-processamento cuidadosa para garantir que os dados fossem adequadamente organizados e utilizados durante o treino e validação dos modelos. Dessa forma, um esforço significativo foi dedicado ao rastreamento das imagens aos conjuntos de dados originais (UCLH Stroke EIT Data e NIH DeepLesion Data) para obter informações adicionais sobre os exames e pacientes, permitindo um particionamento adequado dos dados.

4.1.2 Particionamento ao nível do paciente

O particionamento dos dados foi estratificado por pacientes, garantindo que os *slices* de um mesmo paciente não fossem distribuídos entre os conjuntos de treino, validação e teste. Esta abordagem evita vazamento de informações e assegura uma avaliação mais realista da capacidade de generalização dos modelos.

Dado que os dados do [CT-MAR dataset](#) não continham metadados clínicos detalhados, foi necessário realizar um rastreamento algorítmico dos *slices* até aos conjuntos de dados originais (UCLH Stroke EIT e NIH DeepLesion Data) para tornar possível a associação dos metadados fornecidos aos *slices* do [CT-MAR](#). Este processo permitiu identificar a qual exame e paciente do DeepLesion/UCLH Stroke EIT cada imagem [CT-MAR](#) pertencia. Essas informações foram posteriormente utilizadas para realizar o particionamento dos dados em treino, validação e teste ao nível do paciente, reduzindo o risco de *data leakage* entre conjuntos experimentais.

A correta separação dos dados é particularmente importante em estudos de imagem médica baseados em *deep learning*, uma vez que *slices* pertencentes ao mesmo exame frequentemente apresentam elevada similaridade anatómica. Dessa forma, a presença simultânea de imagens do mesmo paciente em treino e teste pode inflacionar artificialmente o desempenho do modelo e comprometer a avaliação da sua capacidade de generalização [36].

As imagens do dataset DeepLesion [35] encontram-se armazenadas em formato PNG de 16 bits, enquanto as imagens do [CT-MAR](#) são disponibilizadas em formato `.raw` diretamente em unidades de Hounsfield (HU). Já o UCLH Stroke EIT [33] disponibiliza os exames em

formato DICOM. Assim, independentemente do formato original, todas as imagens foram convertidas para HU antes da comparação, garantindo uniformidade entre os diferentes conjuntos de dados.

Após a conversão, todas as imagens foram representadas numa mesma escala de intensidade para permitir comparação direta.

O algoritmo utilizado baseia-se no facto de que imagens CT preservam informação quantitativa em unidades de Hounsfield (HU), refletindo diretamente as propriedades de atenuação dos diferentes tecidos. Como as estruturas anatómicas apresentam elevada continuidade espacial entre *slices* consecutivos de uma mesma aquisição, imagens correspondentes à mesma fatia anatómica tendem a apresentar distribuições semelhantes de HU e padrões estruturais globais altamente consistentes [23, 37].

Dessa forma, o método não procura verificar igualdade absoluta pixel-a-pixel entre imagens, mas sim determinar se a organização estrutural global da anatomia permanece extremamente semelhante entre diferentes representações da mesma fatia. Esse comportamento é particularmente importante porque pequenas variações locais de intensidade, discretização numérica e transformações lineares associadas à conversão entre formatos de armazenamento tendem a preservar a estrutura anatómica global da imagem mesmo quando ocorrem pequenas variações locais de intensidade [23, 37].

Assim, a metodologia adotada procura identificar correspondências entre imagens com base na similaridade estrutural global, permitindo uma margem de variação local que não comprometa a identificação correta do exame e paciente de origem. Inicialmente, cada imagem foi reduzida para uma representação compacta através de *downsampling*, preservando principalmente a informação anatómica global relevante. Essa etapa reduz significativamente o custo computacional sem comprometer a estrutura geral da imagem.

Em seguida, foi calculado um vetor representativo (*fingerprint*) para cada imagem. Os *fingerprints* das imagens CT-MAR foram então comparados com os *fingerprints* das imagens DeepLesion e UCLH Stroke EIT através de uma métrica de similaridade vetorial baseada em produto escalar normalizado (similaridade de cosseno), escolhida por ser invariante a diferenças de escala global entre os vetores — propriedade relevante dado que as imagens provêm de formatos distintos com diferentes normalizações de intensidade. Para cada imagem CT-MAR, foi selecionada a imagem com maior score de similaridade.

Como a maior parte das imagens do CT-MAR teve origem no DeepLesion, o processo de rastreio foi inicialmente priorizado nesse dataset. Posteriormente, a mesma metodologia foi aplicada aos exames DICOM do UCLH Stroke EIT para identificação das imagens restantes.

Dessa forma, foi possível implementar uma estratégia unificada de rastreabilidade independentemente do formato de armazenamento dos datasets de origem.

As correspondências foram consideradas válidas apenas quando o score de similaridade excedia um limiar previamente definido empiricamente. Casos com scores muito elevados foram automaticamente marcados como correspondências seguras, pois observou-se que todos os pares analisados visualmente com pontuação superior a 0.993 correspondiam efetivamente à mesma imagem. Para manter uma margem adicional de segurança, a correspondência foi considerada automaticamente válida apenas quando a pontuação excedia 0.994.

Pontuações inferiores a esse limiar indicavam correspondências potencialmente ambíguas e eram submetidas à inspeção visual manual. Já pontuações inferiores a aproximadamente 0.98 indicavam correspondências claramente incorretas e eram automaticamente descartadas sem necessidade de revisão manual. Dessa forma, todos os pares que apresentavam pontuações entre 0.98 e 0.994 foram analisados visualmente para confirmação da validade da correspondência. A fim de evitar a exclusão de pares de forma desnecessária, todos os pares com pontuação inferior a 0.98 para ambos os datasets (DeepLesion e UCLH Stroke EIT) foram submetidos a inspeção visual para garantir que não fossem erroneamente descartados.

Para os 530 pares que permaneceram sem correspondência aprovada após a busca direta nos dois datasets de origem, foi aplicada uma etapa complementar de correspondência indireta. Nessa etapa, cada imagem **CT-MAR** não correspondida foi comparada com imagens **CT-MAR** já rastreadas; os vizinhos mais semelhantes foram usados para selecionar exames candidatos do DeepLesion e, em seguida, todos os *slices* desses exames foram pesquisados com *fingerprints* de dimensão 64×64 . As 530 propostas foram inspecionadas visualmente: 95 correspondências foram aprovadas e incorporadas ao manifesto consolidado, enquanto 435 permaneceram sem correspondência segura e foram excluídas.

Além disso, o método foi concebido para ignorar automaticamente imagens previamente verificadas como correspondências corretas, reduzindo redundâncias e acelerando reprocessamentos futuros. Devido ao elevado número de imagens presentes nos datasets, o processamento foi paralelizado e otimizado através da utilização de operações matriciais vetorizadas. Quando disponível, o algoritmo utiliza aceleração por **GPU** para reduzir o tempo de execução. Os *fingerprints* calculados também foram armazenados em cache para evitar recomputação desnecessária em execuções subsequentes.

Embora a representação compacta baseada exclusivamente na média de intensidades dos

blocos (HU) seja eficiente, ela pode, em teoria, gerar falsos positivos quando exames de pacientes diferentes são adquiridos com protocolos de aquisição idênticos ou apresentam estruturas anatómicas muito semelhantes, uma vez que essas condições tendem a produzir distribuições de intensidade similares e, consequentemente, *fingerprints* com pontuação elevada. Para mitigar esse risco, adotou-se um limiar de aceitação automática conservador (0,994) e a validação visual sistemática de todos os pares com scores entre 0,98 e 0,994. Adicionalmente, como salvaguarda complementar, todos os *matches* automáticos foram analisados em termos de MS-SSIM, onde os pares com pontuações mais críticas foram submetidos a uma revisão visual adicional para garantir a confiabilidade das correspondências.

Apesar disso, essa limitação não compromete o objetivo principal da metodologia. Pois, mesmo que *Slices* consecutivos de um mesmo exame frequentemente apresentem elevada redundância espacial e podem, portanto, obter scores de similaridade muito próximos entre si. O propósito do algoritmo não foi realizar alinhamento voxel-a-voxel rigoroso, mas sim identificar corretamente o exame e o paciente de origem de cada imagem CT-MAR. Dessa forma, mesmo eventuais ambiguidades entre *slices* adjacentes permanecem restritas ao mesmo volume anatómico e não introduzem risco relevante de *data leakage* entre treino, validação e teste.

A literatura demonstra que a qualidade dos pares utilizados em estudos supervisionados influencia diretamente o desempenho e a capacidade de generalização dos modelos de MAR [9, 19]. Além disso, métricas estruturais de qualidade de imagem, como o SSIM, têm sido amplamente utilizadas em imagem médica devido à sua maior sensibilidade à preservação estrutural [23]. Embora o método implementado não utilize diretamente SSIM, a estratégia adotada procura preservar precisamente a informação estrutural global da imagem durante o processo de correspondência.

Mais ainda, a utilização dos dados sem qualquer tratamento de rastreo desse tipo, condicionaria todo o projeto a um vazamento de dados inerente ao dataset, comprometendo a avaliação do desempenho dos modelos e a validade dos resultados. Assim, mesmo que o método de rastreo não seja perfeito, ele representa uma melhoria significativa em relação à ausência total de rastreo, garantindo uma base mais confiável.

Tendo isso em conta, essa etapa constituiu um importante procedimento de controle de qualidade do dataset experimental e foi fundamental para garantir um particionamento adequado dos dados utilizados no treino, validação e teste dos modelos, assegurando que os subconjuntos fossem estratificados por paciente e evitando vazamento de informação entre conjuntos experimentais.

4.1.3 Coorte final e Exclusões

Nem todas as fatias puderam ser rastreadas, mas a maioria dos dados foi associado com sucesso aos exames originais. Ao final das etapas de correspondência direta e indireta, e antes da análise complementar com [MS-SSIM](#), dos 14.000 pares disponibilizados pelo [CT-MAR](#) Dataset, 11.942 foram rastreados até ao DeepLesion (incluindo os 95 recuperados pela correspondência indireta) e 1.623 até ao UCLH Stroke EIT, totalizando 13.565 pares com metadados associados [4.1](#).

Tabela 4.1 Resultados do rastreio antes da análise complementar com [MS-SSIM](#).

Dataset	Rastreados	Correspondidos	Não correspondidos
DeepLesion	12.374	11.942	432
UCLH Stroke	1.626	1.623	3
Total	14.000	13.565	435

Na etapa de avaliação via [MS-SSIM](#), dentre todos os pares com pontuação abaixo de 0.90, apenas 3, anteriormente associados ao Deep Lesion, foram reprovados na inspeção visual [4.2](#).

Tabela 4.2 Resultados do rastreio depois da análise complementar com [MS-SSIM](#).

Dataset	Rastreados	Correspondidos	Não correspondidos
DeepLesion	12.374	11.939	435
UCLH Stroke	1.626	1.623	3
Total	14.000	13.562	438

Dado que uma quantidade significativa dos dados pôde ser rastreada com elevada confiabilidade, os casos restantes que não puderam ser agrupados de forma segura foram excluídos do processo de treino e validação. No total, 438 pares foram removidos por não apresentarem informação suficiente para garantir agrupamento seguro ao nível do paciente. Entre eles, os 3 pares reprovados por ser falso positivo na etapa de avaliação via [MS-SSIM](#). Todos os pares removidos desse estudo foram inspecionados visualmente para confirmar a ausência de correspondência, garantindo que a exclusão foi justificada.

Tabela 4.3 Dados dos pares sem correspondência que foram excluídos antes e após a análise complementar com MS-SSIM.

	Excluídos	
	Antes	Depois
Total	435	438

Assim, dos 14.000 pares originalmente disponibilizados pelo CT-MAR Dataset, 13.562 foram incluídos neste trabalho, enquanto 438 foram excluídos para preservar a integridade do particionamento experimental e minimizar o risco de *data leakage*.

4.1.4 Estratificação Anatômica

A proporção anatômica dos 14.000 pares do CT-MAR Dataset, mudou pouco após o processo de rastreo e exclusão dos pares com baixa confiabilidade. Dos 438 casos removidos 435 eram do tipo *body*, 3 do tipo *head*. A distribuição anatômica dos pares incluídos no estudo é a seguinte:

- **Body:** aproximadamente 88.03% ;
- **Head:** aproximadamente 11.97% .

A estratificação foi implementada dentro de cada subconjunto (train/val/test) de modo a manter a proporção anatômica ao nível de pacientes, garantindo que a proporção relativa entre categorias seja preservada em todos os subconjuntos. Dessa forma, o balanceamento anatômico é preservado, garantindo que os modelos sejam treinados e avaliados em uma representação adequada da diversidade anatômica presente no conjunto de dados original.

A nível de pacientes, a distribuição anatômica é a seguinte:

- **Body:** aproximadamente 95.9% (258/269 pacientes);
- **Head:** aproximadamente 4.1% (11/269 pacientes).

Após o particionamento, os subconjuntos de treino, validação e teste apresentaram a seguinte distribuição:

Tabela 4.4 Distribuição anatômica por subconjunto ao nível de pacientes.

Split	Body	Head	% Body	% Head
Train	180	7	96.3%	3.7%
Val	39	2	95.1%	4.9%
Test	39	2	95.1%	4.9%
Total	258	11	–	–

A partição paciente-nível foi definida uma única vez, com semente aleatória fixa, mantendo aproximadamente 70% dos pacientes para treino, 15% para validação e 15% para teste. Esta partição fixa garantiu subconjuntos independentes para validação e teste e foi mantida inalterada em todas as repetições experimentais.

Tabela 4.5 Distribuição percentual dos pacientes por subconjunto.

Split	Pacientes	% Total
Train	187	69.52%
Val	41	15.24%
Test	41	15.24%
Total	269	100%

Devido a grande variação na quantidade de fatias por paciente, a distribuição anatômica ao nível de pares é bastante diferente da distribuição ao nível de pacientes (Tabelas 4.6 e 4.7). O mesmo ocorre para a distribuição dos pares totais. Dessa forma, a proporção $\sim 70/15/15$ foi mantida ao nível de pacientes mas ao nível dos pares não segue exatamente a mesma proporção.

Tabela 4.6 Distribuição dos pares por subconjunto e categoria anatômica.

Split	Body	Head	% Body	% Head
Train	8 563	953	89.98%	10.02%
Val	2 147	385	84.79%	15.21%
Test	1 229	285	81.17%	18.83%
Total	11 939	1 623	–	–

Tabela 4.7 Distribuição percentual dos pares por subconjunto.

Split	Pares	% Total
Train	9 516	70.17%
Val	2 532	18.67%
Test	1 514	11.16%
Total	13 562	100%

4.2 Pré-processamento

4.2.1 Verificação de integridade

Todos os pares foram validados através de um relatório de integridade, que verifica a existência de ambos os lados do par (imagem com artefacto e imagem limpa). Não houve nenhum par com dados faltantes, garantindo que o conjunto de dados estava completo e pronto para as etapas subsequentes de pré-processamento e treino dos modelos.

4.2.2 Máscara Corporal

As imagens de [CT](#) frequentemente contêm grandes áreas de fundo que não contribuem para a tarefa de remoção de artefatos metálicos. Isso cria um desequilíbrio de classes nos dados de treino que predomina voxels de fundo irrelevantes sobre as regiões anatômicas de interesse. Esse desequilíbrio, por sua vez, dificulta a aprendizagem e desvia o foco do modelo das estruturas clinicamente relevantes [38, 39]. Para abordar esse desafio, foi implementada uma etapa de pré-processamento também baseada em [Deep Learning \(DL\)](#). Uma [U-Net](#) foi treinada para segmentar o tecido corporal do fundo, gerando máscaras binárias que foram aplicadas às imagens originais para isolar as regiões de interesse. Esse modelo foi treinado utilizando ~ 1.500 amostras do próprio [CT-MAR dataset](#), onde as máscaras de segmentação foram geradas automaticamente através de um processo de limiarização. Além disso, um refinamento manual foi feito nas máscaras obtidas para garantir a qualidade dos dados de treino e consequentemente a eficácia do modelo de segmentação.

Esta etapa foi crucial para reduzir a influência de artefatos de fundo e melhorar a qualidade das *features* extraídas durante o treino.

4.2.3 Janela de intensidade e normalização

As intensidades das imagens vêm expressas em HU do CT-MAR dataset. Para reduzir variações extremas foi aplicada uma janela de intensidade adequada ao contexto anatômico. Após o janelamento, os valores foram normalizados para o intervalo $[0, 1]$ e são gerados tensores NPY de dimensão 256×256 2D para cada fatia e seu par.

4.2.4 Máscara de artefacto para supervisão auxiliar

Foram produzidas máscaras binárias de diferença das regiões afetadas por artefatos que foram utilizadas como sinal de supervisão adicional na arquitetura com dupla supervisão. Essas máscaras são utilizadas exclusivamente durante o treino, não sendo necessárias durante a inferência. A máscara binária de diferenças é definida formalmente como:

$$M_{diff}(i, j) = \begin{cases} 1; & \text{se } |I_{artifact}(i, j) - I_{clean}(i, j)| > \tau \\ 0; & \text{caso contrário} \end{cases} \quad (4.1)$$

onde $I_{artifact}$ representa a imagem com artefatos, I_{clean} a imagem de referência limpa, e τ é o limiar de diferença normalizada. O valor desse limiar foi definido empiricamente para capturar regiões com diferenças perceptíveis mantendo robustez a ruído de baixa amplitude.

4.3 Arquiteturas em comparação

4.3.1 U-Net

O primeiro modelo consiste em uma arquitetura baseada em U-Net [17], composta por *encoder-decoder* com conexões de atalho (*skip connections*). Li et al [40], aplicam blocos de Batch Normalization (BN) e funções de ativação Rectified Linear Unit (ReLU) após cada convolução dinâmica. Esse trabalho faz algo semelhante, mas opta por utilizar convoluções padrão com *kernel* 3×3 , seguida dos blocos de BN e funções de ativação ReLU. A escolha por convoluções padrão é justificada pela simplicidade e eficiência computacional, além de manter a abordagem utilizada por Ronneberger et al [17]. Assim como Li et al [40], o *decoder* também utiliza *bilinear upsampling*. Essa arquitetura possui apenas um *output*.




Fig.4.1 Diagrama da arquitetura Single Supervision.

4.3.2 U-Net Dual Supervision

Uma variação do modelo acima descrito foi concebida, mantendo-se o *encoder* e o *decoder* compartilhados e acrescentando-se uma saída independente na última camada. Dessa forma, há duas saídas distintas no decoder, cada uma com sua própria função de perda. A primeira saída é responsável pela reconstrução da imagem corrigida, enquanto a segunda saída é dedicada à predição da máscara de artefatos.

A justificativa para a adição da supervisão auxiliar da máscara de artefatos baseia-se na premissa de que a presença de uma perda adicional focada na segmentação de regiões afetadas por artefatos pode fornecer informações complementares ao modelo, auxiliando na aprendizagem de representações mais robustas e discriminativas. Essa abordagem é inspirada em trabalhos anteriores que demonstraram que a supervisão multi-tarefa pode melhorar o desempenho em tarefas relacionadas [41, 42].

As duas arquiteturas foram avaliadas entre si para determinar o impacto da supervisão adicional com máscara de artefatos na qualidade da reconstrução e na capacidade de redução de artefatos. Toda a base de ambos os modelos são iguais, sendo a única diferença a presença da saída de predição da máscara de artefatos na segunda versão. Dessa forma, a comparação

entre as duas arquiteturas é justa e isolada, permitindo avaliar exclusivamente o impacto da supervisão adicional da máscara de artefatos.




Fig.4.2 Diagrama da arquitetura Dual Supervision.

4.4 Treino reprodutível

4.4.1 Configuração, determinismo e seleção de checkpoint

Os dois modelos foram treinados sob a mesma configuração, com precisão *float32*. Para avaliar a estabilidade face às diferentes inicializações e ordens de apresentação dos lotes, cada arquitetura foi treinada com operações determinísticas e com as sementes 1337, 42 e 2024, sempre sobre a mesma partição dos pacientes. A precisão mista foi desativada e os lotes foram mantidos completos, incluindo o último lote de cada época, de modo a evitar que amostras fossem excluídas do treino, validação ou avaliação.

Foi utilizado o otimizador AdamW, com taxa de aprendizagem inicial de 2.26×10^{-4} , *weight decay* de 1.00×10^{-4} e *gradient clipping* com norma 1.00, idênticos para as duas arquiteturas. A taxa de aprendizagem foi ajustada pelo scheduler *ReduceLROnPlateau*, com fator de redução 0.50, paciência de duas épocas, *cooldown* de uma época e valor mínimo de 1.00×10^{-6} , monitorizando a métrica **SSIM** da imagem reconstruída no conjunto de validação, em ambos

os modelos. O treino tinha um limite máximo de 300 épocas e a paragem antecipada só podia ser acionada após, no mínimo, cinco épocas e ocorria quando a métrica monitorizada não melhorava pelo menos 1.00×10^{-4} durante 15 épocas consecutivas. Em cada execução, foi retido o checkpoint correspondente ao melhor valor da métrica de validação monitorizada.

Durante o treino, foram monitorizadas as seguintes quantidades:

- **Perda de reconstrução**, para acompanhar a otimização da imagem corrigida;
- **Perda de segmentação**, apenas no modelo dual, para acompanhar a supervisão auxiliar da máscara;
- **SSIM, PSNR e MAE na escala HU**, calculados na região corporal para acompanhar a fidelidade estrutural e radiométrica das reconstruções.

4.4.2 Função de Perda

- **Reconstrução:** Apesar de L2 ser amplamente utilizada para restauração de imagem, Zhao et al. [43] destacam os melhores resultados de L1 ao estudar diferentes funções de perda para essa tarefa. Os autores também estudaram funções de perda baseadas em **SSIM** e **MS-SSIM**, sendo que a primeira alcança resultados igual ou levemente inferior a L1, enquanto a segunda apresenta desempenho melhor que **SSIM** mas ainda não supera L1 de forma clara. O trabalho também testa um mix de L1 e **MS-SSIM**, e obteve-se resultados superiores em todas as métricas avaliadas pelos autores. Essa combinação é justificada pela complementaridade entre as duas funções, onde L1 favorece fidelidade local e **MS-SSIM** promove preservação estrutural, resultando em uma correção mais equilibrada dos artefatos. Embora o melhor resultado relatado pelos autores tenha envolvido L1 e **MS-SSIM**, neste trabalho adotou-se a soma ponderada de L1 e **SSIM**. Esta escolha mantém o princípio geral de combinar uma componente de fidelidade por píxel com uma componente estrutural, sem reproduzir a formulação específica nem os pesos utilizados por Zhao et al. Os pesos utilizados para o protocolo experimental foram 0.7 para L1 e 0.3 para **SSIM**. A relação adotada para a combinação das funções de perda é a seguinte:

$$\mathcal{L}_{Recon} = 0.7 \cdot \mathcal{L}_{L1} + 0.3 \cdot (1 - \text{SSIM})$$

Na perda híbrida, Zhao et al. [43] aplicam uma ponderação espacial Gaussiana à componente L1, de modo a compatibilizá-la com a distribuição espacial dos gradientes da componente **MS-SSIM**. Neste trabalho, a componente L1 foi calculada diretamente como

o erro absoluto médio na região corporal, sem ponderação Gaussiana adicional. Como a normalização utilizada é linear em relação aos valores de **HU**, esta componente mantém uma penalização diretamente proporcional ao erro radiométrico, enquanto o **SSIM** contribui para a preservação estrutural local. Essa combinação de função de perda é adotada para a arquitetura *single task* e também para a cabeça de reconstrução da arquitetura *dual*. Dessa forma, garante-se que a ablação entre as duas versões seja justa, isolando o impacto da supervisão adicional da máscara.

- **Supervisão auxiliar da máscara:** A cabeça de predição da máscara de artefatos, presente na arquitetura *dual*, foi treinada com a soma da perda Dice e da **Binary Cross-Entropy (BCE)**. Essa combinação fornece simultaneamente supervisão para a sobreposição global entre as máscaras e para a classificação por píxel, sendo adequada a problemas de segmentação com desequilíbrio de classes [38]. A relação adotada para a combinação das funções de perda é a seguinte:

$$\mathcal{L}_{Seg} = \mathcal{L}_{Dice} + \mathcal{L}_{BCE}$$

A função de perda total para a versão *dual-head* é composta pela ponderação das perdas de reconstrução e segmentação, e é definida como:

$$\mathcal{L} = 1.0 \cdot \mathcal{L}_{Recon} + 0.045 \cdot \mathcal{L}_{Seg}$$

Os experimentos foram executados numa GPU NVIDIA RTX A4500, utilizando Python e TensorFlow/Keras.

4.5 Avaliação interna

Na fase de inferência, os modelos foram avaliados utilizando métricas quantitativas amplamente adotadas na literatura, em comparação com o *Ground Truth*. As métricas utilizadas para a avaliação da qualidade da imagem reconstruída global e por ROI foram:

- **PSNR** ;
- **SSIM** ;
- **MAE**.

Wang et al. [24] descrevem **MS-SSIM** como um método de avaliação de qualidade de imagem através de cinco escalas com *downsampling* iterativo por fator 2, resultando em uma redução de resolução de até 1/16 do tamanho original. O método foi validado em bases de dados

de imagens completas, sem considerar aplicação em regiões fragmentadas ou espacialmente seletivas. Devido ao *downsampling* progressivo, a aplicação MS-SSIM em ROIs pequenas ou fragmentadas (como a zona distante em nossa análise) resultaria na mistura de pixels de ROI e não-ROI nas escalas reduzidas, comprometendo a interpretabilidade dos resultados. Por isso, utilizou-se SSIM regular em vez de MS-SSIM nesse trabalho. De fato, as literaturas recentes tem demonstrado performance estatisticamente muito melhor em fidelidade para MS-SSIM e SSIM comparado a outras métricas de avaliação de qualidade de imagem[44]. Especialmente para imagens médicas, onde a fidelidade das imagens preditas é crucial, a escolha de métricas que refletem a percepção humana de qualidade e preservação estrutural é fundamental. Portanto, SSIM foi selecionado como a principal métrica para avaliação quantitativa da qualidade das imagens reconstruídas, garantindo uma análise robusta e relevante para o contexto clínico. E o PSNR foi utilizado como métrica complementar para avaliar a fidelidade radiométrica das reconstruções, especialmente importante em tomografias computadorizadas onde a precisão dos valores de HU é essencial para diagnóstico e planejamento clínico.

A validação interna foi conduzida nos conjuntos de validação e teste, avaliando consistência, estabilidade e capacidade de generalização intra-*dataset*.

Após a seleção do melhor checkpoint de cada uma das seis corridas na validação, os checkpoints foram comparados na partição de teste interna para selecionar a candidata à avaliação externa. A decisão privilegiou a maior melhoria de SSIM global e na Zona de Artefacto, seguido de melhor PSNR e MAE global e na Zona de Artefacto como forma de desempate. Após essa comparação, a corrida selecionada foi congelada, sem novo treino, ajuste de hiperparâmetros ou alteração dos pesos antes da avaliação externa.

4.5.1 Métricas globais

Para a avaliação global, as imagens preditas e de referência são desnormalizadas para a janela $[-1000, 400]$ HU, correspondendo a uma amplitude $MAX = 1400$ HU. Adicionalmente, a região de avaliação é recortada ao menor retângulo envolvente (*bounding box*) da máscara corporal antes da avaliação de SSIM, eliminando janelas de varredura compostas exclusivamente por fundo — que pontuariam $SSIM = 1,0$ artificialmente e inflariam a métrica global.

4.5.2 Avaliação por regiões de interesse

A avaliação global não distingue o comportamento do modelo nas regiões diretamente afetadas pelos artefatos daquele nas regiões corporais distantes do implante. Por isso, cada fatia foi dividida em duas zonas complementares a partir da diferença entre a entrada com artefatos

e a referência limpa. Sejam I_{in} a imagem de entrada, I_{ref} a referência limpa e M_{body} a máscara corporal. Calculou-se a diferença assinada $d = I_{\text{ref}} - I_{\text{in}}$ e removeu-se o seu valor mediano no corpo, $b = \text{mediana}(d \mid M_{\text{body}})$, evitando que um desvio global associado ao endurecimento de feixe fosse interpretado como artefato local.

A Zona de Artefato ($\mathcal{R}_{\text{art}}$) foi definida por

$$M_{\text{art}} = [|d - b| > \tau] \cap M_{\text{body}}, \quad \tau = 0,03,$$

valor equivalente a aproximadamente 42 HU na escala normalizada utilizada. Componentes conectados com menos de 20 pixels foram removidos. Não foi aplicada dilatação morfológica adicional ($r = 0$), preservando a geometria observada dos *streaks*. A Zona Distante ($\mathcal{R}_{\text{dist}}$) foi definida como o complemento da zona de artefato na região corporal,

$$M_{\text{dist}} = M_{\text{body}} \setminus M_{\text{art}}.$$

Esta zona quantifica alterações fora da região diretamente afetada; a interpretação clínica da preservação anatômica foi reservada à avaliação externa por leitores.

A [Figure 4.3](#) ilustra a aplicação das duas zonas em fatias representativas do conjunto de dados, cobrindo diferentes regiões anatômicas e padrões de artefato.




Fig.4.3 Exemplos de zonas de ROI em fatias de CT com artefatos metálicos. Em cada par, a imagem da esquerda mostra a Zona de Artefato ($\mathcal{R}_{art}$, sobreposição a vermelho) e a da direita a Zona Distante ($\mathcal{R}_{dist}$, sobreposição a verde). As fatias cobrem anatomias torácica (topo), abdominal (meio) e torácica com implante unilateral (base), ilustrando a variabilidade da extensão e forma da zona de artefato em função da localização e número de implantes metálicos.

Em todos os contextos de avaliação, as métricas foram expressas como variações relativamente ao desempenho da entrada corrompida. Seja Ω o domínio de avaliação, que pode corresponder à região global definida acima (Ω_{global}), à Zona de Artefato ($\mathcal{R}_{\text{art}}$) ou à Zona Distante ($\mathcal{R}_{\text{dist}}$), e seja $\hat{I}$ a reconstrução produzida pelo modelo. As variações foram definidas por:

$$\Delta\text{PSNR}_{\Omega} = \text{PSNR}(\hat{I} \mid_{\Omega}, I_{\text{ref}} \mid_{\Omega}) - \text{PSNR}(I_{\text{in}} \mid_{\Omega}, I_{\text{ref}} \mid_{\Omega})$$

$$\Delta\text{SSIM}_{\Omega} = \text{SSIM}(\hat{I} \mid_{\Omega}, I_{\text{ref}} \mid_{\Omega}) - \text{SSIM}(I_{\text{in}} \mid_{\Omega}, I_{\text{ref}} \mid_{\Omega})$$

$$\Delta\text{MAE}_{\Omega} = \text{MAE}(I_{\text{in}} \mid_{\Omega}, I_{\text{ref}} \mid_{\Omega}) - \text{MAE}(\hat{I} \mid_{\Omega}, I_{\text{ref}} \mid_{\Omega}).$$

Assim, $\Delta\text{PSNR} > 0$ e $\Delta\text{SSIM} > 0$ indicam melhoria face à entrada corrompida. Como menor **MAE** representa melhor fidelidade, a ordem da subtração foi invertida para essa métrica: $\Delta\text{MAE} > 0$ indica redução do erro e, portanto, melhoria; $\Delta\text{MAE} < 0$ indica aumento do erro. Utilizou-se **SSIM** regular, calculado com janela local de 11×11 pixels e recorte com contexto em redor da região avaliada.

Tabela 4.8 Métricas utilizadas por contexto de avaliação.

Métrica	Treino	Global	ROI Artefato	ROI Distante
PSNR	✓	✓	✓	✓
SSIM	✓	✓	✓	✓
MAE	✓	✓	✓	✓

4.5.3 Análise estatística

[A preencher: paciente como unidade independente, Wilcoxon bilateral, intervalos bootstrap e correção de Holm.]

4.6 Avaliação externa por médicos

A validação externa foi realizada em dados independentes provenientes do [The Cancer Imaging Archive \(TCIA\)](#), permitindo avaliar o impacto de *domain shift* e a robustez do modelo em cenários não vistos durante o treino.

4.6.1 Desenho e casos

[A preencher: estudo observacional, transversal, multileitor e cego quanto à condição A/B; conjunto TCIA, 2 casos de treino excluídos da análise, 15 casos principais e 2 repetições ocultas.]

4.6.2 Participantes e proteção de dados

[A preencher: recrutamento direto, autodeclaração de uso mensal de CT, categorias profissionais retidas e ausência de identificadores diretos.]

4.6.3 Apresentação e instrumento de avaliação

[A preencher: apresentação simultânea e contrabalanceada de entrada/saída como Imagem A/B; escalas ordinais para interferência do artefacto e visualização anatômica, preferência pareada e sinalização de possível dano.]

4.6.4 Desfechos e análise

[A preencher: desfecho primário de diferença pareada na visualização de tecidos e limites anatômicos; desfechos secundários, consistência intraleitor e análise ordinal compatível com amostra pequena.]

4.6.5 Estado operacional

[A preencher: distinguir claramente pré-produção, piloto e recolha concluída; não apresentar resultados clínicos antes da recolha aprovada e concluída.]

Capítulo 5

Resultados

5.1 Coorte final e integridade experimental

[A preencher: pares incluídos, pacientes, distribuição anatômica, partições e resultados das verificações de integridade.]

5.1.1 Resultados da Aprovação Automática x Inspeção Manual

É importante deixar claro como ficou a distribuição dos dados que foram aprovados e reprovados automaticamente, e também quais foram avaliados manualmente. O gráfico abaixo, mapeia todos os pares do [CT-MAR](#) Dataset, destacando os que foram aprovados automaticamente, os que foram reprovados e os que foram sujeitos a inspeção visual humana. A distribuição anatômica dos pares é representada por cores, permitindo uma análise visual da relação entre a aprovação automática e a localização anatômica dos artefatos metálicos.

5.1.2 Análise Complementar com [MS-SSIM](#)

Antes de avançar para a análise dos resultados dos modelos de redução de artefatos, foi realizada mais uma avaliação dos resultados [CT-MAR](#) x DeepLesion/Stroke EIT para verificar a qualidade das correspondências automáticas. Esta etapa é crucial para garantir uma camada extra de confiança nos resultados obtidos pelo algoritmo de comparação de similaridade estrutural. Todos os pares que tiveram a correspondência aprovada automaticamente pelo fato de seu score ser acima de 0.994 foram revisados por um novo algoritmo que calcula o [MS-SSIM](#) entre as imagens correspondentes. Um histograma da distribuição dos [MS-SSIM](#) foi gerado, e os pares com pontuação menor que 0.9 foram revisados manualmente sendo aprovado ou recusado com base em avaliação humana.




Fig.5.1 Distribuição de MS-SSIM entre pares correspondentes (CT-MAR vs DL/Stroke, aprovados automaticamente). Acima: histograma com os percentis P1 e P5, mediana, média e limiar de 0.9. Abaixo: zoom do histograma para a região de maior interesse, com destaque para os pares com MS-SSIM inferior a 0.9, que foram sujeitos a revisão manual.

A análise da distribuição entre os pares correspondentes revela que a maioria dos pares apresenta alta similaridade estrutural, com um valor médio de 0.9694 e uma mediana de 0.9830, indicando que o processo de correspondência automática é, em geral, confiável e eficaz na identificação de pares correspondentes entre os datasets CT-MAR e DeepLesion/Stroke

EIT.

Os pares com pontuação de **MS-SSIM** abaixo de 0.9 eram 340 no total, apenas 3 foram reprovados após inspeção visual humana 5.2. Nessa inspeção, percebe-se que mesmo os casos com pontuações bastante baixas de **MS-SSIM** não eram falsos positivos e sim devido a diferenças no pós-processamento ou tratamento geral das imagens que geram alterações locais no qual o **MS-SSIM** é mais sensível. Isso pode ser visualizado na figura 5.3. Esse fato evidencia a eficácia da estratégia de correspondência por similaridade estrutural global adotada, que conseguiu identificar os pares com precisão, com apenas 3 falsos positivos identificados, mesmo após análise rigorosa 5.4. Mostrando que a metodologia é robusta e teve desempenho superior em detectar slices nesse trabalho do que uso do próprio **MS-SSIM**. Pois, enquanto as diferenças locais afetaram o **MS-SSIM** de forma mais significativa, a metodologia baseada em similaridade de cosseno conseguiu identificar as correspondências corretas com pontuação global elevada, mesmo em casos de diferenças locais acentuadas.




Fig.5.2 Distribuição de MS-SSIM entre pares correspondentes (**CT-MAR** vs DL/Stroke, aprovados automaticamente). À esquerda: histograma com os percentis P1 e P5, mediana, média e limiar de 0.9. À direita: ECDF correspondente. Os pares com MS-SSIM inferior a 0.9 foram sujeitos a revisão manual.




Fig.5.3 Exemplos de pares correspondentes com valores de **MS-SSIM** (0.7597, 0.7694 e 0.7717, respetivamente) aprovados após revisão visual humana mesmo com pontuações baixas.

Os pares reprovados apresentavam **MS-SSIM** claramente fora do padrão (< 0.61), com valores extremamente baixos, como podem ver na figura 5.4. Além disso, representaram os pares com pontuação mais próximas do limiar de aceitação automática de 0.994 5.5. Demonstrando que os casos em que o método falha são outliers claros em **MS-SSIM** e permanecem justamente na zona cinzenta e propensa a erros da determinação empírica do limiar de aceitação automática. Além disso, os pares reprovados possuem características visuais bastante

particulares com fundo dominando a imagem e poucas estruturas anatômicas visíveis, o que torna a avaliação de similaridade estrutural mais desafiadora devido a grande homogeneidade das características visuais.




Fig.5.4 3 pares reprovados após inspeção visual humana com valores de **MS-SSIM** (head_1159: 0.4573, head_369: 0.5652 e head_763: 0.6009, respectivamente). As pontuações desses pares na similaridade de cosseno foram head_1159: 0.9960, head_369: 0.9952 e head_763: 0.9951.




Fig.5.5 Distribuição dos valores de similaridade de cosseno para os pares inspecionados visualmente.

Os pares com **MS-SSIM** mais críticos logo acima dos reprovados tinham valores maiores que 0.75 5.3, demonstrando uma distancia clara entre os falsos positivos e os aprovados visualmente. Todos os pares inspecionados com pontuação acima desse valor de **MS-SSIM** passaram no teste de inspeção visual 5.6. Como os pares que não passaram por esse escrutínio tinham pontuação acima de 0.90 em **MS-SSIM**, é seguro assumir que os pares automaticamente aprovados com pontuação acima desse limiar são confiáveis.




Fig.5.6 Distribuição dos valores de **MS-SSIM** para os pares inspecionados visualmente.

Na busca direta, 530 pares não obtiveram correspondência aprovada em nenhum dos dois datasets de origem. A etapa complementar de correspondência indireta recuperou 95 desses casos após inspeção visual, restando 435 pares sem correspondência segura.

Com relação aos possíveis falsos negativos que poderiam ter resultado em exclusão de pares de forma injusta nesse estudo, a metodologia adotada foi ainda mais robusta. Já que eram poucos os pares que não tiveram aprovação em nenhum dos dois datasets de origem, ficou fácil verificar visualmente cada um desses casos para confirmar se realmente não havia correspondência ou se o método falhou em identificá-la. Dos 435 pares excluídos 245 foram excluídos devido ao critério automatizado baseado no limiar de 0.98. Nenhum desses casos eram realmente falsos negativos, confirmando mais uma vez a eficácia do método de correspondência automática adotado. Os outros 190 pares caíram na faixa de pontuação pouco confiável (0.98 – 0.994) e foram marcados como falsa correspondência nessa etapa evidenciando a importância de ter-se determinado uma zona cinzenta de pontuação para a qual o método de correspondência automática não é eficiente, e que a revisão visual humana torna-se indispensável [5.7](#).




Fig.5.7 Distribuição dos *scores* de similaridade de cosseno (DL vs Stroke EIT) para os pares sem correspondência aprovada em nenhum dos dois *datasets* de origem (N=435). Histograma laranja mostra a distribuição das pontuações dos 435 pares reprovados no Stroke EIT Dataset. O histograma em azul, mostra a distribuição dos mesmos 435 pares reprovados no Deep Lesion Dataset.

5.2 Treino dos modelos

5.2.1 Convergência e seleção dos checkpoints

A seleção do *checkpoint* para avaliação final foi baseada na melhor versão do **SSIM** calculado na partição de validação. Obviamente, no modelo Dual, esse critério foi aplicado na saída de reconstrução. Apenas o melhor checkpoint por corrida foi preservado, em formato .keras, com nome que contém arquitetura, época e métrica monitorizada. O CSV de treino marca explicitamente a linha correspondente com `best_checkpoint=1`.

A regra de paragem definia um máximo de épocas de 300 e um mínimo de 5, com *Early Stopping* após 15 épocas sem melhoria mínima de 0.0001 no **SSIM** da partição de validação. Consequentemente, devido à restauração dos pesos da melhor época, a época final de treino não é necessariamente a selecionada.

O otimizador monitoriza a mesma métrica, reduzindo o *learning rate* em 0.5 após 2 épocas sem melhoria relevante (`ReduceLROnPlateau`), até 1×10^{-6} com uma época de *cooldown*. O mesmo valor de variação mínima de 0.0001 foi usado no *Scheduler* e no *Early Stopping*.




Fig.5.8 Curvas de convergência para `seed_1337/training_001_dualhead`. Linhas verticais laranja pontilhadas: reduções da taxa de aprendizagem; linha roxa tracejada: época do melhor checkpoint segundo o SSIM de validação; linha preta traço-ponto: interrupção do treino. O painel de *generalization gap* representa validação menos treino para o SSIM e permite identificar divergência persistente compatível com sobreajuste.




Fig.5.9 Curvas de convergência para `seed_1337/training_008_singlehead`. Linhas verticais laranjas pontilhadas: reduções da taxa de aprendizagem; linha roxa tracejada: época do melhor checkpoint segundo o SSIM de validação; linha preta traço-ponto: interrupção do treino. O painel de *generalization gap* representa validação menos treino para o SSIM e permite identificar divergência persistente compatível com sobreajuste.




Fig.5.10 Curvas de convergência para `seed_2024/training_001_dualhead`. Linhas verticais laranjas pontilhadas: reduções da taxa de aprendizagem; linha roxa tracejada: época do melhor checkpoint segundo o SSIM de validação; linha preta traço-ponto: interrupção do treino. O painel de *generalization gap* representa validação menos treino para o SSIM e permite identificar divergência persistente compatível com sobreajuste.




Fig.5.11 Curvas de convergência para `seed_2024/training_001_singlehead`. Linhas verticais laranjas pontilhadas: reduções da taxa de aprendizagem; linha roxa tracejada: época do melhor checkpoint segundo o SSIM de validação; linha preta traço-ponto: interrupção do treino. O painel de *generalization gap* representa validação menos treino para o SSIM e permite identificar divergência persistente compatível com sobreajuste.




Fig.5.12 Curvas de convergência para `seed_42/training_001_dualhead`. Linhas verticais laranjas pontilhadas: reduções da taxa de aprendizagem; linha roxa tracejada: época do melhor checkpoint segundo o SSIM de validação; linha preta traço-ponto: interrupção do treino. O painel de *generalization gap* representa validação menos treino para o SSIM e permite identificar divergência persistente compatível com sobreajuste.




Fig.5.13 Curvas de convergência para `seed_42/training_001_singlehead`. Linhas verticais laranja pontilhadas: reduções da taxa de aprendizagem; linha roxa tracejada: época do melhor checkpoint segundo o SSIM de validação; linha preta traço-ponto: interrupção do treino. O painel de *generalization gap* representa validação menos treino para o SSIM e permite identificar divergência persistente compatível com sobreajuste.

Nas 6 corridas, todas terminaram entre 38 e 47 épocas, após a taxa de aprendizagem atingir o limite mínimo. Os melhores **SSIMs** de validação ocorreram nas épocas 23–44, antes da paragem, o que sustenta o uso de restauração dos melhores pesos.

O maior valor de **SSIM** foi 0.95113 do Single Model, seed 2024, na época 33. O valor de **PSNR** variou entre ~ 35.0 dB - 35.3 dB, com o maior valor de 35.3009 dB do Single Model, seed 2024, na mesma época 33. Os resultados detalhados podem ser visualizados nas Tabelas 5.1, 5.2 e 5.3.

Seed	Best SSIM (HU)		
	42	1337	2024
Single Model	0.95096 (31)*	0.95106 (44)	0.95113 (33)
Dual Model	0.94938 (41)	0.94895 (28)	0.95025 (23)

*Valores entre parênteses indicam a época correspondente.

Tabela 5.1 Maior SSIM de validação por modelo e seed, com a época correspondente. No Dual Model, o SSIM é calculado na saída de reconstrução de imagem.

Seed	PSNR (dB) - Same Best SSIM Epoch		
	42	1337	2024
Single Model	35.16365 (31)	35.20020 (44)	35.30099 (33)
Dual Model	35.10422 (41)	35.00705 (28)	35.23622 (23)

Tabela 5.2 PSNR de validação na época selecionada pelo melhor SSIM de validação, por modelo e seed. No Dual Model, ambas as métricas são calculadas na saída de reconstrução de imagem.

Seed	MAE (HU) - Same Best SSIM Epoch		
	42	1337	2024
Single Model	17.52002 (31)	17.36296 (44)	17.19180 (33)
Dual Model	17.58006 (41)	17.73584 (28)	17.35387 (23)

Tabela 5.3 MAE de validação na época selecionada pelo melhor SSIM de validação, por modelo e seed. No Dual Model, ambas as métricas são calculadas na saída de reconstrução de imagem.

O melhor resultado de **MAE** foi 17.1918 HU também do Single Model, seed 2024, na época 33. Podemos notar que o Single Model teve desempenho superior nas 3 métricas.

O **PSNR** e **MAE** são apenas métricas complementares, mas não são o foco principal de seleção do melhor checkpoint que considera apenas o **SSIM** isoladamente. Além disso, as métricas separadas por **ROI**, análises visuais, e métricas de teste interno são avaliações feitas após a seleção do melhor checkpoint e portanto não alteram o checkpoint escolhido.

A escolha da corrida que avançará para a avaliação externa é uma decisão distinta da seleção do checkpoint. Entre os checkpoints já selecionados, a comparação é efetuada na partição de teste, buscando equilíbrio entre a maior melhoria de **SSIM** na Zona de Artefacto e menor mudança de **SSIM** na Zona Distante. Após essa seleção não houve novo treino, ajuste de hiperparâmetros ou alterações nos pesos antes da avaliação externa.

5.2.2 Rastreabilidade das execuções

A rastreabilidade das execuções foi assegurada através de *snapshots* de reprodutibilidade em formato JSON, preservados em `outputs/reproducibility/`. Foram congeladas seis avaliações internas finais, correspondentes às três inicializações aleatórias (seeds 42, 1337 e 2024) dos modelos Single Model e Dual Model. Todos os snapshots foram gerados a partir do commit `a950be7276a5585de45e8ae874c59c065a1985be`, no ramo `projeto_final`, com árvore de trabalho limpa (`is_dirty: false`).

Cada snapshot registra o sistema operativo, a versão do Python e as versões das dependências relevantes. O ambiente de execução utilizou Python 3.11.9 em Windows 10, incluindo TensorFlow 2.15.0, NumPy 1.26.4, Pandas 2.2.2, scikit-image 0.21.0 e Matplotlib 3.7.5. Além disso, foram calculados hashes SHA-256 dos ficheiros de configuração, do manifesto canónico de pares, da definição da partição por paciente, dos metadados de geração dos tensores e do ficheiro de requisitos do ambiente.

Para cada execução, o snapshot preserva o caminho, tamanho e hash SHA-256 do checkpoint, o comando completo usado na avaliação no conjunto de teste e os hashes dos ficheiros de saída, incluindo as métricas agregadas e as métricas por amostra. Assim, cada valor, tabela ou figura reportado pode ser associado de forma inequívoca ao código, ambiente, dados de entrada, checkpoint e resultados que o originaram.

A seleção dos checkpoints foi efetuada exclusivamente com base na métrica de validação pré-especificada: `val_ssim_hu` no Single Model e `val_img_out_ssim_hu` na saída de reconstrução do Dual Model.

5.3 Avaliação interna no conjunto de teste

5.3.1 Desfechos globais

A avaliação interna foi realizada na partição de teste fixa, composta por 1478 fatias de 41 pacientes independentes. Para cada checkpoint previamente selecionado na validação, foram calculados PSNR, SSIM e MAE entre a reconstrução e a referência limpa. A unidade de agregação para a inferência estatística foi o paciente: as métricas foram primeiro resumidas dentro de cada paciente e os intervalos de confiança de 95% foram obtidos por *bootstrap* percentil com 10000 reamostragens. O conjunto de teste não foi utilizado para escolher checkpoints.

A [Table 5.5](#), a [Table 5.4](#) e a [Table 5.6](#) apresentam as médias por fatia. Como todas as corridas foram avaliadas na mesma partição de teste, o valor da entrada é comum aos dois

modelos em cada seed. Em todas as corridas, a reconstrução aumentou o PSNR global de 27,39 dB para 34,95–35,20 dB, aumentou o SSIM de 0,8361 para 0,9421–0,9442 e reduziu o MAE de 36,6 HU para 17,3–17,8 HU.

SSIM global

Seed	Input	Single Model	Dual Model
42	0.8361 $\pm$ 0.0880	0.9439 $\pm$ 0.0289	0.9424 $\pm$ 0.0292
1337	0.8361 $\pm$ 0.0880	0.9441 $\pm$ 0.0286	0.9421 $\pm$ 0.0289
2024	0.8361 $\pm$ 0.0880	0.9442 $\pm$ 0.0288	0.9432 $\pm$ 0.0292

Tabela 5.4 SSIM global por fatia no conjunto de teste ($n = 1478$), expresso como média $\pm$ desvio padrão.

PSNR global (dB)

Seed	Input	Single Model	Dual Model
42	27.39 $\pm$ 4.14	35.09 $\pm$ 2.82	35.06 $\pm$ 2.84
1337	27.39 $\pm$ 4.14	35.13 $\pm$ 2.81	34.95 $\pm$ 2.82
2024	27.39 $\pm$ 4.14	35.20 $\pm$ 2.84	35.16 $\pm$ 2.82

Tabela 5.5 PSNR global por fatia no conjunto de teste ($n = 1478$), expresso como média $\pm$ desvio padrão.

MAE global (HU)

Seed	Input	Single Model	Dual Model
42	36.569 $\pm$ 21.906	17.649 $\pm$ 5.689	17.654 $\pm$ 5.905
1337	36.569 $\pm$ 21.906	17.485 $\pm$ 5.624	17.842 $\pm$ 5.789
2024	36.569 $\pm$ 21.906	17.341 $\pm$ 5.573	17.475 $\pm$ 5.563

Tabela 5.6 MAE global por fatia no conjunto de teste ($n = 1478$), expresso como média $\pm$ desvio padrão.

Os deltas e respetivos intervalos de confiança por paciente são apresentados na Table 5.8, na Table 5.7 e na Table 5.9. Todas as corridas melhoraram as três métricas; os testes de Wilcoxon bilaterais foram significativos para os três desfechos em todas as corridas ($p < 0,001$). Os intervalos de confiança não incluem o valor nulo, sustentando a melhoria global face à entrada com artefactos.

 Δ SSIM Global (IC 95%)

Seed	Single Model	Dual Model
42	0.0887 [0.0728; 0.1063]	0.0870 [0.0713; 0.1043]
1337	0.0891 [0.0734; 0.1065]	0.0867 [0.0710; 0.1041]
2024	0.0891 [0.0732; 0.1066]	0.0879 [0.0719; 0.1053]

Tabela 5.7 Δ SSIM global agregado por paciente no conjunto de teste ($n = 41$). IC: intervalo de confiança de 95%. Δ PSNR Global (dB, IC 95%)

Seed	Single Model	Dual Model
42	6.96 [6.22; 7.68]	6.96 [6.24; 7.65]
1337	7.05 [6.33; 7.75]	6.85 [6.12; 7.55]
2024	7.11 [6.36; 7.83]	7.06 [6.31; 7.78]


Tabela 5.8 Δ PSNR global agregado por paciente no conjunto de teste ($n = 41$). IC: intervalo de confiança de 95%.

Δ MAE Global (HU, IC 95%)

Seed	Single Model	Dual Model
42	15.3 [12.2; 19.0]	15.3 [12.3; 18.9]
1337	15.6 [12.4; 19.3]	15.2 [12.1; 18.8]
2024	15.7 [12.5; 19.5]	15.5 [12.4; 19.3]

Tabela 5.9 Δ MAE global agregado por paciente no conjunto de teste ($n = 41$). Valores > 0 representam melhoria; IC: intervalo de confiança de 95%.

Nota-se que o Single Model para as sementes 1337 e 2024 apresentam praticamente o mesmo desempenho em SSIM. No entanto, em PSNR e MAE o mesmo modelo se sai melhor com a seed 2024. Isso já coloca a versão Single com semente 2024 em evidência para ser o candidato selecionado para a avaliação externa. Porém, ainda é necessário verificar o desempenho por ROI, já que essas métricas são muito mais informativas a respeito de onde o modelo está realmente melhorando a imagem. As distribuições por fatia da corrida Single Model com seed 2024 são ilustradas na Figure 5.14.

Single Model — Global Metrics




Fig.5.14 Distribuições por fatia do **SSIM** e do **PSNR** globais para o Single Model, seed 2024.

5.3.2 Avaliação por regiões de interesse

As regiões de interesse e o cálculo das métricas por zona seguiram o procedimento descrito na [subsection 4.5.2](#). Esta estratificação permite quantificar separadamente a correção na região diretamente afetada pelos artefactos e as alterações introduzidas nas regiões corporais distantes do implante.

Os resultados finais, agregados primeiro por paciente e depois resumidos em 41 pacientes independentes, são apresentados nas [Table 5.11](#), [Table 5.10](#) e [Table 5.12](#). Todas as seis corridas apresentaram melhoria substancial na Zona de Artefacto: Δ PSNR entre 11,47 e 11,86 dB, Δ SSIM entre 0,322 e 0,328 e redução de **MAE** entre 96,9 e 98,5 HU. Na Zona Distante, as alterações médias foram menores (Δ PSNR entre 1,36 e 1,61 dB; Δ SSIM entre 0,057 e 0,058; redução de **MAE** entre 3,2 e 3,6 HU), devendo ser interpretadas como descrição quantitativa e não como validação clínica de preservação anatômica.

Novamente, o Single Model com sementes 1337 e 2024 apresentam desempenhos muito semelhantes em **SSIM**, com a semente 2024 levando uma minúscula vantagem. Já na análise por **ROI**, o melhor desempenho em **PSNR** e **MAE** com a semente 2024 fica menos evidente

Δ SSIM

Seed	Model	Artifact ROI	Clean ROI
42	Single Model	0.3276 ± 0.0954	0.0579 ± 0.0426
	Dual Model	0.3233 ± 0.0937	0.0568 ± 0.0421
1337	Single Model	0.3278 ± 0.0933	0.0582 ± 0.0421
	Dual Model	0.3224 ± 0.0953	0.0566 ± 0.0422
2024	Single Model	0.3279 ± 0.0955	0.0581 ± 0.0422
	Dual Model	0.3266 ± 0.0954	0.0576 ± 0.0422

Tabela 5.10 Δ SSIM por ROI no conjunto de teste. Os valores são média $\pm$ desvio-padrão entre pacientes ($n = 41$). Δ PSNR (dB)

Seed	Model	Artifact ROI	Clean ROI
42	Single Model	11.75 ± 2.59	1.46 ± 1.43
	Dual Model	11.65 ± 2.53	1.48 ± 1.43
1337	Single Model	11.84 ± 2.54	1.53 ± 1.35
	Dual Model	11.47 ± 2.57	1.36 ± 1.52
2024	Single Model	11.86 ± 2.69	1.61 ± 1.41
	Dual Model	11.84 ± 2.62	1.53 ± 1.48



Tabela 5.11 Δ PSNR por ROI no conjunto de teste. Os valores são média $\pm$ desvio-padrão entre pacientes ($n = 41$). Δ MAE (HU)

Seed	Model	Artifact ROI	Clean ROI
42	Single Model	97.8 ± 19.6	3.3 ± 3.2
	Dual Model	97.5 ± 19.1	3.4 ± 3.1
1337	Single Model	98.5 ± 19.6	3.5 ± 3.1
	Dual Model	96.9 ± 19.9	3.2 ± 3.3
2024	Single Model	98.4 ± 20.2	3.6 ± 3.1
	Dual Model	98.3 ± 19.8	3.5 ± 3.3

Tabela 5.12 Redução de MAE por ROI no conjunto de teste. Os valores são média $\pm$ desvio-padrão entre pacientes ($n = 41$); valores positivos correspondem a redução do erro.

do que na análise global, especialmente quando considera-se as alterações na Zona Limpa. Mesmo assim, as alterações na Zona Limpa são pequenas e varia pouco entre os modelos e sementes. Dessa forma, foi decidido priorizar o desempenho da semente na análise Global e por ROI (mesmo que muito pequena) para selecionar o modelo que seguirá para a avaliação externa. A escolha final recaiu sobre o Single Model, seed 2024, que apresentou o melhor desempenho global e por ROI. As [Figure 5.15](#) e [Figure 5.16](#) mostram a distribuição por imagem para a corrida selecionada. Por simplicidade, os gráficos de agora em diante são apresentados apenas para o modelo selecionado, mas os dados de todas as corridas estão disponíveis no apêndice ??.

Os diagramas de caixa evidenciam a separação entre a correção na Zona de Artefacto e a alteração menor na Zona Limpa. O diagrama de dispersão permite identificar heterogeneidade entre fatias, incluindo casos individuais com alterações desfavoráveis na Zona Limpa.







Fig.5.15 Distribuições por imagem das variações de SSIM, PSNR e MAE nas zonas de artefacto e limpa para o Single Model, seed 2024.






Fig.5.16 Relação por imagem entre a melhoria de $\Delta SSIM \setminus \Delta PSNR$ na Zona de Artefacto e a alteração de $\Delta SSIM \setminus \Delta PSNR$ na Zona Limpa para o Single Model, seed 2024. A cor codifica a redução de ΔMAE na Zona Limpa.

5.4 Comparação pareada Single x Dual Model

Reconstruction Quality				
Model	$\Delta SSIM$	p_{SSIM} (Holm)	$\Delta PSNR$ (dB)	p_{PSNR} (Holm)
Dual Model	0.1071 ± 0.0897	5.46×10^{-12}	7.77 ± 3.56	5.46×10^{-12}
Single Model	0.1081 ± 0.0897	5.46×10^{-12}	7.82 ± 3.58	3.64×10^{-12}

Holm-adjusted two-sided Wilcoxon p -values for improvement over the corrupted input.

Tabela 5.13 Improvement over the corrupted input on the test set.

Structural Preservation		
Model	EPI	Texture
Dual Model	0.960 ± 0.023	0.942 ± 0.039
Single Model	0.947 ± 0.024	0.931 ± 0.031

EPI: *Edge Preservation Index* (1.0 = perfect; > 0.9 = good). Texture: *Texture Preservation Score* (1.0 = perfect; 0.9–1.1 = good).

Tabela 5.14 Structural preservation metrics on the test set.

Dual Model – Single Model			
Metric	Mean Difference	95% CI	p (Holm)
PSNR (dB)	-0.054	$[-0.099; -0.012]$	1.09×10^{-2}
SSIM	-0.0012	$[-0.0015; -0.0009]$	7.82×10^{-11}

Tabela 5.15 Patient-level paired comparison between architectures ($n = 41$). Negative differences favor the Single Model.





Fig.5.17 Model comparison: comparison_bar_charts.pdf.







Fig.5.18 Global trade-offs between mean structural improvement (Δ SSIM) and preservation: texture preservation score (top) and edge preservation index (bottom), for the Single and Dual Models selected with seed 2024 on the test set.






Fig.5.19 Artifact ROI trade-offs between mean structural improvement (Δ SSIM) and preservation: edge preservation index (top) and texture preservation score (bottom), for the Single and Dual Models selected with seed 2024 on the test set.

5.5 Desempenho computacional

[A preencher: benchmark de inferência, se reportado.]




Fig.5.20 Benchmark de inferencia: benchmark_latency.png.

5.6 Avaliação externa por médicos

5.6.1 Estado da recolha e participantes

[A preencher: estado de pré-produção, piloto ou recolha concluída; número de leitores analisados e características categóricas, apenas quando existirem dados reais.]

5.6.2 Desfecho primário: visualização anatómica

[A preencher: comparação pareada entre entrada e saída para visualização de tecidos e limites anatómicos.]

5.6.3 Desfechos secundários e segurança percebida

[A preencher: interferência do artefacto, preferência A/B, possível dano, utilidade complementar e consistência intraleitor.]

5.6.4 Interpretação limitada ao desenho observacional

[A preencher: reportar intervalos de confiança e limitações; não inferir benefício clínico para além das avaliações realizadas.]

Capítulo 6

Discussão

6.1 Síntese dos achados principais

[A preencher: resposta direta aos objetivos e hipótese primária.]

6.2 Interpretação da comparação arquitetural

[A preencher: significado prático e estatístico da comparação single-head versus dual-head.]

6.3 Preservação anatômica e segurança da reconstrução

[A preencher: leitura conjunta de métricas globais, regiões de interesse e inspeção qualitativa.]

6.4 Generalização e avaliação externa

[A preencher: interpretar apenas as evidências externas disponíveis e delimitar o que permanece por validar.]

6.5 Avaliação por médicos

[A preencher: interpretar a avaliação multileitor cega em conjunto com os resultados técnicos; distinguir melhoria percebida, segurança percebida e eficácia clínica.]

6.6 Limitações

[A preencher: dados simulados/pareados, desequilíbrio anatômico, dimensão ao nível do paciente, desenho observacional e limites da avaliação externa.]

6.7 Implicações e trabalho futuro

[A preencher: validação prospetiva, dados clínicos adicionais e evolução do protocolo de observadores.]

Capítulo 7

Conclusões

7.1 Conclusões do estudo

[A preencher: conclusão proporcional às evidências finais e aos resultados confirmatórios.]

7.2 Contribuições da dissertação

- *[A preencher: curadoria rastreável e partição por paciente.]*
- *[A preencher: comparação controlada entre duas arquiteturas U-Net.]*
- *[A preencher: avaliação por paciente e produção reprodutível de resultados.]*
- *[A preencher: protocolo de avaliação externa por médicos e respetivo estado de execução.]*

7.3 Perspetivas futuras

[A preencher: validação externa concluída, extensão multicêntrica e avaliação clínica prospectiva.]

Bibliografia

- [1] November 8, 1895: Roentgen's Discovery of X-Rays. <https://www.aps.org/apsnews/2001/11/1895-roentgens-discovery-xrays>. [Cited on page 1.]
- [2] Emico Okuno and Elisabeth Yoshimura. *Física das Radiações*. Oficina de Textos, 2010. [Cited on page 1.]
- [3] JOEL D. HOWELL. EARLY CLINICAL USE OF THE X-RAY. *Transactions of the American Clinical and Climatological Association*, 127:341–349, 2016. [Cited on page 1.]
- [4] Allen Taylor. Illuminating Health: The Evolution and Significance of X-ray Imaging. *Imaging in Medicine*, 15(6):133–134, December 2023. [Cited on page 1.]
- [5] Reza Vali. Unveiling the Marvels of Computed Tomography (CT) Imaging. *Imaging in Medicine*, 16(1):150–151, February 2024. [Cited on page 2.]
- [6] Mohd Noor. An Overview of Computed Tomography: What it is and How it Works? Applications of Computed Tomography. *Imaging in Medicine*, 15(5):93–94, October 2023. [Cited on page 2.]
- [7] Raymond A. Schulz, Jay A. Stein, and Norbert J. Pelc. How CT happened: The early development of medical computed tomography. *Journal of Medical Imaging*, 8(5):052110, September 2021. [Cited on page 2.]
- [8] F. Edward Boas and Dominik Fleischmann. CT artifacts: Causes and reduction techniques. *Imaging in Medicine*, 4(2):229–240, April 2012. [Cited on page 2.]
- [9] Cecile E.J. Kleber, Ramez Karius, Lucas E. Naessens, Coen O. Van Toledo, Jochen A. C. Van Osch, Martijn F. Boomsma, Jan W.T. Heemskerk, and Aart J. Van Der Molen. Advancements in supervised deep learning for metal artifact reduction in computed tomography: A systematic review. *European Journal of Radiology*, 181:111732, December 2024. [Cited on pages 2, 7, 8, and 14.]

- [10] Sathyathas Puvanasunthararajah, Davide Fontanarosa, Marie-Luise Wille, and Saskia M. Camps. The application of metal artifact reduction methods on computed tomography scans for radiotherapy applications: A literature review. *Journal of Applied Clinical Medical Physics*, 22(6):198–223, May 2021. [Cited on page 2.]
- [11] Asutosh Sahu, Shobhit Mathur, Hiroyuki Takaoka, Joji Ota, Felix G. Meinel, Benjamin Böttcher, Benoît Magnin, Ankush Jajodia, and Corey T. Jensen. Transforming CT imaging with deep learning: Noise reduction, artifact management, and clinical applications – A comprehensive review. *European Journal of Radiology Artificial Intelligence*, 4:100042, December 2025. [Cited on pages 3, 7, and 8.]
- [12] Mohanad Alkhodari, Eman Alefishat, Herbert F. Jelinek, Ahmed Kaabneh, and Panos Liatsis. Enhancing CCTA image quality: A review of deep learning approaches for advanced artifact correction and denoising. *Artificial Intelligence Review*, 58(10):331, August 2025. [Cited on page 3.]
- [13] Julia F. Barrett and Nicholas Keat. Artifacts in CT: Recognition and Avoidance. *RadioGraphics*, 24(6):1679–1691, November 2004. [Cited on page 7.]
- [14] Mark Selles, Jochen A.C. Van Osch, Mario Maas, Martijn F. Boomsma, and Ruud H.H. Wellenberg. Advances in metal artifact reduction in CT images: A review of traditional and novel metal artifact reduction techniques. *European Journal of Radiology*, 170:111276, January 2024. [Cited on page 7.]
- [15] Lars Gjestebj, Qingsong Yang, Yan Xi, Bernhard E. H. Claus, Yannan Jin, Bruno De Man, Ge Wang, and Hongming Shan. Deep learning methods for CT image-domain metal artifact reduction. In Bert Müller and Ge Wang, editors, *Developments in X-Ray Tomography XI*, page 31, San Diego, United States, September 2017. SPIE. [Cited on pages 7 and 8.]
- [16] Yanbo Zhang and Hengyong Yu. Convolutional Neural Network Based Metal Artifact Reduction in X-Ray Computed Tomography. *IEEE Transactions on Medical Imaging*, 37(6):1370–1381, June 2018. [Cited on page 8.]
- [17] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-Net: Convolutional Networks for Biomedical Image Segmentation, May 2015. [Cited on pages 8 and 19.]
- [18] Esther Meyer, Frank Bergner, Rainer Raupach, Thomas Flohr, and Marc Kachelriess. Normalized metal artifact reduction (NMAR) in computed tomography. In *2009 IEEE Nuclear Science Symposium Conference Record (NSS/MIC)*, pages 3251–3255, Orlando, FL, October 2009. IEEE. [Cited on page 8.]

- [19] Wei-An Lin, Haofu Liao, Cheng Peng, Xiaohang Sun, Jingdan Zhang, Jiebo Luo, Rama Chellappa, and Shaohua Kevin Zhou. DuDoNet: Dual Domain Network for CT Metal Artifact Reduction. In *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 10504–10513, Long Beach, CA, USA, June 2019. IEEE. [Cited on pages 8 and 14.]
- [20] Lequan Yu, Zhicheng Zhang, Xiaomeng Li, Hongyi Ren, Wei Zhao, and Lei Xing. Metal Artifact Reduction in 2D CT Images with Self-supervised Cross-domain Learning. *Physics in Medicine & Biology*, 66(17):175003, September 2021. [Cited on page 8.]
- [21] Zhiwei Huang, Guo Zhang, Jinzhao Lin, Yu Pang, Huiqian Wang, Tong Bai, and Lisha Zhong. Multi-modal feature-fusion for CT metal artifact reduction using edge-enhanced generative adversarial networks. *Computer Methods and Programs in Biomedicine*, 217:106700, April 2022. [Cited on page 9.]
- [22] Xin Yi, Ekta Walia, and Paul Babyn. Generative Adversarial Network in Medical Imaging: A Review. *Medical Image Analysis*, 58:101552, December 2019. [Cited on page 9.]
- [23] Zhou Wang, A.C. Bovik, H.R. Sheikh, and E.P. Simoncelli. Image quality assessment: From error visibility to structural similarity. *IEEE Transactions on Image Processing*, 13(4):600–612, April 2004. [Cited on pages 9, 12, and 14.]
- [24] Z. Wang, E.P. Simoncelli, and A.C. Bovik. Multiscale structural similarity for image quality assessment. In *The Thrity-Seventh Asilomar Conference on Signals, Systems & Computers, 2003*, pages 1398–1402, Pacific Grove, CA, USA, 2003. IEEE. [Cited on pages 9 and 23.]
- [25] Alain Hore and Djemel Ziou. Image Quality Metrics: PSNR vs. SSIM. In *2010 20th International Conference on Pattern Recognition*, pages 2366–2369, Istanbul, Turkey, August 2010. IEEE. [Cited on page 9.]
- [26] John R. Zech, Marcus A. Badgeley, Manway Liu, Anthony B. Costa, Joseph J. Titano, and Eric Karl Oermann. Variable generalization performance of a deep learning model to detect pneumonia in chest radiographs: A cross-sectional study. *PLOS Medicine*, 15(11):e1002683, November 2018. [Cited on page 9.]
- [27] Martin J. Willemink, Wojciech A. Koszek, Cailin Hardell, Jie Wu, Dominik Fleischmann, Hugh Harvey, Les R. Folio, Ronald M. Summers, Daniel L. Rubin, and Matthew P. Lungren. Preparing Medical Imaging Data for Machine Learning. *Radiology*, 295(1):4–15, April 2020. [Cited on page 9.]

- [28] Christopher J. Kelly, Alan Karthikesalingam, Mustafa Suleyman, Greg Corrado, and Dominic King. Key challenges for delivering clinical impact with artificial intelligence. *BMC Medicine*, 17(1):195, December 2019. [Cited on page 9.]
- [29] Eri Haneda, Nils Peters, Jiayong Zhang, Grigorios Karageorgos, Wenjun Xia, Harald Paganetti, Ge Wang, Yi Guo, Jianhua Ma, Hyoung Suk Park, Kiwan Jeon, Fuxin Fan, Mareike Thies, and Bruno De Man. AAPM CT metal artifact reduction grand challenge. *Medical Physics*, 52(10):e70050, October 2025. [Cited on page 10.]
- [30] xcist. AAPM CT Metal Artifact Reduction (CT-MAR) Grand Challenge Benchmark Tool. https://github.com/xcist/example/tree/main/AAPM_datachallenge/. [Cited on page 10.]
- [31] Nils Peters, Eri Haneda, Jiayong Zhang, Grigorios Karageorgos, Wenjun Xia, Joost Verburg, Ge Wang, Harald Paganetti, and Bruno De Man. A hybrid training database and evaluation benchmark for assessing metal artifact reduction methods for X-ray CT imaging. *Medical Physics*, 52(10):e70020, October 2025. [Cited on page 10.]
- [32] Mingye Wu, Paul FitzGerald, Jiayong Zhang, W. Paul Segars, Hengyong Yu, Yongshun Xu, and Bruno De Man. XCIST – An Open Access X-ray/CT Simulation Toolkit. *Physics in medicine and biology*, 67(19):10.1088/1361-6560/ac9174, September 2022. [Cited on page 10.]
- [33] Nir Goren, James Avery, Thomas Dowrick, Eleanor Mackle, Anna Witkowska-Wrobel, David Werring, and David Holder. Multi-frequency electrical impedance tomography and neuroimaging data in stroke patients. *Scientific Data*, 5:180112, July 2018. [Cited on pages 10 and 11.]
- [34] Nir Goren, Thomas Dowrick, James Avery, and David Holder. UCLH Stroke EIT Dataset - Radiology Data, August 2017. [Cited on page 10.]
- [35] Ke Yan, Xiaosong Wang, Le Lu, and Ronald M. Summers. DeepLesion: Automated mining of large-scale lesion annotations and universal lesion detection with deep learning. *Journal of Medical Imaging*, 5(3):036501, July 2018. [Cited on pages 10 and 11.]
- [36] Mustafa Umit Oner, Yi-Chih Cheng, Hwee Kuan Lee, and Wing-Kin Sung. Training machine learning models on patient level data segregation is crucial in practical clinical applications, April 2020. [Cited on page 11.]

- [37] Jiang Hsieh. *Computed Tomography: Principles, Design, Artifacts, and Recent Advances*. Wiley Interscience ; SPIE Press, Hoboken, N.J. : Bellingham, Wash, 2nd ed edition, 2009. [Cited on page 12.]
- [38] Saeid Asgari Taghanaki, Yefeng Zheng, S. Kevin Zhou, Bogdan Georgescu, Puneet Sharma, Daguang Xu, Dorin Comaniciu, and Ghassan Hamarneh. Combo Loss: Handling Input and Output Imbalance in Multi-Organ Segmentation, September 2021. [Cited on pages 18 and 23.]
- [39] Uğur Kesimal, Habip Eser Akkaya, Önder Polat, and Murat Sağlam. Use of Deep Learning Models in the Diagnosis of Proptosis Through Orbital Magnetic Resonance Imaging. *Medical Science Monitor*, 32, April 2026. [Cited on page 18.]
- [40] Yang Li, Bobo Yan, Jianxin Hou, Bingyang Bai, Xiaoyu Huang, Canfei Xu, and Limei Fang. UNet based on dynamic convolution decomposition and triplet attention. *Scientific Reports*, 14(1):271, January 2024. [Cited on page 19.]
- [41] Rich Caruana. Multitask Learning. [Cited on page 20.]
- [42] Sebastian Ruder. An Overview of Multi-Task Learning in Deep Neural Networks, June 2017. [Cited on page 20.]
- [43] Hang Zhao, Orazio Gallo, Iuri Frosio, and Jan Kautz. Loss Functions for Image Restoration With Neural Networks. *IEEE Transactions on Computational Imaging*, 3(1):47–57, March 2017. [Cited on page 22.]
- [44] Lin Zhang, Lei Zhang, Xuanqin Mou, and D. Zhang. FSIM: A Feature Similarity Index for Image Quality Assessment. *IEEE Transactions on Image Processing*, 20(8):2378–2386, August 2011. [Cited on page 24.]

Apêndice A

Appendix Title Here

Write your Appendix content here.